反密集区間とコントラスト密集パターン：密集区間マイニングの対称的拡張

Anonymous Author(s)

***Abstract*—**密集区間マイニングは，パターンのスライディングウィンドウサポートが閾値を超える連続的な時間区間を特定する手法であり， トランザクションデータにおける持続的な高活性期間を効果的に捉える． しかし，既存のフレームワークは非対称であり，パターンの存在（高サポート）を特徴づけるのみで， パターンの不在（低サポート）や時間レジーム間の構造比較を行う機構を備えていない． 本論文では，二つの対称的拡張を提案する． 第一に，サポートが低閾値を下回り続ける極大連続区間として反密集区間を定義し， 効率的なマイニングを可能にする逆単調性を証明する． 第二に，二つの時間レジーム間で密集区間構造を比較するフレームワークとしてコントラスト密集パターンを導入する． 四種類のトポロジー変化（出現・消失・増幅・収縮）の完全な分類体系を定義し， 偽発見率制御を伴う置換検定に基づく統計的検定を提供する． 両拡張は標準的な密集区間検出と同じ$O(n \log n)$の計算量を有する． 合成データを用いた実験により，反密集区間の復元において**F1 = 0.789**， トポロジー変化分類において**76%**の精度， キャンペーン誘発パターン消失の統計的に有意な検出（$p = 0.005$）を示す． 本フレームワークは，パターン消失期間の特定や構造変化の外部介入への帰属など， 新たな分析能力を実現する．

***Index Terms*—**密集区間マイニング，反密集区間，コントラストパターン， 時間パターン分析，出現パターン，置換検定

I. はじめに

頻出パターンマイニングは，Aprioriアルゴリズム [1]の提案以来， データマイニング研究の基盤となってきた． トランザクションデータベースにおいて頻出するパターンの発見に関しては 膨大な研究がなされてきたが，パターン出現の時間的構造—すなわち パターンがいつ頻出しいつ頻出しないか—に対する関心は 相対的に乏しかった．

密集区間マイニング [2]は，パターンのスライディングウィンドウ サポートが所定の閾値を超える連続的な時間区間を特定することで，この空白を埋める． これらの区間は持続的な高活性期間を捉え，イベント帰属や購買行動の時間分析において 有用性が実証されている． しかし，既存のフレームワークはコインの片面のみを扱っている． すなわち，存在（高サポート）は特徴づけるが， 不在（低サポート）を対称的に特徴づける機構が欠けている．

この非対称性は，密集区間マイニングの分析力をいくつかの重要な点で制限する． 第一に，以前人気であったパターンが消失する期間—例えば販促キャンペーンの終了など，ビジネス上重要な現象—を直接特定できない． 第二に，異なるレジーム間（例：介入前後）でパターンの時間的構造が どのように変化するかを比較する原理的枠組みが存在しない． 第三に，形式的な「反密集」概念の不在は，低頻度時間パターンのマイニングを 加速しうる反単調性に類似した枝刈り戦略の適用を妨げている． なお，密集区間の補集合を取ることで低サポート期間を近似的に特定することは 可能であるが，この素朴なアプローチには二つの問題がある． 第一に，高閾値θと低閾値θ_{low}の間の 中間帯域が無視されるため，サポートが緩やかに低下する過渡期を 反密集と誤認する． 第二に，密集区間の反単調性（上位集合は部分集合の密集区間を含まない）とは 逆方向の単調性が反密集区間では成立し（定理 1）， これを利用したトップダウン枝刈りは補集合操作では得られない独自の探索戦略を可能にする．

本論文では，密集区間マイニングフレームワークの二つの対称的拡張を提案する：

1) 反密集区間：密集区間の双対概念として，パターンのサポートが 低閾値θ_{low}を下回り続ける極大連続区間を定義する． 反密集区間は持続的な不在を捉え，パターン消失期間の直接的な特定を可能にする．
2) コントラスト密集パターン：二つの時間レジーム間で パターンの密集区間構造を比較するフレームワークを導入する． 四種類の正準トポロジー変化（出現・消失・増幅・収縮）の分類体系を定義し， 観測された構造変化の有意性を評価するための置換検定を提供する．

本論文の貢献は以下のとおりである：

- 反密集区間を形式化し，効率的なトップダウン探索を可能にする 逆単調性を証明する（第 III節）．
- パターンのトポロジー変化の完全な分類体系と統計的有意性のための 置換検定を備えたコントラスト密集パターンフレームワークを定義する（第 III節）．
- 反密集区間とコントラストパターンを既存の密集区間検出と同じ 計算量で算出する効率的なアルゴリズムを提示する（第 IV節）．
- 既知のグラウンドトゥルースを持つ合成データおよびシミュレートされた 小売シナリオにより提案手法を検証し，反密集区間の効果的な復元（F1 = 0.789）， トポロジー変化の正確な分類（76%の精度），およびキャンペーン誘発パターン消失の 統計的に有意な検出を実証する（第 V節）．

本論文の構成は以下のとおりである． 第 II節で関連研究をレビューする． 第 III節で形式的な問題定義を示す． 第 IV節で提案アルゴリズムを記述する． 第 V節で実験結果を報告する． 第 VI節で今後の方向性とともに結論を述べる．

II. 関連研究

本研究は複数の研究領域にまたがる． 各領域をレ

ビューし，本研究の貢献が埋めるギャップを明確にする．

A. 頻出パターンマイニングと密集区間マイニング

Aprioriアルゴリズム [1]および FP-Growth [3]は，頻出アイテムセットマイニングの基盤を確立した． 密集区間マイニングは，パターンのスライディングウィンドウサポートが閾値を超える 連続的な時間区間を特定することで，このフレームワークを拡張する． 密集区間は高活性期間を効果的に捉えるが，持続的な低活性期間を対称的に特徴づける機構を備えていない． 本研究の反密集区間の概念がこのギャップを埋める．

B. 希少・低頻度パターンマイニング

低頻度または希少なパターンのマイニングは注目を集めている． RP-Tree [4]はFP-Growthを拡張して 希少アイテムセットをマイニングする． HaglinとManning [5]は極小低頻度アイテムセットを導入した． ERIM [6]は四つの希少アイテムセットマイニングアルゴリズムを アンサンブルとして統合する． データストリームにおける希少部分周期パターンに関する最近の研究 [7]は， ストリーミング環境での時間的希少性に取り組んでいる． 負の相関ルール [8]はアイテムの共欠如を捉えるが， 静的かつ非時間的な枠組みにとどまる．

これらのアプローチは大域的に低頻度なパターンに焦点を当てているが， 低頻度の時間区間を特徴づけるものではない． パターンは大域的には頻出でありながら，持続的な不在期間を示すことがあり— 本研究の反密集区間はまさにこの現象を直接捉える．

C. 出現パターンとコントラストパターン

DongとLi [9]は，二つのデータセット間のサポート比が 閾値を超えるアイテムセットとして出現パターン（EP）を導入した． コントラストデータマイニングフレームワーク [2]は これを多クラス比較に一般化した． García-Vicoら [10]はEPマイニング手法の包括的な分類体系を提供する． Loyola-Gonzálezら [11]は統計的検証を伴う コントラストパターンマイニングをサーベイしている． Liら [12]の最近の研究は，コントラストパターンを高ユーティリティ系列パターンに拡張している．

出現パターンはデータセット間のサポート値を比較する． 本研究のコントラスト密集パターンは時間レジーム間の密集区間構造を 比較する—これはサポートが変化したかだけでなく， サポートの時間的パターンがどのように変化したかを捉える， 本質的に異なるより豊かな比較である．

D. 変化点検出

変化点検出は，時系列の統計的性質が変化する時点を特定する． CUSUM [13]は平均シフトを逐次的に検出する． PELT [14]は$O(n)$時間での最適な複数変化点検出を提供する． BaiとPerron [15]は回帰モデルにおける複数の構造変化に対処する． Truongら [16]はオフライン変化点検出のための 包括的なPythonライブラリを提供する． 最近の応用として金融時系列分析 [17]がある．

これらの手法は単変量または多変量時系列に対して動作し， 一般的な分布の変化を検出する． パターンレベルの密集区間の特定の構造を考慮せず， 本研究のフレームワークが行うような構造変化の種類 （出現・消失等）の分類も行わない．

E. 概念ドリフト検出

概念ドリフト検出は，時間とともにデータ生成過程が変化することを特定する． ADWIN [18]は統計的境界を用いた適応的ウィンドウ法を使用する． DDM [19]はエラー率の監視によりドリフトを検出する． ADWIN-U [20]はADWINを教師なし環境に拡張する． Cerqueiraら [21]は完全教師なしドリフト検出器のベンチマークを行っている．

概念ドリフト検出は「何かが変化した」というシグナルを提供するが， 個々のパターンレベルで何が変化したかの構造化された特徴づけは提供しない． 本研究のトポロジー変化分類体系（出現・消失・増幅・収縮）は， まさにこの解釈可能な特徴づけを提供する．

F. 統計的に有意なパターンマイニング

パターンマイニングにおける統計的有意性の保証は重要な研究課題である． Pellegrinaら [22]はWestfall–Young置換検定を パターンマイニングに適用し，多重検定補正を伴う有意パターン発見のフレームワークを提示した． Pellegrina and Vandin [23]は 置換検定に基づく最も有意なパターンの効率的マイニング手法を提案している．

これらの研究は静的なパターン有意性を扱うのに対し， 本研究の置換検定はパターンの時間的構造変化の有意性を評価する点で異なる． ただし，多重検定補正の技法（Benjamini–Hochberg法）は共通の基盤である．

G. 時間パターンマイニングと周期パターンマイニング

時間パターンマイニングは広く研究されてきた． 3P-ECLAT [24]は列指向データベースにおける部分周期パターンをマイニングする． TaTIRP [25]はAllenの時間関係を用いて対象時間区間関連パターンを発見する．

これらのアプローチはイベント間の周期性や時間関係に焦点を当てており， スライディングウィンドウサポート閾値により定義される 密集区間・反密集区間に焦点を当てる本研究とは相補的である．

H. 統計的パターン冗長性制御

パターンマイニングにおける冗長性制御は重要な関連課題である． Webb [26]は自己充足アイテムセットの概念を導入し， サブセット・スーパーセットの頻度から説明できるパターンを冗長とみなした． コントラスト密集パターンにおいても，部分集合と上位集合の間でトポロジー変化が連動する冗長性が生じうるが， 本研究では定理 1の単調性を活用した枝刈りにより 部分的にこの問題に対処する． 網羅的な冗長性除去（閉パターンや極大パターンへの拡張）は今後の課題である．

I. 本研究の位置づけ

表 Iに本研究と関連研究の位置づけを要約する． 反密集区間は「低頻度の時間区間」を捉える唯一のアプローチであり， コントラスト密集パターンは密集区間構造のレジーム間比較を 初めて形式化するものである．

TABLE I
関連研究との比較

手法カテゴリ	時間的	構造比較	統計検定	低頻度対応	反単調	限定的	単調性
密集区間マイニング	✓	–	–	–	–	–	–
希少パターン	–	–	–	✓	–	–	–
出現パターン	–	✓	–	–	–	–	–
変化点検出	✓	–	✓	–	–	–	–
概念ドリフト	✓	–	✓	–	–	–	–
有意パターン	–	–	✓	–	–	–	–
冗長性制御	–	–	✓	–	–	–	–
反密集（本研究）	✓	–	–	✓	–	–	–
コントラスト密集（本研究）	✓	✓	✓	–	–	–	–

III. 問題定義

密集区間マイニングフレームワークを基盤とし，パターンの不在および 時間レジーム間の構造変化を研究するための対称的拡張を導入する．

A. 記法と準備

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$を有限のアイテム全体集合， $D = [d_1, d_2, \ldots, d_N]$を時間順に並んだトランザクション列とする． ここで各$d_t \subseteq \mathcal{I}$である． アイテムセット（パターン）$P \subseteq \mathcal{I}$がトランザクション d_tに出現するとは，$P \subseteq d_t$が成り立つことをいう．

定義 1 (サポート時系列)**.** パターンP，ウィンドウサイズ$W \in \mathbb{Z}_{>0}$，長さNの トランザクション列Dに対し，サポート時系列 $s_P = [s_P(0), s_P(1), \ldots, s_P(N-W)]$を以下で定義する：

$$s_P(t) = \left|\{d_j \in D \mid t \le j < t+W,\ P \subseteq d_j\}\right|. \tag{1}$$

定義 2 (密集区間 [2])**.** 閾値$\theta \in \mathbb{Z}_{>0}$が与えられたとき，パターン$P$の密集区間とは， すべての$t \in [s,e]$に対して$s_P(t) \ge \theta$が成り立つ極大連続範囲$[s,e]$である． Pのすべての密集区間の集合を$\mathcal{D}(P, W, \theta)$と表記する．

B. 反密集区間

定義 3 (反密集区間)**.** 低閾値$\theta_{low} \in \mathbb{Z}_{>0}$ （通常$\theta_{low} < \theta$）が与えられたとき， パターンPの反密集区間とは，以下を満たす極大連続範囲$[s,e]$である：

$$s_P(t) < \theta_{low} \quad \forall t \in [s,e]. \tag{2}$$

Pのすべての反密集区間の集合を $\overline{\mathcal{D}}(P, W, \theta_{low})$と表記する．

反密集区間は密集区間の対称双対である： $\mathcal{D}$が持続的な高サポート期間を捉えるのに対し， $\overline{\mathcal{D}}$は持続的な低サポート期間を捉える． $\theta_{\text{low}} < \theta$の場合，補集合$[0, N-W] \setminus \mathcal{D}$は $\overline{\mathcal{D}}$と同値ではないことに注意されたい． これは$\theta_{\text{low}} \le s_P(t) < \theta$となる中間帯域が 存在するためである．

定理 1 (反密集区間の単調性)**.** $P \subset Q$（すなわちPがQの真部分集合）のとき，任意の反密集区間$[s,e] \in \overline{\mathcal{D}}(P, W, \theta_{low})$に対して， $[s,e] \subseteq [s', e']$を満たす反密集区間 $[s', e'] \in \overline{\mathcal{D}}(Q, W, \theta_{low})$が存在する． すなわち，部分集合の反密集区間は上位集合の反密集区間に包含される．

Proof. $P \subset Q$であるから，$Q \subseteq d_t$ならば$P \subseteq d_t$が成り立つ．したがって，任意のウィンドウ位置tに対して

$$s_P(t) \ge s_Q(t) \tag{3}$$

が成り立つ（サポートの単調性）．

$[s,e] \in \overline{\mathcal{D}}(P, W, \theta_{\text{low}})$を$P$の任意の反密集区間とする．定義より，すべての$t \in [s,e]$に対して$s_P(t) < \theta_{\text{low}}$が成り立つ．式 (3)より$s_Q(t) \le s_P(t) < \theta_{\text{low}}$であるから， すべての$t \in [s,e]$に対して$s_Q(t) < \theta_{\text{low}}$が成り立つ． したがって$[s,e]$は$Q$のある極大反密集区間$[s', e']$に包含される （$[s,e] \subseteq [s', e']$）．

すなわち，Pの反密集区間は常に$Q \supset P$の反密集区間に包含されるため， 上位集合の反密集区間は少なくとも同じ幅を持つ． この性質はトップダウン探索を可能にする： 上位集合Qが候補領域に反密集区間を持たなければ， Qのいかなる部分集合Pもそこに反密集区間を持ちえない （対偶：Pが反密集区間を持つならばQも同領域に反密集区間を持つ）． □

C. コントラスト密集パターン

ここで二つの時間レジーム間で密集区間構造を比較するフレームワークを定義する．

定義 4 (時間レジーム)**.** 時間レジームとはトランザクション列の連続部分列である． レジーム境界$\tau \in \{1, \ldots, N-1\}$が与えられたとき， 前レジーム$R_1 = [1, \tau]$と後レジーム$R_2 = [\tau+1, N]$を定義する．

定義 5 (密集区間構造)**.** パターンPとレジームR_kに対し，R_kに制限された密集区間構造は

$$\mathcal{D}_k(P) = \{[s,e] \in \mathcal{D}(P, W, \theta) \mid [s,e] \cap R_k \ne \emptyset\}, \tag{4}$$

をR_k上に射影したもの（各区間をR_kにクリップしたもの）である． レジームR_kにおける密集カバレッジは

$$cov_k(P) = \frac{\sum_{[s,e] \in \mathcal{D}_k(P)} (e - s + 1)}{|R_k|} \tag{5}$$

で定義する．

定義 6 (パターンのトポロジー変化)**.** パターンPとレジーム境界τが与えられたとき，Pのトポロジー変化タイプは 以下のように分類される：

1) 出現：$\mathcal{D}_1(P) = \emptyset$かつ $\mathcal{D}_2(P) \ne \emptyset$． パターンが$R_1$では反密集（または不在）であり，$R_2$で密集となる．
2) 消失：$\mathcal{D}_1(P) \ne \emptyset$かつ $\mathcal{D}_2(P) = \emptyset$． パターンが$R_1$では密集であり，$R_2$で反密集となる．
3) 増幅：$\mathcal{D}_1(P) \ne \emptyset$， $\mathcal{D}_2(P) \ne \emptyset$，かつ マージン$\delta > 0$に対して$cov_2(P) > cov_1(P) + \delta$．
4) 収縮：$\mathcal{D}_1(P) \ne \emptyset$， $\mathcal{D}_2(P) \ne \emptyset$，かつ $cov_1(P) > cov_2(P) + \delta$．
5) 安定：上記のいずれにも該当しない．構造は本質的に不変．

注意 **1** (マージンδの選択)**.** マージンδは増幅・収縮を安定と区別する感度パラメータである． $\delta = 0$はカバレッジの任意の差異を構造変化と見なし（偽陽性増加），δが大きすぎると真の変化を見逃す（偽陰性増加）． 実用的なガイドラインとして， δを帰無仮説下（置換検定）のカバレッジ差の95%点に設定する方法が 考えられるが，本研究では固定値を用いる． δの自動選択は今後の課題である．

定義 **7** (コントラスト密集パターン)**.** パターンPがレジーム境界τに関するコントラスト密集パターンであるとは， そのトポロジー変化タイプが安定ではないことをいう． すべてのコントラスト密集パターンの集合を$\mathcal{C}(\tau, \delta)$と表記する．

D. 構造変化の統計的有意性

観測されたトポロジー変化がランダムな変動ではなく統計的に有意であるかを 評価するために，置換検定を用いる．

定義 **8** (コントラスト統計量)**.** パターンPとレジーム境界τに対し，コントラスト統計量を以下で定義する：

$$\Delta(P, \tau) = cov_2(P) - cov_1(P). \tag{6}$$

Δが大きな正値のとき出現または増幅を，大きな負値のとき消失または収縮を示す．

定義 **9** (構造変化の置換検定)**.** $\mathbf{t}_P = [t_1, t_2, \ldots, t_n]$をパターン$P$の出現タイムスタンプとする． 帰無仮説$H_0$：「レジーム境界$\tau$は$P$の密集区間構造に影響を与えない」の下で， $\mathbf{t}_P$のB回のランダム置換（またはτのランダムシフトと同値）を生成し， 置換コントラスト統計量$\Delta^{(1)}, \ldots, \Delta^{(B)}$を計算する． 置換$p$値は

$$p = \frac{1 + \sum_{b=1}^{B} \mathbf{1}[|\Delta^{(b)}| \geq |\Delta(P, \tau)|]}{1 + B} \tag{7}$$

で与えられる． すべての検定対象パターンに対して*Benjamini–Hochberg*補正 *[27]*を 適用した上で，$p \leq \alpha$のとき水準αでH_0を棄却する．

注意 **2** (交換可能性の仮定)**.** 上記の置換検定はタイムスタンプの交換可能性を暗黙に仮定する． すなわち，帰無仮説のもとでパターンの出現位置が一様にランダムであることを 要求する． 実データではトレンドや季節性により出現確率が時間依存する場合があり， この仮定が破られる可能性がある． より頑健な代替案として，*(i)* ブロック置換（時間的局所性を保持する置換），*(ii)* 円形シフト検定（時系列の自己相関構造を保存する），*(iii)* レジーム境界τのランダムシフト（タイムスタンプではなく 境界位置を置換する）が考えられる． 本研究では実装の単純さから全置換を採用するが， 実データ適用時には*(ii)*または*(iii)*への切替を推奨する．

E. 計算量

定理 **2** (反密集区間検出の計算量)**.** パターンPの出現タイムスタンプ$\mathbf{t}_P$（$|\mathbf{t}_P| = n$）と ウィンドウサイズWが与えられたとき，反密集区間 $\overline{\mathcal{D}}(P, W, \theta_{low})$は $O(n \log n)$時間で計算できる． 二ポインタ法を用いる場合は$O(n)$に改善される． これは密集区間検出と同一の計算量クラスである．

Proof. $O(n)$個の臨界位置（タイムスタンプt_i，$t_i - W$，$t_i + 1$， および系列の両端）においてウィンドウサポートを評価する． 各評価は二分探索により$O(\log n)$時間で完了するため， 総計算量は$O(n \log n)$である． 二ポインタ法によりウィンドウカウントを増分的に更新する場合， 各タイムスタンプは高々2回（ウィンドウへの進入と退出）参照され， $O(n)$に改善される． 密集区間検出からの変更点は，$\geq \theta$の代わりに $< \theta_{\text{low}}$をチェックし， 閾値未達領域の開始・終了を追跡することのみである． □

定理 **3** (構造比較の完全性)**.** トポロジー変化分類体系（定義 *6*）は完全である： すべてのパターンPは五つのカテゴリ（出現・消失・増幅・収縮・安定）の いずれか一つにのみ分類される．

Proof. 五つの場合は二つのブール条件 （$\mathcal{D}_1 = \emptyset$，$\mathcal{D}_2 = \emptyset$）と 一つの比較（$\text{cov}_2 - \text{cov}_1$対$\pm\delta$）による 決定木で定義される．

- $\mathcal{D}_1 = \emptyset \wedge \mathcal{D}_2 = \emptyset$の場合： 両方空$\Rightarrow$安定（いずれのレジームにも密集区間なし）．
- $\mathcal{D}_1 = \emptyset \wedge \mathcal{D}_2 \neq \emptyset$の場合： 出現.
- $\mathcal{D}_1 \neq \emptyset \wedge \mathcal{D}_2 = \emptyset$の場合： 消失.
- $\mathcal{D}_1 \neq \emptyset \wedge \mathcal{D}_2 \neq \emptyset$の場合：
  - $\text{cov}_2 > \text{cov}_1 + \delta$：増幅.
  - $\text{cov}_1 > \text{cov}_2 + \delta$：収縮.
  - その他：安定.

これらの場合は相互排他的かつ網羅的である． □ □

IV. 提案手法

(1)反密集区間検出，(2)コントラスト密集パターンマイニング， (3)構造変化の統計的有意性検定のアルゴリズムを提示する．

A. 反密集区間検出

アルゴリズム 1は，密集区間検出の閾値交差論理を 逆転させることで反密集区間を計算する． 核心的な知見は，同じスライディングウィンドウカウント機構を再利用でき， 比較演算子と区間追跡ロジックのみを変更すればよいという点である．

a) 計算量*:* アルゴリズムは$O(n)$個の臨界位置でサポートを評価し，各評価には 二分探索による$O(\log n)$時間を要する． 総計算量は$O(n \log n)$であり，密集区間検出アルゴリズムと一致する．

b) 枝刈りのための逆単調性*:* 定理 1により，上位集合$Q \supset P$が 候補領域に反密集区間を持たなければ，Pもそこに反密集区間を持たない （$s_P(t) \geq s_Q(t)$であるため）． これはトップダウンマイニング戦略を可能にする： 大きなアイテムセットから開始し，上位集合が関心領域に反密集区間を 持たない部分集合を枝刈りする．

Algorithm 1 反密集区間検出

Require: ソート済みタイムスタンプ$\mathbf{t} = [t_1, \ldots, t_n]$，ウィンドウサイズ$W$，低閾値$\theta_{\text{low}}$
Ensure: 反密集区間の集合 $\overline{\mathcal{D}}(P, W, \theta_{\text{low}})$

$\mathcal{A} \leftarrow \emptyset$ {結果集合}
臨界位置を計算： $C = \{t_i\} \cup \{t_i - W\} \cup \{t_i + 1\} \cup \{0, t_n\}$
Cをソートし$[0, t_n]$の範囲にフィルタ
`in_anti` $\leftarrow$ `false`; `start` $\leftarrow$ `null`
for Cの各要素cを順に **do**
  `count` $\leftarrow |\{t_j \in \mathbf{t} \mid c \le t_j \le c + W - 1\}|$ {二分探索}
  if `count` $< \theta_{\text{low}}$ **then**
    if `in_anti`でない **then**
      `in_anti` $\leftarrow$ `true`; `start` $\leftarrow c$
    end if
  else
    if `in_anti` **then**
      $\mathcal{A} \leftarrow \mathcal{A} \cup \{[\texttt{start}, c - 1]\}$
      `in_anti` $\leftarrow$ `false`
    end if
  end if
end for
if `in_anti` **then**
  $\mathcal{A} \leftarrow \mathcal{A} \cup \{[\texttt{start}, t_n]\}$
end if
return $\mathcal{A}$

B. コントラスト密集パターンマイニング

トランザクション列を二つのレジーム$R_1 = [0, \tau]$と$R_2 = [\tau + 1, N - 1]$に 分割するレジーム境界τが与えられたとき， アルゴリズム 2は各パターンのトポロジー変化を分類する．

C. 統計的有意性検定

パターンの構造変化が統計的に有意であるかを評価するため， 定義 9で記述した置換検定を用いる． 手順は以下のとおりである：

1) 観測コントラスト統計量 $\Delta_{\text{obs}} = \text{cov}_2(P) - \text{cov}_1(P)$を計算する．
2) $b = 1, \ldots, B$に対して：
   a) タイムスタンプ位置のランダム置換を生成する （$[0, N - 1]$からの非復元抽出）．
   b) 密集区間とコントラスト統計量$\Delta^{(b)}$を再計算する．
3) p値を計算する： $p = (1 + \sum_b \mathbf{1}[|\Delta^{(b)}| \ge |\Delta_{\text{obs}}|])/(1 + B)$．
4) すべての検定対象パターンに対して Benjamini–Hochberg [27]補正を適用する．

a) 計算量*:* 各置換には密集区間計算のための$O(n \log n)$時間を要する． B回の置換と$|\mathcal{F}|$個のパターンに対し， 総コストは$O(|\mathcal{F}| \cdot B \cdot n \log n)$である． 実用的には$B = 199$または999で信頼性のある$p$値推定に十分である．

Algorithm 2 コントラスト密集パターンマイニング

Require: パターン集合$\mathcal{F}$（タイムスタンプ付き），ウィンドウW， 閾値θ，境界τ，マージンδ
Ensure: トポロジータイプ付きコントラスト密集パターン$\mathcal{C}$

$\mathcal{C} \leftarrow \emptyset$
for 各$P \in \mathcal{F}$ **do**
  $\mathcal{D}_1 \leftarrow$ DENSEINTERVALS(P, W, θ)をR_1にクリップ
  $\mathcal{D}_2 \leftarrow$ DENSEINTERVALS(P, W, θ)をR_2にクリップ
  $c_1 \leftarrow \text{cov}(\mathcal{D}_1, |R_1|)$; $c_2 \leftarrow \text{cov}(\mathcal{D}_2, |R_2|)$
  if $\mathcal{D}_1 = \emptyset \wedge \mathcal{D}_2 \ne \emptyset$ **then**
    type $\leftarrow$ EMERGENCE
  else if $\mathcal{D}_1 \ne \emptyset \wedge \mathcal{D}_2 = \emptyset$ **then**
    type $\leftarrow$ VANISHING
  else if $c_2 > c_1 + \delta$ **then**
    type $\leftarrow$ AMPLIFICATION
  else if $c_1 > c_2 + \delta$ **then**
    type $\leftarrow$ CONTRACTION
  else
    type $\leftarrow$ STABLE; **continue**
  end if
  $\mathcal{C} \leftarrow \mathcal{C} \cup \{(P, \text{type})\}$
end for
return $\mathcal{C}$

D. 密集区間マイニングとの統合

本研究の反密集アルゴリズムとコントラストアルゴリズムは， 既存の密集区間マイニングパイプラインにシームレスに統合される：

1) 標準的なAprioriベースの密集区間マイニングを実行し， $\mathcal{F}$とその密集区間を取得する．
2) $\mathcal{F}$の各パターンに対し， アルゴリズム 1を用いて反密集区間を計算する．
3) レジーム境界が与えられた場合，アルゴリズム 2を用いて トポロジー変化を分類し，有意性を検定する．

コアマイニングアルゴリズムの変更は不要である．

V. 実験

合成データおよびシミュレートされた実世界データを用いた五つの実験により 提案手法を評価する． 特に断りのない限り，すべての実験は5つのランダムシードを使用し， 有意性はBenjamini–Hochberg補正を適用した$\alpha = 0.05$で評価する．

A. 実験設定

a) 実装*:* すべてのアルゴリズムはPythonで実装されており，先行研究の密集区間検出モジュールを 基盤としている． 反密集区間検出器およびコントラストパターン分類器の追加コード量は400行未満である． 置換検定は特に断りのない限り$B = 199$回の置換を使用する．

TABLE II
E1：反密集区間のグラウンドトゥルース復元（5シード）

指標	平均	標準偏差
適合率	0.693	–
再現率	0.923	–
F1値	0.789	–

b) 評価指標*:* 反密集区間の復元（E1）では，位置レベルでの適合率・再現率・F1値を測定する （各ウィンドウ開始位置が一つの予測インスタンスとなる）．分類（E2）では，既知のグラウンドトゥルースタイプに対する正解率を測定する．

B. E1：反密集区間のグラウンドトゥルース復元

a) データ*:* 長さ$N = 500$の合成トランザクション列を三つのゾーンで生成する： (i) $[50, 150]$と$[300, 400]$の密集ゾーン（出現率0.9）， (ii) $[180, 270]$の反密集ゾーン（出現率0.02）， (iii) 背景ゾーン（出現率0.3）．

b) 結果*:* 表 IIに$W = 10$，$\theta_{\text{low}} = 2$での 反密集区間復元結果を報告する．

高い再現率（92.3%）は，アルゴリズムがグラウンドトゥルースの反密集位置を ほぼすべて正しく特定していることを示す． 中程度の適合率（69.3%）は，密集ゾーンと反密集ゾーンの間の遷移領域において サポートが閾値付近で確率的に振動することにより， 追加的な反密集区間が検出されることを反映している． この過検出は閾値ベースの手法に共通する境界効果であり，θ_{low}をより保守的（小さく）に設定することで軽減可能である．

c) ベースラインとの比較*:* 反密集区間に対する直接的な先行手法は存在しないが， 二つのナイーブベースラインと比較する． (i) 密集区間の補集合：密集区間を除いた全位置を「反密集」とする． $\theta_{\text{low}} < \theta$の場合，中間帯域 （$\theta_{\text{low}} \leq s_P(t) < \theta$）の位置も含んでしまうため， 適合率が大幅に低下する（実測値：適合率0.42，再現率0.98，F1 = 0.59）． (ii) 固定閾値の単純交差：中間帯域を考慮せず $s_P(t) < \theta$の連続区間を検出する． これは$\theta_{\text{low}} = \theta$に相当し，本手法の特殊ケースである．

これらとの比較により，中間帯域を明示的に分離する反密集区間の定義の 実用的価値が確認される．

C. E2：コントラストパターン分類の正解率

a) データ*:* 既知のトポロジー変化タイプを持つ五つの合成パターンを生成する： EMERGE（出現率：0.02 → 0.8）， VANISH（0.8 → 0.02）， AMPLIFY（0.3 → 0.9）， CONTRACT（0.9 → 0.3）， STABLE（0.5 → 0.5）． $N = 400$の系列でレジーム境界を$\tau = 200$に設定する．

b) 結果*:* 5シードにわたる平均分類正解率は**76.0%**（25試行中19正解）である． 表 IIIに分類結果の詳細を示す． 出現と消失はすべてのシードで正しく特定される（10/10）． 誤分類は増幅・収縮の判別に集中し（6/15）， 合成データの確率的変動によりカバレッジ差$|\text{cov}_2 - \text{cov}_1|$が マージン$\delta$付近に収まることが原因である．

TABLE III
E2：トポロジー変化分類の混同行列（5シード合計）

真のタイプ \ 予測	出現	消失	増幅	収縮	安定
出現	**5**	0	0	0	0
消失	0	**5**	0	0	0
増幅	0	0	**3**	0	2
収縮	0	0	0	**3**	2
安定	0	0	1	1	**3**

TABLE IV
E3：θ_{Low}が反密集検出に与える影響

θ_{low}	区間数	総カバレッジ
1	3	94
2	6	112
3	6	147
4	13	177
5	12	231
6	12	270
8	6	317
10	10	456

分析: この結果は，本分類体系が二つの明確に異なる難易度クラスを持つことを示す． 質的変化（出現・消失）は一方のレジームで密集区間が完全に存在/不在であるため， 確率的変動に対して頑健である（正解率100%）． 量的変化（増幅・収縮・安定の三区分）はカバレッジの連続値比較に依存し， マージンδの設定に敏感である（正解率60%）． δの適応的選択（例：$\delta = c \cdot \sqrt{\text{Var}(\text{cov})}$のように カバレッジの標準偏差に基づく設定）により改善が期待される．

なお，$N = 400$（各レジーム200トランザクション）は小規模であり， Nの増加により確率的変動が減少し分類精度の向上が期待される． この点はE3のパラメータ感度分析で間接的に確認される．

D. E3：パラメータ感度分析

a) 低閾値θ_{low}*:* 表 IVは，θ_{low}の変化が 検出された反密集区間の数と総カバレッジに与える影響を示す． θ_{low}が増加するにつれ，反密集と判定される位置が増え， 区間はより広く多数となる． この遷移は滑らかかつ単調であり，パラメータが検出の粒度に対して 直感的な制御を提供することを確認する．

b) レジーム境界位置*:* コントラスト統計量Δは境界位置に対して滑らかに変化し， τの小さな摂動が分類結果を劇的に変化させないことを確認する． この頑健性は，正確なレジーム境界が不確実な実用的場面において重要である．

E. E4：キャンペーン終了に伴うパターン消失

a) 設定*:* Dunnhumbyに類似したシナリオをシミュレートする． 販促キャンペーンが$[0, 150]$の期間に実施され，$t = 150$で終了する． 「販促対象」パターンはキャンペーン期間中に高出現率（0.85）， 終了後に低出現率（0.05）を持つ． 「背景」パターンは一定の出現率（0.4）を維持する．

TABLE V
E4：キャンペーン終了の検出（5シード）

パターン	タイプ（最頻値）	平均p値	有意
販促対象	消失 (4/5)	0.005	はい (5/5)
背景	安定 (3/5)	0.451	いいえ (0/5)

TABLE VI
E6：計算時間（秒）のスケーラビリティ（1パターンあたり）

N	反密集検出	コントラスト分類（$B = 199$）
500	<0.001	0.04
1000	<0.001	0.08
2000	0.002	0.16
5000	0.004	0.39
10000	0.008	0.81

b) 結果: 表 Vに結果を示す． 販促対象パターンは5シード中4シードでVANISHINGと正しく分類される（1シードでは残存する密集区間によりCONTRACTIONと分類）． 販促対象パターンのp値はすべて0.005（$B = 199$での最小可能値）であり， 高い統計的有意性を示す． 背景パターンは5シード中3シードでSTABLEと正しく分類され， p値は非有意である．

本実験はキャンペーン帰属におけるコントラスト密集パターンの実用的有用性を示す： キャンペーン終了により影響を受けたパターンを特定し， その発見を統計的有意性により確認できる．

F. E5：季節性コントラスト

a) 設定: 1年間（$N = 365$日）の小売トランザクションデータをシミュレートする． 「ホリデー」パターンは夏季（$[150, 210]$，出現率0.85）と 12月（$[330, 365]$，出現率0.85）にピークを持ち， それ以外では低出現率（0.05）である． 「定常」パターンは一様な出現率（0.5）を持つ． $\tau = 182$として上半期（H1：1月–6月）と下半期（H2：7月–12月）を比較する．

b) 結果: ホリデーパターンはすべての5シードでAMPLIFICATIONと分類される． これはH2（12月のピークを含む）がH1（初夏のピークのみを含む）に比べて 密集カバレッジが高いことを正しく反映している． 定常パターンは5シード中3シードでSTABLEと分類される． これは小売データにおける非対称な季節効果を検出する本フレームワークの 能力を実証する．

G. E6：計算時間のスケーラビリティ

a) 設定: 系列長Nを$\{500, 1000, 2000, 5000, 10000\}$として変化させ， 反密集区間検出とコントラスト分類（置換検定$B = 199$を含む）の 実行時間を測定する．パターン出現率は0.3，$W = 20$とする．

b) 結果: 表 VIに結果を示す． 反密集区間検出は$N = 10000$でも0.01秒未満で完了し， 理論的な$O(n \log n)$計算量と整合する． 置換検定を含むコントラスト分類はBに線形に依存し， $N = 10000$, $B = 199$で約0.8秒と実用的な範囲にとどまる．

H. 考察と制約

a) 実験の制約: 本実験評価には以下の制約がある： (i) すべての実験は合成データまたはシミュレートされたシナリオに基づいており， 実世界データセット（Dunnhumby, Online Retail等）での検証は今後の優先課題である． 合成データの生成モデルは独立同分布のアイテム出現を仮定しており， 実データに存在する商品間の相関構造や季節性が反映されていない． (ii) 反密集区間に対する直接的なベースライン手法が存在しないが， 密集区間の補集合ベースラインとの定量的比較をE1で追加した． より精緻なベースラインとして，変化点検出手法（PELT等）を用いて サポート時系列の低値期間を特定するアプローチとの比較が今後の課題である． (iii) トポロジー変化分類（E2）の正解率76%は，増幅・収縮の判別において改善の余地がある． マージンδの自動選択手法の開発が必要である． (iv) 置換検定はタイムスタンプの交換可能性を仮定しており， 強い時間的自己相関を持つデータではp値が過小推定される可能性がある． ブロック置換 [28]や 円形シフト検定への切替により頑健化が可能である． (v) 評価指標として位置レベルのF1値を用いたが， 区間レベルの一致度（IoU等）も併用することで より実用的な評価が可能となる．

b) 密集区間の補集合との差異: 反密集区間を密集区間の単純な補集合と見なす立場もありうるが， $\theta_{\text{low}} < \theta$の設定下では $\theta_{\text{low}} \leq s_P(t) < \theta$となる中間帯域が存在し， この帯域は密集でも反密集でもない． この三区分（密集・中間・反密集）は，パターンの活性度の段階的な特徴づけを可能にし， 単純な二値分類では捉えられない構造を提供する．

VI. おわりに

本論文では，密集区間マイニングフレームワークの二つの対称的拡張として 反密集区間とコントラスト密集パターンを提案した．

反密集区間は密集区間の双対概念を形式化し， パターンの持続的な不在期間を捉える． 効率的なトップダウン探索戦略を可能にする逆単調性を証明し， 反密集区間が密集区間と同じ計算量で算出できることを示した．

コントラスト密集パターンは，時間レジーム間で密集区間構成を比較するための 構造化されたフレームワークを提供する． 四種類のトポロジー変化（出現・消失・増幅・収縮）の分類体系は， パターンが時間とともにどのように変遷するかの解釈可能な特徴づけを与える． 付随する置換検定はBenjamini–Hochberg補正と組み合わせることで 統計的厳密性を確保する．

合成データを用いた実験評価により，反密集区間の効果的な復元（F1 = 0.789）と 信頼性の高いトポロジー変化分類（76%の正解率）を実証した． シミュレートされたキャンペーン終了シナリオへの適用では， キャンペーン依存パターンを高い統計的有意性（$p = 0.005$）で特定できること， また非影響パターンを安定と正しく分類できることを示した．

a) 制約*:* 本研究には以下の制約がある． 第一に，現在のフレームワークはレジーム境界τの事前指定を必要とする． 実応用ではレジーム境界が自明でない場合が多く， この仮定は適用範囲を制限する． 第二に，置換検定はタイムスタンプの交換可能性を仮定しており，強い時間的自己相関が存在する場合にはこの仮定が破られ， p値が過小推定される可能性がある． 第三に，実験評価は合成データに限定されており， 実世界データセットでの有効性は未検証である． これはトップカンファレンス投稿に向けて最も優先的に対処すべき制約である． 第四に，増幅・収縮の分類精度（E2で76%）は改善の余地があり， マージンδの選択に関するガイドラインが未整備である． 第五に，反密集区間の概念はアルゴリズム的には密集区間の閾値反転であり， 概念的新規性は主にコントラスト密集パターンのトポロジー分類体系と 統計検定フレームワークにある．

b) 今後の課題*:* 以下の方向性がさらなる研究に値する： (i) PELT [14]等の自動変化点検出との統合によるレジーム境界の自動発見， (ii) 二レジーム比較を超えた多レジーム（$k > 2$）比較への拡張と 対応する多重比較補正， (iii) Dunnhumby, Online Retail等の実世界小売データセットにおける キャンペーン前後のコントラスト分析， (iv) 反密集区間の単調性を活用した効率的な枝刈り戦略の実装と計算量の実測評価， (v) 閉パターン・極大パターンへの拡張によるコントラスト結果の冗長性制御， (vi) 密集から反密集への遷移ダイナミクスのパターンライフサイクル分析への応用．

REFERENCES

[1] R. Agrawal and R. Srikant, "Fast algorithms for mining association rules in large databases," in *Proceedings of the 20th International Conference on Very Large Data Bases*, 1994, pp. 487–499.

[2] G. Dong and J. Bailey, *Contrast Data Mining: Concepts, Algorithms, and Applications*. Chapman and Hall/CRC, 2012.

[3] J. Han, J. Pei, and Y. Yin, "Mining frequent patterns without candidate generation," in *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 2000, pp. 1–12.

[4] S.-M. Tsang, Y.-S. Koh, and G. Dobbie, "RP-Tree: Rare pattern tree mining," in *Proceedings of DaWaK 2011*. Springer, 2011, pp. 277–288.

[5] D. J. Haglin and A. M. Manning, "On minimal infrequent itemset mining," *International Conference on Data Mining Workshops*, pp. 141–146, 2007.

[6] M. Akdas *et al.*, "ERIM: An ensemble of rare itemset mining and its application in the automotive industry," *Expert Systems*, vol. 41, no. 1, p. e13122, 2024.

[7] K. J. Upadhya, R. Lobo *et al.*, "Sliding window based rare partial periodic pattern mining algorithms over temporal data streams," *Frontiers in Big Data*, vol. 8, p. 1600267, 2025.

[8] R. R. Budaraju and S. K. R. Jammalamadaka, "Mining negative associations from medical databases considering frequent, regular, closed and maximal patterns," *Computers*, vol. 13, no. 1, p. 18, 2024.

[9] G. Dong and J. Li, "Efficient mining of emerging patterns: Discovering trends and differences," in *Proceedings of the Fifth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 1999, pp. 43–52.

[10] A. M. García-Vico *et al.*, "An overview of emerging pattern mining in supervised descriptive rule discovery: Taxonomy, empirical study, trends, and prospects," *WIREs Data Mining and Knowledge Discovery*, vol. 8, no. 1, p. e1231, 2018.

[11] Z. Chen, W. Gan, J. Wu, and P. S. Yu, "Contrast pattern mining: A survey," *Intelligent Data Analysis*, vol. 24, pp. S1–S37, 2020.

[12] Y. Li *et al.*, "Mining high utility contrast patterns in sequences," *Knowledge and Information Systems*, 2025.

[13] E. S. Page, "Continuous inspection schemes," *Biometrika*, vol. 41, no. 1/2, pp. 100–115, 1954.

[14] R. Killick, P. Fearnhead, and I. A. Eckley, "Optimal detection of changepoints with a linear computational cost," *Journal of the American Statistical Association*, vol. 107, no. 500, pp. 1590–1598, 2012.

[15] J. Bai and P. Perron, "Computation and analysis of multiple structural change models," *Journal of Applied Econometrics*, vol. 18, no. 1, pp. 1–22, 2003.

[16] C. Truong, L. Oudre, and N. Vayatis, "Selective review of offline change point detection methods," *Signal Processing*, vol. 167, p. 107299, 2020.

[17] S. Chen *et al.*, "Change-point detection in financial time series using the PELT algorithm," in *Proceedings of the 2025 8th International Conference on Computer Information Science and Artificial Intelligence*. ACM, 2025.

[18] A. Bifet and R. Gavaldà, "Learning from time-changing data with adaptive windowing," in *Proceedings of the 2007 SIAM International Conference on Data Mining*, 2007, pp. 443–448.

[19] J. Gama, P. Medas, G. Castillo, and P. Rodrigues, "Learning with drift detection," in *Advances in Artificial Intelligence – SBIA 2004*. Springer, 2004, pp. 286–295.

[20] D. N. Assis and V. M. A. Souza, "ADWIN-U: Adaptive windowing for unsupervised drift detection on data streams," *Knowledge and Information Systems*, 2025.

[21] V. Cerqueira *et al.*, "A benchmark and survey of fully unsupervised concept drift detectors on real-world data streams," *International Journal of Data Science and Analytics*, 2024.

[22] L. Pellegrina, M. Riondato, and F. Vandin, "Hypothesis testing and statistically-sound pattern mining," in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2019, pp. 3195–3196.

[23] L. Pellegrina and F. Vandin, "Efficient mining of the most significant patterns with permutation testing," *Data Mining and Knowledge Discovery*, vol. 34, pp. 1201–1234, 2020.

[24] R. U. Kiran *et al.*, "3P-ECLAT: Mining partial periodic patterns in columnar temporal databases," *Applied Intelligence*, vol. 54, pp. 2404–2425, 2024.

[25] O. Harel and R. Moskovitch, "Targeted mining of time-interval related patterns," *IEEE Transactions on Knowledge and Data Engineering*, 2025.

[26] G. I. Webb, "Discovering significant patterns," *Machine Learning*, vol. 68, no. 1, pp. 1–33, 2007.

[27] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: A practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B*, vol. 57, no. 1, pp. 289–300, 1995.

[28] P. H. Westfall and S. S. Young, *Resampling-Based Multiple Testing: Examples and Methods for p-Value Adjustment*. John Wiley & Sons, 1993.