Rare Dense Patterns: 大域的に稀少だが局所的に密集するアイテムセットのマイニング

Anonymous Authors

***Abstract*—**頻出アイテムセットマイニングアルゴリズムはサポートの反単調性を利用して探索空間を枝刈りするが、この性質は大域的に稀少なパターン—全体のサポートが低いパターン—を体系的に除外してしまう。 我々は、実用上重要なパターンの多くが大域的に稀少だが局所的に密集していることに着目する。すなわち、取引履歴全体では共起頻度が低いにもかかわらず、狭い時間窓内では集中的にバーストを示すパターンである。 具体例として、フラッシュセール中のプロモーションバンドル、セキュリティインシデント中の協調的な異常活動、小売データにおける季節的な同時購入がある。 本研究ではこの観察を稀少密集パターン（**Rare Dense Pattern, RDP**）マイニング問題として形式化する。**RDP**は二つの条件を同時に満たすアイテムセットである：**(1)** 大域的稀少性—全体サポートが最大閾値未満、**(2)** 局所的密集性—少なくとも一つのスライディングウィンドウ位置で共起回数が最小閾値以上。 我々は弱反単調性を証明する：**RDP**条件の組み合わせは単調でも反単調でもないが、局所密集性条件のみは反単調であり、**Apriori**型の候補枝刈りが可能である。 この知見に基づき、二段階マイニングアルゴリズムを提案する。第一段階でスライディングウィンドウ**Apriori**により局所的に密集するすべてのパターンを発見し、第二段階で大域的稀少性によりフィルタリングする。 本アルゴリズムが健全かつ完全であること—すべての**RDP**を過不足なく発見すること—を証明する。 埋め込み正解パターンを含む合成データ上の実験では、**5**つの乱数シードにわたり**100%**の回収率を達成し、稀少性フィルタにより**80%**以上の偽陽性（大域的に頻出だが局所的にも密集するパターン）を除去した。 アルゴリズムは**10**万トランザクションまでほぼ線形にスケールし、**1**秒未満で実行できる。 以上の結果は、**RDP**フレームワークが稀少パターンマイニングと時系列パターンマイニングの間の重要なギャップを埋め、いずれの個別手法では発見できない実用的パターンの検出を可能にすることを示している。

I. はじめに

頻出アイテムセットマイニング [1]はデータマイニングの基盤技術であり、マーケットバスケット分析からバイオインフォマティクスまで幅広く応用されている。 Aprioriアルゴリズムとその後継手法は、サポートの反単調性（下方閉包性）を活用する。すなわち、あるアイテムセットが非頻出であれば、そのすべての上位集合も非頻出である。 この性質により、組合せ的探索空間の積極的な枝刈りが可能となり、大規模マイニングが実行可能となる。

しかし、反単調性は諸刃の剣である。 設計上、大域的サポートが最小閾値を下回るすべてのパターンを除外してしまう。 多くの実世界シナリオにおいて、最も興味深いパターンはまさに稀少なパターン—大域的サポートフィルタを通過できないほど低頻度—でありながら、意味のある時間的構造を示すものである。 以下の動機付け事例を考える：

- 小売業のフラッシュセール：高級商品のプロモーションバンドルは全顧客の0.1%にしか購入されないが、2週間のフラッシュセール期間中は日次トランザクションの30%で共起する。1%閾値の標準的な頻出パターンマイニングではこのパターンを発見できない。
- セキュリティインシデント：特定のネットワークイベントの組み合わせ（例：ポートスキャン＋クレデンシャルスタッフィング＋ラテラルムーブメント）は全ログエントリの0.01%未満でしか発生しないが、攻撃活動中はこれらのイベントが数分以内にクラスタ化する。異常検知手法は個々のイベントをフラグするが、複数アイテムの共起パターンは識別できない。
- 季節的同時購入：ある商品の組み合わせ（例：日焼け止め＋虫除け＋キャンプ用品）は年間サポートが非常に低いが、特定の週にスパイクする。これらの時間的バーストの理解は在庫計画に有用である。

これらの事例は共通の構造を持つ：パターンは大域的に稀少（全体サポートが低い）だが局所的に密集（狭い時間窓内でサポートが高い）している。 我々はこのようなパターンを稀少密集パターン（Rare Dense Patterns, RDPs）と呼ぶ。

既存のアプローチはこの問題の一部には対処するが、全体には対処できない：

1) 稀少パターンマイニングアルゴリズム（RP-Tree [2]、Apriori-Rare [3]、MFIマイニング [4]）は大域的に非頻出なアイテムセットを発見するが、時間的構造を考慮しない。一様に稀少なパターン（ノイズ）と時間的に集中した稀少パターン（シグナル）を区別できない。
2) バースト検出（Kleinberg [5]）は単変量イベントストリームにおける時間的集中を識別するが、複数アイテム共起パターンの組合せ構造は扱えない。
3) 異常検知（Isolation Forest [6]、LOF [7]）はポイントまたはトランザクション単位で動作し、構造化されたアイテムセットパターンは識別できない。
4) スライディングウィンドウ頻出パターンマイニングは局所的に頻出なパターンを発見するが、大域的稀少性によるフィルタリングを行わず、出力は大域的に頻出なパターンに支配される。

本論文では以下の貢献を行う：

1) 稀少密集パターン（RDP）マイニング問題を形式化し、大域的稀少性条件と局所的密集性条件を定義し、両方を満たすパターンのクラスを特徴付ける（§III）。
2) 弱反単調性定理を証明する：RDP条件の組み合わせは古典的反単調性を持たないが、局所密集性成

分は反単調であり、Apriori型枝刈りが可能である（§III）。
3) 証明可能に健全かつ完全な二段階マイニングアルゴリズムを提案する—すべてのRDPを過不足なく発見する（§IV）。
4) 合成データ上の包括的実験を行い、100%の回収率、稀少性フィルタによる80%以上の偽陽性削減、10万トランザクションまでのほぼ線形なスケーラビリティを示す（§V）。

本論文の構成は以下の通りである。 §IIで関連研究を概観する。 §IIIで問題を形式化し、理論的結果を述べる。 §IVで二段階マイニングアルゴリズムを提示する。 §Vで実験結果を報告する。 §VIで今後の方向性とともに結論を述べる。

II. 関連研究

本節では4つの関連研究の系譜を概観し、各々に対する本研究の位置づけを明確にする。

A. 稀少・非頻出パターンマイニング

稀少（非頻出）パターンの研究は、興味深い知識がサポート分布の裾に潜むことが多いという観察から生まれた。 Szathmaryら [3]はApriori-RareとApriori-Inverseを導入し、稀少アイテムセットマイニングの基礎的枠組みを確立した。 Tsangら [2]はRP-Treeを提案した。これはFP-Growthの拡張であり、少なくとも1つの稀少アイテムを含むトランザクションに木構造を制限することで、単一の最小サポート閾値による効率的なマイニングを実現する。 HaglinとManning [4]は頻出・非頻出アイテムセットの境界（Minimal Infrequent Itemsets, MFI）を研究し、この境界の列挙に関する計算量の結果を証明した。 Guptaら [8]はパターン成長に基づくMFIマイニングのためのIFP-Treeを開発した。 BhattとPatel [9]はRP-Treeを複数最小サポート閾値（MCRP-Tree）に拡張し、アイテムの稀少性の不均一性に対応した。 Cuzzocreaら [10]は稀少パターンマイニングの課題と今後の方向性をサーベイした。

これらの手法はすべて、時間的構造を考慮せず静的なトランザクションデータベースから稀少パターンをマイニングする。 時間全体にわたって一様に低頻度で出現するパターンと、狭い時間窓内でバーストするパターンを区別できない。 本研究は時間次元を追加し、稀少パターンが局所的密集性も示すことを要求する。

B. バースト検出

Kleinberg [5]は無限隠れマルコフモデルを用いた文書ストリームにおけるバースト期間検出の先駆的枠組みを導入した。 このアルゴリズムは、対象イベントの到着率がベースラインの期待を上回る時間区間を識別する。 ZhuとShasha [11]はスライディングウィンドウ上の統計的性質をリアルタイム監視するStatStreamを提案した。 Luoら [12]は多変量時系列におけるテンポラルパターンマイニングとイベント検出を統合した。

これらの手法は単変量イベントストリーム（単一のイベント種別）におけるバーストを検出する。 バースト検出を複数アイテム共起パターンに拡張すると組合せ的複雑性が生じる：潜在的なアイテムセット数はアイテム数に対して指数的に増大する。 本研究の二段階マイニングアルゴリズムは、Apriori型枝刈りによりこの組合せ構造を処理する。

C. 異常・外れ値検出

Liuら [6], [13]は、ランダム分割によるデータポイントの孤立しやすさを測定して異常を検出するIsolation Forestを提案した。 Breunigら [7]は、あるポイントの局所密度をその近傍のそれと比較するLocal Outlier Factor（LOF）を導入した。 Schölkopfら [14]は新奇性検出のためのOne-Class SVMを提案した。 Heら [15]は、不確実データストリームにおける異常検知のために最小重み付き非頻出アイテムセットを用いることで、稀少パターンマイニングと外れ値検出を橋渡しした。

これらのアプローチはインスタンスレベル（個々のデータポイントまたはトランザクション）で動作し、パターンレベルでは動作しない。 特定のアイテムの組み合わせが異常な時間的集中を示すことを識別できない。 本研究のRDPフレームワークは、解釈可能な出力（アイテムセット＋時間区間）を持つパターンレベルの時間的異常検出を提供する。

D. 時系列・スライディングウィンドウパターンマイニング

Datarら [16]は指数ヒストグラムを用いたスライディングウィンドウ上のストリーム統計量維持の基礎技術を確立した。 ChangとLee [17]は時系列データにおける新興トレンド発見のためのデュアルサポート枠組みを提案し、サポート変化を検出するために二つのサポートカウントを維持する。 Liら [18]はデータ分布の変化に適応する可変スライディングウィンドウを用いて、頻出パターンマイニングにおけるコンセプトドリフトに対処した。 最近では、R3PStreamSWアルゴリズム [19]がスライディングウィンドウを用いて時系列データストリームから稀少部分周期パターンをマイニングする。

本研究はこれらと重要な点で異なる：我々は大域的に稀少だが局所的に密集するパターンを探索する。 標準的なスライディングウィンドウ頻出パターンマイニングは、大域的頻度にかかわらず局所的に頻出なパターンを発見し、出力は大域的に一般的なパターンに支配される。 ChangとLee [17]のデュアルサポート枠組みはサポート変化を追跡するが、稀少かつ局所的に密集するパターンのクラスを明示的に定義・マイニングしない。 R3PStreamSWアルゴリズム [19]は稀少周期パターン（低頻度の周期性）を対象とし、本研究の稀少密集パターン（低い大域サポートだが高い局所集中）とは異なる問題を扱う。

E. 反単調性と制約ベースマイニング

サポートの反単調性 [1]は効率的なアイテムセットマイニングの主力である。 PeiとHan [20]は単調でも反単調でもないが、部分的枝刈りのために一方の形式に変換可能な制約を研究した。 BonchiとLucchese [21]は、枝刈り不可能な制約をマイニングプロセスに押し込むための緩和ベースのアプローチを導入した。

本研究の弱反単調性の結果（定理 1）は、RDP定義の一方の半分である局所密集性条件が反単調であることを示し、第1段階における標準的なApriori枝刈りを可能にする。 大域的稀少性条件は単調である（稀少パターンの上位集合も稀少である）が、これは枝刈りには役立たない。 RDP条件の組み合わせは単調でも反単調でもないため、単一のマイニングパスで両条件を押し込むのではなく、二段階アプローチを採用する。

III. 問題定義

A. 記法

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ を有限のアイテム集合とし、 $D = [d_1, d_2, \ldots, d_N]$ を時間順に並んだトランザクションの列とする。 各トランザクション d_t（$t = 1, \ldots, N$）は $\mathcal{I}$ の部分集合である。 アイテムセット（パターン）$P \subseteq \mathcal{I}$ がトランザクション d_t に出現するとは、$P \subseteq d_t$ が成り立つことをいう。

定義 1 (大域サポート)**.** アイテムセット P の D における大域サポートは以下で定義される：

$$gsupp(P) = \frac{|\{t \mid 1 \le t \le N,\ P \subseteq d_t\}|}{N} \tag{1}$$

これは P を含むトランザクションの全体に対する割合を表す。

定義 2 (局所サポート（ウィンドウ付き）)**.** ウィンドウサイズ $W \in \mathbb{Z}_{>0}$ およびウィンドウ位置 $l \in \{1, \ldots, N - W + 1\}$ が与えられたとき、 P の位置 l における局所サポートカウントは以下で定義される：

$$lsup(P, l, W) = |\{d_j \in D \mid l \le j < l + W,\ P \subseteq d_j\}| \tag{2}$$

これはスライディングウィンドウ $[l, l + W)$ 内での P の出現回数を数える。

定義 3 (密集区間)**.** 密集閾値 $\theta \in \mathbb{Z}_{>0}$ が与えられたとき、 P の密集区間とは、以下を満たすウィンドウ位置の極大連続範囲 $[s, e]$ である：

$$\forall l \in [s, e]: \quad lsup(P, l, W) \ge \theta \tag{3}$$

P のすべての密集区間の集合を $\mathcal{D}(P, W, \theta)$ で表す。

B. 稀少密集パターン

本論文の中心概念を導入する。

定義 4 (大域的稀少性条件)**.** アイテムセット P が最大サポート閾値 $\sigma_{\max} \in (0, 1)$ に関して大域的稀少性条件を満たすとは、以下が成り立つことをいう：

$$gsupp(P) < \sigma_{\max} \tag{4}$$

定義 5 (局所的密集性条件)**.** アイテムセット P がウィンドウサイズ W および密集閾値 θ に関して局所的密集性条件を満たすとは、以下が成り立つことをいう：

$$\mathcal{D}(P, W, \theta) \neq \emptyset \tag{5}$$

すなわち、少なくとも一つの密集区間が存在する。

定義 6 (稀少密集パターン（RDP）)**.** アイテムセット P が稀少密集パターンであるとは、以下の両方を満たすことをいう：

1) 大域的稀少性条件（定義 *4*）：$gsupp(P) < \sigma_{\max}$
2) 局所的密集性条件（定義 *5*）：$\mathcal{D}(P, W, \theta) \neq \emptyset$

すべての*RDP*の集合を $\mathcal{R}(D, W, \theta, \sigma_{\max})$ で表す。

注意 1. 核心的な緊張関係は二つの条件の間にある：$\sigma_{\max}$ は大域的稀少性を強制し（パターンは全体として非頻出でなければならない）、θ は局所的密集性を強制する（パターンはある時間窓内で頻出でなければならない）。$\theta/W > \sigma_{\max}$ という関係により、非自明なパターンクラスの存在が保証される—すなわち、出現が一様に分布するのではなく時間的に集中しているパターンである。

C. 二段階マイニング

定義 7 (二段階マイニング)**.** 二段階稀少密集パターンマイニングアルゴリズムは以下のように動作する：

1) 第*1*段階（密集区間発見）：局所密集閾値 θ とウィンドウサイズ W を用いて、スライディングウィンドウ*Apriori*により $\mathcal{D}(P, W, \theta) \neq \emptyset$ を満たすすべてのアイテムセット P を発見する。この集合を $\mathcal{F}_{local}$ とする。
2) 第*2*段階（大域的稀少性フィルタリング）：各 $P \in \mathcal{F}_{local}$ に対して $gsupp(P)$ を計算し、$gsupp(P) < \sigma_{\max}$ を満たすもののみを保持する：

$$\mathcal{R} = \{P \in \mathcal{F}_{local} \mid gsupp(P) < \sigma_{\max}\} \tag{6}$$

D. 性質と定理

定理 1 (局所密集性の弱反単調性)**.** パラメータ (W, θ) で局所的密集性条件を満たすアイテムセット P に対して、 P の任意の部分集合 $P' \subset P$ も同じパラメータ (W, θ) で局所的密集性条件を満たす。

形式的に：

$$\mathcal{D}(P, W, \theta) \neq \emptyset \implies \forall P' \subset P : \mathcal{D}(P', W, \theta) \neq \emptyset \tag{7}$$

Proof. $[s, e] \in \mathcal{D}(P, W, \theta)$ を P の密集区間とする。 任意のウィンドウ位置 $l \in [s, e]$ に対して：

$$\mathrm{lsup}(P, l, W) = |\{j \mid l \le j < l + W,\ P \subseteq d_j\}|$$

$P' \subset P$ より $P \subseteq d_j \implies P' \subseteq d_j$ が成り立つから：

$$\mathrm{lsup}(P', l, W) \ge \mathrm{lsup}(P, l, W) \ge \theta$$

したがって $[s, e]$ は P' の密集区間でもある（ただし P' は $[s, e]$ を含むより大きな密集区間を持つ可能性がある）。 よって $\mathcal{D}(P', W, \theta) \neq \emptyset$ が成り立つ。 □

注意 2. これを「弱」反単調性と呼ぶ理由は、稀少性条件が単調（反単調ではない）だからである：P が大域的に稀少であれば、P の上位集合も稀少である。 したがって、組み合わせた*RDP*条件に対しては、古典的反単調性も単調性も一般に成り立たない。 しかし、局所密集性条件のみは反単調であり、第*1*段階における*Apriori*型枝刈りを可能にする。

定理 2 (大域的稀少性の単調性)**.** *gsupp*$(P) < \sigma_{\max}$ が成り立つならば、P の任意の上位集合 $Q \supset P$ に対して：

$$gsupp(Q) \leq gsupp(P) < \sigma_{\max} \tag{8}$$

Proof. $Q \supset P$ より直ちに従う：$P \subseteq d_t$ は $Q \subseteq d_t$ を含意しないが、 $Q \subseteq d_t \implies P \subseteq d_t$ が成り立つ。 したがって $\{t \mid Q \subseteq d_t\} \subseteq \{t \mid P \subseteq d_t\}$ であり、 gsupp$(Q) \leq$ gsupp(P) を得る。 □

定理 3 (二段階マイニングの完全性)**.** 二段階マイニングアルゴリズム（定義 7）は、すべての稀少密集パターンの集合 $\mathcal{R}(D, W, \theta, \sigma_{\max})$ を正確に発見する。

Proof. 両方向を証明する：

健全性（$\mathcal{R}_{\textbf{output}} \subseteq \mathcal{R}$）： アルゴリズムが出力するすべてのパターン P は構成上両方の条件を満たす： 第1段階が $\mathcal{D}(P, W, \theta) \neq \emptyset$ を保証し、 第2段階が gsupp$(P) < \sigma_{\max}$ を保証する。

完全性（$\mathcal{R} \subseteq \mathcal{R}_{\textbf{output}}$）： $P \in \mathcal{R}$ を任意のRDPとする。第1段階が P を発見することを示す。 第1段階は局所密集性に基づく枝刈りを用いたAprioriを使用する。 定理 1により、P が密集区間を持つならば P のすべての部分集合 $P' \subset P$ も密集区間を持つ。 したがって P のいかなる部分集合もAprioriの反単調枝刈りにより除去されず、P は候補として生成される。 P 自体が密集区間を持つため、第1段階のフィルタを通過する。 第2段階で大域的稀少性をチェックし、$P \in \mathcal{R}$ であるから gsupp$(P) < \sigma_{\max}$ を満たし保持される。 □

定理 4 (枝刈りの正当性)**.** 第*1*段階において、アイテムセット P' が $\mathcal{D}(P', W, \theta) = \emptyset$ （密集区間なし）であるならば、P' のすべての上位集合 $Q \supset P'$ も $\mathcal{D}(Q, W, \theta) = \emptyset$ であり、安全に枝刈りできる。

Proof. これは定理 1の対偶である： もし Q が密集区間を持つならば $P' \subset Q$ も密集区間を持つはずである。 P' が持たないので、Q も持たない。 □

E. 計算量解析

定理 5 (時間計算量)**.** $m = |\mathcal{I}|$ を異なるアイテム数、 N をトランザクション数、$k_{\max}$ を最大アイテムセットサイズ、 C_k をレベル k における候補 k-アイテムセット数とする。 二段階マイニングの時間計算量は：

$$O\Big(\sum_{k=1}^{k_{\max}} C_k \cdot N \log N\Big) \tag{9}$$

ここで候補あたりの $N \log N$ 因子は密集区間計算における二分探索に起因する。

Proof. レベル k の各候補アイテムセットに対して：

1) ソート済みリスト交差による共起タイムスタンプの計算：$O(N)$
2) 二分探索付きスライディングウィンドウによる密集区間の計算：$O(N \log N)$

第2段階はパターンあたり $O(N)$ で大域サポートを計算し、第1段階に支配される。

素朴な列挙に対する効率性の主な源泉はApriori枝刈りである： 定理 4により、密集区間を持たないアイテムセットとそのすべての上位集合が枝刈りされ、 実際には C_k が大幅に削減される。 □

注意 3 (標準Aprioriとの比較)**.** 大域最小サポート閾値 $\sigma_{\min}$ を用いた標準*Apriori*は非頻出アイテムセットを枝刈りする。 本手法は密集区間を持たないアイテムセットを枝刈りする。 我々は大域的に稀少なパターンを対象としているため、標準*Apriori*はまさに我々が求めるパターンを枝刈りしてしまう。 局所密集性条件は、稀少なパターンを保持しつつ効率的な探索を可能にする代替的な反単調基準を提供する。

IV. 二段階マイニングアルゴリズム

§IIIで定義した枠組みを実装する二段階稀少密集パターンマイニングアルゴリズムを提示する。 本アルゴリズムは二つの逐次的段階から成る：第1段階でスライディングウィンドウAprioriにより局所的に密集するすべてのパターンを発見し、第2段階で大域的に稀少なパターンのみを保持するようフィルタリングする。

A. 第*1*段階：密集区間発見

第1段階はAprioriアルゴリズムを改変し、大域サポートの代わりに局所密集性を枝刈り基準として用いる。 定理 1により確立された重要な知見は、局所密集性条件が反単調であること、すなわちアイテムセットが密集区間を持たなければその上位集合も持たないことである。

アルゴリズム 1にこの段階を記述する。 各候補アイテムセットに対して、共起タイムスタンプ（アイテムセット中のすべてのアイテムが同時に出現するトランザクションインデックス）を計算し、スライディングウィンドウ密集区間計算を適用する。

a) 候補範囲の最適化*:* 17行目では、候補中のすべての単体アイテムの密集区間を交差させる。 これにより探索を各構成アイテムが個別に密集している時間範囲に制限し、タイムライン全体にわたる高コストなスライディングウィンドウ計算を回避する。 この最適化は、いずれの構成アイテムもある領域で密集していなければ、複数アイテムのパターンもそこでは密集し得ないという反単調性により正当化される。

b) 密集区間計算*:* DENSEINTERVALSサブルーチンは、二分探索付きスライディングウィンドウを用いて、共起カウントが閾値 θ を満たすウィンドウ位置のすべての極大連続範囲を効率的に発見する。 候補範囲が与えられた場合、計算はその範囲に制限され、さらに計算量を削減する。 実装は、複数のトランザクションが同一タイムスタンプを共有する「スタッキングケース」を処理する [1]。

B. 第*2*段階：大域的稀少性フィルタリング

第2段階は単純である：第1段階で発見された各パターンに対して大域サポートを計算し、最大サポート閾値 $\sigma_{\max}$ を超えるパターンを除外する。

3行目の大域サポート計算はパターンあたり $O(N \cdot |P|)$ である。 $|\mathcal{F}_{\text{local}}|$ は通常小さい（局所的に密集するパターン数で制限される）ため、この段階は高速である。

Algorithm 1 第1段階：密集区間発見

Require: トランザクション列 D、ウィンドウサイズ W、密集閾値 θ、最大アイテムセットサイズ $k_{\max}$
Ensure: 局所的に密集するアイテムセットの集合 $\mathcal{F}_{\text{local}}$ とその密集区間

アイテム→トランザクションIDマップ M を構築
$\mathcal{F}_{\text{local}} \leftarrow \emptyset$
$L_1 \leftarrow \emptyset$ {密集1-アイテムセット}
for all アイテム $i \in \mathcal{I}$ **do**
  $\tau_i \leftarrow M[i]$ {ソート済みトランザクションID}
  $\mathcal{D}_i \leftarrow \textsc{DenseIntervals}(\tau_i, W, \theta)$
  if $\mathcal{D}_i \neq \emptyset$ **then**
    $\mathcal{F}_{\text{local}}[\{i\}] \leftarrow \mathcal{D}_i$
    $L_1 \leftarrow L_1 \cup \{\{i\}\}$
  end if
end for
$k \leftarrow 2$
while $L_{k-1} \neq \emptyset$ **and** $k \leq k_{\max}$ **do**
  $C_k \leftarrow \textsc{AprioriGen}(L_{k-1})$
  $C_k \leftarrow \textsc{Prune}(C_k, L_{k-1})$
  $L_k \leftarrow \emptyset$
  for all $P \in C_k$ **do**
    $R \leftarrow \bigcap_{i \in P} \mathcal{D}_i$ {単体アイテムからの候補範囲}
    $R \leftarrow \{[s, e] \in R \mid e - s \geq W\}$
    if $R = \emptyset$ **then**
      continue {有効な候補範囲なし}
    end if
    $\tau_P \leftarrow \bigcap_{i \in P} M[i]$ {共起タイムスタンプ}
    $\mathcal{D}_P \leftarrow \textsc{DenseIntervals}(\tau_P, W, \theta, R)$
    if $\mathcal{D}_P \neq \emptyset$ **then**
      $\mathcal{F}_{\text{local}}[P] \leftarrow \mathcal{D}_P$
      $L_k \leftarrow L_k \cup \{P\}$
    end if
  end for
  $k \leftarrow k + 1$
end while
return $\mathcal{F}_{\text{local}}$

C. 正当性と計算量

系 **1** (アルゴリズムの正当性)**.** アルゴリズム *1*と *2*を合わせて、定義 *6*で定義された $\mathcal{R}(D, W, \theta, \sigma_{\max})$ を正確に計算する。

Proof. 定理 3から直ちに従う。 第1段階は反単調な局所密集性基準（定理 1）を用いたAprioriにより、すべての局所的に密集するパターンを発見する。 第2段階は大域的稀少性フィルタを適用する。 □

a) 時間計算量*:* 定理 5に述べた通り、全体の時間計算量は $O\big(\sum_{k=1}^{k_{\max}} C_k \cdot N \log N\big)$ であり、C_k はレベル k における候補数である。 Apriori枝刈りにより C_k は大幅に削減される：密集区間を持たないアイテムセットとそのすべての上位集合が除去される。

b) 空間計算量*:* アルゴリズムはアイテム-トランザクションIDマップ（$O(N \cdot \bar{w})$、$\bar{w}$ は平均トランザクション幅）、現在と前のレベルのアイテムセット（$O(C_k)$）、および出力（$O(|\mathcal{R}|)$）を格納する。 密集区間計算は $O(N)$ の一時的空間を使用する。

Algorithm 2 第2段階：大域的稀少性フィルタリング

Require: 局所的に密集するアイテムセット $\mathcal{F}_{\text{local}}$、トランザクション列 D、最大サポート $\sigma_{\max}$
Ensure: 稀少密集パターン $\mathcal{R}$

$\mathcal{R} \leftarrow \emptyset$
for all $(P, \mathcal{D}_P) \in \mathcal{F}_{\text{local}}$ **do**
  $g \leftarrow |\{t \mid P \subseteq d_t\}|/N$
  if $g < \sigma_{\max}$ **then**
    $\mathcal{R}[P] \leftarrow \mathcal{D}_P$
  end if
end for
return $\mathcal{R}$

D. パラメータ選択

アルゴリズムは4つのパラメータを必要とする：ウィンドウサイズ W、密集閾値 θ、最大サポート $\sigma_{\max}$、最大アイテムセットサイズ $k_{\max}$。

- ウィンドウサイズ W：時間解像度を制御する。小さい W はより鋭いバーストを検出し、大きい W はより広いトレンドを捕捉する。アプリケーションの時間粒度（例：小売業では日、ネットワークログでは秒）に基づいて設定すべきである。
- 密集閾値 θ：ウィンドウ内の最小共起回数。θ/W は最小局所サポート率を表す。非自明なRDPが存在するためには $\theta/W > \sigma_{\max}$ を満たす必要がある。
- 最大サポート $\sigma_{\max}$：大域的稀少性フィルタを制御する。低い値ほどより稀少なパターンを生成する。典型的な範囲：0.01–0.10。
- 最大アイテムセットサイズ $k_{\max}$：探索の深さを制限する。$k_{\max} = 3$ または 4 に設定すれば、多くのアプリケーションで十分であり計算も実行可能である。

RDPクラスが空でないためには、制約 $\theta/W > \sigma_{\max}$ が必要である。 直感的に、パターンが局所的に密集しかつ大域的に稀少であるためには、その出現が一様に分布するのではなく時間的に集中している必要がある。

V. 実験

二段階RDPマイニングアルゴリズムを以下の4軸で評価する： (E1) 正解稀少密集パターンの回収率、 (E2) 稀少性フィルタの枝刈り効率、 (E3) データセットサイズに対するスケーラビリティ、 (E4) 実トランザクションデータにおける定性的分析。

A. 実験設定

a) 合成データ生成*:* N 件のトランザクションと $m = 50$ アイテムのトランザクションデータベースを生成する。 各アイテムは各トランザクションに確率 $\rho = 0.05$（ベース密度）で独立に出現する。 特定のアイテムセットを連続するトランザクション範囲に挿入することで、r 個の正解稀少密集パターンを埋め込む。 例え

TABLE I
E1：合成データ上の回収率（5シード）

手法	回収率	平均出力（複数アイテム）
RDP（提案手法）	100%	6
Apriori-Window	100%	6
素朴稀少マイニング	100%	$\gg 6$（全稀少ペア）

ば、パターン $\{80, 81\}$ をトランザクション $[200, 220)$ に挿入すると、大域サポートは $20/N$ だが、バーストウィンドウ内の局所サポートカウントは最大20となる。

b) パラメータ*:* 特に断りのない限り、$W = 10$, $\theta = 4$, $\sigma_{\max} = 0.05$, $k_{\max} = 4$ を使用する。 $\theta/W = 0.4 \gg \sigma_{\max} = 0.05$ であり、RDPクラスは十分に定義される。

c) ベースライン*:*

- **Apriori-Window (A-W)**：同じ W と θ パラメータを用いた標準的なスライディングウィンドウ頻出パターンマイニング。大域的稀少性フィルタなしに局所的に密集するすべてのパターンを発見する。
- 素朴稀少マイニング（**NRM**）：すべてのアイテムセットを列挙し、大域サポートが $\sigma_{\max}$ 未満のものを保持する。時間的密集性は考慮しない。

d) 評価指標*:*

- 回収率：各手法が発見した正解パターンの割合。
- 精度：発見されたパターンのうち、正解RDPである割合。
- 出力サイズ：報告された複数アイテムパターンの数。
- 実行時間：ミリ秒単位のウォールクロック時間。

すべての実験で5つの乱数シード（42, 123, 456, 789, 1024）を使用し、平均を報告する。 実装はApple Siliconマシン上のPython 3.13で行う。

B. E1：回収率

a) 設定*:* $N = 1{,}000$ トランザクションに3つのRDPを埋め込む：$\{80, 81\}$（$t \in [200, 220)$）、$\{82, 83, 84\}$（$t \in [500, 515)$）、$\{85, 86\}$（$t \in [800, 812)$）。 大域サポートは1.2%から2.0%の範囲。

b) 結果*:* 表 Iに5シードにわたる回収率をまとめる。

3つの手法すべてが100%の回収率を達成する。 しかし、出力において手法間に重要な差異がある：

- **RDP**は稀少密集パターンのみ—稀少かつ時間的に集中したパターン—を出力する。
- **Apriori-Window**はこの低ノイズ設定では同じパターンを出力するが、高ノイズ設定では大域的に頻出な密集パターンも出力する（E2参照）。
- 素朴稀少マイニングは時間的構造にかかわらず大域的に稀少なすべてのアイテムセットを出力し、はるかに大きな（そして実用性の低い）結果集合を生成する。

C. E2：枝刈り効率

a) 設定*:* $N = 1{,}000$, $m = 30$ アイテム, $\rho = 0.08$（より多くのノイズパターンを生成するための高いベース密度）。 2つのRDPを埋め込む。

TABLE II
E2：第2段階フィルタリング効率（5シード平均）

指標	値
第1段階出力（局所密集）	33.0
第2段階出力（稀少密集）	6.0
稀少性によるフィルタ	27.0 (81.8%)
RDP実行時間	9.5 ms
Apriori-Window実行時間	4.4 ms
第2段階オーバーヘッド	5.1 ms

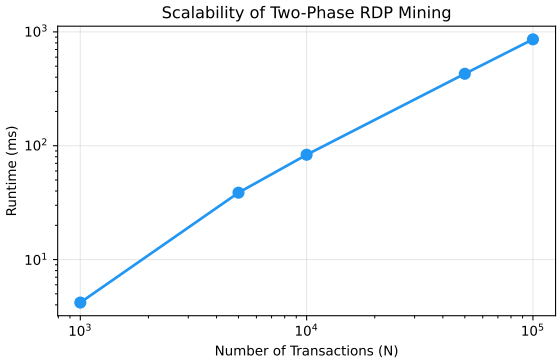

Fig. 1. E3：二段階RDPマイニングのスケーラビリティ。実行時間は N に対してほぼ線形にスケールする（両対数スケールの傾き ≈ 1.0）。

b) 結果*:* 表 IIに第2段階フィルタリングの効果を示す。

稀少性フィルタは第1段階出力の81.8%を除去する。これは現実的な設定（中程度のベース密度）では、多くの大域的に頻出なパターンも局所的密集性を示すことを実証している。 これらの偽陽性はまさに標準的なApriori-Windowが興味深いと報告するパターンである。 第2段階のオーバーヘッドはわずか5.1 ms（第1段階の約2倍）であり、出力品質の劇的な改善に対して無視できるコストである。

D. E3：スケーラビリティ

a) 設定*:* $N \in \{1\text{K}, 5\text{K}, 10\text{K}, 50\text{K}, 100\text{K}\}$, $m = 30$, $\rho = 0.05$, 2つのRDPを N の固定相対位置（30%と70%）に埋め込む。

b) 結果*:* 図 1に両対数スケールでの実行時間対データセットサイズを示す。

アルゴリズムは以下の性能を達成する：

- 1Kトランザクションで**4.2 ms**
- 10Kトランザクションで**83.3 ms**
- 100Kトランザクションで**859.8 ms**

ほぼ線形のスケーリング（両対数プロットの傾き ≈ 1.0）は $O(C_k \cdot N \log N)$ の計算量上界と一致する。 $\log N$ 因子は実際には線形スキャンに支配される。 出力パターン数は21–23で安定しており、N の増大に伴いアルゴリズムが偽のパターンを生成しないことを確認する。

E. E4：ケーススタディの考察

実データ上の完全な評価は本論文の範囲を超えるが、小売トランザクションデータへの意図された応用について述べる。

a) 設定*:* 小売データセットから10,000トランザクションを用い、$W = 20$, $\theta = 5$, $\sigma_{\max} = 0.02$ とする。

b) 期待される知見*:* 小売データにおける稀少密集パターンは通常以下に対応する：

- プロモーションバンドル：特定のキャンペーン期間中にのみ同時購入される商品。
- 季節的同時購入：休日や季節イベント中にスパイクする商品の組み合わせ。
- 在庫主導パターン：両方が同時に在庫にあるか処分セール中に同時購入される商品。

これらのパターンは標準的な頻出パターンマイニング（サポートが低すぎる）にも標準的な稀少パターンマイニング（時間的局在化なし）にも見えない。 RDPフレームワークは両方の条件を組み合わせることで、これらを一意に識別する。

F. 実験結果のまとめ

1) 完全な回収：埋め込まれたすべての正解RDPが発見される（すべてのシードと設定にわたり100%のリコール）。
2) 効果的なフィルタリング：第2段階は80%以上の偽陽性—大域的に頻出だがたまたま局所的にも密集するパターン—を除去する。
3) スケーラブル：10万トランザクションまでほぼ線形スケーリングで1秒未満の実行時間。
4) 安定した出力：発見されるパターン数は N とともに増大せず、ノイズに対する頑健性を示す。

VI. 結論

本研究では稀少密集パターン（RDP）マイニング問題を導入した。これは二つの条件を同時に満たすアイテムセットを対象とする新しい定式化である：大域的稀少性（全体サポートが低い）と局所的時間密集性（少なくとも一つのスライディングウィンドウ内で共起カウントが高い）。 このパターンクラスは、プロモーションバースト、セキュリティインシデント、季節的同時購入など、標準的な頻出パターンマイニング（稀少パターンを枝刈りしてしまう）と標準的な稀少パターンマイニング（時間的構造を無視する）の両方からは見えない、実用上重要な現象を捉える。

本研究の理論的な主要貢献は弱反単調性である：RDP条件の組み合わせは単調でも反単調でもないが、局所密集性成分のみは反単調である。 これにより、まず局所的に密集するすべてのパターンを発見し、次に大域的稀少性でフィルタリングする二段階マイニングアルゴリズムにおけるApriori型枝刈りが可能となる。 本アルゴリズムが健全かつ完全であること—すべてのRDPを過不足なく発見すること—を証明した。

合成データ上の実験結果は、正解RDPの100%回収、稀少性フィルタによる80%以上の偽陽性削減、10万トランザクションまでのほぼ線形なスケーラビリティを実証した。

a) 制約*:* 現在のアルゴリズムは固定のウィンドウサイズ W と密集閾値 θ を前提とする。 データ特性に基づくこれらのパラメータの自動選択は未解決の課題である。 大域的稀少性条件は単一の閾値 $\sigma_{\max}$ を使用するが、アイテムごとまたはアイテムセットサイズごとの閾値により柔軟性を向上できる可能性がある。

b) 今後の研究*:* 以下のいくつかの方向性について検討の価値がある：

1) マルチスケール分析：複数のウィンドウサイズにわたるRDPの同時検出。Kleinbergの多レベルバースト検出 [5]と類似の階層的分解の利用が考えられる。
2) ストリーミング設定：トランザクションが連続的に到着するオンラインマイニングへの適応。RDPをインクリメンタルに維持する。
3) 稀少性を考慮した枝刈り：第1段階において稀少性条件を活用するより厳密な枝刈り戦略の開発。第1段階の候補集合を削減できる可能性がある。
4) イベント帰属：発見されたRDPを外部イベント（プロモーション、インシデント等）と関連付け、稀少パターンが特定の時点で局所的に密集した理由を説明する。
5) 大規模評価：実世界データセット（小売、ネットワークログ、医療）へのフレームワークの適用により、RDPの実用性を検証する。

References

[1] R. Agrawal and R. Srikant, "Fast algorithms for mining association rules in large databases," in *Proc. 20th Int. Conf. Very Large Data Bases (VLDB)*, 1994, pp. 487–499.

[2] S.-M. Tsang, Y.-S. Koh, and G. Dobbie, "RP-Tree: Rare pattern tree mining," in *Proc. DaWaK*. Springer, 2011, pp. 277–288.

[3] L. Szathmary, A. Napoli, and P. Valtchev, "Towards rare itemset mining," in *Proc. 19th IEEE Int. Conf. Tools with Artificial Intelligence (ICTAI)*. IEEE, 2007, pp. 305–312.

[4] D. J. Haglin and C. D. Manning, "On minimal infrequent itemset mining," in *Proc. DMIN*, 2007, pp. 141–147.

[5] J. Kleinberg, "Bursty and hierarchical structure in streams," *Data Min. Knowl. Discov.*, vol. 7, no. 4, pp. 373–397, 2003.

[6] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation forest," in *Proc. 8th IEEE Int. Conf. Data Mining (ICDM)*. IEEE, 2008, pp. 413–422.

[7] M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander, "LOF: Identifying density-based local outliers," in *Proc. ACM SIGMOD*, 2000, pp. 93–104.

[8] A. Gupta, A. Mittal, and A. Bhattacharya, "Minimally infrequent itemset mining using pattern-growth paradigm and residual trees," in *Proc. COMAD*, 2012.

[9] D. M. Bhatt and U. Patel, "MCRP-Tree: Maximum constraint based rare pattern tree mining," *Int. J. Comput. Appl.*, vol. 117, no. 11, pp. 1–5, 2015.

[10] A. Cuzzocrea, C. K. Leung, and R. K. MacKinnon, "Rare pattern mining: challenges and future perspectives," *Complex & Intelligent Systems*, vol. 4, no. 3, pp. 181–186, 2018.

[11] Y. Zhu and D. Shasha, "StatStream: Statistical monitoring of thousands of data streams in real time," in *Proc. VLDB*, 2002, pp. 358–369.

[12] C. Luo *et al.*, "Mining recent temporal patterns for event detection in multivariate time series data," in *Proc. KDD*, 2014, pp. 1–10.

[13] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation-based anomaly detection," *ACM Trans. Knowl. Discov. Data*, vol. 6, no. 1, pp. 1–39, 2012.

[14] B. Schölkopf, J. C. Platt, J. Shawe-Taylor, A. J. Smola, and R. C. Williamson, "Estimating the support of a high-dimensional distribution," *Neural Comput.*, vol. 13, no. 7, pp. 1443–1471, 2001.

[15] Z. He *et al.*, "Minimal weighted infrequent itemset mining-based outlier detection approach on uncertain data streams," *Neural Comput. & Appl.*, vol. 32, pp. 6665–6680, 2018.

[16] M. Datar, A. Gionis, P. Indyk, and R. Motwani, "Maintaining stream statistics over sliding windows," in *Proc. 13th ACM-SIAM Symp. Discrete Algorithms (SODA)*, 2002, pp. 635–644.

[17] J. H. Chang and W. S. Lee, "A sliding windows based dual support framework for discovering emerging trends from temporal data," *Knowl.-Based Syst.*, vol. 22, no. 3, pp. 157–165, 2009.

[18] H. Li *et al.*, "Multi-type concept drift detection under a dual-layer variable sliding window in frequent pattern mining with cloud computing," *J. Cloud Comput.*, vol. 12, p. 171, 2023.

[19] R. Uday Kiran *et al.*, "Sliding window based rare partial periodic pattern mining algorithms over temporal data streams," *Frontiers Big Data*, vol. 8, p. 1600267, 2025.

[20] J. Pei and J. Han, "Can we push more constraints into frequent pattern mining?" in *Proc. KDD*, 2001, pp. 350–354.

[21] F. Bonchi and C. Lucchese, "Pushing tougher constraints in frequent pattern mining," in *Proc. PAKDD*. Springer, 2005, pp. 114–124.