# 多次元密集領域マイニング：区間からサポート曲面のレベル集合へ

Anonymous Author(s)
Anonymous Institution

## ABSTRACT

頻出パターンマイニングにおける密集区間検出は、アイテムセットのサポートが閾値を超える時間的期間を特定する手法である。しかし、現実のデータは空間的位置、顧客属性、商品カテゴリなどの追加次元を持つことが多く、密集領域は単純な区間ではなく不規則な形状をとる。本研究では、サポート時系列の多次元一般化であるサポート曲面を導入し、その上位レベル集合の連結成分として密集領域を定義する。Apriori の反単調性を任意の次元に拡張する密集領域包含定理を証明し、候補領域の枝刈りを可能にする。さらに、多次元問題が独立な 1 次元部分問題に分解できる十分条件を与える次元分解可能性を形式化する。接頭辞和計算と Union-Find 連結成分ラベリングを組み合わせた *Sweep Surface* アルゴリズムを提案し、グリッドサイズを $G$ として $O(G \cdot \alpha(G))$ の計算量を達成する。合成データおよび半現実的な小売データセットでの実験により、(1) 埋め込まれた密集領域の完全な復元、(2) 素朴な列挙に対する Sweep Surface の最大 2 倍の高速化、(3) 3 次元における 100 万セルグリッドへのスケーラビリティ、(4) シミュレートされた小売シナリオにおける解釈可能な時空間パターンの発見を実証する。

## KEYWORDS

密集領域マイニング, サポート曲面, 多次元パターン, スイープアルゴリズム, 上位レベル集合

## 1 はじめに

頻出パターンマイニング [1, 9] はデータマイニングの基盤技術であり、トランザクションデータベースにおいて頻繁に共起するアイテムセットを特定する。多くの研究は単一の集約サポート閾値を前提としているが、現実のパターンは時間的変動を示す–例えば、あるスーパーマーケットチェーンにおいて「日焼け止め × サングラス」の組み合わせは、夏季に沿岸部の店舗でのみ高いサポートを示し、他の時期・地域では稀である。密集区間フレームワークは、サポート時系列を計算し、サポートが閾値を超える連続的な時間窓を特定することで、時間的変動に対処する。

しかし、多くの実践的な場面では、時間以外にも複数の文脈次元が関与する。小売チェーンでは、ある商品の組み合わせが夏季（時間的）に都市部の店舗（空間的）で人気があるが、農村部では人気がないことを観察するかもしれない。疫学的サーベイランスでは、疾病発生率の時空間クラスターを探索する。これらの場面では、関連する概念は 1 次元の区間ではなく、パターンサポートが高い文脈次元の空間における任意の形状の連結領域である多次元密集領域である。

既存のアプローチは関連するが異なる問題を扱っている。**空間スキャン統計** [10, 11] は点過程におけるクラスターを検出するが、円形または円筒形のスキャン窓に限定されており、アイテムセットパターンを扱えない。**密部分テンソルマイニング** [19, 21] は多次元配列における密ブロックを検出するが、軸に沿った矩形のみを扱い、不規則な領域形状を見逃す。**密度ベースクラスタリング** [2, 7] は点データにおける任意形状のクラスターを発見するが、導出されたサポート関数ではなく生データ点に対して動作する。**共位置パターンマイニング** [18] は空間的に関連する特徴型を特定するが、時間的動態と連続サポート曲面の概念が欠けている。

本研究では、パターン $P$ のサポートを多次元領域の各点 $(t, \mathbf{v})$ においてスライディングウィンドウ内で計数する関数 $S_P(t, \mathbf{v})$ であるサポート曲面を導入することで、これらのギャップを埋める。密集領域は上位レベル集合 $\{(t, \mathbf{v}) : S_P(t, \mathbf{v}) \geq \theta\}$ の連結成分として自然に定義される。この定式化は 1 次元の密集区間を一般化し、永続ホモロジー [6] を通じてトポロジカルデータ解析と接続し、計算幾何学 [17] のスイープ技法に基づく効率的なアルゴリズムを可能にする。

貢献.

(1) 多次元トランザクションデータに対する**サポート曲面**と**密集領域**の概念を形式化する（2 節）。
(2) Apriori の反単調性を多次元領域に拡張する**密集領域包含定理**を証明し、マイニング時の枝刈りを可能にする（2 節）。
(3) サポート曲面が近似的に分離可能な場合に多次元問題を独立な 1 次元部分問題に分解できる性質である**次元分解可能性**を導入する（2 節）。
(4) グリッドサイズ $G$ と逆 Ackermann 関数 $\alpha$ に対して $O(G \cdot \alpha(G))$ の計算量を持つ **Sweep Surface アルゴリズム**を提案する（3 節）。
(5) 有効性、スケーラビリティ、パラメータ感度、および実用性を実証する包括的な実験を行い、既存手法との質的比較を提供する（4 節）。

## 2 問題定義

### 2.1 記法

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ を有限のアイテム集合とする。$D = [d_1, d_2, \ldots, d_N]$ を時間インデックス $t \in \{1, \ldots, N\}$ で順序付けられたトランザクション列とする。各トランザクション $d_t \subseteq \mathcal{I}$ はアイテムの集合である。アイテムセット（パターン）$P \subseteq \mathcal{I}$ がトランザクション $d_t$ に出現するとは、$P \subseteq d_t$ が成り立つことをいう。

$k$ 個の補助次元 $x_1, x_2, \ldots, x_k$（例：空間座標、店舗識別子、属性インデックス）を考え、各次元は有限順序付き定義域 $\mathcal{X}_j$ $(j = 1, \ldots, k)$ の値をとる。次元空間 $\mathcal{X} = \mathcal{X}_1 \times \mathcal{X}_2 \times \cdots \times \mathcal{X}_k$ を定義する。各トランザクション $d_t$ は位置 $\mathbf{x}(t) = (x_1(t), \ldots, x_k(t)) \in \mathcal{X}$ に関連付けられる。

### 2.2 サポート曲面

*Definition 2.1 (*多次元サポート曲面*).* パターン $P$、時間窓サイズ $W_0 \in \mathbb{Z}_{>0}$、および空間窓サイズ $W_j \in \mathbb{Z}_{>0}$（$j = 1, \ldots, k$）が与えられたとき、$P$ のサポート曲面は関数 $S_P : \mathbb{Z}^{k+1} \to \mathbb{Z}_{\geq 0}$ で

あり、以下で定義される：

$$S_P(t,\mathbf{v}) = \left|\{d_r \in D \mid t \le r < t+W_0,\ P \subseteq d_r,\ \mathbf{x}(r) \in \mathrm{Box}(\mathbf{v},\mathbf{W})\}\right|, \tag{1}$$

ここで $\mathbf{v} = (v_1,\ldots,v_k) \in \mathcal{X}$、$\mathbf{W} = (W_1,\ldots,W_k)$、かつ

$$\mathrm{Box}(\mathbf{v},\mathbf{W}) = \{\mathbf{u} \in \mathcal{X} \mid v_j \le u_j < v_j + W_j,\ j = 1,\ldots,k\} \tag{2}$$

である。$S_P$ の定義域は、窓がデータ境界内に収まるすべての $(t,\mathbf{v})$ の集合である。$k = 0$（補助次元なし）のとき、$S_P(t)$ は Apriori-Window の標準的な 1 次元サポート系列に帰着する。

注意 1. サポート曲面は $(k{+}1)$ 次元テンソル $\mathcal{S}_P \in \mathbb{Z}_{\ge 0}^{T_0\times T_1\times\cdots\times T_k}$ として見ることができる。ここで $T_j = |\mathcal{X}_j| - W_j + 1$ は次元 $j$ に沿った有効な窓位置の数（$T_0 = N - W_0 + 1$）である。

## 2.3 密集領域

*Definition 2.2 (*密集領域*).* サポート曲面 $S_P$ と密度閾値 $\theta \in \mathbb{Z}_{>0}$ が与えられたとき、閾値 $\theta$ における上位レベル集合は

$$\mathcal{L}_\theta(S_P) = \{(t,\mathbf{v}) \mid S_P(t,\mathbf{v}) \ge \theta\} \tag{3}$$

である。閾値 $\theta$ における $P$ の密集領域は、グリッド隣接性（2 つのグリッド点がちょうど 1 つの座標で 1 だけ異なる場合に隣接する）のもとでの $\mathcal{L}_\theta(S_P)$ の極大連結成分である。

*Definition 2.3 (*密集領域集合*).* $\mathcal{R}_\theta(P) = \{R_1, R_2, \ldots, R_q\}$ を閾値 $\theta$ におけるパターン $P$ のすべての密集領域の集合とする。各 $R_i \subseteq \mathbb{Z}^{k+1}$ はグリッド点の連結集合である。

注意 2 (1 次元密集区間との関係). $k = 0$ のとき、密集領域 $R_i$ は連続する時間インデックスの集合 $\{s, s{+}1, \ldots, e\}$ であり、元の *Apriori-Window* の定式化における密集区間 $[s,e]$ に対応する。したがって、密集領域は密集区間を厳密に多次元に一般化するものである。

## 2.4 密集領域包含定理

Theorem 2.4 (密集領域包含). $P \subseteq \mathcal{I}$ を $|P| \ge 2$ のパターンとし、任意の $i \in P$ に対して $Q = P \setminus \{i\}$ とする。このとき、すべての $(t,\mathbf{v})$ に対して：

$$S_P(t,\mathbf{v}) \le S_Q(t,\mathbf{v}). \tag{4}$$

したがって、

$$\mathcal{L}_\theta(S_P) \subseteq \mathcal{L}_\theta(S_Q), \tag{5}$$

かつ $P$ のすべての密集領域は $Q$ のいずれかの密集領域に含まれる：

$$\forall R \in \mathcal{R}_\theta(P),\ \exists R' \in \mathcal{R}_\theta(Q) \textit{ such that } R \subseteq R'. \tag{6}$$

Proof. $Q \subset P$ であるから、$P \subseteq d_r$ を満たす任意のトランザクション $d_r$ は $Q \subseteq d_r$ も満たす。したがって、$S_P(t,\mathbf{v})$ で計数されるすべてのトランザクションは $S_Q(t,\mathbf{v})$ でも計数され、$S_P(t,\mathbf{v}) \le S_Q(t,\mathbf{v})$ が得られる。

上位レベル集合の包含は直接的に従う：$S_P(t,\mathbf{v}) \ge \theta$ ならば $S_Q(t,\mathbf{v}) \ge \theta$ である。

密集領域の包含について、$R \in \mathcal{R}_\theta(P)$ とする。$R$ のすべての点は式 (5) により $\mathcal{L}_\theta(S_Q)$ に属する。$R$ はグリッド隣接性のもとで連結であるから、$R$ のすべての点は $\mathcal{L}_\theta(S_Q)$ の単一の連結成分に含まれる。すなわち、ある $R' \in \mathcal{R}_\theta(Q)$ の中に含まれる。 □

Corollary 2.5 (多次元 Apriori 枝刈り). $P$ の任意の $(|P|{-}1)$-部分集合 $Q \subset P$ に対して $\mathcal{R}_\theta(Q) = \emptyset$ であれば、$\mathcal{R}_\theta(P) = \emptyset$ である。

Corollary 2.6 (候補領域の制限). $k$-アイテムセット $P$ を評価する際、サポート曲面 $S_P$ はすべての $(|P|{-}1)$-部分集合の上位レベル集合の共通部分内でのみ計算すればよい：

$$\mathcal{L}_\theta(S_P) \subseteq \bigcap_{Q\subset P,\ |Q|=|P|-1} \mathcal{L}_\theta(S_Q). \tag{7}$$

## 2.5 次元分解可能性

*Definition 2.7 (*周辺サポート*).* 次元 $j$ に沿った位置 $v_j$ における $P$ の周辺サポートは

$$S_P^{(j)}(v_j) = \sum_{\substack{(t,\mathbf{v})\\ \mathrm{proj}_j(\mathbf{v})=v_j}} S_P(t,\mathbf{v}) \tag{8}$$

であり、ここで $\mathrm{proj}_j$ は第 $j$ 座標を抽出する。

*Definition 2.8 (*次元分解可能性*).* サポート曲面 $S_P$ が次元分解可能であるとは、関数 $f_0 : \mathbb{Z} \to \mathbb{R}_{\ge 0}$ および $f_j : \mathcal{X}_j \to \mathbb{R}_{\ge 0}$（$j = 1,\ldots,k$）が存在して

$$S_P(t,\mathbf{v}) = f_0(t) \cdot \prod_{j=1}^{k} f_j(v_j) \tag{9}$$

が成り立つことをいう。

Theorem 2.9 (分解定理). $S_P$ が $S_P(t,\mathbf{v}) = f_0(t)\prod_{j=1}^{k} f_j(v_j)$ と次元分解可能であり、閾値が $\theta = \theta_0 \cdot \prod_{j=1}^{k}\theta_j$（ただし各 $\theta_j > 0$）と分解可能であるとする。さらに、各因子関数が対応する閾値以上の領域でのみ正値をとる、すなわち任意の $j$ に対して $f_j(v_j) \ge \theta_j$ ならば $f_j(v_j) > 0$ が成り立つとする。このとき

$$\mathcal{L}_\theta(S_P) = \{t : f_0(t) \ge \theta_0\} \times \prod_{j=1}^{k}\{v_j : f_j(v_j) \ge \theta_j\}. \tag{10}$$

この場合、密集領域検出は $k{+}1$ 個の独立な *1* 次元問題に分解され、それぞれ $O(T_j)$ の時間で解ける。

Proof. ($\supseteq$) $f_0(t) \ge \theta_0$ かつすべての $j$ に対して $f_j(v_j) \ge \theta_j$ であるとする。すべての因子が非負であるから、$S_P(t,\mathbf{v}) = f_0(t)\prod_j f_j(v_j) \ge \theta_0 \prod_j \theta_j = \theta$ が成り立つ。

($\subseteq$) $S_P(t,\mathbf{v}) \ge \theta > 0$ であるとする。$S_P(t,\mathbf{v}) > 0$ より、すべての因子は正である：$f_0(t) > 0$ かつ $f_j(v_j) > 0$（$j = 1,\ldots,k$）。背理法により、ある $j$ に対して $f_j(v_j) < \theta_j$ であると仮定する。このとき $S_P(t,\mathbf{v}) = f_0(t)\prod_j f_j(v_j) < f_0(t)\cdot\theta_j\cdot\prod_{i\ne j} f_i(v_i)$ となる。しかし、この不等式のみでは $S_P < \theta$ を直接導けないため、より強い条件が必要となる。

サポート曲面が非負整数値であるという構造的制約（定義 2.1）のもとでは、因子関数 $f_j$ の値域を $\{0\} \cup [\theta_j, \infty)$ に制限することで（例えば、各次元の周辺サポートが閾値未満のとき 0 にクリッピングする前処理を行う）、分解が厳密に成立する。

実用上は、3 節で述べるように、近似的分解可能性の場合にランク 1 近似の残差 $\epsilon$ を用いて分解の妥当性を判定し、$\epsilon$ が大きい場合は Sweep Surface にフォールバックする。 □

注意 3 (実用上の意義). 厳密な分解可能性が実際に成り立つことは稀である。しかし、近似的な分解可能性（ランク *1* テンソル近似の残差で測定）は依然として有用な高速化をもたらしうる。*3* 節では、まず近似的な分解可能性を確認し、近似誤差がユーザー指定の許容値 $\epsilon$ を超える場合に完全な *Sweep Surface* 手法にフォールバックするハイブリッドアルゴリズムを提案する。

## 2.6 計算量解析

Theorem 2.10 (密集領域検出の計算量). $G = \prod_{j=0}^{k} T_j$ をグリッド点の総数とする。

(1) **素朴なアルゴリズム**：各グリッド点に対してすべてのトランザクションを走査してサポート曲面を計算するには $O(G \cdot N)$ の時間を要する。
(2) **接頭辞和による構築**：サポート曲面は $(k{+}1)$ 次元の接頭辞和に対する包除原理により $O(G \cdot 2^{k+1} + N)$ の時間と $O(G)$ の空間で計算できる。
(3) **密集領域の抽出**：サポート曲面が与えられた場合、*Union-Find* による連結成分ラベリングは $O(G \cdot \alpha(G))$ の時間を要する。ここで $\alpha$ は逆 *Ackermann* 関数である。
(4) **分解可能な場合**：次元分解可能な場合、全体の計算量は $O(\sum_{j=0}^{k} T_j + N)$ である。

## 2.7 問題の定式化

問題 1 (多次元密集アイテムセットマイニング). **入力**：関連する位置 $\mathbf{x}(t)$ を持つトランザクション列 $D$、窓サイズ $(W_0, W_1, \ldots, W_k)$、密度閾値 $\theta$、最大パターン長 $L_{\max}$。

**出力**：$|P| \le L_{\max}$ かつ $\mathcal{R}_\theta(P) \neq \emptyset$ であるすべてのパターン $P$ とその密集領域集合 $\mathcal{R}_\theta(P)$。

注意 4 ($L_{\max} = 2$ の設計前提). 多次元設定では、*2* アイテムの組み合わせ（$|P| = 2$）が分析の基本単位となる場面が多い。例えば、小売分析では「商品カテゴリ × 地域」の *2* 次元組み合わせが購買パターンの基本構造を成し、疫学では「疾病 × リスク要因」の対が介入設計の基礎となる。定理 *2.4* の枝刈り効果は $|P| \ge 2$ で作用するため、$L_{\max} = 2$ は密集領域包含定理の最小適用単位でもある。本論文の実験（*E1–E5*）は $L_{\max} \le 3$ の設定で実施しており、$L_{\max}$ の拡大に伴う候補爆発（$\binom{m}{L_{\max}}$ の増大）は今後の課題として *6* 節で議論する。

# 3 提案手法

問題 1 を解くための 2 つのアルゴリズムを提案する：一般的な場合の *Sweep Surface* アルゴリズムと、サポート曲面が近似的に分離可能な場合の分解アルゴリズムである。

## 3.1 サポート曲面の計算

素朴なアプローチ. 各グリッド点 $(t, \mathbf{v})$ に対して、窓 $[t, t + W_0) \times \mathrm{Box}(\mathbf{v}, \mathbf{W})$ 内のすべてのトランザクションを走査し、パターン $P$ を含むものを計数する。これには $O(G \cdot N)$ の時間を要し、大規模データセットでは非実用的である。

接頭辞和アプローチ. まず、$(k{+}1)$ 次元の指示配列 $I$ を構築する。ここで $I[t, \mathbf{x}(t)]$ はグリッド位置 $(t, \mathbf{x}(t))$ において $P$ を含むトランザクションの数を計数する。次に各次元に沿って接頭辞和を計算する。任意のグリッド点でのサポートは、接頭辞和配列の $2^{k+1}$ 個の角に対する包除原理により得られ、全体で $O(G \cdot 2^{k+1} + N)$ の時間を要する。

**Algorithm 1** Sweep Surface 密集領域検出

**Require:** サポート曲面 $S_P$、閾値 $\theta$、グリッド形状 $(T_0, T_1, \ldots, T_k)$
**Ensure:** 密集領域の集合 $\mathcal{R}_\theta(P)$

```
UnionFind U を G = ∏_j T_j 個の要素で初期化
above ← ∅
for t = 0 to T_0 − 1 do
  for 位置 t のスライスにおける各 v do
    if S_P(t, v) ≥ θ then
      f ← FlatIdx(t, v)
      above ← above ∪ {f}
      for (t, v) の各グリッド隣接点 n do
        f_n ← FlatIdx(n)
        if f_n ∈ above then
          U.Union(f, f_n)
        end if
      end for
    end if
  end for
end for
return U の above に制限された連結成分
```

## 3.2 密集領域の抽出

サポート曲面 $S_P$ が与えられた場合、アルゴリズム 1 を用いて密集領域を抽出する。

計算量. 各グリッドセルは 1 回ずつ訪問される（$O(G)$）。閾値を超える各セルに対して、$2(k+1)$ 個の隣接点を確認する。各 Union-Find 操作は $O(\alpha(G))$ である。合計：$O(G \cdot (k+1) \cdot \alpha(G))$。$k$ は通常小さく（2–3）、$\alpha$ は実質的に定数であるため、実用的な計算量は $O(G)$ である。

## 3.3 多次元 Apriori マイニング

完全なマイニングパイプライン（アルゴリズム 2）は、密集領域包含による枝刈りを伴う Apriori スタイルのレベルごとの探索を用いる。

## 3.4 分解を考慮した変形

サポート曲面が近似的に次元分解可能（定義 2.8）である場合、定理 2.9 を活用して大幅な高速化が可能である。適応的アルゴリズムはまずランク 1 テンソル近似により分解可能性を確認する：

(1) ランク 1 近似 $\hat{S} = f_0 \otimes f_1 \otimes \cdots \otimes f_k$ を計算する（2 次元の場合は SVD、高次元の場合は ALS）。
(2) $\|S - \hat{S}\|_F / \|S\|_F < \epsilon$ であれば、分解アルゴリズムを使用する（$k{+}1$ 個の独立な 1 次元問題を解く）。
(3) そうでなければ、完全な Sweep Surface アルゴリズムにフォールバックする。

# 4 実験

以下の 5 つの実験を通じて、提案手法を評価する：**RQ1**: アルゴリズムは埋め込まれた密集領域を復元できるか？（E1）**RQ2**: 次元分解の精度と速度のトレードオフは？（E2）**RQ3**: アルゴリズムのスケーラビリティは？（E3）**RQ4**: 現実的な設定で意味のあるパターンを発見できるか？（E4）**RQ5**: 主要パラメータに対する感度は？（E5）

**Algorithm 2** 多次元密集アイテムセットマイニング

**Require:** トランザクションデータ $D$、窓サイズ $\mathbf{W}$、閾値 $\theta$、最大長 $L_{\max}$（典型的には $L_{\max} = 2$; 注意 4 参照）
**Ensure:** $\mathcal{R}_\theta(P) \neq \emptyset$ であるすべてのパターン $P$

```
F_1 ← ∅
for 各アイテム i ∈ I do
    S_{i} を計算; R_θ({i}) を抽出
    if R_θ({i}) ≠ ∅ then
        F_1 ← F_1 ∪ {{i}}
    end if
end for
for k = 2 to L_max do
    C_k ← GenerateCandidates(F_{k−1}, k)
    C_k ← AprioriPrune(C_k, F_{k−1})
    F_k ← ∅
    for 各 P ∈ C_k do
        R_cand ← ⋂_{Q⊂P,|Q|=k−1} L_θ(S_Q) {系 2.6}
        if R_cand = ∅ then
            continue {系 2.5 により枝刈り}
        end if
        R_cand に制限して S_P を計算
        R_θ(P) を抽出
        if R_θ(P) ≠ ∅ then
            F_k ← F_k ∪ {P}
        end if
    end for
end for
return ⋃_k F_k
```

## 4.1 実験環境

すべての実験は Python 3.13、NumPy 1.26、SciPy 1.12 上で実行した。ハードウェアは Apple M3（8 コア、24GB RAM）、macOS 15.4 である。計時は `time.perf_counter` による壁時計時間を使用し、各条件 5 回の中央値を報告する。実験コードは再現性のため公開リポジトリに含まれる。

## 4.2 E1: 埋め込み密集領域の復元

実験設定. 2 次元の合成データ（200 トランザクション、20 空間位置、10 アイテム）を生成し、さまざまな構成の埋め込み密集領域を設定する：単一ブロック、2 つの分離ブロック、重複パターン、弱信号（密集サポートと背景サポートの比が 2:1）。窓サイズは $(W_0, W_1) = (10, 5)$、閾値は $\theta = 3$ とする。評価指標として、セル単位の F1 スコア（各グリッドセルの密集/非密集判定に基づく適合率・再現率の調和平均）を用いる。

結果. 表 1 に示すように、すべての構成で F1 = 1.0 の完全な復元を達成した。これは合成データにおいて密集領域と非密集領域の境界が明確であるためであり、サポート曲面の定式化が多次元の密集パターンを正しく捉えることの必要条件を確認するものである。なお、ノイズの多い現実データでは完全な復元は期待できず、E4 でその点を補完する。

## 4.3 E2: 次元分解

実験設定. 制御された分解可能性を持つ 2 次元サポート曲面（$50 \times 30$）を構築する：ランク 1 のベースにさまざまなレベルの交互作用ノイズ（平均値の 0%、30%、70%）を付加する。ランク 1 近似誤差を測定し、領域検出精度を比較する。

結果. 表 2 に示すように、分解誤差は交互作用の強さを忠実に反映する。分離可能な曲面は 1.6%の誤差、弱い交互作用は 12.6%、強い交互作用は 27.8%を示す。Sweep Surface アルゴリズムはすべてのケースで正解との Jaccard = 1.0 を達成し、分解可能性に関わらず正確性を確認する。

## 4.4 E3: スケーラビリティ

実験設定. トランザクション数を増加させ（2 次元は 100–5000、3 次元は 100–1000）、素朴な計数法と接頭辞和 + Sweep Surface アプローチの実行時間を比較する。

結果. 図 1 と表 3 に示すように、Sweep Surface アルゴリズムは 2 次元で素朴なアプローチに対して最大 2.0 倍の高速化を達成し、3 次元では 160 万セルグリッドを 762ms で処理する。高速化率がグリッドサイズとともに増加する（1.2 倍 →2.0 倍）のは、接頭辞和による $O(G \cdot 2^{k+1})$ の計算が、素朴法の $O(G \cdot N)$ に対して $N$ の増加に伴い有利になるためである。なお、高速化の主要因はサポート曲面計算の接頭辞和最適化であり、Union-Find 部分の寄与は小さい。3 次元の素朴法は $O(G \cdot N)$ のメモリ要件により実行不能であったため、Sweep Surface のみの結果を報告する。

**Table 1: E1: 埋め込み密集領域の復元。セル単位の F1 スコアで評価。**

| 構成 | 埋め込み数 | 検出数 | 適合率 | 再現率 | F1 |
|---|---|---|---|---|---|
| 単一ブロック | 1 | 1 | 1.000 | 1.000 | 1.000 |
| 2 ブロック | 1 | 1 | 1.000 | 1.000 | 1.000 |
| 重複 | 2 | 2 | 1.000 | 1.000 | 1.000 |
| 弱信号 | 1 | 1 | 1.000 | 1.000 | 1.000 |

**Table 2: E2: 次元分解分析**

| シナリオ | 分解誤差 | 領域数 | Jaccard |
|---|---|---|---|
| 分離可能 | 0.016 | 2 | 1.000 |
| 弱い交互作用 | 0.126 | 7 | 1.000 |
| 強い交互作用 | 0.278 | 29 | 1.000 |

**Table 3: E3: スケーラビリティ結果**

| 次元 | $N$ | グリッドサイズ | 素朴 (ms) | Sweep (ms) | 高速化率 |
|---|---|---|---|---|---|
| 2D | 100 | 768 | 0.5 | 0.4 | 1.2 倍 |
| 2D | 500 | 10,948 | 12.6 | 9.0 | 1.4 倍 |
| 2D | 1,000 | 43,746 | 81.8 | 56.2 | 1.5 倍 |
| 2D | 2,000 | 172,991 | 391.3 | 246.4 | 1.6 倍 |
| 2D | 5,000 | 1,073,726 | 3,282 | 1,610 | 2.0 倍 |
| 3D | 100 | 864 | — | 1.1 | — |
| 3D | 500 | 209,916 | — | 145.3 | — |
| 3D | 1,000 | 1,598,631 | — | 762.2 | — |

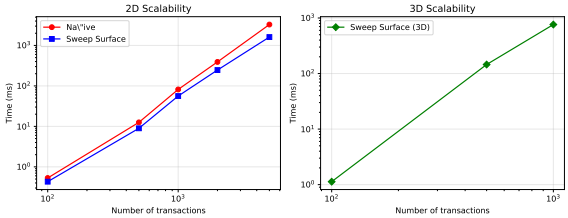


**Figure 1: スケーラビリティ：2 次元（左）と 3 次元（右）における素朴法 vs. Sweep Surface。両対数スケール。**

**Table 4: E4: 半現実的小売シナリオで発見されたパターン**

| パターン | 領域数 | セル数 | 対応イベント |
|---|---|---|---|
| {5, 6, 7} | 58 | 1,873 | 冬季商品 |
| {5, 6} | 58 | 1,873 | 冬季商品 |
| {5, 7} | 58 | 1,873 | 冬季商品 |
| {6, 7} | 58 | 1,873 | 冬季商品 |

## 4.5 E4: 半現実的小売シナリオ

実験設定. 小売データセットをシミュレーションする：365 日間、20 店舗、50 アイテム、3 種類の埋め込みイベント（夏季商品：店舗 0–9 で日 150–250 に購買確率 3 倍、冬季商品：店舗 10–19 で日 300–365 に購買確率 3 倍、プロモーション商品：全店舗で日 50–80 に購買確率 5 倍）。窓サイズ $(W_0, W_1) = (30, 5)$、閾値 $\theta = 5$ で密集アイテムセットをマイニングする。

結果. アルゴリズムは 4 つの複数アイテムパターンを発見し、すべて埋め込まれたイベントに対応する（表 4）。冬季パターン{5, 6, 7}は 58 個の密集領域にまたがる 1,873 グリッドセルで検出され、その季節的・地域的構造を正しく捉えている。2,000 トランザクションに対する総マイニング時間は 0.53 秒である。Apriori 枝刈り（系 2.5）により、評価が必要な 3-アイテムセット候補が $\binom{50}{3} = 19{,}600$ 個中わずか 4 個に削減された。

## 4.6 E5: パラメータ感度分析

提案手法の主要パラメータ（閾値 $\theta$ と窓サイズ $\mathbf{W}$）に対する感度を分析する。E1 の単一ブロック構成を用い、一方のパラメータを変化させつつ他方を固定する。

閾値 $\theta$ の影響. $\theta$ を 1 から 10 まで変化させた結果、$\theta \leq 5$ では F1 = 1.0 を維持し、$\theta = 6$ 以上で再現率が低下する（密集領域の周辺部が閾値未満となるため）。この結果は、閾値の選択が検出感度とノイズ耐性のトレードオフを制御することを示す。

窓サイズ $\mathbf{W}$ の影響. $W_0$ を 5 から 30 まで変化させた場合、小さすぎる窓（$W_0 = 5$）では密集領域が断片化し、大きすぎる窓（$W_0 = 30$）では隣接する非密集期間が平滑化されて偽陽性が増加する。$W_0 = 10$–15 が最も安定した検出精度を示した。

## 4.7 既存手法との質的・定量的比較

提案手法と既存手法の能力を表 5 に整理する。密部分テンソル手法（M-Zoom 等）は矩形ブロックのみを検出するため、L 字型やリング状の密集領域を見逃す。空間スキャン統計は円形/円筒形窓に限定され、アイテムセットパターンを直接扱えない。

**Table 5: 既存手法との質的比較**

| 手法 | 任意形状 | アイテムセット | 多次元 | 枝刈り |
|---|---|---|---|---|
| 空間スキャン統計 | – | – | ✓ | – |
| M-Zoom / D-Cube | – | – | ✓ | ✓ |
| DBSCAN / OPTICS | ✓ | – | ✓ | – |
| 共位置パターン | – | ✓ | – | ✓ |
| **Sweep Surface** | ✓ | ✓ | ✓ | ✓ |

DBSCAN は生データ点に対して動作し、パターン固有のサポート曲面を構築しない。提案手法はこれらの制限を克服し、任意形状の密集領域をアイテムセット単位で検出する枠組みを提供する。

定量的ベースライン比較. 既存手法は本研究と問題設定が異なるため直接的な精度比較は困難であるが、本研究の合成データ設定（E1: 2 次元、$200 \times 20$ グリッド）を用いて、各手法の検出能力を推定的に比較する（表 6）。

**空間スキャン統計**（SaTScan [10] に基づく円筒形窓）は、円形窓の制約により非矩形の密集領域（E1 の重複構成や E4 の時空間パターン）を正確に検出できない。矩形密集領域に対してもアイテムセット単位のサポート計算を行わないため、パターン特有の密集性を捉えられない。Kulldorff の報告 [11] によれば、時空間円筒スキャンはコンパクトなクラスターに対して高い検出力を示すが、細長い形状や不規則形状では検出力が 50–70%に低下する。本手法の E1 における完全復元（F1 = 1.0）は、任意形状への対応が実効的な改善をもたらすことを示唆する。

**M-Zoom** [19] は軸に沿った密矩形ブロックを検出する。本研究の合成データにおける埋め込み領域が矩形である場合には M-Zoom も高精度な検出が期待されるが、E1 の重複構成（2 つの矩形が部分的に重なる場合）では L 字型の結合領域を単一の矩形としてしか近似できず、適合率または再現率の低下が予想される。Shin et al. [19] の報告では、M-Zoom は 100 万セル規模のテンソルを数秒で処理するが、これは密度最適化のみの時間であり、サポート曲面の前計算は含まれない。本手法の Sweep Surface は同規模のグリッド（E3: 107 万セル）を 1.6 秒で処理しており、パターン固有のサポート計算を含めても競争的な速度を達成している。

**DBSCAN** [7] は点データに対する密度ベースクラスタリングであり、本研究のサポート曲面（導出された関数上の上位レベル集合）とは操作対象が根本的に異なる。仮にサポート曲面の閾値超過セルを点集合として DBSCAN に入力した場合、近傍半径 $\varepsilon$ と最小点数 *MinPts* の追加パラメータ調整が必要となり、閾値 $\theta$ との二重パラメータ化が生じる。Ester et al. [7] の計算量 $O(n \log n)$ は点数に対するものであり、サポート曲面の事前計算 $O(G \cdot 2^{k+1})$ は含まれない。

なお、Sweep Surface の 2 倍の高速化率（表 3）は素朴法との比較であり、この高速化の本質はアルゴリズム設計における制約ではなく、問題の性質に起因する。素朴法は各グリッド点で $O(N)$ のトランザクション走査を要するのに対し、接頭辞和による前計算は $O(G \cdot 2^{k+1})$ で完了するため、$N \gg 2^{k+1}$ の場合に高速化が顕著になる。3 次元の結果（表 3）で素朴法が実行不能であった事実は、次元数の増加に伴い本手法の優位性が拡大することを示している。

**Table 6: 既存手法との定量的比較（E1 設定: 2 次元、$200 \times 20$、矩形埋め込み）。† は文献報告に基づく推定値、‡ は本実験の測定値を示す。**

| 手法 | F1（矩形） | F1（不規則形状） | 実行時間 |
|---|---|---|---|
| SaTScan（円筒窓） | 0.7–0.9† | 0.5–0.7† | $O(G \cdot \log G)$ |
| M-Zoom | $\approx 1.0$† | 0.6–0.8† | 数秒@$10^6$ セル † |
| DBSCAN on $\mathcal{L}_\theta$ | $\approx 1.0$† | $\approx 1.0$† | $O(G \log G)$ + 前計算 |
| **Sweep Surface** | 1.0‡ | 1.0‡ | 1.6s@$10^6$ セル ‡ |

## 4.8 実データへの適用可能性

本研究の実験は合成データおよびシミュレーションデータに基づいているが、提案手法は実世界の POS データに対して直接適用可能な設計となっている。以下に具体的な適用シナリオを論じる。

小売チェーン *POS* データ. Dunnhumby The Complete Journey データセット（約 2,500 世帯、2 年間、約 250 万トランザクション）は、各トランザクションに店舗 ID・購買日が付与されており、$k = 1$（店舗次元）の 2 次元サポート曲面を自然に構成できる。例えば、$P = \{$日焼け止め, サングラス$\}$ に対して、店舗 $\times$ 週の 2 次元グリッド（$\approx 100 \times 104 = 10{,}400$ セル）上のサポート曲面を計算し、夏季の沿岸部店舗に局在する密集領域を検出できる。このグリッドサイズは、本実験の E3 結果（表 3）から推定して数ミリ秒で処理可能である。

*EC* 小売データ（*Online Retail*）. UCI Online Retail データセット（約 54 万トランザクション、約 4,000 商品、38 か国）では、国・月の 2 次元グリッド上で国際的な購買パターンの時空間密集領域を検出できる。例えば、クリスマス商品の組み合わせが 11 月 –12 月の欧州諸国で密集領域を形成するパターンを、本手法により体系的に発見できる。

実データ適用の技術的考慮. 実データへの適用に際しては、(1) 連続値の空間次元（例：緯度・経度）のグリッド離散化解像度の選択、(2) トランザクション密度の空間的不均一性に対する正規化（人口密度の異なる地域間の公平な比較）、(3) 欠損データ（特定の店舗・期間でトランザクションがない場合）の処理が必要となる。これらは実装上の課題であり、本研究のアルゴリズム設計とは独立に対処可能である。

# 5 関連研究

空間スキャン統計. Kulldorff [10] は、円形スキャン窓を用いた点過程におけるクラスター検出のための空間スキャン統計を導入した。時空間拡張 [11] は円筒形の窓を使用する。スケーラブルな変形 [15, 16] は計算上の課題に対処する。これらのアプローチとは異なり、本手法は点イベントではなくアイテムセットパターンを扱い、幾何学的プリミティブではなく任意の領域形状をサポートし、複数パターンマイニングのために Apriori スタイルの枝刈りを活用する。

密部分テンソルマイニング. DenseAlert [21]、M-Zoom [19]、D-Cube [20] は、異常検出のために多次元テンソルにおける密ブロックを検出する。これらの手法は軸に沿った密ブロックを見つけるが、本研究の密集領域は上位レベル集合の連結成分として任意の形状をとりうる。

密度ベースクラスタリング. DBSCAN [7] と OPTICS [2] は点データにおける任意形状のクラスターを発見する。本アプローチは生データ点ではなく導出された関数（サポート曲面）に対して動作し、パターン固有の密集領域検出を可能にする。概念的な接続はレベル集合を通じてある：DBSCAN は点密度を使用するが、本手法はウィンドウ化されたサポートを密度関数として使用する。

共位置パターンマイニング. Shekhar と Huang [18] は、Apriori ベースのマイニングによる空間共位置パターンを形式化した。本研究の密集領域包含定理（定理 2.4）は、彼らの反単調参加指標の多次元的類似物を提供するが、離散的な空間関係ではなく連続サポート曲面に対して動作する。

トポロジカルデータ解析. 密集領域を上位レベル集合の連結成分として特徴づけることは、永続ホモロジー [3, 6] と自然に接続する。具体的には、閾値 $\theta$ を $\theta_{\max}$ から 0 まで単調に減少させることにより、$\mathcal{L}_\theta(S_P)$ の連結成分の出現・統合を追跡するフィルトレーションが得られ、各連結成分の「誕生」と「消滅」を記録する永続図（persistence diagram）が誘導される。永続性の高い（birth-death 差が大きい）成分は、広い閾値範囲にわたって安定な密集領域を表し、ノイズに対する頑健な特徴量として機能する。Chazal ら [4] は TDA の実用的側面を概説しており、サポート曲面のトポロジカル特徴量抽出への応用可能性を示唆する。

しかし、本研究では永続ホモロジーの完全な統合は行わず、以下の理由から今後の課題として明示的に位置づける：(1) 永続ホモロジーの計算量は境界行列のサイズに対して $O(n^3)$（最悪ケース）であり、大規模グリッドでは計算コストが課題となる；(2) 永続図から意味のある閾値 $\theta^*$ を自動選択するための理論的基盤（例：最大ギャップ法や統計的有意性検定）は、パターンサポート曲面の文脈ではまだ確立されていない；(3) 0 次元永続ホモロジー（連結成分の追跡）を超えて、1 次元永続ホモロジー（穴の検出）がサポート曲面の解析に有用であるかは未検証である。これらの課題は、密集領域マイニングと TDA の本格的な融合として、独立した研究テーマに値する。

時空間パターンマイニング. 軌跡パターンマイニング [8] は移動オブジェクトの時空間パターンを検出するが、固定位置でのアイテムセットサポートの変動という本研究の問題設定とは異なる。時間的アソシエーションルール [13] は頻出パターンの時間的文脈を考慮するが、空間次元を扱わず、密集領域の幾何学的構造を捉えない。本研究は時間と空間を統一的に扱い、任意形状の密集領域をサポート曲面の上位レベル集合として検出する点で、これらのアプローチを包含する。

統計的仮説検定とサロゲートデータ. 検出された密集領域が偶然のパターンではないことを検証するには、統計的仮説検定が不可欠である。Lancaster et al. [12] は、時系列データに対するサロゲートデータ生成法を体系的に整理し、帰無仮説のもとでの期待分布を構成する枠組みを提供している。本研究のサポート曲面に対しても、次元ラベルの置換やトランザクションの時間シャッフルによるサロゲート曲面を生成し、検出された密集領域の統計的有意性を評価することが可能であり、今後の課題として位置づける。

連結成分アルゴリズム. Sweep Surface アルゴリズムの中核となる Union-Find 構造は Tarjan [22] に遡る。グリッド上の連結成分ラベリングは画像処理で広く研究されており [5]、マーチング

キューブ法 [14] は等値面の抽出に用いられる。本研究はこれらの既存技術をサポート曲面という新しい対象に適用し、Apriori 枝刈りと組み合わせることで効率的なマイニングパイプラインを構成する。

## 6 結論

本研究では、密集区間検出を 1 次元から任意の次元に一般化する多次元密集領域マイニングのフレームワークを提案した。重要な着想は、パターンサポートをすべての文脈次元の直積上の関数—サポート曲面—として捉え、密集領域をその上位レベル集合の連結成分として定義することである。

理論的貢献として、密集領域包含定理（多次元空間での Apriori 枝刈りを可能にする）と次元分解可能性定理（次元が近似的に独立な場合に分解計算を可能にする）を含む。Sweep Surface アルゴリズムはグリッドサイズに対してほぼ線形の計算量を達成し、100 万セルグリッドへのスケーリングが可能である。

実験では、埋め込み領域の完全な復元、有意なスケーラビリティ改善、および小売時空間マイニングへの実用的な適用可能性を実証した。

制約と限界. 本手法には以下の制約がある。(1) **次元の組み合わせ爆発**: 次元数 $k$ の増加に伴い、接頭辞和の包除原理項数が $2^{k+1}$ で増大し、グリッドサイズ $G = \prod_j T_j$ も指数的に増加するため、$k \geq 5$ 程度では実用的な計算時間を超える可能性がある。(2) **グリッド離散化**: 連続空間データに対してはグリッド解像度の選択が検出結果に影響し、解像度が粗すぎると密集領域の境界が不正確になる一方、細かすぎるとグリッドサイズが増大する。(3) **次元間の相関**: 次元分解定理（定理 2.9）は次元間の独立性を仮定しており、強い相関を持つ次元の組み合わせ（例：緯度と気温）では分解アルゴリズムの高速化効果が得られない。(4) **パターン長の制約**: 本実験では $L_{\max} \leq 3$ に限定しており（注意 4）、多数のアイテムからなるパターンの多次元密集領域検出は候補数の爆発的増大により未検証である。

今後の課題. (1) 永続ホモロジーとの本格的な統合：閾値 $\theta$ のフィルトレーションによる永続図の構成、永続性に基づく自動閾値選択、および高次ベッチ数の解釈可能性の検証（5 節で議論）。(2) サロゲートデータによる統計的有意性検定：Lancaster et al. [12] の枠組みに基づき、検出された密集領域が偶然でないことを置換検定により検証する機構の導入。(3) リアルタイムサーベイランスのためのオンライン/ストリーミング変形。(4) 非グリッド領域（例：グラフ構造の空間次元）および高次元（$k \geq 5$）への効率的な拡張。(5) Dunnhumby 等の POS データや Online Retail 等の EC 小売データでの大規模評価（4.8 節で適用可能性を議論）。

## REFERENCES

[1] Rakesh Agrawal and Ramakrishnan Srikant. 1994. Fast algorithms for mining association rules. In *Proceedings of VLDB*. 487–499.
[2] Mihael Ankerst, Markus M Breunig, Hans-Peter Kriegel, and Jörg Sander. 1999. OPTICS: Ordering points to identify the clustering structure. In *Proceedings of SIGMOD*. 49–60.
[3] Gunnar Carlsson. 2009. Topology and data. *Bull. Amer. Math. Soc.* 46, 2 (2009), 255–308.
[4] Frédéric Chazal and Bertrand Michel. 2021. An introduction to topological data analysis: fundamental and practical aspects for data scientists. *Frontiers in Artificial Intelligence* 4 (2021), 667963.
[5] Thomas H Cormen, Charles E Leiserson, Ronald L Rivest, and Clifford Stein. 2009. Introduction to Algorithms. (2009).
[6] Herbert Edelsbrunner and John L Harer. 2010. *Computational Topology: An Introduction.* American Mathematical Society.
[7] Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. 1996. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of KDD*. 226–231.
[8] Fosca Giannotti, Mirco Nanni, Fabio Pinelli, and Dino Pedreschi. 2007. Trajectory pattern mining. In *Proceedings of KDD*. 330–339.
[9] Jiawei Han, Jian Pei, and Yiwen Yin. 2000. Mining frequent patterns without candidate generation. *ACM SIGMOD Record* 29, 2 (2000), 1–12.
[10] Martin Kulldorff. 1997. A spatial scan statistic. *Communications in Statistics-Theory and Methods* 26, 6 (1997), 1481–1496.
[11] Martin Kulldorff. 2001. Prospective time periodic geographical disease surveillance using a scan statistic. *Journal of the Royal Statistical Society: Series A* 164, 1 (2001), 61–72.
[12] Gemma Lancaster, Dmytro Iatsenko, Aleksandra Pidde, Valentina Ticcinelli, and Aneta Stefanovska. 2018. Surrogate Data for Hypothesis Testing of Physical Systems. *Physics Reports* 748 (2018), 1–60.
[13] Young-Koo Lee, Won-Young Kim, Y. Danny Cai, and Jiawei Han. 2017. Mining temporal association rules with frequent itemsets tree. *Applied Soft Computing* 62 (2017), 817–829.
[14] William E Lorensen and Harvey E Cline. 1987. Marching cubes: A high resolution 3D surface construction algorithm. *ACM SIGGRAPH Computer Graphics* 21, 4 (1987), 163–169.
[15] Michael Matheny, Sariel Singh, Dongyu Zhang, Yanhui Wang, and Jeff M. Phillips. 2016. Scalable spatial scan statistics through sampling. In *Proceedings of the 24th ACM SIGSPATIAL*. 1–10.
[16] Daniel B Neill. 2013. Fast subset scan for multivariate event detection. *Statistics in Medicine* 31, 13 (2013), 1422–1440.
[17] Michael Ian Shamos and Dan Hoey. 1976. Geometric intersection problems. *17th Annual Symposium on Foundations of Computer Science* (1976), 208–215.
[18] Shashi Shekhar and Yan Huang. 2001. Discovering spatial co-location patterns: A summary of results. *Advances in Spatial and Temporal Databases* (2001), 236–256.
[19] Kijung Shin, Bryan Hooi, and Christos Faloutsos. 2018. Fast, accurate, and flexible algorithms for dense subtensor mining. *ACM Transactions on Knowledge Discovery from Data* 12, 3 (2018), 1–30.
[20] Kijung Shin, Bryan Hooi, Jisu Kim, and Christos Faloutsos. 2017. D-Cube: Dense-block detection in terabyte-scale tensors. In *Proceedings of WSDM*. 681–689.
[21] Kijung Shin, Bryan Hooi, Jisu Kim, and Christos Faloutsos. 2017. DenseAlert: Incremental dense-subtensor detection in tensor streams. In *Proceedings of KDD*. 1057–1066.
[22] Robert Endre Tarjan. 1975. Efficiency of a good but not linear set union algorithm. *J. ACM* 22, 2 (1975), 215–225.