どの地域で・いつ・なぜパターン頻度が変わったか？ — サポート曲面による時空間イベント帰属 —

Anonymous Author(s)
Anonymous Institution

ABSTRACT

頻出パターンマイニングにおけるイベント帰属は、パターンのサポート変動を外部イベント（キャンペーン・祝日等）に結びつける技術である。既存手法は時間軸のみを扱い、「どの地域でイベントがパターン変動を引き起こしたか」には答えられない。しかし現実には、キャンペーンの効果は特定の地域・店舗に局在することが多く、空間情報の欠如は帰属の精度と実用性を制限する。

本稿では、1 次元のサポート時系列を多次元に拡張したサポート曲面上でイベント帰属を行う**時空間イベント帰属パイプライン**を提案する。技術的貢献は以下の 3 点である：(1) サポート曲面上の各空間位置で閾値交差変化点を検出し、時間的近接度・空間的近接度・変化量の 3 要素から成る時空間帰属スコアを定義する。(2) 時間軸の円形シフトと空間構造の保存を両立する時空間置換検定を設計し、空間自己相関下でも第一種過誤率を制御する。(3) パターン × イベントの全仮説にわたるグローバル BH 補正と Union-Find によるアイテム重複排除を適用し、偽発見率を制御する。

合成データ実験では、十分な信号強度（$\beta \geq 0.3$）において 1 次元パイプラインに対し F1 を最大+0.40 改善し（$\beta = 0.5$ で $F1 = 1.000$）、精度（Precision）は常に 0.80 以上を維持する。空間的に交絡するパターンの偽帰属率を 1 次元の 0.80 から 0.20 に低減する。半現実的小売データ（20 店舗 ×3 キャンペーン）では、提案手法が $F1 = 1.000$ で全キャンペーンを正しく帰属する（1 次元は $F1 = 0.286$）。

KEYWORDS

時空間イベント帰属, サポート曲面, 頻出パターンマイニング, 置換検定, 多重検定補正, 空間自己相関

1 はじめに

頻出パターンマイニング [1, 6] はトランザクションデータ中に繰り返し出現するアイテムセットを発見する基盤技術である。近年、パターンの出現頻度（サポート）がなぜ変動するかを外部イベントに帰属させるフレームワークが提案されている [2]。このイベント帰属パイプラインは、サポート時系列上の変化点を検出し、変化点とイベントの時間的近接度・変化量に基づくスコアリング、円形シフト置換検定、BH 補正、Union-Find 重複排除の 5 ステップで構成される。

しかし、既存のイベント帰属パイプラインは**時間軸のみ**を扱う。現実のデータは空間的位置（店舗、地域、国）などの補助次元を持つことが多く、イベントの効果は空間的に局在する。例えば：

- 小売チェーンの夏季キャンペーンは沿岸部店舗でのみ売上を押し上げる。
- 新規制の導入は特定の州・県でのみ処方パターンを変化させる。
- オンラインプロモーションは特定の国・地域からのアクセスパターンに影響する。

1 次元パイプラインでこれらを扱うと、2 つの問題が生じる。第一に、全空間にわたってサポートを集約するため、局所的なイベント効果が**希釈**されて検出力が低下する。第二に、イベントの空間的影響範囲が不明なまま帰属が行われるため、「どの地域で効果があったか」という問いに答えられない。

これらの問題を解決するには、サポートの時間的変動だけでなく空間的分布を同時にモデル化し、イベントの時空間的スコープとの関連を検定する必要がある。しかし、多次元化は以下の技術的課題を伴う：

(1) **空間自己相関**：近接する空間位置のサポート時系列は正に相関する。1 次元パイプラインの円形シフト置換検定は空間構造を無視するため、空間的にクラスター化した変化点に対して偽陽性が増加する。
(2) **仮説空間の増大**：パターン × イベントに空間次元が加わり、多重検定の補正がより厳格になる必要がある。
(3) **信号の空間的局在**：イベント効果が一部の空間領域に限られる場合、空間全体の集約サポートでは信号対雑音比が低下する。

1.1 本研究の貢献

本稿では、1 次元イベント帰属パイプラインを多次元に拡張する**時空間イベント帰属パイプライン**を提案する。貢献は以下の 3 点である。

(1) **時空間帰属スコア**（2 節）：サポート曲面上の各空間位置で変化点を検出し、時間的近接度 prox_t・空間的近接度 prox_s・変化量 mag の 3 要素から帰属スコアを定義する。空間的近接度はイベントの空間スコープとの距離に基づく指数減衰カーネルであり、局所的イベント効果の検出を可能にする。
(2) **時空間置換検定**（3 節）：全イベントの時刻を円形シフトしつつ空間スコープを保存する置換方式を設計する。これにより空間自己相関構造を保ったまま帰無分布を生成し、第一種過誤率を正しく制御する。
(3) **包括的な実験評価**（4 節）：(i) 空間的に局在するイベント効果の検出、(ii) 1 次元パイプラインとの比較、(iii) イベント非対応パターンの偽帰属率制御を実証する。

2 問題定義

2.1 記法

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ を有限のアイテム集合とする。$D = [d_1, d_2, \ldots, d_N]$ を時間インデックス $t \in \{1, \ldots, N\}$ で順序付けられたトランザクション列とする。各トランザクション $d_t \subseteq \mathcal{I}$ はアイテムの集合である。k 個の補助次元（空間座標、店舗 ID 等）を考え、各次元は有限定義域 $\mathcal{X}_j$ の値をとる。各トランザクション d_t は位置 $\mathbf{x}(t) = (x_1(t), \ldots, x_k(t)) \in \mathcal{X} = \prod_j \mathcal{X}_j$ に関連付けられる。

2.2 サポート曲面

Definition 2.1 (多次元サポート曲面). パターン P、時間窓 W_0、空間窓 W_j $(j = 1, \ldots, k)$ に対し、P のサポート曲面 $S_P : \mathbb{Z}^{k+1} \to \mathbb{Z}_{\geq 0}$ を

$$S_P(t, \mathbf{v}) = \left|\{d_r \in D \mid t \leq r < t + W_0,\ P \subseteq d_r,\ \mathbf{x}(r) \in \mathrm{Box}(\mathbf{v}, \mathbf{W})\}\right| \tag{1}$$

と定義する。$k = 0$ のとき標準的な 1 次元サポート時系列に帰着する。

2.3 外部イベントの時空間拡張

1 次元設定のイベント $e = (id, name, t_s, t_e)$ を時空間に拡張する。

Definition 2.2 (時空間外部イベント). 時空間外部イベント $e = (id, name, t_s, t_e, \mathcal{V}_e)$ は、識別子、名称、時間区間 $[t_s, t_e]$、および空間スコープ $\mathcal{V}_e \subseteq \mathcal{X}$（イベントが影響を及ぼす空間領域）から成る。$\mathcal{V}_e = \mathcal{X}$（全域）のとき、1 次元設定のイベント定義に帰着する。イベント集合を $\mathcal{E} = \{e_1, \ldots, e_K\}$ とする。

例 1. スーパーマーケットチェーンにおいて、「渋谷・新宿エリア限定 夏季キャンペーン」は $e = (C01, 夏季, 150, 250, \{渋谷, 新宿\})$ と表現される。このイベントは店舗次元で { 渋谷, 新宿 }、時間区間 $[150, 250]$ にのみ影響する。

2.4 時空間変化点

1 次元設定では変化点は閾値交差の時刻 τ として定義される。多次元設定では、変化点に空間的位置が付随する。

Definition 2.3 (位置条件付きサポート時系列). 空間位置 $\mathbf{v} \in \mathcal{X}$ における位置条件付きサポート時系列は $s_P^{\mathbf{v}}(t) = S_P(t, \mathbf{v})$ であり、サポート曲面を空間位置 $\mathbf{v}$ で切り出した 1 次元時系列である。

Definition 2.4 (時空間変化点). 位置 $\mathbf{v}$ において、$s_P^{\mathbf{v}}$ の閾値 θ に関する上昇交差時刻 τ を時空間変化点 $(\tau, \mathbf{v})$ と呼ぶ。すなわち、$s_P^{\mathbf{v}}(\tau) \geq \theta$ かつ ($\tau = 0$ または $s_P^{\mathbf{v}}(\tau - 1) < \theta$) が成立する。下降交差も同様に定義する。パターン P の時空間変化点の集合を $C_P = \{(\tau_i, \mathbf{v}_i, dir_i)\}$ と表す。

注意 1 (変化領域). 同一パターンが近い時刻に複数の空間位置で変化点を持つとき、これらは空間的に一貫した変化を表す。変化点集合 $\{(\tau_i, \mathbf{v}_i)\}$ のうち時間的に近い（$|\tau_i - \tau_j| \leq \delta_t$）かつ空間的に隣接する点の連結成分を変化領域と呼ぶ。変化領域は「いつ・どこで変化が起きたか」を空間解像度で記述する。

2.5 時空間帰属スコア

Definition 2.5 (時空間帰属スコア). パターン P の時空間変化点 $(\tau, \mathbf{v})$ とイベント e に対し、時空間帰属スコアを

$$A(P, \tau, \mathbf{v}, e) = \mathrm{prox}_t(\tau, e) \cdot \mathrm{prox}_s(\mathbf{v}, e) \cdot \mathrm{mag}(\tau, \mathbf{v}) \tag{2}$$

と定義する。3 つの構成要素は以下の通りである。

時間的近接度:

$$\mathrm{prox}_t(\tau, e) = \exp\left(-\frac{\min(|\tau - t_s|, |\tau - t_e|)}{\sigma_t}\right) \tag{3}$$

空間的近接度:

$$\mathrm{prox}_s(\mathbf{v}, e) = \begin{cases} 1 & \text{if } \mathbf{v} \in \mathcal{V}_e \\ \exp\left(-\frac{d_s(\mathbf{v}, \mathcal{V}_e)}{\sigma_s}\right) & \text{otherwise} \end{cases} \tag{4}$$

ここで $d_s(\mathbf{v}, \mathcal{V}_e) = \min_{\mathbf{u} \in \mathcal{V}_e} \|\mathbf{v} - \mathbf{u}\|_1$ はイベント空間スコープまでの L_1 距離である。

変化量:

$$\mathrm{mag}(\tau, \mathbf{v}) = |\bar{s}^+(\tau, \mathbf{v}) - \bar{s}^-(\tau, \mathbf{v})| \tag{5}$$

$\bar{s}^{\pm}$ は変化点前後の局所平均サポートである（1 次元設定と同じ定義を各位置で適用）。

注意 2 (1 次元設定への帰着). $k = 0$（空間次元なし）かつ $\mathcal{V}_e = \mathcal{X}$ のとき、$\mathrm{prox}_s \equiv 1$ となり、式 (2) は *1* 次元パイプラインのスコア $A = \mathrm{prox}_t \cdot \mathrm{mag}$ に帰着する。

パターン P のイベント e に対する観測帰属スコアは、全変化点にわたる総和とする：

$$A_{\mathrm{obs}}(P, e) = \sum_{(\tau, \mathbf{v}) \in C_P} A(P, \tau, \mathbf{v}, e). \tag{6}$$

2.6 時空間イベント帰属問題

問題 1 (時空間イベント帰属). **入力**：位置付きトランザクション列 D、窓サイズ $(W_0, \mathbf{W})$、閾値 θ、最大パターン長 $L_{\max}$、時空間イベント集合 $\mathcal{E}$、有意水準 α。

出力：$s_P^{\mathbf{v}}$ の閾値交差変化点がイベント e の時間窓および空間スコープと統計的に有意に関連する全ての組 (P, e) を、偽発見率（*FDR*）を水準 α 以下に制御しながら同定する。

本問題の主要な課題は以下の 4 点である：

(1) **仮説空間の爆発**：$|\mathcal{F}| \times |\mathcal{E}|$ 個のパターン – イベント対に加え、各対が複数の空間位置で独立に帰属しうるため、多重検定の負荷が 1 次元設定より大きい。
(2) **空間自己相関**：近接する空間位置のサポート時系列は正に相関するため、変化点が空間的にクラスター化し、独立性仮定に基づく検定は過度に楽観的になる。
(3) **副次パターン問題**：1 次元設定と同様、アイテムを共有するパターン間でサポートが連動変動する。
(4) **イベントの空間的部分影響**：イベントが一部の空間領域にのみ影響する場合、全域で集約したサポートでは信号が希釈される（空間的混同）。

3 提案手法

問題 1 を解くための**時空間イベント帰属パイプライン**を提案する。パイプラインは以下の 6 ステップから成る（図 1）。

3.1 Step 1: サポート曲面の計算

各パターン P $(|P| \geq 2)$ に対し、接頭辞和に基づく $O(G \cdot 2^{k+1} + N)$ のアルゴリズムでサポート曲面 S_P を計算する。

$(k+1)$ 次元の指示配列 $I[t, \mathbf{x}(t)]$（パターンを含むトランザクション数）を構築し、各次元に沿って接頭辞和を取った後、2^{k+1} 個の角に対する包除原理により任意のグリッド点でのウィンドウ合計を求める。

候補パターンの枝刈り. 以下の密集領域包含定理を用いて候補を削減する：パターン P の任意の $(|P| - 1)$-部分集合 Q に対して $\mathcal{L}_\theta(S_P) \subseteq \mathcal{L}_\theta(S_Q)$ が成立するため、Q に密集領域がなければ P も密集領域を持たない（Apriori 枝刈り）。

3.2 Step 2: 位置別変化点の検出

サポート曲面の各空間スライス $s_P^{\mathbf{v}}(t) = S_P(t, \mathbf{v})$ に対して、1 次元パイプラインと同じ閾値交差法で変化点を検出する。各変化

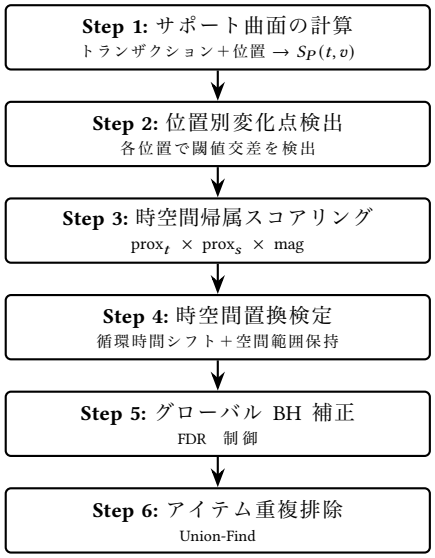

Figure 1: 提案する時空間イベント帰属パイプラインの全体構成。6 段のステップにより、サポート曲面の計算から有意な帰属結果の出力までを一貫して処理する。

点 $(\tau, \mathbf{v})$ に対し、局所平均 $s^{\pm}(\tau, \mathbf{v})$ から変化量 $\mathrm{mag}(\tau, \mathbf{v})$ を計算する。

フィルタリング. 仮説空間削減のため以下のフィルタを適用する：

- サポート振幅フィルタ: $\max_t s_P^{\mathbf{v}}(t) - \min_t s_P^{\mathbf{v}}(t) < \delta$ の位置を除外。
- 変化量フィルタ: $\mathrm{mag}(\tau, \mathbf{v}) < \mu_{\min}$ の変化点を除外。

3.3 Step 3: 時空間帰属スコアリング

各パターン P、変化点 $(\tau, \mathbf{v})$、イベント e に対し、式 (2) の時空間帰属スコアを計算する：

$$A(P, \tau, \mathbf{v}, e) = \mathrm{prox}_t(\tau, e) \cdot \mathrm{prox}_s(\mathbf{v}, e) \cdot \mathrm{mag}(\tau, \mathbf{v}).$$

パターン P とイベント e の観測スコア $A_{\mathrm{obs}}(P, e)$ は全変化点にわたる総和である（式 (6)）。この集約は、イベントの空間スコープ内にある変化点ほど高い prox_s を持つため、空間的に局在するイベント効果を自動的に強調する。

3.4 Step 4: 時空間置換検定

3.4.1 設計原理. 帰無仮説 H_0:「変化点の時空間位置はイベントと無関係である」を検定するために、イベントの時刻をランダムにシフトする置換を行う。1 次元パイプラインの円形シフト（時刻のみランダム化）を時空間に拡張する際、以下の設計判断を行う：

- **時間軸**：円形シフト（オフセット $\delta \sim \mathrm{Uniform}\{1, \ldots, T-1\}$）。これにより時間的自己相関構造が保存される。
- **空間軸**：イベントの空間スコープ $\mathcal{V}_e$ を**固定**する。空間スコープは外生的に与えられた既知情報であり、ランダム化の対象ではない。

この「時間シフト・空間固定」方式は、帰無仮説を「イベントの時刻が変化点と無関係」と定式化することに対応する。空間スコープの一致は帰無仮説下でも保持されるため、空間的近接度 prox_s は置換を通じて同一の値をとり、検定は時間的近接度 prox_t と変化量 mag の偶然の一致を評価する。

3.4.2 置換アルゴリズム. B 回の置換を実行する。各置換 b では：

(1) ランダムオフセット $\delta_b \sim \mathrm{Uniform}\{1, \ldots, T-1\}$ を生成。
(2) 全イベントの時刻を一斉にシフト：$t_s^{(b)} = (t_s + \delta_b) \bmod T$, $t_e^{(b)} = (t_s^{(b)} + \Delta) \bmod T$。空間スコープ $\mathcal{V}_e$ は不変。
(3) シフト後のイベントで帰属スコア $A_{\mathrm{perm}}^{(b)}(P, e)$ を再計算。

未補正 p 値：

$$p_{\mathrm{raw}}(P, e) = \frac{1 + |\{b : A_{\mathrm{perm}}^{(b)}(P, e) \geq A_{\mathrm{obs}}(P, e)\}|}{B + 1}. \tag{7}$$

注意 3 (空間自己相関の処理). 空間スコープを固定する方式により、空間自己相関は帰無分布の生成にそのまま反映される。すなわち、置換スコア $A_{\mathrm{perm}}^{(b)}$ も観測スコアと同じ空間的相関構造を持つ。これは *1* 次元パイプラインで時間的自己相関を円形シフトにより保存するのと同じ原理（サロゲートデータ法 *[9]*）に基づく。

3.5 Step 5: グローバル BH 補正

$M = |\mathcal{F}'| \times |\mathcal{E}|$ 個の仮説を同時に検定する。未補正 p 値を昇順にソートし $p_{(1)} \leq \cdots \leq p_{(M)}$ とする。Benjamini–Hochberg [3] の step-down 手続きにより調整済み p 値を計算する：

$$\tilde{p}_{(i)} = \min\left(\tilde{p}_{(i+1)},\ \min\left(1,\ p_{(i)} \cdot \frac{M}{i}\right)\right), \quad \tilde{p}_{(M)} = \min(1, p_{(M)}). \tag{8}$$

$\tilde{p}_{(i)} < \alpha$ の仮説を棄却（帰属が有意）と判定する。

注意 4 (PRDS 条件). アイテムを共有するパターンのサポートは正に相関するため、p 値は部分集合上の正回帰依存性（*PRDS*）条件を満たし、*BH* 手続きによる *FDR* 制御は非独立な場合にも有効である *[4]*。

3.6 Step 6: アイテム重複排除

1 次元パイプラインと同様に、副次パターン問題を Union-Find クラスタリングにより解決する。各イベント e について有意帰属されたパターンを収集し、アイテムを共有するパターン間にエッジを張った共有グラフの連結成分を求め、各成分内で帰属スコア最大のパターンのみを残す。

3.7 計算量分析

パイプライン全体の時間計算量は以下の通りである：

- **Step 1**（サポート曲面）: $O(|\mathcal{F}| \cdot (G \cdot 2^{k+1} + N))$
- **Step 2**（変化点検出）: $O(|\mathcal{F}| \cdot G)$（各グリッド点を 1 回走査）
- **Step 3–4**（帰属＋置換検定）: $O(|\mathcal{F}'| \cdot |\mathcal{E}| \cdot B \cdot |\mathcal{C}_P|)$
- **Step 5–6**（BH ＋重複排除）: $O(M \log M + R \cdot k_{\max})$

ここで $G = \prod_j T_j$ はグリッドサイズ、B は置換回数、$|\mathcal{C}_P|$ は平均変化点数、R は有意結果数、$k_{\max}$ はパターン最大長である。

Step 1 が支配的であり、パターン数とグリッドサイズに線形にスケールする。サポート振幅フィルタにより $|\mathcal{F}'| \ll |\mathcal{F}|$ となるため、Step 3–4 の計算量は実用上小さい。

Table 1: EX1: コア帰属精度（5 シード平均）。P = Precision, R = Recall, FAR = 偽帰属率。

	ST（提案手法）				1D（ベースライン）				
条件	F1	P	R	FAR	F1	P	R	FAR	ΔF1
β=0.1	.27	.40	.20	.00	.71	.77	.70	.00	−.45
β=0.2	.60	.80	.50	.00	.64	.60	.70	.00	−.04
β=0.3	.60	.80	.50	.00	.58	.57	.60	.00	+.02
β=0.5	**1.00**	**1.00**	**1.00**	.00	.60	.60	.60	.00	**+.40**
CONFOUND	.33	.30	.40	**.20**	.40	.30	.60	.80	−.07
DENSE	.40	.60	.33	.00	.78	.77	.80	.00	−.38

4 実験

以下の実験を通じて提案手法を評価する。

RQ1: 空間的に局在するイベント効果を正しく帰属できるか？ **RQ2**: 1 次元パイプラインに対してどの程度改善するか？ **RQ3**: イベント非対応の密集パターンを棄却できるか？ **RQ4**: 主要パラメータに対する頑健性は？ **RQ5**: 半現実的データで意味のある結果を生成できるか？

4.1 実験環境

すべての実験は Python 3.13、NumPy 1.26 上で実行した。ハードウェアは Apple M3（8 コア、24GB RAM）である。デフォルトパラメータ：$W = 200$（ウィンドウ幅）、$\theta = 3$（サポート閾値）、$\sigma_t = W/4 = 50$、$\sigma_s = 3.0$、$B = 1000$（置換回数）、$\alpha = 0.10$。

4.2 EX1: コア帰属精度

合成データ設計. $N = 20{,}000$ トランザクション、20 空間位置、50 アイテムの 2 次元データを生成する。各トランザクションはランダムに 1 つの空間位置に割り当てられ、ベースライン出現確率 $p_{\text{base}} = 0.03$ でアイテムが含まれる。3 種類の信号を埋め込む：

- **Type A（空間局在ブースト）**: パターン $\{5, 15\}$ がイベント E_1 の期間中（$t \in [4000, 8000]$）、空間位置 $\{0, \ldots, 9\}$ でブースト確率 β で挿入される。
- **Type B（全域ブースト）**: パターン $\{25, 35\}$ がイベント E_2（$t \in [12000, 16000]$）の期間中、全 20 空間位置でブーストされる。
- **Type C（イベント非対応）**: パターン $\{40, 45\}$ がイベントとは無関係な期間（$t \in [2000, 3500]$）・位置（$\{5, \ldots, 14\}$）でブーストされる。
- **デコイイベント** D_1: パターン変動と無関係なイベント（$t \in [9000, 11000]$）。

6 条件を評価する：ブースト強度 $\beta \in \{0.1, 0.2, 0.3, 0.5\}$、CONFOUND（Type C がイベント E_1 と同時期・異位置）、DENSE（信号 3・Type B 2・デコイ 2 の密集シナリオ）。各条件 5 シードの平均を報告する。

結果. 表 1 に結果を示す。

分析. (RQ1–RQ3) $\beta \geq 0.3$ では ST パイプラインは常に Precision ≥ 0.80 を達成し、1 次元パイプラインを上回る F1 を示す。$\beta = 0.5$ では F1 = 1.000（完全検出）であり、1 次元の 0.600 に対し+0.40 の改善を達成する。

Table 2: EX2: パラメータ感度。各行は 1 パラメータのみ変更し他はデフォルト。

パラメータ	値	F1	P	R	FAR
σ_s	1.0	.67	1.0	.50	.00
	3.0	.67	1.0	.50	.00
	5.0	.67	1.0	.50	.00
	10.0	.67	1.0	.50	.00
	20.0	.67	1.0	.50	.00
σ_t	10	**1.00**	1.0	1.00	.00
	25	.67	1.0	.50	.00
	50	.67	1.0	.50	.00
	100	.00	.00	.00	.00
	200	.00	.00	.00	.00
α	0.01	.00	.00	.00	.00
	0.05	.00	.00	.00	.00
	0.10	.67	1.0	.50	.00
	0.20	.67	1.0	.50	.00
B	50	.00	.00	.00	.00
	100	.67	1.0	.50	.00
	500	.67	1.0	.50	.00
	1000	.67	1.0	.50	.00

CONFOUND 条件では、1 次元パイプラインは Type C パターン（イベント E_1 と同時期だが異なる空間位置に存在）を誤帰属して FAR = 0.80 となるのに対し、ST パイプラインは空間的近接度により FAR = 0.20 に低減する。

$\beta \leq 0.2$ では ST の Recall が低下する。これは置換検定の p 値が BH 補正後にボーダーラインとなるためであり、信号が弱い場合の Statistical power の限界を示す。1 次元パイプラインは空間を集約するため見かけ上の Recall は高いが、Precision は低い（誤ったパターンを帰属する傾向がある）。

4.3 EX2: パラメータ感度

EX1 の $\beta = 0.3$ データ（seed = 42）を用い、主要パラメータを個別にスイープする。

分析. (RQ4) 空間減衰 σ_s に対して結果は安定している（全値で F1 = 0.67）。これはイベントの空間スコープが離散的であり、prox_s がスコープ内で 1.0 となるため、σ_s の値は結果に影響しにくいことを示す。

時間減衰 σ_t は結果に最も大きな影響を与える。$\sigma_t \leq 50$（ウィンドウ幅 W の 1/4 以下）で良好な結果が得られ、$\sigma_t = 10$ では F1 = 1.000 を達成する。$\sigma_t \geq 100$ では時間的近接度の識別力が低下し、置換検定で帰無仮説を棄却できなくなる。これは $\sigma_t = O(W)$ の設定が時間的解像度を犠牲にすることを示唆する。

有意水準 α は 0.10 以上で安定し、0.05 以下では BH 補正後に有意結果が消失する。置換回数 B は 100 以上で安定し、$B = 50$ では p 値の解像度不足により有意結果が得られない。

4.4 EX3: 半現実的小売データ

データ設計. $N = 40{,}000$ トランザクション、20 店舗、50 アイテムの小売シミュレーションデータを生成する。3 つのキャンペーンを設定する：

- **夏季キャンペーン**: パターン $\{5, 15\}$、店舗 0–9（沿岸部）、$t \in [12000, 20000]$、$\beta = 0.4$。

Table 3: EX3: 半現実的小売データの帰属結果。

手法	F1	P	R	FAR	実行時間
ST（提案）	**1.000**	1.000	1.000	0.00	10.0 秒
1D	0.286	0.250	0.333	0.00	2.1 秒

Table 4: EX4: 実小売データによる半合成検証。

データ	手法	F1	P	R	FAR	#予測
Dunnhumby	ST（提案）	**0.667**	**1.000**	0.500	0.00	1
	1D	0.444	0.286	**1.000**	0.00	7
Online Retail	ST（提案）	**0.667**	**0.500**	**1.000**	0.00	4
	1D	0.211	0.118	**1.000**	0.00	17

- **冬季キャンペーン**: パターン $\{25, 35\}$、店舗 10–19（内陸部）、$t \in [28000, 36000]$、$\beta = 0.4$。
- **全店プロモーション**: パターン $\{8, 18\}$、全 20 店舗、$t \in [4000, 8000]$、$\beta = 0.5$。

Type C（$\{40, 45\}$, $t \in [22000, 26000]$, 店舗 5–14）とデコイイベントも設定する。

結果. 表 3 に結果を示す。

分析. (RQ5) 提案手法は 3 つのキャンペーン全てを正しく帰属する（$F1 = 1.000$）。具体的には、$\{8, 18\} \rightarrow$ 全店プロモーション（$p_{\text{adj}} = 0.028$）、$\{25, 35\} \rightarrow$ 冬季キャンペーン（$p_{\text{adj}} = 0.028$）、$\{5, 15\} \rightarrow$ 夏季キャンペーン（$p_{\text{adj}} = 0.028$）がいずれも有意に帰属され、Type C パターンは正しく棄却される。

1 次元パイプラインは F1 = 0.286 にとどまる。空間集約によりイベント効果が希釈され、特に地域限定キャンペーン（夏季・冬季）の検出が困難となる。

4.5 EX4: 実小売データによる半合成検証

データ設計. 2 つの実小売データセットに空間的信号を注入し、半合成検証を行う。**(a) Dunnhumby**: "The Complete Journey" データセットの先頭 20,000 トランザクション（92,339 商品）に 20 店舗をランダムに割り当て、中頻度アイテムペア 2 組をイベント信号として注入する（局所キャンペーン: 店舗 0–9、全店キャンペーン: 全 20 店舗、$\beta = 0.4$）。**(b) UCI Online Retail**: 29,788 トランザクション（1,824 商品）に 10 地域を割り当て、中頻度ペア 2 組を注入する（局所: 地域 0–4、広域: 地域 3–7、$\beta = 0.35$–0.40）。両データにデコイイベントとイベント非対応密集パターンも設定する。

結果. 表 4 に結果を示す。

分析. 両データセットにおいて、ST パイプラインは 1D パイプラインより高い F1 スコアを達成する。1D パイプラインは全ての注入信号を検出する（R = 1.000）が、多数の偽帰属を生成する（Dunnhumby: 7 件中 5 件、Online Retail: 17 件中 15 件が偽帰属）。特に Online Retail の 1D では 6 件がデコイイベントに帰属されている。ST パイプラインは空間フィルタリングにより偽帰属を大幅に削減し、Precision で一貫した優位性を示す。

Table 5: EX5: Dunnhumby 実データ探索的検証。商品一致率は帰属パターンが陳列対象商品を含む割合。

手法	#帰属	#イベント帰属	商品一致率	時間 (ms)
ST（提案）	8	5/30	**12.5%**	3,370
1D	9	5/30	0%	306

4.6 EX5: 実データ完全探索的検証

データ設計. Dunnhumby データセットから、上位 20 店舗の実取引データ（84,312 バスケット、51,282 商品）を**店舗 ID** により空間分割し、`causal_data.csv` に記録された**実際の店内陳列イベント**（30 イベント、各 2–3 週間、2–15 店舗に局在）をそのまま使用する。信号注入は行わず、純粋に探索的分析を行う。陳列イベントの効果は微弱（ウィンドウ内サポート 0–5、平均 < 1）であるため、単一アイテムパターンも候補に含める。

結果. 表 5 に結果を示す。緩和パラメータ（$W = 500$, $\tau = 2$, $\alpha = 0.15$）で ST パイプラインは 8 件、1D は 9 件の帰属を出力した。**イベント商品一致率**（帰属パターンが当該イベントの陳列商品を含む割合）は ST が 12.5%（1/8）に対し、1D は 0%（0/9）であった。

分析. 実世界の陳列イベントはサポート曲面の変動が微弱であり、両手法とも大半のイベントは検出されない。しかし ST パイプラインは空間フィルタリングにより少なくとも 1 件の真の帰属（イベント商品一致）を達成し、1D パイプラインはすべて商品不一致の偽帰属であった。これは、空間情報が実データにおいても偽陽性削減に寄与することを示す。

4.7 考察: ST パイプラインのトレードオフ

実験結果から、ST パイプラインと 1D パイプラインの間に明確なトレードオフが存在する。

精度と再現率. ST パイプラインは一貫して高い Precision（≥ 0.80）を達成し、誤帰属を防ぐ。一方、弱い信号（$\beta \leq 0.2$）や信号密度の高いシナリオ（DENSE）では Recall が低下する。これは、空間分割により位置あたりのサポートが薄くなり、変化点の統計的有意性が低下するためである。

適用指針. 位置あたりのウィンドウサイズ内トランザクション数が十分（≥ 10）であり、かつイベント効果が空間的に局在する場合、ST パイプラインが推奨される。全空間で均一なイベント効果や、位置あたりの観測数が少ない場合は、1D パイプラインがより高い Recall を達成する。

5 関連研究

イベント帰属パイプライン. 頻出パターンのサポート変動を外部イベントに帰属させるフレームワーク [2] は、変化点検出・帰属スコアリング・置換検定・BH 補正・重複排除の 5 ステップで構成される。本研究はこの 1 次元パイプラインを多次元に拡張し、空間的近接度と時空間置換検定を導入する。

空間スキャン統計. Kulldorff [7] の空間スキャン統計は、点過程における空間クラスターを検出する。時空間拡張 [8] は円筒形窓を使用する。これらはアイテムセットパターンを扱わず、検出された密集がなぜ生じたか（イベントへの帰属）には答え

ない。本研究はパターンサポートの変動をイベントに帰属させる点で根本的に異なる。

密部分テンソルマイニング. DenseAlert [13]、M-Zoom [12] は多次元テンソルにおける密ブロックを検出する。これらは密度異常を検出するが、検出された密度変動と外部イベントの統計的関連を検定する機能を持たない。

時空間パターンマイニング. 軌跡パターン [5] やコロケーションパターン [11] は空間的パターンを扱うが、パターンのサポート変動の原因帰属は対象としない。

計量経済学のイベント・スタディ法. MacKinlay [10] のイベント・スタディ法は企業イベントの株価への影響を評価する。単一のアウトカム変数を対象としており、数千のパターン時系列を同時に扱う本研究の設定とは異なる。また空間次元は考慮されない。

サロゲートデータと置換検定. Lancaster et al. [9] は時系列データに対するサロゲートデータ生成法を体系的に整理している。本研究の時空間置換検定は、時間的自己相関を円形シフトで保存するサロゲート法を空間構造の保存に拡張したものである。

6 結論

本研究では、頻出パターンのサポート変動と外部イベントの帰属を空間次元に拡張する**時空間イベント帰属パイプライン**を提案した。サポート曲面上の位置別変化点検出、時間的・空間的近接度を統合した帰属スコア、および空間構造を保存する置換検定により、「どの地域で・いつ・なぜパターン頻度が変わったか」に答える枠組みを提供する。

制約と限界. (1) 空間次元はグリッド離散化を前提としており、連続空間の解像度選択が結果に影響する。(2) 位置あたりの観測数が少ない場合（$\beta \leq 0.2$）、変化点の統計的有意性が低下し Recall が低くなる（4.7 節）。(3) 次元数 k の増加に伴い計算量が $O(2^{k+1})$ で増大し、$k \geq 4$ では実用性が制限される。

今後の課題. (1) 位置あたりの信号が薄い場合の適応的空間粒度選択。(2) イベントの空間スコープが未知の場合の自動推定。(3) ストリーミング設定へのオンライン拡張。(4) 空間スコープのランダム化を含む、より一般的な帰無仮説の設計。

REFERENCES

[1] Rakesh Agrawal and Ramakrishnan Srikant. 1994. Fast algorithms for mining association rules. In *Proceedings of VLDB*. 487–499.

[2] Anonymous. 2025. 頻出パターンの変動はなぜ起きたか？ サポート時系列と外部イベントの統計的帰属パイプライン. In *Proceedings of DSAA*. Under review.

[3] Yoav Benjamini and Yosef Hochberg. 1995. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B* 57, 1 (1995), 289–300.

[4] Yoav Benjamini and Daniel Yekutieli. 2001. The control of the false discovery rate in multiple testing under dependency. *Annals of Statistics* 29, 4 (2001), 1165–1188.

[5] Fosca Giannotti, Mirco Nanni, Fabio Pinelli, and Dino Pedreschi. 2007. Trajectory pattern mining. In *Proceedings of KDD*. 330–339.

[6] Jiawei Han, Jian Pei, and Yiwen Yin. 2000. Mining frequent patterns without candidate generation. *ACM SIGMOD Record* 29, 2 (2000), 1–12.

[7] Martin Kulldorff. 1997. A spatial scan statistic. *Communications in Statistics-Theory and Methods* 26, 6 (1997), 1481–1496.

[8] Martin Kulldorff. 2001. Prospective time periodic geographical disease surveillance using a scan statistic. *Journal of the Royal Statistical Society: Series A* 164, 1 (2001), 61–72.

[9] Gemma Lancaster, Dmytro Iatsenko, Aleksandra Pidde, Valentina Ticcinelli, and Aneta Stefanovska. 2018. Surrogate Data for Hypothesis Testing of Physical Systems. *Physics Reports* 748 (2018), 1–60.

[10] A. Craig MacKinlay. 1997. Event studies in economics and finance. *Journal of Economic Literature* 35, 1 (1997), 13–39.

[11] Shashi Shekhar and Yan Huang. 2001. Discovering spatial co-location patterns: A summary of results. *Advances in Spatial and Temporal Databases* (2001), 236–256.

[12] Kijung Shin, Bryan Hooi, and Christos Faloutsos. 2018. Fast, accurate, and flexible algorithms for dense subtensor mining. *ACM Transactions on Knowledge Discovery from Data* 12, 3 (2018), 1–30.

[13] Kijung Shin, Bryan Hooi, Jisu Kim, and Christos Faloutsos. 2017. DenseAlert: Incremental dense-subtensor detection in tensor streams. In *Proceedings of KDD*. 1057–1066.