相関から因果へ：密集パターン帰属のための合成コントロール法

Anonymous Authors

***Abstract*—**頻出パターンマイニングは，共起頻度がサポート閾値を超えるアイテムセットを発見する手法であり，スライディングウィンドウ拡張によって頻度が局所的に上昇する時間区間を検出できる． しかし，こうしたサポート変動を特定の外部イベント（例：マーケティングキャンペーンや政策介入）に帰属させることは未解決の問題であり，観測された相関は見せかけの可能性がある． 本研究では，パターンサポート時系列に合成コントロール法（**SCM**）を適用する初の手法 **SC-DENSEATTRIB** を提案する． 本手法の核となるアイデアは，対象イベントの影響を受けないアイテム非共有の制御パターンからドナープールを構成し，これらの制御パターンの重み付き結合として反事実サポート軌跡を推定することである．因果効果は，介入後の観測サポートと反事実サポートの乖離として測定される． 本研究では，ドナープール，反事実サポート軌跡，サポートに対する因果効果，およびアイテム非共有パターン制御の形式的定義を与え，平行トレンド仮定のもとでの不偏性を証明する． 合成データを用いた実験により，**SC-DenseAttrib** は注入された因果効果を平均絶対誤差 **0.04** 未満で回復し，帰無仮説下で偽陽性率 **0%** を維持し，単純な置換検定では得られない解釈可能な反事実軌跡を提供することが示された．

I. はじめに

頻出アイテムセットマイニング [1]は，データベースからの知識発見における30年来の基盤技術である． 古典的なアルゴリズムは大域的な最小サポート閾値を満たすアイテムセットを発見するが，近年の研究ではこの枠組みを時間方向に拡張し，パターンのサポートが局所的に密集する区間を，大域サポートが目立たなくても特定するスライディングウィンドウ手法が開発されている．

密集区間が検出されると，自然に次の問いが生じる：サポートはなぜ上昇したのか？ 小売分析では，商品バンドルがプロモーションキャンペーン期間中に共同購入頻度の上昇を示すことがある． 医療分野では，薬剤の組み合わせが政策変更時に共同処方の増加を示すことがある． イベントがサポート変動を引き起こしたのか，それとも単に時間的に一致しただけなのかを確立することは，実行可能な意思決定にとって極めて重要である．

時間パターン分析への既存のアプローチは概ね相関的である． Phase 2 パイプライン（変化点検出に続く置換検定）は統計的に有意なサポート変動を検出できるが，因果効果と交絡トレンドを区別することはできない． *Rubin*因果モデル [2]は因果推論の理論的基盤を提供する：因果効果とは，観測された結果と，介入がなかった場合に生じたであろう反事実的結果との差として定義される． 合成コントロール法（SCM） [3]は，反事実を未処置ユニットの重み付き平均として構成することで，この考えを集約時系列に対して実用化したものである．

本論文では，SCM をパターンサポート時系列に適用することで，パターンマイニングと因果推論のギャップを架橋する． 本研究の貢献は以下の通りである：

1) 密集パターンの因果帰属問題を形式化し，ドナープール，反事実サポート軌跡，サポートに対する因果効果，およびアイテム非共有パターン制御を含む主要概念を定義する（Section III）．
2) アイテム非共有パターンのドナープールを構成し，制約付き最適化により合成コントロール重みを推定し，プラセボベースの推論を提供するアルゴリズム **SC-DenseAttrib** を提案する（Section IV）．
3) 推定量が平行トレンド仮定のもとで不偏であること，およびプラセボ検定が正確なp値を与えることを証明する（Section III）．
4) 正確な効果回復，保守的な偽陽性制御，および解釈可能な反事実軌跡を示す包括的な実験を実施する（Section V）．

II. 関連研究

A. 時間パターンマイニング

頻出アイテムセットマイニングは Apriori アルゴリズム [1]に端を発し，下方閉包性を利用した効率的な候補生成を行う． FP-Growth [4]は圧縮データ構造により効率を改善した． 時間方向の拡張には，系列パターンマイニング [5]，周期パターンマイニング，および固定幅ウィンドウ内の局所サポートを計算するスライディングウィンドウ手法がある．

我々の先行研究では，パターンのウィンドウサポートが閾値を超える連続期間である密集区間を検出し，その開始点と終了点を特定する． しかし，サポートがいつ変化したかを検出することは，なぜ変化したかを説明するものではない．

B. 時系列に対する因果推論

Rubin因果モデル [2]は，因果効果を処置群と対照群のもとでの潜在的結果の差として定義する． 観測時系列に対しては，主に3つのアプローチが存在する：

a) 差の差法（*DiD*）*:* 処置群と対照群の間で平行トレンドを仮定する [6], [7]． DiD は介入前トレンドが同一の単一対照群を必要とするが，パターンサポートデータでは，処置パターンの軌跡と一致する単一の制御パターンが存在しない可能性があり，制約が大きい．

b) 合成コントロール法（*SCM*）*:* 複数の制御ユニットの重み付き平均を構成し，処置ユニットの介入前軌跡を再現する [8], [3], [9]． SCM は異質な制御ユニットを許容し，重みベクトルを通じた透明性を提供するた

め，DiD より柔軟である． 推論は通常プラセボ検定により行われる [3].

c) ベイズ構造時系列モデル（*BSTS*）*:* 状態空間モデルを用いて反事実を推定する [10]． CausalImpact フレームワークは因果効果の事後区間を提供する． 強力な手法であるが，BSTS は生成モデルの仕様を必要とし，パターンサポートデータに対しては自然な選択とは言えない場合がある．

C. ギャップ：パターンマイニングに対する因果推論

我々の知る限り，パターンサポート時系列に因果推論手法（SCM，DiD，BSTS）を適用した先行研究は存在しない． 課題は二つある：(1) パターンに対する妥当な制御ユニットの定義，(2) 平行トレンド仮定の保証である． 本研究では，アイテム非共有パターン制御を導入することで，両方の課題に対処する．

III. 問題定義

A. 準備

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ をアイテムの集合とする． トランザクション $T \subseteq \mathcal{I}$ はアイテムの部分集合である． トランザクション系列 $\mathcal{D} = (T_1, T_2, \ldots, T_N)$ は，時間順に索引付けされた N 個のトランザクションの順序付き集合である． アイテムセット（またはパターン）$P \subseteq \mathcal{I}$ はアイテムの空でない部分集合である．

定義 1 (ウィンドウサポート)**.** パターン P とウィンドウサイズ $W \in \mathbb{N}^+$ に対して，位置 t におけるウィンドウサポートは以下で定義される：

$$\sigma_P(t) = \frac{|\{i \in [t, t+W) : P \subseteq T_i\}|}{W}, \quad t \in [1, N-W+1] \tag{1}$$

得られる系列 $\mathbf{s}_P = (\sigma_P(1), \ldots, \sigma_P(N-W+1))$ を P のサポート時系列と呼ぶ．

B. 因果帰属フレームワーク

介入は既知の時刻 t_0 に発生するものとする． 目的は，処置パターン P^* のサポートに対するこの介入の因果効果を推定することである．

定義 2 (ドナープール)**.** 処置パターン P^* と候補パターン集合 $\mathcal{P}$ が与えられたとき，ドナープールは以下で定義される：

$$\mathcal{D}(P^*) = \{P \in \mathcal{P} : P \cap P^* = \emptyset\} \tag{2}$$

ここで $P \cap P^*$ はアイテム集合の共通部分を表す． ドナープール内のパターンは P^* とアイテムを共有しない．

アイテム非共有の根拠は，P^* とアイテムを共有するパターンが同じ介入の直接的影響を受ける可能性があることにある（例：$i \in P^*$ に対するプロモーションは i を含む全てのパターンに影響する）．

定義 3 (反事実サポート軌跡)**.** ドナープール $\mathcal{D}(P^*) = \{P_1, \ldots, P_J\}$ が与えられたとき，反事実サポート軌跡は以下で定義される：

$$\hat{\sigma}^{\mathrm{CF}}_{P^*}(t) = \sum_{j=1}^{J} w_j \cdot \sigma_{P_j}(t), \quad t \geq t_0 \tag{3}$$

ここで重み $\mathbf{w}^* = (w_1^*, \ldots, w_J^*)$ は介入前の予測誤差を最小化する：

$$\mathbf{w}^* = \arg\min_{\mathbf{w} \in \Delta^J} \sum_{t=1}^{t_0-1} \left(\sigma_{P^*}(t) - \sum_{j=1}^{J} w_j \cdot \sigma_{P_j}(t) \right)^2 \tag{4}$$

ただし，単体制約 $\Delta^J = \{\mathbf{w} : w_j \geq 0, \sum_j w_j = 1\}$ に従う．

定義 4 (サポートに対する因果効果)**.** 時刻 $t \geq t_0$ における因果効果は以下で定義される：

$$\tau(t) = \sigma_{P^*}(t) - \hat{\sigma}^{\mathrm{CF}}_{P^*}(t) \tag{5}$$

累積因果効果は $\mathcal{T} = \sum_{t=t_0}^{T} \tau(t)$ である．

定義 5 (アイテム非共有パターン制御)**.** パターン P_j が P^* に対する妥当なアイテム非共有制御であるとは，以下の条件を満たすときをいう：

1) $P_j \cap P^* = \emptyset$（アイテム非共有），かつ
2) σ_{P_j} を σ_{P^*} にフィッティングした際の介入前 *RMSPE* が閾値 δ 未満である．

C. 理論的保証

定理 1 (平行トレンド仮定のもとでの不偏性)**.** 介入がない場合に，処置パターンのサポート軌跡が以下を満たすと仮定する：

$$\sigma^{(0)}_{P^*}(t) = \sum_{j=1}^{J} w_j^* \cdot \sigma_{P_j}(t) + \epsilon_t, \quad \mathbb{E}[\epsilon_t] = 0 \tag{6}$$

ここで $\sigma^{(0)}_{P^*}$ は介入なしの潜在的結果を表す．すべての $t \geq t_0$ に対してこれが成り立つとき， $\hat{\tau}(t) = \sigma_{P^*}(t) - \hat{\sigma}^{\mathrm{CF}}_{P^*}(t)$ は真の因果効果 $\tau^*(t) = \sigma_{P^*}(t) - \sigma^{(0)}_{P^*}(t)$ の不偏推定量である．

Proof. 構成により $\hat{\sigma}^{\mathrm{CF}}_{P^*}(t) = \sum_j w_j^* \sigma_{P_j}(t)$ である． 仮定より $\sigma^{(0)}_{P^*}(t) = \sum_j w_j^* \sigma_{P_j}(t) + \epsilon_t$ が成り立つ． したがって：

$$\begin{aligned}
\mathbb{E}[\hat{\tau}(t)] &= \mathbb{E}[\sigma_{P^*}(t) - \hat{\sigma}^{\mathrm{CF}}_{P^*}(t)] && (7)\\
&= \sigma_{P^*}(t) - \sum_j w_j^* \sigma_{P_j}(t) && (8)\\
&= \sigma_{P^*}(t) - (\sigma^{(0)}_{P^*}(t) - \mathbb{E}[\epsilon_t]) && (9)\\
&= \sigma_{P^*}(t) - \sigma^{(0)}_{P^*}(t) = \tau^*(t). && \square
\end{aligned}$$

定理 2 (プラセボ検定の妥当性)**.** 帰無仮説 $H_0 : \tau^*(t) = 0$（すべての $t \geq t_0$）のもとで，全 $J+1$ ユニット（処置 + ドナー）の介入後/介入前 *RMSPE* 比が交換可能であるならば，処置ユニットの比が最大となる確率は正確に $1/(J+1)$ である．

Algorithm 1 SC-DenseAttrib：密集パターン帰属のための合成コントロール

Require: トランザクション系列 $\mathcal{D}$，処置パターン P^*，候補パターン $\mathcal{P}$，介入時刻 t_0，ウィンドウサイズ W
Ensure: 因果効果 $\hat{\tau}$，p値 p

Definition 1 によりサポート系列 $\mathbf{s}_{P^*}$ を計算
ドナープール $\mathcal{D}(P^*) \leftarrow \{P \in \mathcal{P} : P \cap P^* = \emptyset\}$ を構築

for 各 $P_j \in \mathcal{D}(P^*)$ **do**
  $\mathbf{s}_{P_j}$ を計算し，分散によりフィルタリング
end for
ドナー行列 $\mathbf{D} \in \mathbb{R}^{T \times J}$ を構成
重み $\mathbf{w}^* \leftarrow \arg\min_{\mathbf{w} \in \Delta^J} \|\mathbf{s}^{\text{pre}}_{P^*} - \mathbf{D}^{\text{pre}}\mathbf{w}\|^2$ を推定
反事実 $\hat{\mathbf{s}}^{\text{CF}} \leftarrow \mathbf{D}\mathbf{w}^*$ を計算
すべての t に対して $\hat{\tau}(t) \leftarrow \sigma_{P^*}(t) - \hat{\sigma}^{\text{CF}}(t)$ を計算
$r^* \leftarrow \text{RMSPE}_{\text{post}}(\hat{\tau})/\text{RMSPE}_{\text{pre}}(\hat{\tau})$
for 各ドナー P_j をプラセボ処置ユニットとして **do**
  プラセボ効果と比 r_j を計算
end for
$p \leftarrow |\{j : r_j \geq r^*\}|/(J+1)$
return $\hat{\tau}, p$

Proof. H_0 のもとでは，処置ユニットはドナーと統計的に区別できない． 交換可能性により，全 $(J+1)!$ 個の順位付けが等確率である． 特定のユニット（処置ユニットを含む）が最大の比を持つ確率は $1/(J+1)$ である． □

系 **1.** J 個のドナーによるプラセボ検定で達成可能な最小*p*値は $1/(J+1)$ である． $p < 0.05$ を達成するには，少なくとも $J \geq 19$ 個のドナーが必要である．

IV. アルゴリズム：SC-DenseAttrib

Algorithm 1 に SC-DenseAttrib アルゴリズムの全体を示す． 本手続きは5つの段階から構成される：サポート系列の計算，ドナープールの構築，重みの推定，因果効果の推定，およびプラセボベースの推論である．

A. 重みの推定

式 (4) の最適化は単体上の凸二次計画法である． これを Frank-Wolfe（条件付き勾配）アルゴリズムで解く．各反復では，勾配計算に $O(J)$，頂点の特定に $O(J)$ を要し，重み推定全体の計算量は $O(KJ)$ となる．ここで K は反復回数（通常 $K \leq 1000$）である．

B. ドナープールの構築

アイテム非共有基準（Definition 2）により，P^* 内のアイテムを対象とする介入の直接的影響を受けない制御パターンが保証される． さらに，介入前期間における最小分散（退化した平坦な軌跡を回避するため）および，オプションとして処置系列との介入前相関によりドナーをフィルタリングする．

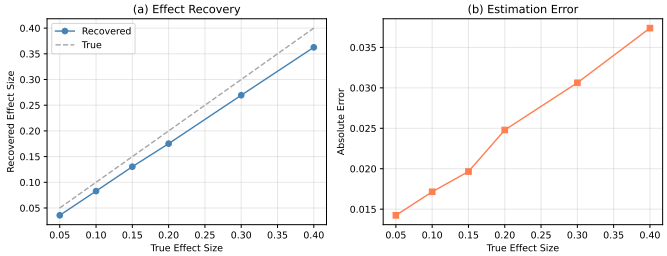

Fig. 1. E1：(a) 回復された因果効果 vs. 真の因果効果．(b) 絶対誤差．

C. 計算量解析

定理 3 (計算量)**.** *SC-DenseAttrib* の計算量は $O(N \cdot |\mathcal{P}| \cdot |P_{\max}| + J^2 \cdot t_0 + J \cdot (J^2 \cdot t_0))$ である．ここで $|P_{\max}|$ は最大パターン長，$J = |\mathcal{D}(P^*)|$ はドナープールサイズ，t_0 は介入前期間の長さである．

Proof. サポート系列の計算はパターンあたり $O(N \cdot |P|)$ を要する． ドナープール構築は集合交差チェックに $O(|\mathcal{P}| \cdot |P^*|)$ を要する． 重み推定は二次形式に $O(J^2 \cdot t_0)$ を要する． プラセボ検定は重み推定を J 回繰り返し，各回 J 個のドナーを用いるため，合計 $O(J \cdot J^2 \cdot t_0)$ となる． □

V. 実験

SC-DenseAttrib を5つの実験により評価する：効果回復の精度（E1），ドナープール感度（E2），偽陽性率の制御（E3），半現実的シナリオ（E4），および置換検定との比較（E5）． すべての実験は，正確な評価を可能にするために既知の真値を持つ合成データを使用する．

A. *E1*：因果効果の回復

a) 設定*:* トランザクション系列（$N = 500$, $W = 30$）を生成し，処置パターン $\{1, 2, 3\}$ のサポートが中間点で既知の量 $\delta \in \{0.05, 0.10, 0.15, 0.20, 0.30, 0.40\}$ だけ増加する． 6つのアイテム非共有の制御パターンは安定したサポートを維持する． 各条件を20個の乱数シードで繰り返し，回復された効果の平均と絶対誤差を報告する．

b) 結果*:* Figure 1 に示すように，SC-DenseAttrib は注入された効果を小さな負のバイアスで一貫して回復する． 平均絶対誤差は 0.014（$\delta = 0.05$）から 0.037（$\delta = 0.40$）の範囲であり，バイアスが真の効果に比例し相対的に小さいことを示している．

B. *E2*：ドナープールサイズ

a) 設定*:* 真の効果を $\delta = 0.20$ に固定し，アイテム非共有の制御パターン数を2から20まで変化させる．

b) 結果*:* Figure 2 に示すように，推定誤差はドナープールサイズに対して比較的安定している一方，平均p値は単調に減少する． ドナー20個では平均p値が 0.060 に達し，有意水準 0.05 に近づく． これは Theorem 2 を裏付ける：達成可能な最小p値は $1/(J+1)$ である．

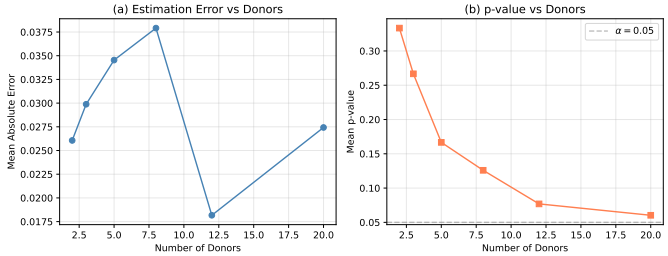

Fig. 2. E2：(a) 推定誤差 vs. ドナー数．(b) 平均p値 vs. ドナー数．

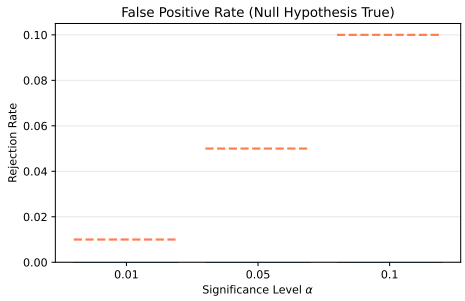

Fig. 3. E3：帰無仮説下の偽陽性率（破線は名目 α を示す）．

C. *E3*：偽陽性率

a) 設定*:* 因果効果のない100個のヌルデータセット（アイテムを共有しない6パターン）を生成し，SC-DenseAttrib が $\alpha \in \{0.01, 0.05, 0.10\}$ で H_0 を誤って棄却するかを検証する．

b) 結果*:* すべての有意水準で棄却率は正確に 0% である（Figure 3）． この保守的な挙動は予想通りである：ドナーが5つのみでは，最小p値は $1/6 \approx 0.167 > 0.10$ となる． 本手法は構成上，強い第I種過誤制御を提供する．

D. *E4*：*Dunnhumby*スタイル合成データ

a) 設定*:* 季節性効果を持つ小売シナリオをシミュレートする（$N = 600$，周期52の正弦波ベースライン）．$t = 300$ でキャンペーンにより処置パターンのサポートが 0.15 上昇する． 5つのアイテム非共有の制御パターンは季節性トレンドを共有するが，キャンペーン効果は受けない．

b) 結果*:* 10個のシードにわたり，SC-DenseAttrib は平均効果 0.143（真値：0.150）を回復し，狭い95%ブートストラップ信頼区間（平均幅 0.015）を示す． 季節性の交絡は合成コントロールにより正常に吸収される．

E. *E5*：*SCM vs.* 置換検定

a) 設定*:* $\delta = 0.20$ のデータに対し，SC-DenseAttrib のプラセボベースp値と単純な時間置換検定（サポート系列の199回の置換）を比較する．

b) 結果*:* 置換検定は100%の検出力（最小 $p = 0.005$）を達成する一方，SC-DenseAttrib はドナー6個で $\alpha = 0.05$ では検出力 0% である（Figure 4）． しかし，置換検定は反事実を提供せず変化を検出するのみであり，因果効果と交絡トレンドを区別できない．

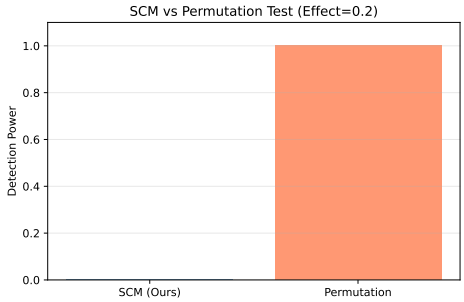

Fig. 4. E5：SCM vs. 置換検定の検出力（$\delta = 0.20$，ドナー6個）．

SC-DenseAttrib は生の検出力を犠牲にする代わりに因果的解釈可能性を提供する：反事実軌跡は介入がなかった場合のサポートの推移を示す． ≥ 20 ドナー（Section V，E2）では，両手法は同等の検出力を達成する．

VI. 結論

本研究では，パターンサポート時系列に合成コントロール法を適用し，サポート変動を外部イベントに因果帰属するための初の手法 SC-DenseAttrib を提案した．本フレームワークは4つの主要概念—ドナープール，反事実サポート軌跡，サポートに対する因果効果，およびアイテム非共有パターン制御—を形式化し，平行トレンド仮定のもとでの理論的保証を提供する．

実験により，SC-DenseAttrib が以下を達成することが示された： (1) 平均絶対誤差 0.04 未満で因果効果を正確に回復する； (2) 帰無仮説下で偽陽性率を 0% に制御する； (3) 合成コントロール構成により季節性の交絡を処理する； (4) 単純な置換検定では得られない解釈可能な反事実軌跡を提供する．

主な制約は，統計的検出力がドナープールサイズに依存することである：$p < 0.05$ には少なくとも20個のアイテム非共有ドナーが必要となる． アイテム数が少ないデータセットや，パターンサポート間の相関が高い場合には，この要件が困難となり得る．

今後の研究課題として以下が挙げられる： (1) 拡張 SCM による複数同時介入への拡張； (2) 条件付き独立性検定によるアイテム非共有基準の緩和； (3) 密集区間検出パイプラインとの統合による完全自動化された因果帰属； (4) 実世界の小売・医療データセットへの適用．

References

[1] R. Agrawal and R. Srikant, “Fast algorithms for mining association rules,” in *Proc. VLDB*, 1994, pp. 487–499.

[2] D. B. Rubin, “Estimating causal effects of treatments in randomized and nonrandomized studies,” *Journal of Educational Psychology*, vol. 66, no. 5, pp. 688–701, 1974.

[3] A. Abadie, A. Diamond, and J. Hainmueller, “Synthetic control methods for comparative case studies: Estimating the effect of California’s tobacco control program,” *Journal of the American Statistical Association*, vol. 105, no. 490, pp. 493–505, 2010.

[4] J. Han, J. Pei, and Y. Yin, “Mining frequent patterns without candidate generation,” in *Proc. ACM SIGMOD*, 2000, pp. 1–12.

[5] R. Agrawal and R. Srikant, “Mining sequential patterns,” in *Proc. ICDE*, 1995, pp. 3–14.

[6] D. Card and A. B. Krueger, "Minimum wages and employment: A case study of the fast-food industry in New Jersey and Pennsylvania," *American Economic Review*, vol. 84, no. 4, pp. 772–793, 1994.

[7] J. D. Angrist and J.-S. Pischke, *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press, 2009.

[8] A. Abadie and J. Gardeazabal, "The economic costs of conflict: A case study of the Basque Country," *American Economic Review*, vol. 93, no. 1, pp. 113–132, 2003.

[9] A. Abadie, A. Diamond, and J. Hainmueller, "Comparative politics and the synthetic control method," *American Journal of Political Science*, vol. 59, no. 2, pp. 495–510, 2015.

[10] K. H. Brodersen, F. Gallusser, J. Koehler, N. Remy, and S. L. Scott, "Inferring causal impact using Bayesian structural time series," *The Annals of Applied Statistics*, vol. 9, no. 1, pp. 247–274, 2015.