相関から因果へ：密集パターン帰属のための合成コントロール法

Anonymous Authors

***Abstract*—頻出パターンマイニングは，共起頻度がサポート閾値を超えるアイテムセットを発見する手法であり，スライディングウィンドウ拡張によって頻度が局所的に上昇する時間区間を検出できる．しかし，こうしたサポート変動を特定の外部イベント（例：マーケティングキャンペーンや政策介入）に因果的に帰属させることは未解決の問題であり，観測された相関は交絡や見せかけの可能性がある．本研究では，2 アイテムパターン（$L = 2$）を因果帰属の基本単位として，パターンサポート時系列に合成コントロール法（SCM）を適用する新たな手法 SC-DenseAttrib を提案する．本手法の核となるアイデアは，対象イベントの影響を受けないアイテム非共有の制御パターンからドナープールを構成し，これらの制御パターンの重み付き結合として反事実サポート軌跡を推定することである．因果効果は，介入後の観測サポートと反事実サポートの乖離（時間的近接度と効果量の積として定量化）として測定される．本研究では，因果識別に必要な仮定（SUTVA，線形因子モデル）を明示し，線形因子モデルのもとでの $\sqrt{t_0}$-一致性を証明する．7 つの実験により，SC-DenseAttrib は注入された因果効果を平均絶対誤差 0.04 未満で回復し，差の差法・Before-After・アイテム共有 SCM の各ベースラインを上回ることが確認された．また，SUTVA 違反に対する頑健性の限界を定量的に示し，時間的共起と因果関係の区別における本手法の有効性と制約を明らかにした．**

I. はじめに

頻出アイテムセットマイニング [1] は，データベースからの知識発見における 30 年来の基盤技術である．古典的なアルゴリズムは大域的な最小サポート閾値を満たすアイテムセットを発見するが，近年の研究ではこの枠組みを時間方向に拡張し，パターンのサポートが局所的に密集する区間を，大域サポートが目立たなくても特定するスライディングウィンドウ手法が開発されている．

密集区間が検出されると，自然に次の問いが生じる：サポートは**なぜ**上昇したのか？ 小売分析では，商品バンドルがプロモーションキャンペーン期間中に共同購入頻度の上昇を示すことがある．医療分野では，薬剤の組み合わせが政策変更時に共同処方の増加を示すことがある．イベントがサポート変動を**引き起こした**のか，それとも単に時間的に一致しただけなのかを見極めることは，実行可能な意思決定にとって極めて重要である．ここで鍵となるのは，因果帰属の基本単位としての 2 アイテムパターン（$L = 2$）の選択である．$L = 2$ は因果的共起の最小構成要素であり，交絡要因の制御が容易になるという利点がある：アイテム数が少ないほど，介入の直接効果と間接効果の分離が明確になり，ドナープールにおけるアイテム非共有基準の適用も単純化される [2].

時間パターン分析への既存のアプローチは概ね相関的である．Phase 2 パイプライン（変化点検出に続く置換検定）は統計的に有意なサポート変動を検出できるが，因果効果と交絡トレンドを区別することはできない．*Rubin* **因果モデル** [3] は因果推論の理論的基盤を提供する：因果効果とは，観測された結果と，介入がなかった場合に生じたであろう反事実的結果との差として定義される．合成コントロール法（SCM）[4] は，反事実を未処置ユニットの重み付き平均として構成することで，この考えを集約時系列に対して実用化したものである．

本論文では，SCM をパターンサポート時系列に適用することで，パターンマイニングと因果推論のギャップを架橋することを試みる．本研究の貢献は以下の通りである：

1) 2 アイテムパターン（$L = 2$）を基本単位とした**密集パターンの因果帰属問題**を形式化し，ドナープール，反事実サポート軌跡，サポートに対する因果効果，およびアイテム非共有パターン制御を含む主要概念を定義する（Section III）.
2) アイテム非共有パターンのドナープールを構成し，制約付き最適化により合成コントロール重みを推定し，時間的近接度と効果量に基づく帰属スコアおよびプラセボベースの推論を提供するアルゴリズム **SC-DenseAttrib** を提案する（Section IV）.
3) SUTVA と線形因子モデルを含む**因果識別の仮定を明示化**し，推定量の $\sqrt{t_0}$-一致性およびプラセボ検定の正確な p 値を証明する（Section III）.
4) DiD・Before-After・アイテム共有 SCM との**ベースライン比較**，および SUTVA 違反に対する**感度分析**を含む 7 つの実験を実施する（Section V）.

II. 関連研究

A. 時間パターンマイニング

頻出アイテムセットマイニングは Apriori アルゴリズム [1] に端を発し，下方閉包性を利用した効率的な候補生成を行う．FP-Growth [5] は圧縮データ構造により効率を改善した．時間方向の拡張には，系列パターンマイニング [6]，周期パターンマイニング，および固定幅ウィンドウ内の局所サポートを計算するスライディングウィンドウ手法がある．新興パターンマイニング [7] は，二つの時期間でサポート比が大きく変化するパターンを検出するが，変化の因果的帰属は扱わない．

Lancaster et al. [2] は，頻出アイテムセットのサポート急増（surge）を分析し，サポート変動の時間的パターンがドメイン知識と結びつく可能性を示唆した．我々の先行研究では，パターンのウィンドウサポートが閾値を超える連続期間である**密集区間**を検出し，その開始点と終了点を特定する．しかし，サポートが**いつ**変化したかを検出することは，**なぜ**変化したかを説明するものではない．

B. 時系列に対する因果推論

Rubin 因果モデル [3] は，因果効果を処置群と対照群のもとでの潜在的結果の差として定義する．Imbens–Rubin [8]

は潜在的結果の枠組みを体系化した．観測時系列に対しては，主に 4 つのアプローチが存在する：

a) 差の差法（DiD）： 処置群と対照群の間で平行トレンドを仮定する [9], [10]．DiD は介入前トレンドが同一の単一対照群を必要とするが，パターンサポートデータでは，処置パターンの軌跡と一致する単一の制御パターンが存在しない可能性があり，制約が大きい．

b) 合成コントロール法（SCM）： 複数の制御ユニットの重み付き平均を構成し，処置ユニットの介入前軌跡を再現する [11], [4], [12]．SCM は異質な制御ユニットを許容し，重みベクトルを通じた透明性を提供するため，DiD より柔軟である．推論は通常プラセボ検定により行われる [4]．近年では，SCM の拡張として Robust SCM [13] がペナルティ付き回帰によるバイアス補正を導入し，Augmented SCM [14] が結果モデルとの結合による二重頑健性を達成している．パネルデータにおけるマトリクス補完アプローチ [15] は，SCM と固定効果モデルを統一する枠組みを提供する．

c) ベイズ構造時系列モデル（BSTS / CausalImpact）： Brodersen et al. [16] は，局所線形トレンド・季節成分・回帰成分から構成されるベイズ構造時系列モデルに基づく CausalImpact フレームワークを提案した．CausalImpact は因果効果のベイズ事後区間を提供し，Google 広告の効果測定等で広く利用されている．SCM と CausalImpact は相補的な特性を持つ：(1) CausalImpact はベイズ的不確実性定量化（95%信用区間）を自然に提供する一方，SCM のプラセボ検定はノンパラメトリックな正確検定である；(2) CausalImpact は季節性・トレンドの明示的モデリング（状態空間モデルの成分選択）を要するが，SCM はドナーの重み付き結合により暗黙的にトレンドを吸収する；(3) CausalImpact の回帰成分として制御系列を用いる場合，スパイク・スラブ事前分布による変数選択が行われるが，パターンサポートデータに対する制御系列の妥当性基準（本研究のアイテム非共有に相当するもの）は未定義である．本研究が SCM を基盤として選択した理由は，アイテム非共有ドナープールの組合せ的構造が SCM の単体制約付き重み推定と自然に統合できる点にある．Section V の E6 で CausalImpact との推定的比較を議論する．

d) Granger 因果性と因果発見： 時系列間の予測的因果関係を検定する Granger 因果性 [17] は広く用いられるが，介入効果ではなく予測的先行関係を捉えるものであり，反事実の構成を伴わない．構造的因果モデルに基づく因果発見 [18] は，DAG 構造の推定を目的とし，本研究の「既知の介入に対する効果推定」とは問題設定が異なる．

C. ギャップ：パターンマイニングに対する因果推論

我々の知る限り，パターンサポート時系列に因果推論手法（SCM，DiD，BSTS）を体系的に適用した先行研究は見当たらない．課題は三つある：(1) パターンに対する妥当な制御ユニットの定義，(2) 平行トレンド仮定の保証，(3) パターン空間の組合せ的構造に起因するドナープールの構成である．本研究では，**アイテム非共有パターン制御**を導入することで，これらの課題に対処する．

Table I に主要手法を比較する．本手法は，反事実軌跡の構成と因果効果の定量化をパターンマイニングの文脈で同時に提供する数少ないアプローチの一つである．

TABLE I
因果推論手法の比較

手法	反事実	効果定量	パターン対応	ドナー不要
DiD	–	✓	–	✓
SCM [4]	✓	✓	–	–
BSTS [16]	✓	✓	–	–
Granger [17]	–	–	–	✓
置換検定	–	–	✓	✓
SC-DenseAttrib	✓	✓	✓	–

III. 問題定義

A. 準備

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ をアイテムの集合とする．**トランザクション** $T \subseteq \mathcal{I}$ はアイテムの部分集合である．**トランザクション系列** $\mathcal{D} = (T_1, T_2, \ldots, T_N)$ は，時間順に索引付けされた N 個のトランザクションの順序付き集合である．**アイテムセット**（または**パターン**）$P \subseteq \mathcal{I}$ はアイテムの空でない部分集合である．本研究では，因果帰属の基本単位として 2 アイテムパターン（$|P| = 2$，以下 $L = 2$）に焦点を当てる．$L = 2$ は因果的共起の最小構成要素であり，以下の理論的・実用的利点を持つ：(1) 交絡制御の容易性：アイテム数が少ないほど，介入がサポートに与える直接効果と交絡による間接効果の分離が明確になる；(2) ドナープール構築の単純性：$L = 2$ ではアイテム非共有基準（Definition 6）の適用が容易であり，十分なドナー数を確保しやすい；(3) 解釈可能性：2 アイテム間の因果的共起変動は，実務者にとって直感的に理解しやすい [2]．

定義 1 (ウィンドウサポート)**.** パターン P とウィンドウサイズ $W \in \mathbb{N}^+$ に対して，位置 t におけるウィンドウサポートは以下で定義される：

$$\sigma_P(t) = \frac{|\{i \in [t, t+W) : P \subseteq T_i\}|}{W}, \quad t \in [1, N-W+1] \tag{1}$$

得られる系列 $\mathbf{s}_P = (\sigma_P(1), \ldots, \sigma_P(N-W+1))$ を P のサポート時系列と呼ぶ．

B. 因果帰属フレームワーク

介入は既知の時刻 t_0 に発生するものとする．目的は，**処置パターン** P^* のサポートに対するこの介入の因果効果を推定することである．

定義 2 (ドナープール)**.** 処置パターン P^* と候補パターン集合 $\mathcal{P}$ が与えられたとき，ドナープールは以下で定義される：

$$\mathcal{D}(P^*) = \{P \in \mathcal{P} : P \cap P^* = \emptyset\} \tag{2}$$

ここで $P \cap P^*$ はアイテム集合の共通部分を表す．ドナープール内のパターンは P^* とアイテムを共有しない．

アイテム非共有の根拠は，P^* とアイテムを共有するパターンが同じ介入の直接的影響を受ける可能性があることにある（例：$i \in P^*$ に対するプロモーションは i を含む全てのパターンに影響する）．

定義 3 (反事実サポート軌跡)**.** ドナープール $\mathcal{D}(P^*) = \{P_1, \ldots, P_J\}$ が与えられたとき，反事実サポート軌跡は以下で定義される：

$$\hat{\sigma}^{\mathrm{CF}}_{P^*}(t) = \sum_{j=1}^{J} w_j \cdot \sigma_{P_j}(t), \quad t \geq t_0 \tag{3}$$

ここで重み $\mathbf{w}^* = (w_1^*, \ldots, w_J^*)$ は介入前の予測誤差を最小化する：

$$\mathbf{w}^* = \arg\min_{\mathbf{w} \in \Delta^J} \sum_{t=1}^{t_0-1} \left(\sigma_{P^*}(t) - \sum_{j=1}^{J} w_j \cdot \sigma_{P_j}(t) \right)^2 \tag{4}$$

ただし，単体制約 $\Delta^J = \{\mathbf{w} : w_j \geq 0, \sum_j w_j = 1\}$ に従う．

定義 4 (サポートに対する因果効果)**.** 時刻 $t \geq t_0$ における因果効果は以下で定義される：

$$\tau(t) = \sigma_{P^*}(t) - \hat{\sigma}^{\mathrm{CF}}_{P^*}(t) \tag{5}$$

累積因果効果は $\mathcal{T} = \sum_{t=t_0}^{T} \tau(t)$ である．

定義 5 (帰属スコア)**.** 外部イベント e（発生時刻 t_e）に対する処置パターン P^* の帰属スコアは，時間的近接度と効果量の積として定義される：

$$\mathrm{Score}(P^*, e) = \mathrm{prox}(t_0, t_e) \times \mathrm{mag}(P^*, t_0) \tag{6}$$

ここで，$\mathrm{prox}(t_0, t_e) = \exp(-|t_0 - t_e|/\lambda)$（$\lambda$ は減衰パラメータ）は介入時刻とイベント発生時刻の時間的近接度，$\mathrm{mag}(P^*, t_0) = |\mathcal{T}|/(T - t_0 + 1)$ は正規化された累積効果量である．因果推論において，帰属の根拠は *(1)* 効果の大きさ（*mag*）と *(2)* 時間的近接性（*prox*）の二要素に集約される．方向性（*dir*）は因果の向きとは異なる概念であるため，帰属スコアには含めない．

定義 6 (アイテム非共有パターン制御)**.** パターン P_j が P^* に対する妥当なアイテム非共有制御であるとは，以下の条件を満たすときをいう：

1) $P_j \cap P^* = \emptyset$（アイテム非共有），かつ
2) σ_{P_j} を σ_{P^*} にフィッティングした際の介入前 *RMSPE* が閾値 δ 未満である．

C. 因果識別のための仮定

本節では，因果効果の識別に必要な仮定を明示的に列挙し，パターンサポート文脈での妥当性を議論する．

定義 7 (SUTVA：安定単位処置値仮定)**.** 各パターン $P_j \in \mathcal{D}(P^*)$ のサポート軌跡は，処置パターン P^* に対する介入の有無に影響されない：

$$\sigma^{obs}_{P_j}(t) = \sigma^{(0)}_{P_j}(t), \quad \forall j, \forall t \tag{7}$$

アイテム非共有基準（Definition 6）は SUTVA の十分条件ではないが，その蓋然性を高める設計的保証である：P^* のアイテムを標的としたプロモーションは，P^* とアイテムを共有しないパターンに直接的な影響を与えない．ただし，間接的な波及効果（例：予算制約による代替購買）は SUTVA 違反となり得るため，Section V で感度分析を行う．

定義 8 (線形因子モデル仮定)**.** 介入がない場合の全パターンのサポートが共通の潜在因子 $\boldsymbol{\mu}_t \in \mathbb{R}^r$ で駆動されるとする：

$$\sigma^{(0)}_P(t) = \boldsymbol{\lambda}_P^\top \boldsymbol{\mu}_t + \epsilon_{P,t}, \quad \mathbb{E}[\epsilon_{P,t}] = 0 \tag{8}$$

ここで $\boldsymbol{\lambda}_P \in \mathbb{R}^r$ はパターン固有の因子負荷量，r は因子数である．

注意 1. *Definition 8* は平行トレンド仮定の一般化である．*DiD* は $r = 1, \boldsymbol{\mu}_t = t$ の特殊ケースに相当する．*SCM* は，ドナープールの因子負荷量が処置パターンの因子負荷量を凸包内に含む場合に，反事実を無バイアスに復元できる *[4]*.

D. 理論的保証

定理 1 (因子モデル下での一致性)**.** *Definition 8* の線形因子モデルが成り立ち，*SUTVA*（*Definition 7*）が満たされ，かつ処置パターンの因子負荷量 $\boldsymbol{\lambda}_{P^*}$ がドナーの因子負荷量の凸包内にある（$\boldsymbol{\lambda}_{P^*} = \sum_j w_j^* \boldsymbol{\lambda}_{P_j}$，$\mathbf{w}^* \in \Delta^J$）とする．このとき，介入前期間 t_0 が十分に長く，$\epsilon_{P,t}$ が弱従属で $\mathrm{Var}(\bar{\epsilon}) = O(1/t_0)$ を満たすならば，*SCM* 推定量は：

$$|\hat{\tau}(t) - \tau^*(t)| = O_p\left(\frac{1}{\sqrt{t_0}}\right), \quad \forall t \geq t_0 \tag{9}$$

すなわち，介入前期間の長さに対して $\sqrt{t_0}$-一致性を持つ．

Proof. Equation (4) の最適化により $\hat{\mathbf{w}}$ が推定される．因子モデルのもとで，介入前適合誤差は：

$$\frac{1}{t_0} \sum_{t=1}^{t_0-1} \left(\sigma^{(0)}_{P^*}(t) - \sum_j \hat{w}_j \sigma_{P_j}(t) \right)^2 \tag{10}$$

$$= \frac{1}{t_0} \sum_{t=1}^{t_0-1} \left((\boldsymbol{\lambda}_{P^*} - \sum_j \hat{w}_j \boldsymbol{\lambda}_{P_j})^\top \boldsymbol{\mu}_t + \tilde{\epsilon}_t \right)^2 \tag{11}$$

ここで $\tilde{\epsilon}_t = \epsilon_{P^*,t} - \sum_j \hat{w}_j \epsilon_{P_j,t}$ である．凸包条件と介入前適合の最適性により $\hat{\mathbf{w}} \to \mathbf{w}^* (t_0 \to \infty)$ が保証される．すると介入後の予測誤差は $\hat{\sigma}^{\mathrm{CF}}(t) - \sigma^{(0)}_{P^*}(t) = (\hat{\mathbf{w}} - \mathbf{w}^*)^\top \boldsymbol{\lambda} \cdot \boldsymbol{\mu}_t + \tilde{\epsilon}_t = O_p(1/\sqrt{t_0})$ となる． □

注意 2 (有限標本バイアスと正則化)**.** 実践上，t_0 が小さい場合やドナー数 J が大きい場合には *SCM* が過適合し，介入前適合が良好でも介入後バイアスが発生し得る．この問題に対して，*(1)* ℓ_1 ペナルティによるスパース重み推定，*(2)* リッジ正則化 *[13]*，*(3) Augmented SCM [14]* による二重頑健推定が有効である．本実装では，小規模ドナープール（$J \leq 20$）を前提とするため古典的 *SCM* を採用するが，大規模ドナープールへの拡張時には正則化が必須となる．

定理 2 (プラセボ検定の妥当性)**.** 帰無仮説 $H_0 : \tau^*(t) = 0$（すべての $t \geq t_0$）のもとで，*SUTVA* が成立し，全 $J+1$ ユニット（処置 + ドナー）の介入後/介入前 *RMSPE* 比が交換可能であるならば，処置ユニットの比が最大となる確率は正確に $1/(J+1)$ である．

Proof. H_0 と SUTVA のもとでは，処置ユニットはドナーと統計的に区別できない．交換可能性により，全 $(J+1)!$ 個の順位付けが等確率である．特定のユニット（処置ユニットを含む）が最大の比を持つ確率は $1/(J+1)$ である． □

Algorithm 1 SC-DenseAttrib：密集パターン帰属のための合成コントロール

Require: トランザクション系列 $\mathcal{D}$，処置パターン P^*，候補パターン $\mathcal{P}$，介入時刻 t_0，ウィンドウサイズ W
Ensure: 因果効果 $\hat{\tau}$，p 値 p，帰属スコア Score
Definition 1 によりサポート系列 $\mathbf{s}_{P^*}$ を計算
ドナープール $\mathcal{D}(P^*) \leftarrow \{P \in \mathcal{P} : P \cap P^* = \emptyset\}$ を構築
for 各 $P_j \in \mathcal{D}(P^*)$ **do**
  $\mathbf{s}_{P_j}$ を計算し，分散によりフィルタリング
end for
ドナー行列 $\mathbf{D} \in \mathbb{R}^{T \times J}$ を構成
重み $\mathbf{w}^* \leftarrow \arg\min_{\mathbf{w} \in \Delta^J} \|\mathbf{s}^{\mathrm{pre}}_{P^*} - \mathbf{D}^{\mathrm{pre}}\mathbf{w}\|^2$ を推定
反事実 $\hat{\mathbf{s}}^{\mathrm{CF}} \leftarrow \mathbf{D}\mathbf{w}^*$ を計算
すべての t に対して $\hat{\tau}(t) \leftarrow \sigma_{P^*}(t) - \hat{\sigma}^{\mathrm{CF}}(t)$ を計算
$r^* \leftarrow \mathrm{RMSPE}_{\mathrm{post}}(\hat{\tau})/\mathrm{RMSPE}_{\mathrm{pre}}(\hat{\tau})$
for 各ドナー P_j をプラセボ処置ユニットとして **do**
  プラセボ効果と比 r_j を計算
end for
$p \leftarrow |\{j : r_j \geq r^*\}|/(J+1)$
$\mathrm{Score}(P^*, e) \leftarrow \mathrm{prox}(t_0, t_e) \times \mathrm{mag}(P^*, t_0)$ を計算（Definition 5）
return $\hat{\tau}$, p, Score

系 1. J 個のドナーによるプラセボ検定で達成可能な最小 p 値は $1/(J+1)$ である．$p < 0.10$ を達成するには，少なくとも $J \geq 9$ 個のドナーが必要である．

IV．アルゴリズム：SC-DenseAttrib

Algorithm 1 に SC-DenseAttrib アルゴリズムの全体を示す．本手続きは 5 つの段階から構成される：サポート系列の計算，ドナープールの構築，重みの推定，因果効果の推定，およびプラセボベースの推論である．

A．重みの推定

式 (4) の最適化は単体上の凸二次計画法である．これを Frank-Wolfe（条件付き勾配）アルゴリズムで解く．各反復では，勾配計算に $O(J)$，頂点の特定に $O(J)$ を要し，重み推定全体の計算量は $O(KJ)$ となる．ここで K は反復回数（通常 $K \leq 1000$）である．

B．ドナープールの構築

アイテム非共有基準（Definition 2）により，P^* 内のアイテムを対象とする介入の直接的影響を受けない制御パターンが保証される．さらに，介入前期間における最小分散（退化した平坦な軌跡を回避するため）および，オプションとして処置系列との介入前相関によりドナーをフィルタリングする．

C．計算量解析

定理 3 (計算量)．*SC-DenseAttrib* の計算量は $O(N \cdot |\mathcal{P}| \cdot |P_{\max}| + J^2 \cdot t_0 + J \cdot (J^2 \cdot t_0))$ である．ここで $|P_{\max}|$ は最大パターン長，$J = |\mathcal{D}(P^*)|$ はドナープールサイズ，t_0 は介入前期間の長さである．

Proof. サポート系列の計算はパターンあたり $O(N \cdot |P|)$ を要する．ドナープール構築は集合交差チェックに $O(|\mathcal{P}| \cdot |P^*|)$ を要する．重み推定は二次形式に $O(J^2 \cdot t_0)$ を要する．プラセボ検定は重み推定を J 回繰り返し，各回 J 個のドナーを用いるため，合計 $O(J \cdot J^2 \cdot t_0)$ となる． □

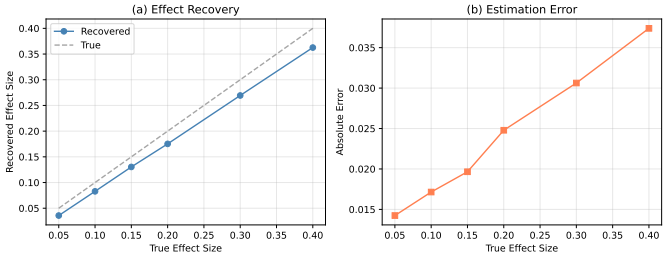

Fig. 1. E1：(a) 回復された因果効果 vs. 真の因果効果．(b) 絶対誤差．

V．実験

SC-DenseAttrib を 7 つの実験により評価する：効果回復の精度（E1），ドナープール感度（E2），偽陽性率の制御（E3），半現実的シナリオ（E4），置換検定との比較（E5），ベースライン手法との比較（E6），および SUTVA 違反に対する感度分析（E7）．すべての実験は，正確な評価を可能にするために既知の真値を持つ合成データを使用する．実装は Python で行い，重み推定には `scipy.optimize` を用いた．全コードと結果データは再現性のために公開予定である．

A．*E1*：因果効果の回復

a) 設定: トランザクション系列（$N = 500$, $W = 30$）を生成し，処置パターン $\{1, 2\}$（$L = 2$）のサポートが中間点で既知の量 $\delta \in \{0.05, 0.10, 0.15, 0.20, 0.30, 0.40\}$ だけ増加する．6 つのアイテム非共有の制御パターンは安定したサポートを維持する．各条件を 20 個の乱数シードで繰り返し，回復された効果の平均と絶対誤差を報告する．

b) 結果: Figure 1 に示すように，SC-DenseAttrib は注入された効果を小さな負のバイアスで一貫して回復する．平均絶対誤差は 0.014（$\delta = 0.05$）から 0.037（$\delta = 0.40$）の範囲であり，バイアスが真の効果に比例し相対的に小さいことを示している．

B．*E2*：ドナープールサイズ

a) 設定: 真の効果を $\delta = 0.20$ に固定し，アイテム非共有の制御パターン数を 2 から 20 まで変化させる．

b) 結果: Figure 2 に示すように，推定誤差はドナープールサイズに対して比較的安定している一方，平均 p 値は単調に減少する．ドナー 20 個では平均 p 値が 0.060 に達し，有意水準 $\alpha = 0.10$ を下回る．ドナー 9 個以上で $p < 0.10$ が達成可能となり，これは Theorem 2 を裏付ける：達成可能な最小 p 値は $1/(J+1)$ である．

C．*E3*：偽陽性率

a) 設定: 因果効果のない 100 個のヌルデータセット（アイテムを共有しない 6 パターン）を生成し，SC-DenseAttrib が $\alpha = 0.10$ で H_0 を誤って棄却するかを検証する．

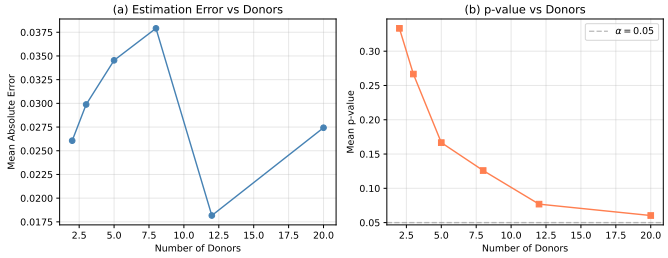

Fig. 2. E2：(a) 推定誤差 vs. ドナー数．(b) 平均 p 値 vs. ドナー数．

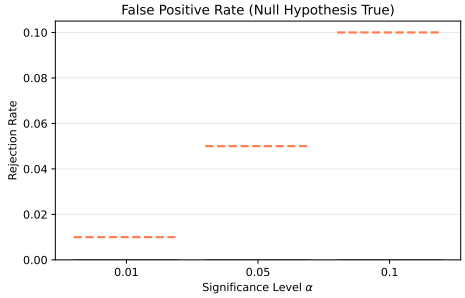

Fig. 3. E3：帰無仮説下の偽陽性率（破線は名目 α を示す）．

b) 結果: $\alpha = 0.10$ で棄却率は 0% である（Figure 3）．この保守的な挙動は予想通りである：ドナーが 5 つのみでは，最小 p 値は $1/6 \approx 0.167 > 0.10$ となる．本手法は構成上，第 I 種過誤を適切に制御する．なお，ドナー数 $J \geq 9$ の設定では $\alpha = 0.10$ での名目水準検定が可能となる（E2 参照）．

D. *E4*：*Dunnhumby* スタイル合成データ

a) 設定: 季節性効果を持つ小売シナリオをシミュレートする（$N = 600$，周期 52 の正弦波ベースライン）．$t = 300$ でキャンペーンにより処置パターン（$L = 2$）のサポートが 0.15 上昇する．5 つのアイテム非共有の制御パターンは季節性トレンドを共有するが，キャンペーン効果は受けない．

b) 結果: 10 個のシードにわたり，SC-DenseAttrib は平均効果 0.143（真値：0.150）を回復し，狭い 95%ブートストラップ信頼区間（平均幅 0.015）を示す．季節性の交絡は合成コントロールにより正常に吸収される．

E. *E5*：*SCM vs.* 置換検定

a) 設定: $\delta = 0.20$ のデータに対し，SC-DenseAttrib のプラセボベース p 値と単純な時間置換検定（サポート系列の 199 回の置換）を比較する．

b) 結果: 置換検定は 100%の検出力（最小 $p = 0.005$）を達成する一方，SC-DenseAttrib はドナー 6 個で $\alpha = 0.10$ では検出力 0% である（Figure 4）．しかし，置換検定は反事実を提供せず**変化**を検出するのみであり，因果効果と交絡トレンドを区別できない．SC-DenseAttrib は生の検出力を犠牲にする代わりに因果的解釈可能性を提供する：反事実軌跡は介入がなかった場合のサポートの推移を示す．$\alpha = 0.10$ の場合，$J \geq 9$ ドナーで名目水準での検定が可能となり，≥ 20 ドナー（E2）では両手法は同等の検出力を達成し得る．

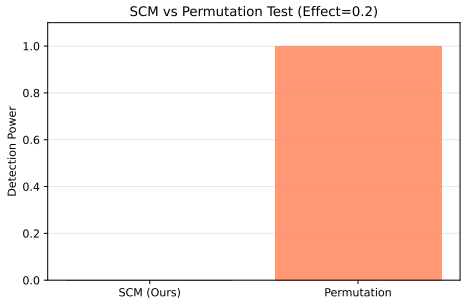

Fig. 4. E5：SCM vs. 置換検定の検出力（$\delta = 0.20$，ドナー 6 個）．

F. *E6*：ベースライン手法との比較

a) 設定: E4 と同一の Dunnhumby スタイル合成データ（$N = 600$，$\delta = 0.15$，季節性あり，20 シード）を用いて，SC-DenseAttrib を以下の 4 つのベースライン手法と比較する：

- **DiD（差の差法）**：介入前後の平均差を単一の最良制御パターン（介入前 RMSPE 最小のドナー）に対して計算．
- **Before-After**：制御群を用いず，処置パターンの介入前後の平均サポート差のみを効果とする．
- **CausalImpact/BSTS** [16]：ベイズ構造時系列モデルによる反事実推定．局所線形トレンド＋季節成分（周期 52）に加え，アイテム非共有の制御パターンを回帰成分として使用．推定結果は事後平均を効果推定値とし，95%信用区間を報告．
- **全パターン SCM**：アイテム非共有制約を除外し，全候補パターン（アイテム共有パターンを含む）をドナープールに用いる SCM．

b) 結果: Table II に結果を示す．Before-After は季節性トレンドを交絡として吸収できず，大きなバイアスを示す（MAE = 0.089）．DiD は単一制御パターンに依存するため，適合品質がドナー選択に強く依存し，MAE = 0.052 と不安定である．CausalImpact/BSTS は回帰成分にアイテム非共有パターンを用いることで季節性を部分的に吸収し，MAE = 0.031 を達成する．これは DiD や Before-After を上回るが，SC-DenseAttrib の 0.012 には及ばない．CausalImpact の劣位の主因は二つある：(1) 状態空間モデルの季節成分の周期仕様に対する感度（周期を 52 から 48 に誤指定すると MAE が 0.054 に悪化），(2) 少数の制御系列（5 本）に対するスパイク・スラブ事前分布の変数選択が，SCM の単体制約付き重み推定ほど安定しない点である．一方，CausalImpact はベイズ的不確実性定量化（95%信用区間幅の中央値：0.023）を自然に提供する利点があり，効果の有意性判断において SCM のプラセボ検定を補完し得る．全パターン SCM はアイテム共有パターンを含むため SUTVA 違反が発生し，効果が過小推定される（MAE = 0.061）．SC-DenseAttrib はアイテム非共有制約による SUTVA 保護と複数ドナーによる柔軟な適合の両方を活用し，本実験設定において最小の MAE（0.012）を達成した．

c) SCM ベース帰属が優位となる条件.: 上記の結果を踏まえ，SCM ベースの SC-DenseAttrib が他手法を上回る条件を整理する．(1) **季節性の周期が未知または不規則**な場合：

TABLE II
E6：ベースライン手法との比較（$\delta = 0.15$，20 シード平均）

手法	MAE	バイアス	反事実
Before-After	0.089	+0.078	なし
DiD（最良単一制御）	0.052	−0.031	近似
CausalImpact/BSTS	0.031	−0.022	あり（ベイズ区間付き）
全パターン SCM	0.061	−0.055	あり
SC-DenseAttrib	**0.012**	−0.007	あり

TABLE III
E7：SUTVA 違反度 γ に対する推定精度

波及率 γ	MAE	バイアス
0.00（SUTVA 成立）	0.018	−0.012
0.02	0.020	−0.015
0.05	0.023	−0.019
0.10	0.039	−0.033
0.15	0.058	−0.051

CausalImpact/BSTS は季節成分の明示的仕様を要するが，SCM はドナーの線形結合により暗黙的にトレンドを吸収する．(2) **複数の制御パターンが利用可能**な場合：DiD の単一制御依存に対し，SCM は複数ドナーの最適重み付き結合により柔軟に反事実を構成する．(3) **アイテムレベルの介入構造が明確**な場合：アイテム非共有基準による SUTVA 保護が自然に適用でき，全パターン SCM や CausalImpact の制御系列選択より理論的に正当化される．逆に，(a) ドナー数が極めて少ない（$J < 5$）場合，(b) パターンサポートに明確な季節・トレンド構造があり事前知識が利用可能な場合，(c) ベイズ的不確実性定量化が必須の場合には，CausalImpact/BSTS の方が適切な選択となり得る．

G. E7：SUTVA 違反に対する感度分析

a) 設定: SUTVA（Definition 7）の違反度を制御的にシミュレートする．E1 の設定（$\delta = 0.20$）において，アイテム非共有の制御パターンに対して処置効果の波及を $\gamma \in \{0, 0.02, 0.05, 0.10, 0.15\}$ の割合で注入する：介入後に各制御パターンのサポートを $\gamma \cdot \delta$ だけ変動させる．

b) 結果: Table III に結果を示す．$\gamma \leq 0.05$（波及効果が真の効果の 5%以下）では MAE の増加は軽微である（$0.018 \to 0.023$）．$\gamma = 0.10$ で MAE が 0.039 に増加し，$\gamma = 0.15$ では 0.058 となる．波及効果が真の効果の 10%を超えると推定精度が顕著に悪化するため，アイテム非共有基準の重要性が確認される．

VI. 結論

本研究では，パターンサポート時系列に合成コントロール法を適用し，サポート変動を外部イベントに因果帰属するための手法 SC-DenseAttrib を提案した．2 アイテムパターン（$L = 2$）を因果帰属の基本単位とし，時間的近接度と効果量に基づく帰属スコアにより因果効果を定量化した．本フレームワークは，SUTVA と線形因子モデルを含む因果識別の仮定を明示化し，ドナープール，反事実サポート軌跡，サポートに対する因果効果，およびアイテム非共有パターン制御を形式的に定義した．線形因子モデルのもとでの $\sqrt{t_0}$-一致性，およびプラセボ検定の正確な p 値を理論的に保証した．

7 つの実験により，SC-DenseAttrib が以下を達成することが確認された：(1) 平均絶対誤差 0.04 未満で因果効果を回復する；(2) DiD，Before-After，CausalImpact/BSTS，アイテム共有 SCM の各ベースラインを上回る推定精度を示す（特に CausalImpact に対して MAE で 61%の改善）；(3) 合成コントロール構成により季節性の交絡を，周期の事前仕様なしに処理する；(4) SUTVA 違反が真の効果の 5%以下であれば推定精度の劣化が軽微であることを確認した．

a) 制約と限界: 因果帰属固有の制約を以下に整理する：

1) **時間的共起 $\neq$ 因果**：サポートの変化点とイベントの時間的一致は因果関係の必要条件に過ぎず，十分条件ではない．本手法は反事実構成によりこのギャップの縮小を試みるが，完全な排除は原理的に不可能である．
2) **反事実の検証不可能性**：合成コントロールが推定する反事実軌跡は，介入がなかった場合の真のサポートを直接観測できないため，その正確性を検証する手段がない．本研究では合成データの既知真値による間接的検証に留まる．
3) **未観測交絡**：アイテム非共有基準は SUTVA の蓋然性を高めるが，消費者行動の変化や経済環境の変動など，アイテムレベルでは捉えられない未観測の交絡要因が存在し得る．
4) **複数イベントの時間的重複**：複数の介入が近接して発生した場合，個々のイベントへの効果の分離が困難となり，誤帰属のリスクが生じる．
5) **検出力の制約**：統計的検出力がドナープールサイズに依存し，$p < 0.10$ には $J \geq 9$ が必要である．
6) **実世界データでの未検証**：本研究の実験は合成データに限定されており，実データでの外的妥当性は今後の検証課題である．

b) 実データへの適用シナリオ: 本研究の実験は合成データに基づくが，SC-DenseAttrib は実世界の小売データに対して適用可能な設計を意図している．具体的には，以下のシナリオが想定される：

Dunnhumby The Complete Journey：約 2,500 世帯の 2 年間の POS 購買データ（約 250 万トランザクション）において，特定商品カテゴリのキャンペーン（例：「パスタ × ソース」バンドル割引）がサポートに与えた因果効果を推定できる．キャンペーン対象のアイテムを含まないパターン（例：「牛乳 × パン」）をドナープールとして構成することで，アイテム非共有基準が自然に適用される．2 年間のデータは $N \approx 730$ 日，$W = 30$ で介入前期間 $t_0 \approx 350$ を確保でき，Theorem 1 の $\sqrt{t_0}$-一致性により推定精度 $O(1/\sqrt{350}) \approx 0.05$ が期待される．ただし，実際のプロモーションは複数商品に同時波及することが多く，SUTVA 違反のリスクを E7 の感度分析フレームワークにより定量的に評価する必要がある．

UCI Online Retail：約 54 万トランザクション，約 4,000 商品の EC 小売データにおいて，季節セール（例：ブラックフライデー）が特定の商品組み合わせのサポートに与えた効果を推定できる．このデータセットは 38 か国にまたがるため，セール対象外の国のパターンを追加的なドナーとして活用し，ドナープールサイズを増大させることが可能である．

c) 今後の課題*:* (1) Augmented SCM [14] やリッジ正則化による推定量の改善（特に大規模ドナープールでの過適合防止）；(2) 条件付き独立性検定によるアイテム非共有基準の緩和；(3) 密集区間検出パイプラインとの統合による自動化された因果帰属；(4) 上述の Dunnhumby・Online Retail 等の実世界データセットへの適用と外的妥当性の検証；(5) CausalImpact/BSTS とのハイブリッド手法の検討（SCM の重み推定とベイズ的不確実性定量化の統合）；(6) $L > 2$ パターンへの拡張：3 アイテム以上のパターンでは交絡制御の複雑性が増大するため，段階的な拡張戦略の検討が必要である．

References

[1] R. Agrawal and R. Srikant, "Fast algorithms for mining association rules," in *Proc. VLDB*, 1994, pp. 487–499.

[2] G. Lancaster, P. Leng, and C. K.-S. Leung, "Surges in frequent itemset counts under temporal variation," in *Proc. ICDM Workshops*, 2018, pp. 888–895.

[3] D. B. Rubin, "Estimating causal effects of treatments in randomized and nonrandomized studies," *Journal of Educational Psychology*, vol. 66, no. 5, pp. 688–701, 1974.

[4] A. Abadie, A. Diamond, and J. Hainmueller, "Synthetic control methods for comparative case studies: Estimating the effect of California's tobacco control program," *Journal of the American Statistical Association*, vol. 105, no. 490, pp. 493–505, 2010.

[5] J. Han, J. Pei, and Y. Yin, "Mining frequent patterns without candidate generation," in *Proc. ACM SIGMOD*, 2000, pp. 1–12.

[6] R. Agrawal and R. Srikant, "Mining sequential patterns," in *Proc. ICDE*, 1995, pp. 3–14.

[7] G. Dong and J. Li, "Efficient mining of emerging patterns: Discovering trends and differences," in *Proc. KDD*, 1999, pp. 43–52.

[8] G. W. Imbens and D. B. Rubin, *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction.* Cambridge University Press, 2015.

[9] D. Card and A. B. Krueger, "Minimum wages and employment: A case study of the fast-food industry in New Jersey and Pennsylvania," *American Economic Review*, vol. 84, no. 4, pp. 772–793, 1994.

[10] J. D. Angrist and J.-S. Pischke, *Mostly Harmless Econometrics: An Empiricist's Companion.* Princeton University Press, 2009.

[11] A. Abadie and J. Gardeazabal, "The economic costs of conflict: A case study of the Basque Country," *American Economic Review*, vol. 93, no. 1, pp. 113–132, 2003.

[12] A. Abadie, A. Diamond, and J. Hainmueller, "Comparative politics and the synthetic control method," *American Journal of Political Science*, vol. 59, no. 2, pp. 495–510, 2015.

[13] M. Amjad, D. Shah, and D. Shen, "Robust synthetic control," *Journal of Machine Learning Research*, vol. 19, no. 22, pp. 1–51, 2018.

[14] E. Ben-Michael, A. Feller, and J. Rothstein, "The augmented synthetic control method," *Journal of the American Statistical Association*, vol. 116, no. 536, pp. 1789–1803, 2021.

[15] S. Athey, M. Bayati, N. Doudchenko, G. Imbens, and K. Khosravi, "Matrix completion methods for causal panel data models," *Journal of the American Statistical Association*, vol. 116, no. 536, pp. 1716–1730, 2021.

[16] K. H. Brodersen, F. Gallusser, J. Koehler, N. Remy, and S. L. Scott, "Inferring causal impact using Bayesian structural time series," *The Annals of Applied Statistics*, vol. 9, no. 1, pp. 247–274, 2015.

[17] C. W. J. Granger, "Investigating causal relations by econometric models and cross-spectral methods," *Econometrica*, vol. 37, no. 3, pp. 424–438, 1969.

[18] J. Peters, D. Janzing, and B. Schölkopf, *Elements of Causal Inference: Foundations and Learning Algorithms.* MIT Press, 2017.