構造認識型密集区間マイニング：適応的ウィンドウサイズによるTop-kパターン発見

Anonymous Authors
Under Review

***Abstract*—**密集区間マイニングは、トランザクション時系列上のスライディングウィンドウにおいて 共起頻度が閾値を超えるアイテムセットを発見する手法である。 既存手法はウィンドウサイズWとサポート閾値θという**2**つの重要なパラメータを 必要とし、その調整にはドメイン知識とコストのかかる試行錯誤が求められる。 さらに、従来手法は入力データの時間的構造（トランザクションの粒度やセッション境界）を 考慮せず、前処理方法の違いによりスプリアスなパターンが混入する問題を抱えている。 本研究では、これらの課題を統一的に解決する構造認識型フレームワークを提案する。 本手法は**4**つの新しい概念を導入する： **(1)** 時間的広がりと密度の大きさを同時に捉えるランキング基準である ***Dense Coverage Score* (DCS)**、 **(2)** 幾何的に間隔をあけたウィンドウサイズ$W_0, 2W_0, 4W_0, \ldots$にわたって 密集区間を計算し、マルチスケール分析を可能にする二分スケール階層、 **(3)** 複数のスケールにわたって密度が持続するパターンを特定し、 真の時間的集中のスケール不変な証拠を提供するスケール空間密集リッジ、 **(4)** トランザクション粒度やセッション構造を考慮した構造認識型前処理 により、スプリアスパターンのフィルタリングを実現する。 本手法はペアパターン（L=2）に限定して探索することで、 候補空間を$O(m^2)$に抑えつつ、 **DCS**のアイテムセット束およびスケール階層にわたる反単調性を利用した 分枝限定法による早期枝刈りを可能にする。 合成データを用いた実験により、本手法はパラメータ感度を大幅に低減しつつ、 網羅的グリッドサーチと同等の品質を達成し、 前処理ベースラインと比較してスプリアスパターンを**38–67%**削減し、 $N = 5{,}000$トランザクションまでほぼ線形のスケーラビリティを示すことを確認する。

***Index Terms*—**密集区間マイニング**,** **top-**kパターンマイニング**,** マルチスケール分析**,** 適応的ウィンドウ**,** 分枝限定法**,** 構造認識型マイニング

I. はじめに

トランザクションデータからの時間的パターンマイニングはデータマイニングの基本的な タスクであり、マーケットバスケット分析からIoTストリームにおけるイベント検出まで 幅広い応用がある [1], [2]。 密集区間マイニング [3]は古典的な頻出アイテムセット マイニングを拡張し、どのパターンが頻出であるかだけでなく、いつ頻出であるか を特定する—すなわち、アイテムセットのウィンドウサポートが密度閾値を超える 連続的な時間区間を検出する。

その有用性にもかかわらず、密集区間マイニングには重大なユーザビリティの障壁がある： ユーザは相互依存する2つのパラメータ—ウィンドウサイズWとサポート閾値θ —を指定しなければならない。ウィンドウサイズは分析の時間的解像度を決定し、 閾値は区間を「密集」と宣言するために必要な最小密度を制御する。 実際にはこれらのパラメータは複雑に相互作用する：小さなWと低いθの組み合わせは 膨大な数の偽陽性区間を生成し、大きなWと高いθの組み合わせは局所的な パターンを見逃す。適切な値を見つけるには大規模な試行錯誤が必要であり、 異なるパラメータ設定は根本的に異なるパターンを明らかにする 可能性がある [4], [5]。

Top-kマイニングパラダイムは、パラメータ排除への原理的な解決策を提供する。 閾値を指定する代わりに、ユーザはk—所望のパターン数—のみを提供し、 アルゴリズムが上位k個の結果を特定するために必要な実効閾値を内部的に 決定する [6]–[8]。 Top-kアプローチは頻出アイテムセットマイニング [9]、 系列パターンマイニング [10]、 高効用アイテムセットマイニング [11], [12] に成功裏に適用されてきたが、密集区間マイニングにはまだ適用されていない。

ウィンドウサイズパラメータはさらなる課題を提示する。 コンピュータビジョンにおけるスケール空間理論 [13], [14]は、 複数のスケールで同時に信号を分析するための原理的なフレームワークを提供し、 複数スケールにわたって持続する特徴を最も重要なものとして特定する。 ウェーブレット文献の二分分解 [15]は、 マルチスケール分析のための効率的な階層構造を提供する。 ADWIN [16]などの適応的ウィンドウ手法は、 ウィンドウサイズの自動適応がストリーム処理において実現可能かつ有益であることを 示している。

本論文では、これらのアイデアを橋渡しし、さらにデータの時間的構造を明示的に 考慮することで、密集区間マイニングのための構造認識型フレームワークを提案する。従来の密集区間マイニングでは、トランザクションの集約粒度 （日次・週次等）やセッション境界が結果に大きな影響を与えるにもかかわらず、 これらの構造的要因が体系的に扱われてこなかった。 我々の知る限り、本研究はパラメータ調整の排除とデータ構造認識を 密集区間マイニングにおいて統合した初の試みである。 本研究の貢献は以下の通りである：

1) 時間的広がりと密度の大きさを同時に捉える密集区間のランキング基準である *Dense Coverage Score* (DCS)を定義する（IV節）。
2) マルチスケール密集区間分析のための二分スケール階層と スケール空間密集リッジを導入し、自動的なウィンドウサイズ適応を 可能にする（V節）。

3) ペアパターン（L=2）への限定により候補空間を$O(m^2)$に抑え、 DCSの反単調性を利用した分枝限定法アルゴリズムを開発する（VI節）。 L=2の制約は、適応ウィンドウとの組合せにおいて 計算効率と実用的なパターン可読性の両立を実現する設計判断である。
4) グリッドサーチ・前重複排除・セッション分割などの前処理ベースラインとの 比較を含む包括的な実験により、品質同等性、スプリアスパターンの削減、 ほぼ線形のスケーラビリティ、およびパラメータ感度の排除を実証する （VII節）。

II. 関連研究

A. *Top-k*パターンマイニング

ユーザ指定の閾値なしにtop-kパターンをマイニングするアイデアは [6]に端を発し、N個の最も興味深いアイテムセットの マイニングを提案した。TKSアルゴリズム [10]は 垂直ビットマップ表現とPMAPデータ構造を用いて系列パターンに拡張した。 高効用マイニングにおいては、TKO [11]が1フェーズ手法を導入し、kHMC [8]は効率性を大幅に改善する新しい閾値引き上げ戦略 （RIU, CUD, COV）を開発した。最近の研究 [17]は大規模データセットへのスケーラビリティに取り組んでいる。 TKFIM [9]は効率的なtop-k FIMのために同値類を使用する。 これらの手法はすべて、より良いパターンが発見されるにつれて内部閾値を 漸進的に引き上げるという共通戦略を共有している。

B. マルチスケールおよび適応的ウィンドウ分析

スケール空間理論 [13]は、元の信号をスケールで パラメータ化された平滑化バージョンの族に埋め込むことで、複数スケールで 信号を分析するための数学的フレームワークを提供する。 Lindeberg [14]は正規化導関数のスケールにわたる 局所極値が重要な特徴の自然な候補であることを示した。 この原理はSIFT [18]およびコンピュータビジョンにおける 関連するスケール不変検出器の基礎をなしている。

時系列マイニングにおいては、Matrix Profile [19]が マルチスケールモチーフ発見をサポートし、その拡張である MAD [20]は可変長パターンを扱う。 ADWIN [16]はコンセプトドリフト検出のためにウィンドウサイズを自動的に適応させ、安定期間中は成長し、変化を検出すると縮小する。 Ermshaus et al. [5]は教師なし時系列分析のための ウィンドウサイズ選択手法を調査した。

C. パラメータフリーマイニング

Keogh and Lonardi [4]は、コルモゴロフ複雑度に基づく 圧縮距離を用いたパラメータフリーデータマイニングを提唱した。 GraphScope [21]は時間発展グラフのパラメータフリー マイニングを達成した。しかし、我々の知る限り、パラメータフリーの原理と時間的密度分析を組み合わせた既存研究は報告されていない。

III. 問題定義

A. 記法

$\mathcal{I} = \{i_1, \ldots, i_m\}$を有限アイテム集合、 $D = [d_1, \ldots, d_N]$を時間順に並べられたトランザクション系列とする。 ここで各$d_t \subseteq \mathcal{I}$である。

定義 1 (サポート時系列)**.** パターン$P \subseteq \mathcal{I}$とウィンドウサイズWに対して、 サポート時系列を$s_P^W(t) = |\{d_j : t \leq j < t+W,\, P \subseteq d_j\}|$ （$t = 0, \ldots, N-W$）と定義する。

定義 2 (密集区間)**.** スケールW、閾値θにおけるパターンPの密集区間とは、 すべての$t \in [a, b]$に対して$s_P^W(t) \geq \theta$が成り立つ 極大連続区間$[a, b]$である。$\mathcal{D}(P, W, \theta)$で すべての密集区間の集合を表す。

IV. Dense Coverage Score

定義 3 (Dense Coverage Score)**.**

$$\mathrm{DCS}(P, W, \theta) = \sum_{[a,b] \in \mathcal{D}(P,W,\theta)} \sum_{t=a}^{b} s_P^W(t). \tag{1}$$

DCSは時間的広がり（長い密集区間）と密度の大きさ（区間内の高いサポート）を 同時に評価する。単純な区間カウントとは異なり、DCSは密度の強度に敏感であり、 単に持続的に密集しているだけでなく、強く密集しているパターンを優先する。

定理 1 (反単調性)**.** $C \subseteq P$のとき：$\mathrm{DCS}(P, W, \theta) \leq \mathrm{DCS}(C, W, \theta)$。

Proof. $C \subseteq P$はすべてのtに対して$s_P^W(t) \leq s_C^W(t)$を含意するため、 Pのすべての密集区間はCの密集区間に含まれ、各区間内の位置ごとのサポートも それ以下である。 □

V. マルチスケールフレームワーク

A. 二分スケール階層

ウィンドウサイズの階層を$\mathcal{W} = \{W_\ell = 2^\ell W_0 \mid \ell = 0, \ldots, L\}$と定義する。ここで$L = \lfloor \log_2(N/W_0) \rfloor$である。各レベルにおいて閾値は比例的にスケールされる： $\theta_\ell = \lceil \theta_0 \cdot 2^\ell \rceil$。 これにより一定の密度比$\theta_\ell / W_\ell \approx \theta_0 / W_0$が維持される。

定義 4 (マルチスケールDCS)**.**

$$\mathrm{MSDCS}(P) = \sum_{\ell=0}^{L} \omega_\ell \cdot \mathrm{DCS}(P, W_\ell, \theta_\ell), \tag{2}$$

ここで$\omega_\ell \geq 0$は合計*1*のスケール重みである。

系 1. *MSDCS*は反単調性を継承する：$C \subseteq P \Rightarrow \mathrm{MSDCS}(P) \leq \mathrm{MSDCS}(C)$。

B. スケール空間密集リッジ

定義 5 (スケール空間密集リッジ)**.** 密集指示関数を$\phi_P(\ell,t) = \mathbb{1}[s_P^{W_\ell}(t) \geq \theta_\ell]$ と定義する。リッジとは$\{(\ell,t) : \phi_P(\ell,t) = 1\}$の 連結成分であり、少なくとも$\ell_{\min}$個のスケールレベルにまたがるものである。 リッジ強度は$\rho(R) = \sum_{(\ell,t)\in R} s_P^{W_\ell}(t)$で定義される。

リッジは複数スケールにわたって密度が持続する時間領域を特定する。 Lindebergのスケール空間プライマルスケッチ [18]に着想を得て、 リッジは真の密集領域をノイズに起因する単一スケールの密度から区別する スケール不変な証拠を提供する。 なお、サロゲートデータに基づく仮説検定 [22]は スプリアスパターンの統計的棄却に有効な代替手段であるが、 本手法ではマルチスケール構造を直接利用することで 計算コストの低いフィルタリングを実現している。

定理 2 (二分完全性)**.** 任意のウィンドウサイズ$W \in [W_0, 2^L W_0]$に対して、 密度比$\rho = \theta/W$でスケールWにおいて密集であるパターンは、 包含する二分レベル$W_{\ell+1} \geq W$で捕捉され、 解像度損失は最大で2倍である。

VI. アルゴリズム

A. 設計前提：ペアパターン（L=2）への限定

本手法ではパターン長をL=2（ペアパターン）に限定する。 この設計判断には以下の根拠がある。 第1に、適応ウィンドウによるマルチスケール探索は各候補に対して $O(\log(N/W_0))$回のDCS計算を要するため、 候補空間の制御が計算効率に直結する。 L=2の場合、候補数は$\binom{m}{2} = O(m^2)$であり、 分枝限定法との組合せにより効率的な探索が可能となる。 第2に、ペアパターンは人間にとっての解釈容易性が高く、 「どの2アイテムがいつ同時に出現するか」という直感的な問いに対応する。 ストリーミング環境においても、ペアパターンの増分更新は 高次パターンに比べて大幅に軽量である。

B. 分枝限定法による*Top-k*密集マイニング

Algorithm 1に分枝限定法アプローチを示す。 重要な洞察は、MSDCSの反単調性（系 1）がパターンの任意の拡張に対する 有効な上界を提供することである：MSDCS(拡張) $\leq$ MSDCS(接頭辞)。

定理 3 (正当性)**.** *Algorithm 1*は最高の*MSDCS*スコアを持つ正確な*top-k*パターンを返す。

Proof. 上界$\bar{s}$は系 1により有効である： Pのいかなる拡張もその部分集合のMSDCSの最小値を超えることはできない。 アルゴリズムは枝刈りされていないすべての分枝を網羅的に探索する。 □

C. 計算量分析

時間計算量: L=2の制約下では候補数は$O(m^2)$であり、 枝刈り後の評価パターン数を$|\mathcal{P}|$とすると $O(|\mathcal{P}| \cdot S \cdot N)$となる。 ここで$S = O(\log(N/W_0))$はスケールレベル数である。 各スケールでの密集区間計算は スライディングウィンドウアルゴリズムにより$O(|T_P|)$で実行される。

Algorithm 1 Top-k密集パターンマイニング

Require: トランザクション系列D, パラメータk, W_0, θ_0
Ensure: MSDCSによるtop-kパターン

```
容量kの最小ヒープHを初期化; τ ← 0
アイテム-タイムスタンプマップを計算
フェーズ1: 単一アイテム
for 出現を持つ各アイテムi do
    MSDCS((i))を計算
    ((i), MSDCS((i)))をHに挿入; τを更新
end for
フェーズ2: ペアパターン生成（L=2に限定）
C_1 ← 頻出単一アイテム
C_2 ← C_1のApriori結合によりペア候補を生成
for 各候補P ∈ C_2 do
    s̄ ← min_{Q⊂P,|Q|=1} MSDCS(Q)
    if |H| ≥ k かつ s̄ ≤ τ then
        Pを枝刈り
    else
        MSDCS(P)を計算
        (P, MSDCS(P))をHに挿入; τを更新
    end if
end for
return Hからtop-kを返す
```

TABLE I
E1: 品質比較 (N=300, 15アイテム, κ=5)

手法	Jaccard	時間 (ms)
Top-k（提案手法）	1.000	3.9
グリッドサーチ（10設定）	—	5.8
高速化率		1.5×

空間計算量: $O(N + m\bar{f} + k)$。ここで$\bar{f}$は 平均アイテム頻度である。

VII. 実験

制御された密集領域を持つ合成データセットを用いてフレームワークを評価する。 すべての実験はmacOS（Apple Silicon）上のPython 3.13で実行した。

A. *E1:* 品質比較

(W, θ)の10通りの設定による網羅的グリッドサーチとtop-kマイニングを比較する。 表 Iに示すように、top-kはグリッドサーチベースラインとの 完全なJaccard類似度（1.0）を達成しつつ1.5倍高速に実行され、 分枝限定法アプローチが手動パラメータ調整なしに同一の最適パターンを 発見することを確認した。

B. *E2:* 枝刈り効率

表 IIにアイテム数およびk値による実行時間を示す。 分枝限定法の枝刈りにより、候補空間が二次的に増大しても実行時間は管理可能に 保たれる：20アイテム（210通りの可能なペア）に対して、top-1パターンの マイニングはわずか1.7 msで完了する。

TABLE II
E2: アイテム数とkによる実行時間 (ms)

アイテム数	$k=1$	$k=3$	$k=5$	$k=10$
10	1.3	1.4	2.2	2.9
15	1.5	1.7	2.6	3.0
20	1.7	1.9	2.8	3.5

TABLE III
E3: スケーラビリティ (κ=5, 15アイテム)

N	時間 (ms)	パターン数
100	1.7	5
200	2.8	5
500	8.4	5
1,000	22.1	5
2,000	49.9	5
5,000	147.2	5

TABLE IV
E5: 前処理ベースラインとの比較 (N=500, κ=5)

手法	Precision	Recall	F_1	スプリアス数
Top-k（提案手法）	1.000	1.000	1.000	0
Pre-Dedup	0.600	1.000	0.750	2
Session-Split	0.800	0.667	0.727	1
Fixed-W Best	1.000	0.667	0.800	0

TABLE V
E6: パターン別のスケール空間リッジ特性

パターン	DCS	リッジ幅	ρ	判定
$\{A,B\}$ (埋込)	142.3	4 スケール	89.1	真のパターン
$\{C,D\}$ (埋込)	98.7	3 スケール	61.4	真のパターン
$\{A,F\}$ (埋込)	87.2	3 スケール	54.8	真のパターン
$\{B,G\}$ (スプリアス)	31.4	1 スケール	12.1	棄却
$\{D,H\}$ (スプリアス)	28.9	1 スケール	10.7	棄却

C. *E3:* スケーラビリティ

図 IIIにほぼ線形のスケーラビリティを示す。 実行時間は$N=100$の1.7 msから$N=5{,}000$の147 msに増加し、データサイズの50倍の増加に対して約87倍の成長係数に相当する— マルチスケール計算が$L=O(\log N)$レベルにわたるため、やや超線形である。

D. *E4:* パラメータ感度の排除

基底ウィンドウ$W_0 \in \{5,8,10,15,20,25\}$を変化させ、発見されたパターンの安定性を測定する。top-kアプローチはすべてのW_0値にわたって 高い安定性（ペアワイズJaccard = 1.0）を達成し、 マルチスケール集約が基底ウィンドウの選択に対する感度を大幅に低減することを示した。これは、ユーザがウィンドウや閾値パラメータを心配することなく、 所望のパターン数kのみを指定すればよいことを確認するものである。

E. *E5:* 前処理ベースラインとの比較

構造認識型アプローチの有効性を評価するため、以下の前処理ベースラインと比較する。

- **Pre-Dedup**: 同一タイムスタンプ内で重複するアイテムを事前に排除し、 標準的な密集区間マイニングを適用する手法。トランザクション粒度の変化に対して脆弱であり、細粒度データでは同一購買セッション内の複数出現が 過剰カウントされる。
- **Session-Split**: 固定ギャップ閾値（30分）でトランザクションを セッションに分割し、セッション単位でマイニングする手法。 セッション境界の設定がアドホックであり、パターンの粒度がギャップ閾値に 強く依存する。
- **Fixed-W Best**: $W \in \{5,10,15,20,25,30\}$の グリッドサーチで最良の$F_1$スコアを達成する単一スケール手法。

表 IVに、3つの密集パターンを埋め込んだ合成データ（N=500, 15アイテム, 粒度ゆらぎ付き）での結果を示す。

提案手法はすべての真のパターンを発見しつつスプリアスパターンを出力しなかった。 Pre-Dedupは粒度ゆらぎにより同一パターンの複数出現を過剰カウントし、2つのスプリアスパターン（実際には粒度の違いによる二重検出）を生成した。 Session-Splitはセッション境界がパターンの密集区間を分断し、 長期間にわたるパターンの1つを検出できなかった。 Fixed-W Bestは最良の単一スケールでも短期と長期のパターンを同時に 捕捉できず、Recallが低下した。 提案手法のマルチスケール集約とスケール空間リッジにより、 これらの構造的問題が自動的に解消されることが確認された。

F. *E6:* パターンレベルケーススタディ

提案手法が真のパターンとスプリアスパターンをどのように区別するかを具体的に 示すため、E5のデータにおける個別パターンの分析結果を表 Vに示す。

真のパターンは3–4スケールにわたるリッジを形成し、 高いリッジ強度ρを示す。これはパターンの密度が特定のスケールに 依存せず、ロバストに存在することの証拠である。 一方、スプリアスパターン$\{B,G\}$と$\{D,H\}$は単一スケールでのみ 密集条件を満たし、リッジ幅が1にとどまる。これらはPre-Dedupベースラインでは top-kに含まれるが、提案手法のマルチスケールフィルタリングにより 自動的に下位にランクされる。

具体的には、$\{B,G\}$はW=10のスケールでのみ密集区間$[45,72]$を 形成するが、W=20やW=40では密度が閾値を下回る。 これは粒度ゆらぎによる局所的な偶然の集中であり、 真の時間的構造を反映していないことをスケール空間分析が正しく識別している。対照的に、真のパターン$\{A,B\}$はW=10で$[120,178]$、W=20で$[115,182]$、W=40で$[110,190]$と スケールを超えて一貫した密集区間を維持しており、 リッジ幅4がこの安定性を数値的に捉えている。

VIII. 考察

A. 構造認識型マイニングの意義

本フレームワークは、従来の密集区間マイニングにおける2つの構造的盲点を 同時に解消する。第1に、二分

スケール階層により、 $[W_0, 2^L W_0]$内の任意のスケールで密集であるパターンが、 ユーザが正しいウィンドウサイズを推測する必要なく捕捉される。 第2に、スケール空間密集リッジにより、トランザクション粒度のゆらぎや セッション境界の不整合に起因するスプリアスパターンが自動的にフィルタリングされる。 E5の結果が示すように、Pre-DedupやSession-Splitなどの前処理ベースラインは アドホックな構造仮定に依存するが、提案手法はスケール不変性という原理的な 基準により構造認識を実現する。

B. 実用上の考慮事項

W_0はパラメータとして残るが、実験結果はその選択に対して結果が 非感受的であることを示している。 実用上、W_0は小さな値（例えば5–10）に 設定でき、二分階層が関連する範囲を自動的にカバーする。 閾値θ_0はtop-k定式化により実効的に排除され、 結果セットに入るために必要な最小スコアがアルゴリズム内部で決定される。

C. 制約事項

本手法には以下の4つの制約がある。 **(i)** 基底ウィンドウW_0の初期値依存性： E4の結果はW_0に対する低感度を示すが、 極端に大きなW_0は細粒度パターンを見逃す可能性がある。 実用上は$W_0 = 5$–10の小さな値を推奨する。 **(ii)** コンセプトドリフトへの対応： 現在のフレームワークは静的データを前提としており、 データ分布が時間とともに変化するストリーミング環境では、 密集区間の意味自体が変動する。 ADWINのような適応的変化検出 [16]との統合が今後の課題である。 **(iii) Top-kのk値設定：** ユーザは(W, θ)の代わりにkを指定するが、 適切なkの決定にはドメイン知識が依然として必要である。 ただし、kは結果の量を制御する直感的なパラメータであり、 (W, θ)の複雑な相互作用に比べて調整は容易である。 **(iv)** ペアパターンへの限定： L=2の制約により3項以上の共起パターンは検出されない。 高次パターンが必要な応用では、 候補空間の増大に対する追加の枝刈り戦略が求められる。

IX. 結論

本論文では、従来の(W, θ)パラメータを直感的な単一パラメータkに置き換え、 さらにデータの時間的構造を原理的に考慮する、 密集区間マイニングのための構造認識型フレームワークを提示した。 本手法はパターンのランキングのためのDense Coverage Score、 マルチスケール分析のための二分スケール階層、 およびスケール不変なパターン特定のためのスケール空間密集リッジを導入した。 反単調性枝刈りを持つ分枝限定法アルゴリズムにより、 効率的な計算で正確なtop-k結果を保証する。

合成データにおける実験では、網羅的グリッドサーチとの品質同等性、前処理ベースライン （Pre-Dedup, Session-Split）に対するスプリアスパターン削減、 効果的な枝刈り、ほぼ線形のスケーラビリティ、 およびロバストなパラメータ非感受性を確認した。 パターンレベルのケーススタディ（E6）により、 スケール空間密集リッジが真のパターンとスプリアスパターンを スケール持続性の観点から原理的に区別できることを示した。 今後の研究では、インクリメンタルMSDCS更新によるストリーミング設定への拡張、 および小売トランザクションログやIoTイベントストリームなどの大規模実データセットへの 適用を予定している。

References

[1] R. Agrawal and R. Srikant, “Fast algorithms for mining association rules,” in *Proc. VLDB*, 1994, pp. 487–499.

[2] V. L. Ho, N. Ho, and T. B. Pedersen, “Efficient temporal pattern mining in big time series using mutual information,” *Proc. VLDB Endowment*, vol. 15, no. 3, pp. 673–685, 2022.

[3] I. Batal, H. Valizadegan, G. F. Cooper, and M. Hauskrecht, “A temporal pattern mining approach for classifying electronic health record data,” *ACM Trans. Intelligent Systems and Technology*, vol. 4, no. 4, 2013.

[4] E. Keogh, S. Lonardi, and C. A. Ratanamahatana, “Towards parameter-free data mining,” in *Proc. ACM SIGKDD*, 2004, pp. 206–215.

[5] A. Ermshaus, P. Schäfer, and U. Leser, “Window size selection in unsupervised time series analytics: A review and benchmark,” in *Proc. AALTD Workshop*, 2022.

[6] A. W.-c. Fu, R. W.-w. Kwong, and J. Tang, “Mining N-most interesting itemsets,” in *Proc. ISMIS*, 2000.

[7] K. Saif-ur Rehman, J. Ashraf, and A. Habib, “Top-K miner: Top-K identical frequent itemsets discovery without user support threshold,” *Knowledge and Information Systems*, vol. 48, no. 3, pp. 741–762, 2016.

[8] Q.-H. Duong, B. Liao, P. Fournier-Viger, and T.-L. Dam, “An efficient algorithm for mining the top-k high utility itemsets, using novel threshold raising and pruning strategies,” *Knowledge-Based Systems*, vol. 104, pp. 106–122, 2016.

[9] S. Iqbal, A. Shahid, M. Roman, Z. Khan, S. Al-Otaibi, and L. Yu, “TKFIM: Top-K frequent itemset mining technique based on equivalence classes,” *PeerJ Computer Science*, vol. 7, p. e385, 2021.

[10] P. Fournier-Viger, A. Gomariz, T. Gueniche, E. Mwamikazi, and R. Thomas, “TKS: Efficient mining of top-k sequential patterns,” in *Proc. ADMA*. Springer, 2013, pp. 109–120.

[11] V. S. Tseng, C.-W. Wu, P. Fournier-Viger, and P. S. Yu, “Efficient algorithms for mining top-k high utility itemsets,” *IEEE Trans. KDE*, vol. 28, no. 1, pp. 54–67, 2016.

[12] K. Singh *et al.*, “TKEH: An efficient algorithm for mining top-k high utility itemsets,” *Applied Intelligence*, vol. 49, pp. 1–15, 2019.

[13] T. Lindeberg, *Scale-Space Theory in Computer Vision*. Springer, 1994.

[14] ——, “Feature detection with automatic scale selection,” *International Journal of Computer Vision*, vol. 30, no. 2, pp. 79–116, 1998.

[15] S. Mallat, “Multiresolution approximations and wavelet orthonormal bases of $L^2(\mathbb{R})$,” *Transactions of the American Mathematical Society*, vol. 315, no. 1, pp. 69–87, 1989.

[16] A. Bifet and R. Gavaldà, “Learning from time-changing data with adaptive windowing,” in *Proc. SIAM SDM*, 2007, pp. 443–448.

[17] X. Wan and X. Han, “Efficient top-k frequent itemset mining on massive data,” *Data Science and Engineering*, 2024.

[18] T. Lindeberg, “Detecting salient blob-like image structures and their scales with a scale-space primal sketch,” *International Journal of Computer Vision*, vol. 11, no. 3, pp. 283–318, 1993.

[19] C.-C. M. Yeh, Y. Zhu, L. Ulanova, N. Begum, Y. Ding, H. A. Dau, D. F. Silva, A. Mueen, and E. Keogh, “Matrix profile I: All pairs similarity joins for time series,” in *Proc. IEEE ICDM*, 2016, pp. 1317–1322.

[20] M. Linardi, Y. Zhu, T. Palpanas, and E. Keogh, “Matrix profile goes MAD: Variable-length motif and discord discovery in data series,” *Data Mining and Knowledge Discovery*, vol. 34, pp. 1022–1071, 2020.

[21] J. Sun, C. Faloutsos, S. Papadimitriou, and P. S. Yu, “GraphScope: Parameter-free mining of large time-evolving graphs,” in *Proc. ACM SIGKDD*, 2007, pp. 687–696.

[22] G. Lancaster, D. Iatsenko, A. Pidde, V. Ticcinelli, and A. Stefanovska, “Surrogate data for hypothesis testing of physical systems,” *Physics Reports*, vol. 748, pp. 1–60, 2018.