差分プライバシー密集区間マイニング

Anonymous Author(s) 査読中

Abstract*—**トランザクションデータにおける密集区間マイニングは、特定のアイテムセットが時間的に集中して出現する区間を検出する強力な手法であるが、個人のトランザクション情報の漏洩リスクが存在する。 本研究では、スライディングウィンドウに基づく密集区間検出に(ε, δ)-差分プライバシー保証を付与するDP-DIM***（**Differentially Private Dense Interval Mining**）フレームワークを提案する。 まず、ウィンドウカウントクエリの窓感度（**Window Sensitivity**）を解析し、感度が$\Delta f = 1$であることを証明する。 次に、ラプラスメカニズムおよびガウスメカニズムを適用した***DP***密集区間（**DP Dense Interval**）検出アルゴリズムを提示する。 さらに、ノイズ付きカウントの閾値判定の信頼性を保証する閾値安定性（**Threshold Stability**）条件を導出し、**Sparse Vector Technique** による予算効率的な変種も提案する。 プライバシ予算合成（**Privacy Budget Composition**）として逐次合成定理および高度合成定理を適用し、**Apriori**型の多レベル探索における総プライバシ消費を管理する。 合成データに対する実験により、**(i)** $\varepsilon = 1.0$で平均**F1**スコア**0.60**を達成し、**(ii)** ラプラスメカニズムがガウスメカニズムおよび**SVT**より高い精度を示し、**(iii)** 実行時間がトランザクション数に対してほぼ線形にスケールし、**(iv)** 高度合成定理により$k = 500$クエリで逐次合成比**77.5%**の予算削減が可能であることを実証する。

***Index Terms*—**差分プライバシー**,** 密集区間**,** アイテムセットマイニング**,** スライディングウィンドウ**,** ラプラスメカニズム**,** プライバシ予算合成

I. はじめに

トランザクションデータにおけるアイテムセットマイニングは、小売分析、ウェブログ解析、医療データ分析など幅広い応用を持つ [1], [2]。 近年、単なる頻出パターンの発見にとどまらず、特定のアイテムセットが時間的に集中して出現する区間（密集区間）を検出する手法が注目されている [3]。 スライディングウィンドウを用いた密集区間検出は、サポート値の時間的変動を捉え、マーケティングキャンペーンの効果検証や異常検知に有用である。

しかし、トランザクションデータには個人の購買履歴や行動ログが含まれるため、マイニング結果から個人情報が推論されるリスクがある。 例えば、特定の薬品の組み合わせが密集する時間区間が公開されると、その期間に購入した個人の疾病状態が推測される可能性がある。 欧州一般データ保護規則（GDPR）や米国カリフォルニア州消費者プライバシー法（CCPA）の施行により、プライバシーを保証したデータマイニング手法の必要性は急速に高まっている。

差分プライバシー（Differential Privacy, DP） [4], [5]は、データベースへの1レコードの追加・削除が出力分布に与える影響を数学的に制限するフレームワークであり、プライバシー保証の黄金基準とされる。 頻出アイテムセットマイニングへの差分プライバシーの適用は既に研究されているが [6], [7]、密集区間検出への適用は未踏の領域である。

密集区間マイニングに差分プライバシーを導入する際の主要な技術的課題は以下の通りである：

1) 窓感度の解析：スライディングウィンドウ内のカウントクエリに対する感度（1レコード変更の最大影響量）を正確に評価する必要がある。
2) 閾値判定の安定性：ノイズ付加後のカウントに基づく密集/非密集の判定が、ノイズにより頻繁に反転する問題を制御する必要がある。
3) 予算管理：Apriori型の多レベル探索では多数のクエリが発行されるため、プライバシ予算の効率的な配分と合成が不可欠である。

本研究の主要な貢献は以下の通りである：

- ウィンドウカウントクエリの窓感度が$\Delta f = 1$であることの形式的証明（定理1）。
- ラプラスメカニズムおよびガウスメカニズムに基づくDP密集区間検出アルゴリズム（アルゴリズム1）。
- 閾値安定性条件の導出と、安定マージンに基づく信頼度保証（定理3）。
- Sparse Vector Technique を用いた予算効率的な変種。
- 逐次合成および高度合成定理に基づく多レベルApriori探索の総プライバシ消費量の解析。
- 合成データに対する包括的な実験評価。

本論文の構成は以下の通りである。第II節で関連研究を概観し、第III節で予備知識を定義する。第IV節で提案手法DP-DIMを詳述し、第V節で実験結果を示す。第VI節で結論と今後の展望を述べる。

II. 関連研究

A. 差分プライバシー

Dwork ら [4]は差分プライバシーの概念を導入し、ラプラスメカニズムによるカウントクエリのプライバシー保護を提案した。 (ε, δ)-差分プライバシーの緩和定義 [5]はガウスメカニズムを可能にし、合成定理（逐次合成・高度合成） [8]は複数クエリにわたるプライバシ保証の管理を可能にした。 Sparse Vector Technique (SVT) [9], [10]は、閾値判定のみが必要な場合にプライバシ予算を節約する技法である。

B. 差分プライバシーと頻出パターンマイニング

頻出アイテムセットマイニングへの差分プライバシーの適用は複数の研究で取り組まれている。 Zeng ら [6]はトランザクションの切断（truncation）とFP-tree への指数メカニズムの適用を提案した。 Li ら [7]はPrivBasisアルゴリズムを提案し、基底集合からのノイズ付きサポート推定を行った。 Bhaskar ら [11]は指数メカニズムを用いた top-k 頻出アイテムセットの発見を提案した。 これらの研究はいずれもグローバルなサポート値を対象としており、時間的な密集パターンは扱っていない。

C. 密集区間マイニング

スライディングウィンドウに基づく密集区間検出 [3]は、Apriori性質を利用してアイテムセットの時間的集中を効率的に検出する。 ウィンドウサイズWと最小サポートθをパラメータとし、ウィンドウ内の共起カウントがθ以上となる連続区間を出力する。 本手法は時系列マイニングとトランザクション分析の交差領域に位置するが、プライバシー保証は考慮されていない。

D. 差分プライバシーと時系列・ストリームマイニング

時系列データへの差分プライバシーの適用も研究されている。 Chan ら [12]はストリームデータに対する連続的なカウントクエリの差分プライバシーを研究した。 Dwork ら [13]は連続観測モデルにおけるプライバシ保証を分析した。 Kellaris ら [14]は時系列データに対するプライバシー保護を議論した。 しかし、これらは連続的なカウント発行に焦点を当てており、密集区間の検出というパターンマイニング的側面は扱っていない。

E. 本研究の位置づけ

以上の関連研究を踏まえ、本研究は「密集区間マイニング」と「差分プライバシー」の交差領域における空白を埋めるものである。 具体的には、ウィンドウカウントクエリの感度解析、閾値安定性の理論的保証、およびApriori型多レベル探索における予算合成を統合したフレームワークを提案する。

III. 予備知識

A. 密集区間マイニング

定義 1 (トランザクションデータベース)**.** トランザクションデータベース$\mathcal{D} = \{T_0, T_1, \ldots, T_{n-1}\}$は、各$T_t$がアイテム集合$\mathcal{I}$の部分集合であるトランザクションの時系列である。添字tはタイムスタンプを表す。

定義 2 (ウィンドウカウント)**.** アイテムセット$X \subseteq \mathcal{I}$のウィンドウ位置lにおけるウィンドウカウント$C_W(X, l)$を以下で定義する：

$$C_W(X, l) = |\{t \mid l \le t \le l + W,\ X \subseteq T_t\}|$$

ここでWはウィンドウサイズである。

定義 3 (密集区間 [3])**.** アイテムセットXの密集区間とは、$C_W(X, l) \ge \theta$を満たすウィンドウ左端lの極大連続区間$[s, e]$である。ここでθは最小サポート閾値である。

B. 差分プライバシー

定義 4 ((ε, δ)-差分プライバシー [4], [5])**.** ランダム化メカニズム$\mathcal{M} : \mathcal{X} \to \mathcal{R}$が$(\varepsilon, \delta)$-差分プライバシーを満たすとは、任意の隣接データベース$\mathcal{D}, \mathcal{D}'$（*1*レコードの追加または削除で異なる）および任意の出力集合$S \subseteq \mathcal{R}$に対して：

$$\Pr[\mathcal{M}(\mathcal{D}) \in S] \le e^{\varepsilon} \cdot \Pr[\mathcal{M}(\mathcal{D}') \in S] + \delta$$

が成り立つことをいう。$\delta = 0$の場合を純粋差分プライバシー（ε-*DP*）と呼ぶ。

定義 5 (グローバル感度 [4])**.** 関数$f : \mathcal{X} \to \mathbb{R}^d$のグローバル感度$\Delta f$を以下で定義する：

$$\Delta f = \max_{\mathcal{D}, \mathcal{D}' : |\mathcal{D} \triangle \mathcal{D}'| = 1} \|f(\mathcal{D}) - f(\mathcal{D}')\|_1$$

定義 6 (ラプラスメカニズム [4])**.** 関数fに対するラプラスメカニズムは$\mathcal{M}(\mathcal{D}) = f(\mathcal{D}) + Lap(\Delta f / \varepsilon)$を出力する。ここで$Lap(b)$はスケール$b$のラプラス分布からのサンプルである。このメカニズムはε-*DP*を満たす。

定義 7 (ガウスメカニズム [5])**.** 関数fに対するガウスメカニズムは$\mathcal{M}(\mathcal{D}) = f(\mathcal{D}) + \mathcal{N}(0, \sigma^2)$を出力する。ここで$\sigma = \Delta f \cdot \sqrt{2\ln(1.25/\delta)}/\varepsilon$である。このメカニズムは$(\varepsilon, \delta)$-*DP*を満たす。

C. 合成定理

性質 1 (逐次合成 [5])**.** $\mathcal{M}_1, \ldots, \mathcal{M}_k$がそれぞれ$(\varepsilon_i, \delta_i)$-*DP*を満たすとき、合成メカニズム$(\mathcal{M}_1, \ldots, \mathcal{M}_k)$は$(\sum_i \varepsilon_i, \sum_i \delta_i)$-*DP*を満たす。

性質 2 (高度合成定理 [8])**.** k個のメカニズムがそれぞれε_0-*DP*を満たすとき、任意の$\delta' > 0$に対して、合成メカニズムは$(\varepsilon', k\delta + \delta')$-*DP*を満たす。ここで：

$$\varepsilon' = \varepsilon_0 \sqrt{2k \ln(1/\delta')} + k\varepsilon_0 (e^{\varepsilon_0} - 1)$$

IV. 提案手法：DP-DIM

本節では、差分プライバシー密集区間マイニング（DP-DIM）フレームワークを提示する。

A. 窓感度の解析

定義 8 (窓感度（Window Sensitivity）)**.** ウィンドウカウント関数$C_W(X, l)$の窓感度Δ_Wを、*1*トランザクションの追加または削除によるカウントの最大変化量として定義する：

$$\Delta_W = \max_{\mathcal{D}, \mathcal{D}' : |\mathcal{D} \triangle \mathcal{D}'| = 1} \max_{l} |C_W(X, l; \mathcal{D}) - C_W(X, l; \mathcal{D}')|$$

定理 1 (窓感度)**.** 任意のアイテムセットXおよびウィンドウサイズWに対して、窓感度は$\Delta_W = 1$である。

Proof. 1つのトランザクションT_tを追加（または削除）した場合を考える。ウィンドウ位置lに対して、T_tがウィンドウ$[l, l + W]$に含まれるのは$l \le t \le l + W$のときのみである。 このとき、$X \subseteq T_t$であればカウントが1増加（減少）し、$X \not\subseteq T_t$であればカウントは変化しない。 したがって、各ウィンドウ位置においてカウントの変化量は最大1であり、$\Delta_W = 1$が成り立つ。 □

B. *DP*密集区間

定義 9 (DP密集区間（DP Dense Interval）)**.** ノイズ付きウィンドウカウント$\tilde{C}_W(X, l) = C_W(X, l) + \eta$（$\eta$はラプラスまたはガウスノイズ）に基づいて、$\tilde{C}_W(X, l) \ge \theta$を満たすウィンドウ左端$l$の極大連続区間を*DP*密集区間と定義する。

定理 2 (DP-DIMのプライバシー保証)**.** アルゴリズム*1*はε-差分プライバシーを満たす。

Algorithm 1 DP-DIM: 差分プライバシー密集区間検出

Require: タイムスタンプ列**t**、ウィンドウサイズW、閾値θ、プライバシパラメータε
Ensure: DP密集区間集合$\mathcal{I}$

```
L ← ユニークウィンドウ位置の集合
ε_q ← ε/|L|                    {逐次合成による予算配分}
b ← Δ_W/ε_q                     {ラプラスノイズのスケール}
I ← ∅
in_dense ← false
for 各ウィンドウ位置 l ∈ L do
    c ← C_W(X, l)               {真のカウント}
    c̃ ← c + Lap(b)              {ノイズ付加}
    if c̃ ≥ θ then
        if ¬in_dense then
            start ← l
        end if
        end ← l
        in_dense ← true
    else
        if in_dense then
            I ← I ∪ {(start, end)}
        end if
        in_dense ← false
    end if
end for
if in_dense then
    I ← I ∪ {(start, end)}
end if
return I
```

Proof. 各ウィンドウ位置lでのクエリにラプラスメカニズム（$\varepsilon_q = \varepsilon/|L|$, 感度$\Delta_W = 1$）を適用する。逐次合成定理より、$|L|$個のクエリの合成は$|L| \cdot \varepsilon_q = \varepsilon$-DPを満たす。 □

C. 閾値安定性

ノイズ付加により、真のカウントが閾値近傍にある場合、密集/非密集の判定が不安定になる。この問題を制御するために閾値安定性の概念を導入する。

定義 10 (閾値安定性（Threshold Stability）)**.** ノイズ付きカウント$\tilde{c}$と閾値θに対して、安定性マージンγを以下で定義する：

$$\gamma = \frac{\Delta_W}{\varepsilon_q} \cdot \ln \frac{1}{1-p}$$

ここでpは所望の信頼度である。$|\tilde{c} - \theta| \geq \gamma$のとき、閾値判定は確率$p$以上で正しい。

定理 3 (閾値安定性保証)**.** 真のカウントcが$|c - \theta| \geq \gamma$を満たすとき、ラプラスメカニズムによるノイズ付きカウント$\tilde{c}$に基づく密集判定は確率p以上で正しい。

Proof. ラプラス分布Lap(b)（$b = \Delta_W/\varepsilon_q$）に対して、$\Pr[|\eta| < b \cdot \ln(1/(1-p))] = p$が成り立つ。$|c - \theta| \geq \gamma = b \cdot \ln(1/(1-p))$のとき、$|\eta| < \gamma$ならば$\text{sign}(\tilde{c} - \theta) = \text{sign}(c - \theta)$であり、この事象の確率は$p$以上である。 □

D. Sparse Vector Technique

ウィンドウ位置の多くが非密集であるスパースなケースでは、Sparse Vector Technique (SVT) [9]によりプライバシ予算を節約できる。SVTでは：

1) 予算εを$\varepsilon/2$（ノイズ閾値用）と$\varepsilon/2$（クエリノイズ用）に分割する。
2) 閾値θにラプラスノイズLap($2/\varepsilon$)を加えてノイズ閾値$\tilde{\theta}$を生成する。
3) 各クエリにラプラスノイズLap($2c_{\max}/\varepsilon$)を加え、$\tilde{\theta}$と比較する。
4) above-threshold の応答が$c_{\max}$回に達したら停止する。

SVTの総プライバシ消費は、above-threshold回数$c_{\max}$のみに依存し、全クエリ数$|L|$には依存しない。

E. プライバシ予算合成

定義 11 (プライバシ予算合成（Privacy Budget Composition）)**.** *Apriori*型の多レベル探索において、レベルk（$k = 1, \ldots, K$）に予算$\varepsilon_k = \varepsilon/K$を配分する。レベル$k$内の候補数を$m_k$とすると、各候補に$\varepsilon_k/m_k$を配分する。

逐次合成では総消費はεに一致する。一方、高度合成定理（性質2）を適用すると、同一ε_0のk回クエリに対してより厳密な上界が得られる。

系 1 (多レベル探索の予算効率)**.** Kレベル、各レベルm_k候補の探索において、均一配分$\varepsilon_0 = \varepsilon/(\sum_k m_k)$のとき、高度合成定理により総プライバシ消費は$O(\varepsilon_0\sqrt{\sum_k m_k \cdot \ln(1/\delta')})$に抑えられる。

V. 実験

A. 実験設定

合成データを用いてDP-DIMフレームワークを評価する。 データ生成では、nトランザクション（$n = 300$、スケーラビリティ実験では100–2000）、$|\mathcal{I}| = 20$アイテムを使用し、指定区間$[s_d, e_d]$にアイテムセットX_dを出現確率0.85で注入する（背景出現確率0.05）。 ウィンドウサイズ$W = 20$、閾値$\theta = 5$、最大アイテムセットサイズ$K = 3$とする。 評価指標としてヤッカード類似度（Jaccard）、F1スコア（位置ベースのprecision/recall）を用いる。 各条件で10シード（42–51）の平均を報告する。

B. E1: プライバシー・精度トレードオフ

εを$\{0.1, 0.5, 1.0, 2.0, 5.0, 10.0\}$で変化させ、非DPの密集区間を真値としてJaccardおよびF1を測定した（表I）。

εの増大に伴いJaccard・F1ともに単調に向上し、$\varepsilon = 10.0$で最大Jaccard 0.449、F1 0.617を達成した。$\varepsilon = 1.0$でもF1 0.60を維持しており、実用的なプライバシーレベルで合理的な精度が得られることを示している。 $\varepsilon = 0.1$（強いプライバシー保護）でもJaccard 0.429を達成しており、密集パターンの概形は捕捉されている。

TABLE I
E1: εに対するJACCARDおよびF1（$W = 20, \theta = 5$, 10シード平均）

ε	Jaccard (平均)	Jaccard (標準偏差)	F1 (平均)	F1 (標準偏差)
0.1	0.429	0.031	0.598	0.030
0.5	0.430	0.031	0.599	0.029
1.0	0.431	0.030	0.600	0.029
2.0	0.433	0.029	0.602	0.028
5.0	0.439	0.030	0.608	0.029
10.0	0.449	0.029	0.617	0.027

TABLE II
E2: メカニズム比較（$\varepsilon = 2.0$, 10シード平均）

メカニズム	Jaccard (平均)	Jaccard (標準偏差)	実行時間 (ms)
Laplace	0.348	0.083	0.31
Gaussian	0.311	0.049	0.37
SVT	0.233	0.089	0.11

TABLE III
E3: スケーラビリティ（$\varepsilon = 1.0$, 3シード平均）

n	実行時間 (ms, 平均)	実行時間 (ms, 標準偏差)
100	2.2	0.1
200	4.5	0.0
500	12.2	0.2
1000	24.9	0.9
2000	51.2	1.1

TABLE IV
E4: 安定性マージンγ（$\Delta_W = 1$）

ε	$p = 0.80$	$p = 0.90$	$p = 0.95$	$p = 0.99$
0.5	3.22	4.61	5.99	9.21
1.0	1.61	2.30	3.00	4.61
2.0	0.80	1.15	1.50	2.30
5.0	0.32	0.46	0.60	0.92

C. E2: メカニズム比較

ラプラスメカニズム、ガウスメカニズム、SVTの3手法を$\varepsilon = 2.0$で比較した（表II）。

ラプラスメカニズムが最も高いJaccard（0.348）を達成した。 ガウスメカニズムはやや低いが標準偏差が小さく安定している。 SVTは最も高速であるが、ノイズ閾値との比較という性質上、区間境界の精度がやや低い。

D. E3: スケーラビリティ

トランザクション数nを$\{100, 200, 500, 1000, 2000\}$で変化させ、実行時間を測定した（表III）。

実行時間はnに対してほぼ線形にスケールしており、$n = 2000$でも51 msと実用的な速度である。 DPのオーバーヘッド（ノイズ生成）は全体の実行時間に対して無視できる水準である。

E. E4: 閾値安定性

εと信頼度pに対する安定性マージンγを算出した（表IV）。

$\varepsilon = 2.0$、信頼度$p = 0.95$で安定性マージンは1.50であり、真のカウントが閾値から2以上離れていれば95%の信頼度で正しい判定が保証される。 $\varepsilon = 5.0$では$\gamma = 0.60$（$p = 0.95$）となり、閾値近傍のカウントでもほぼ安定した判定が可能である。

F. E5: 予算合成

逐次合成と高度合成定理による総ε消費を比較した（表V、$\varepsilon_0 = 0.01$）。

クエリ数が少ない場合（$k = 10$）は高度合成の$\sqrt{k}$項のオーバーヘッドが支配的で逐次合成が有利であるが、$k \geq 50$では高度合成が優位となる。 $k = 500$で77.5%の予算削減を達成しており、大規模データセットへの適用時に実質的な利点がある。

VI. 結論

本研究では、スライディングウィンドウに基づく密集区間マイニングに(ε, δ)-差分プライバシー保証を付与するDP-DIMフレームワークを提案した。

主要な理論的貢献として、(1) ウィンドウカウントクエリの窓感度が$\Delta_W = 1$であることの証明、(2) ラプラスメカニズムおよびガウスメカニズムに基づくDP密集区間検出アルゴリズム、(3) 閾値安定性条件の導出、(4) Sparse Vector Technique による予算効率的な変種、(5) 逐次合成および高度合成定理に基づくApriori型多レベル探索の予算管理手法を示した。

実験結果より、以下が確認された：

- $\varepsilon = 1.0$の実用的なプライバシーレベルで平均F1スコア0.60を達成し、密集パターンの概形を捕捉可能であること。
- ラプラスメカニズムがガウスメカニズムおよびSVTと比較して最も高い精度を示すこと。
- 実行時間がトランザクション数に対してほぼ線形にスケールし、$n = 2000$でも51 msであること。
- 高度合成定理により$k = 500$クエリで逐次合成比77.5%の予算削減が可能であること。

A. 今後の課題

今後の研究方向として以下が挙げられる：

局所差分プライバシー：本研究は中央集権型DPを想定しているが、各ユーザーが自身のトランザクションにローカルにノイズを加える局所差分プライバシー（LDP）モデルへの拡張が求められる。LDPでは感度が異なるため、精度とプライバシーのトレードオフが変化する。

実データでの評価：合成データに加え、小売・医療・ウェブログなどの実データでの評価が必要である。特に、密集パターンの疎密度やアイテム数がDP精度に与える影響を調査する。

Renyi差分プライバシー：RDP [15]を用いた合成定理は高度合成よりも厳密な上界を与える場合があり、予算管理のさらなる改善が期待される。

適応的予算配分：候補アイテムセットの数やウィンドウ位置に応じた適応的な予算配分戦略の開発により、固定配分を上回る精度が達成できる可能性がある。

TABLE V
E5: 逐次合成 vs 高度合成（$\varepsilon_0 = 0.01, \delta' = 10^{-5}$）

クエリ数k	逐次合成ε	高度合成ε	削減率
10	0.10	0.15	-52.7%
50	0.50	0.34	31.1%
100	1.00	0.49	51.0%
500	5.00	1.12	77.5%

REFERENCES

[1] R. Agrawal and R. Srikant, "Fast algorithms for mining association rules in large databases," in *Proceedings of the 20th International Conference on Very Large Data Bases (VLDB)*, 1994, pp. 487–499.

[2] J. Han, J. Pei, Y. Yin, and R. Mao, *Mining Frequent Patterns without Candidate Generation: A Frequent-Pattern Tree Approach*. Springer, 2004, vol. 8, no. 1.

[3] K. Suzuki, "Dense interval detection via sliding window apriori," in *Proceedings of the IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 2024.

[4] C. Dwork, F. McSherry, K. Nissim, and A. Smith, "Calibrating noise to sensitivity in private data analysis," in *Theory of Cryptography Conference (TCC)*. Springer, 2006, pp. 265–284.

[5] C. Dwork and A. Roth, *The Algorithmic Foundations of Differential Privacy*. Now Publishers, 2014, vol. 9, no. 3–4.

[6] C. Zeng, J. F. Naughton, and J.-Y. Cai, "Differentially private frequent itemset mining," 2012.

[7] N. Li, W. Qardaji, D. Su, and J. Cao, "Privbasis: Frequent itemset mining with differential privacy," in *Proceedings of the VLDB Endowment*, vol. 5, no. 11, 2012, pp. 1340–1351.

[8] C. Dwork, G. N. Rothblum, and S. Vadhan, "Boosting and differential privacy," in *51st Annual IEEE Symposium on Foundations of Computer Science (FOCS)*. IEEE, 2010, pp. 51–60.

[9] C. Dwork, "The complexity of differentially private data release," in *Proceedings of the 41st Annual ACM Symposium on Theory of Computing (STOC)*, 2009.

[10] M. Hardt and G. N. Rothblum, "A simple and practical algorithm for differentially private data release," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2010.

[11] R. Bhaskar, S. Laxman, A. Smith, and A. Thakurta, "Discovering frequent patterns in sensitive data," in *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2010, pp. 503–512.

[12] T.-H. H. Chan, E. Shi, and D. Song, "Private and continual release of statistics," in *Automata, Languages and Programming (ICALP)*. Springer, 2011, pp. 405–417.

[13] C. Dwork, M. Naor, T. Pitassi, and G. N. Rothblum, "Differential privacy under continual observation," in *Proceedings of the 42nd Annual ACM Symposium on Theory of Computing (STOC)*, 2010, pp. 715–724.

[14] G. Kellaris, S. Papadopoulos, X. Xiao, and D. Papadias, "Differentially private event sequences over infinite streams," in *Proceedings of the VLDB Endowment*, vol. 7, no. 12, 2014, pp. 1155–1166.

[15] I. Mironov, "Rényi differential privacy," in *IEEE 30th Computer Security Foundations Symposium (CSF)*. IEEE, 2017, pp. 263–275.