薬剤疫学における密集処方パターン検出と規制イベント帰属

匿名著者
JAMIA 投稿

Abstract

医薬品安全性監視（ファーマコビジランス）は、規制当局の安全性情報発出後における処方パターンの変化を検出することに依拠している。既存手法——不均衡分析、自己対照ケースシリーズ（SCCS）、分割時系列（ITS）分析——は、単一の薬剤 – イベント対を対象とし、介入時点を手動で指定する必要がある。本研究では、スライディングウィンドウ頻出アイテムセットマイニングと自動規制イベント帰属を組み合わせ、併用処方パターンが異常に高頻度となる期間である**密集処方区間**を検出するフレームワークを提案する。本手法は、(1) Apriori-window アルゴリズムを WHO ATC 分類体系に基づく処方トランザクションに適応し、(2) パターン密度の変化点を同定し、(3) Welch の t 検定と Benjamini–Hochberg 法による偽発見率（FDR）制御を用いてこれらの変化を規制イベントに帰属させる。MIMIC-IV 形式の合成処方データを用いた実験により、本フレームワークは 19 の ATC レベル 3 薬効分類にわたり 3,100 件の密集パターンを検出し、模擬 FDA 安全性情報に対して適合率 0.94・再現率 0.88 の帰属精度を達成し、1,000 トランザクション規模のデータに対し 1 秒未満で解析を完了することを示す。ITS ベースライン比較では、本手法が複数パターンの同時検出と自動帰属において優位であることを確認した。心血管系、疼痛管理、抗菌薬の各薬効群にまたがるクロスクラス分析では、差異的応答パターンが明らかとなり、オピオイド – ベンゾジアゼピン併用処方が模擬枠囲み警告後に最も顕著な減少を示した。

キーワード: 薬剤疫学、密集区間マイニング、処方パターン分析、医薬品安全性監視、規制イベント帰属、併用処方マイニング

1　はじめに

薬剤処方パターンの監視は、ファーマコビジランスの基盤である。米国食品医薬品局（FDA）などの規制当局が安全性情報——枠囲み警告（Boxed Warning）、安全性アラート（Drug Safety Communication）、薬剤の市場撤退など——を発出した場合、医療提供者はそれに応じて処方行動を変更することが期待される [Dusetzina et al., 2012]。しかし、これらの情報の影響は大きく異なり、即座に強い効果を示すものもあれば、遅延的または測定可能な影響を持たないものもある [Marcum et al., 2012]。実際、FDA の Risk Evaluation and Mitigation Strategies（REMS）プログラムの体系的レビュー [Onakpoya et al., 2016] では、安全性情報の処方行動への効果は薬効群により著しく異なることが報告されている。

規制措置が処方パターンに与える影響を評価する現行手法には、いくつかの限界がある。**不均衡分析**手法である比例報告比（PRR）[Evans et al., 2001]、報告オッズ比（ROR）、およびベイジアン信頼伝播ニューラルネットワーク（BCPNN）[Bate et al., 1998] は、観察期間全体にわたる集計カウントに基づいて動作し、時間的動態を捕捉できない。**分割時系列**（ITS）分析 [Bernal et al., 2017, Wagner et al., 2002] は時間的評価を提供するが、介入時点の手動指定が必要であり、通常は一度に一つの薬剤のみを分析する。**自己対照ケースシリーズ**（SCCS）[Whitaker et al., 2006, Cadarette and Kim, 2021] 法は個人間交絡を制御するが、一過性の曝露と個人レベルの分析に限定される。

一方、データマイニング手法は処方データに適用されてきた。相関ルールマイニングはポリファーマシーパターンの同定に [Faquetti et al., 2023, Held et al., 2017]、系列パターンマイニングは順序付

き処方系列の発見に [Wright et al., 2015]、時間パターン発見は薬剤 – アウトカム関連の検出に [Norén et al., 2010, Batal et al., 2013] 用いられてきた。しかし、これらの手法はいずれも以下の 3 つの重要な要件を同時に満たしていない：(i) 特定の併用処方パターンが異常に高頻度となる**時期**の検出、(ii) **複数パターン**の同時処理、(iii) 検出された変化の既知の規制イベントへの**自動**帰属。

本論文では、頻出アイテムセットマイニングとファーマコビジランスを橋渡しするフレームワークを提案し、以下の 3 つの方法論的貢献を行う：

1. **密集処方区間検出**：スライディングウィンドウ Apriori アルゴリズムを WHO ATC 分類体系 [World Health Organization, 2024] に基づく処方トランザクションデータに適応し、併用処方パターンが異常に密集する期間の自動同定を可能にする。

2. **規制イベント帰属**：コントラストパターン分析と Welch の t 検定および Benjamini–Hochberg 偽発見率制御を用いて、検出された密度変化を規制イベントに結びつける問題を定式化する。サポート時系列の自己相関構造を考慮した有効標本サイズ補正を含む。

3. **マルチパターン監視**：単一薬剤手法とは異なり、本フレームワークは消失パターン（対象薬剤の減少）、出現パターン（代替薬剤の増加）、および安定パターン（影響を受けない薬効群）を同時に検出し、処方行動変化の包括的な全体像を提供する。

本フレームワークを MIMIC-IV 電子健康記録の構造に基づく合成処方データ [Johnson et al., 2023] で評価し、(a) 埋め込み済みの真のイベント効果に対する適合率・再現率、(b) ITS ベースラインとの比較、(c) 模擬 FDA 安全性情報前後における臨床的に意味のあるパターン変化を検出する能力を実証する。

2 関連研究

2.1 ファーマコビジランスにおけるシグナル検出

自発的副作用（ADR）報告システムは、市販後医薬品安全性監視の基盤を成す。主な分析手法は不均衡指標である：PRR [Evans et al., 2001] と ROR は薬剤 – イベント頻度をバックグラウンド率と比較し、BCPNN [Bate et al., 1998] およびガンマ・ポアソン縮小推定量（GPS）[DuMouchel, 1999] を含むベイズ手法は縮小推定に基づく推定値を提供する。比較研究 [Lee et al., 2020] では、頻度論的手法（PRR、ROR）は感度が高い傾向にある一方、ベイズ手法はより保守的であることが示されている。これらの手法は集計データに対して動作し、シグナル強度の時間的変動を捕捉しない。

FDA Sentinel System [Platt et al., 2009] は OMOP 共通データモデル [Hripcsak et al., 2015] 上で大規模な市販後安全性監視を実施しているが、分析対象は事前定義された薬剤 – アウトカム対であり、探索的な併用処方パターン発見には対応していない。

2.2 薬剤疫学における時間分析

自己対照デザイン [Cadarette and Kim, 2021, Petersen et al., 2016] は、同一個人内の曝露期間と非曝露期間を比較し、時間安定的な交絡因子を制御する。SCCS 法はリスクウィンドウの事前指定が必要であり、一過性の曝露と急性アウトカムに最も適している。

分割時系列（ITS）分析 [Bernal et al., 2017, Jandoc et al., 2015] は、規制介入を評価するための準実験デザインとして最も広く用いられている。セグメント回帰は薬剤利用研究における ITS 研究の 67%で使用されている [Jandoc et al., 2015] が、介入時点の手動指定が必要である。

処方順序対称性分析（PSSA）[Hallas, 1996, Pratt et al., 2015] は薬剤開始間の時間的関連を検出するが、併用処方密度には対応していない。

2.3 変化点検出と因果推論

統計的変化点検出手法は時系列データにおける構造変化の自動同定を対象とする。CUSUM [Page, 1954] は逐次的な平均変化検出の古典的手法であり、PELT [Killick et al., 2012] はペナルティ付き尤度に基づく最適分割手法として計算効率と検出精度を両立する。これらの手法は単一時系列に対して設計されており、多数の併用処方パターンの同時監視には直接適用できない。

薬剤疫学における因果推論手法として、差分の差分法（DID）[Dimick and Ryan, 2014] は規制介入の因果効果推定に用いられる。回帰不連続デザイン（RDD）[Bor et al., 2014] は閾値前後の比較による因果推定を提供する。本研究の密度変化スコアは記述的指標であり、因果的主張には補完的な因果推論手法との組み合わせが必要である（§6.2）。

2.4 処方パターンマイニング

相関ルールマイニングはポリファーマシー分析に適用されており [Faquetti et al., 2023, Held et al., 2017, Doherty et al., 2020]、特定の患者集団における一般的な薬剤の組み合わせを同定している。Agrawal–Srikant の Apriori アルゴリズム [Agrawal and Srikant, 1994] および FP-growth [Han et al., 2000] が基盤技術として広く用いられている。系列パターンマイニング [Wright et al., 2015] は順序付き服薬系列を発見する。時間パターン発見 [Norén et al., 2010, Batal et al., 2013, Campbell et al., 2020, Alonso Moral et al., 2023] は電子健康記録における時間的関連を同定する。

トピックモデル [Chen et al., 2017] および表現学習アプローチ [Jensen et al., 2012] は、MIMIC データ [Johnson et al., 2023, Gupta et al., 2022] に対して服薬パターン発見に適用されてきた。しかし、これらのアプローチは静的パターンまたは次回処方予測に焦点を当てており、時間的密度変動は扱っていない。

2.5 本研究の位置づけ

本研究は、(i) 併用処方パターンに対するスライディングウィンドウ密集区間検出、(ii) 複数パターンにわたる規制イベントへの自動帰属、(iii) コントラストパターン分類（消失 対 出現 対 安定）を組み合わせる点で既存手法と異なる。表 1 に比較を示す。

Table 1: 既存のファーマコビジランスおよび処方マイニング手法との比較

手法	時間的	多剤対応	自動帰属	密集区間	多重検定補正
PRR / ROR	×	×	×	×	×
BCPNN / GPS	×	×	×	×	✓
SCCS	✓	×	×	×	×
ITS	✓	×	手動	×	×
CUSUM / PELT	✓	×	×	部分的	×
Apriori ARM	×	✓	×	×	×
系列 PM	✓	✓	×	×	×
TPD	✓	×	×	部分的	×
提案手法	✓	✓	✓	✓	✓

3　手法

3.1　処方トランザクションモデル

定義 1 (ATC 階層と処方トランザクション)**.** *WHO ATC* 分類体系 *[World Health Organization, 2024]* はレベル $\ell \in \{1, \ldots, 5\}$ の階層構造を持ち、レベル *1* は解剖学的主グループ（例：C = 循環器系)、レベル *3* は薬理サブグループ（例：*C09A* = *ACE* 阻害薬、単剤)、レベル *5* は化学物質（例：*C09AA01* = カプトプリル）に対応する。$\mathcal{A}_\ell$ をレベル ℓ における *ATC* コードの集合とし、ϕ_ℓ を薬剤名をレベル ℓ に切り詰める写像とする。

時刻 t における処方トランザクション d_t は、時間期間 t に処方された薬剤の *ATC* コード集合である：

$$d_t = \{\phi_\ell(drug) : drug \in Prescriptions(t)\} \subseteq \mathcal{A}_\ell$$

トランザクション系列は $D = [d_1, \ldots, d_N]$ である。

本研究では ATC レベル 3（薬理サブグループ）を使用する。この選択は以下の理由に基づく：(a) レベル 3 は Defined Daily Dose（DDD）が定義される最小レベルであり処方量の標準化が可能、(b) レベル 4–5 では薬効分類内の個別化合物に細分化されすぎてパターンが希薄化する、(c) レベル 1–2 では異なる薬理作用を持つ薬剤が集約されすぎて臨床的解釈が困難になる。各時間期間は 1 日、1 週間、または患者の受診に対応しうる。

注意 1 (集約レベルの影響)**.** トランザクション粒度の選択（日次 *vs* 週次 *vs* 受診単位）は検出されるパターンに影響する。日次集約は急性期の処方変動を捕捉するが、ノイズが増加する。週次集約はより安定した推定を提供するが、短期的変動を平滑化する。本合成データ実験では受診単位の集約を使用するが、実データ適用時にはロバスト性の検証が必要である。

3.2　密集処方区間検出

定義 2 (サポート時系列)**.** パターン $P \subseteq \mathcal{A}_\ell$ およびウィンドウサイズ W に対して：

$$s_P(t) = |\{d_j \in D : t \leq j < t + W, P \subseteq d_j\}| \tag{1}$$

定義 3 (密集処方区間)**.** 閾値 θ に対するパターン P の密集処方区間は、すべての $t \in [s, e]$ について $s_P(t) \geq \theta$ を満たす極大連続範囲 $[s, e]$ である。そのような区間の集合を $\mathcal{D}(P, W, \theta)$ とする。

密集処方パターンの列挙にはアルゴリズム 1 を用いる。これは Apriori 頻出アイテムセットマイニング [Agrawal and Srikant, 1994] のフレームワークをスライディングウィンドウサポートカウントと反単調枝刈りで拡張したものである。

DenseIntervals サブルーチンは、繰り返しタイムスタンプを処理するためのスタックケース修正を伴うカーソルベースの走査を用い、パターンあたり $O(N \log N)$ を達成する。

3.3　規制イベント帰属

定義 4 (規制イベント)**.** 規制イベント $r = (\mathrm{id}, \mathrm{type}, t_r, \mathcal{I}_r)$ は、一意の識別子、種別（*safety_alert, boxed_warning, withdrawal, label_change, REMS*)、タイムスタンプ t_r、および対象薬剤集合 $\mathcal{I}_r \subseteq \mathcal{A}_\ell$ を持つ。ここで種別は *FDA* の公式分類 *[Dusetzina et al., 2012]* に準拠する。

定義 5 (密度変化スコア)**.** パターン P およびイベント r に対し、ルックバックパラメータ h を用いて：

$$\Delta(P, r) = \bar{s}_P^+(r) - \bar{s}_P^-(r) \tag{2}$$

ここで $\bar{s}_P^-(r) = \frac{1}{h}\sum_{t=t_r-h}^{t_r-1} s_P(t)$ および $\bar{s}_P^+(r) = \frac{1}{h}\sum_{t=t_r}^{t_r+h-1} s_P(t)$ は、それぞれイベント前後ウィンドウにおける平均サポートである。

Algorithm 1 密集処方パターンマイニング

Require: トランザクション系列 D、ウィンドウサイズ W、閾値 θ、最大サイズ $k_{\max}$
Ensure: 密集パターン $\mathcal{F}$ とその区間

アイテム $\to$ トランザクション写像 M を構築
$\mathcal{F} \leftarrow \emptyset$, $L_1 \leftarrow \emptyset$
for 各アイテム $i \in \mathcal{A}_\ell$ **do**
    $\mathcal{D}_i \leftarrow \textsc{DenseIntervals}(M[i], W, \theta)$
    if $\mathcal{D}_i \neq \emptyset$ **then**
        $\mathcal{F}[\{i\}] \leftarrow \mathcal{D}_i$; $L_1 \leftarrow L_1 \cup \{\{i\}\}$
    end if
end for
for $k = 2$ **to** $k_{\max}$ **do**
    $C_k \leftarrow \textsc{AprioriGen}(L_{k-1})$
    $C_k \leftarrow \textsc{Prune}(C_k, L_{k-1})$ ▷ Apriori 性質
    $L_k \leftarrow \emptyset$
    for 各 $P \in C_k$ **do**
        $R \leftarrow \bigcap_{i \in P} \mathcal{D}_i$ ▷ 単独区間の共通部分
        if $R = \emptyset$ **then continue**
        end if
        $T_P \leftarrow \bigcap_{i \in P} M[i]$ ▷ 共起タイムスタンプ
        $\mathcal{D}_P \leftarrow \textsc{DenseIntervals}(T_P, W, \theta)$
        if $\mathcal{D}_P \neq \emptyset$ **then**
            $\mathcal{F}[P] \leftarrow \mathcal{D}_P$; $L_k \leftarrow L_k \cup \{P\}$
        end if
    end for
end for
return $\mathcal{F}$

統計検定と自己相関補正　各パターン – イベント対 (P, r) に対し、H_0: $\bar{s}_P^-(r) = \bar{s}_P^+(r)$ を検定する。サポート時系列 $s_P(t)$ はスライディングウィンドウの重複により正の自己相関を持つ。これに対処するため、Welch の t 検定を適用する際に有効標本サイズ n_{eff} を用いる：

$$n_{\text{eff}} = \frac{h}{1 + 2\sum_{k=1}^{K}(1 - k/h)\hat{\rho}(k)} \tag{3}$$

ここで $\hat{\rho}(k)$ はサポート時系列のラグ k 自己相関、$K = \min(W, h/3)$ は打ち切りラグである。Welch の t 検定は不等分散に頑健であり、サポート水準が変化する前後で分散が異なる薬剤疫学データに適している [Welch, 1947]。

$M = |\mathcal{F}| \times |\mathcal{R}|$ 個の同時仮説検定に対し、Benjamini–Hochberg 法 [Benjamini and Hochberg, 1995] を用いて FDR を水準 α で制御する。

定義 6 (コントラストパターン分類)**.** 有意水準閾値 α および変化閾値 δ のもとで、パターン P はイベント r に対して以下のように分類される：

- **消失**（*disappearing*）：$p < \alpha_{\text{BH}}$ かつ $\Delta(P, r) < -\delta$
- **出現**（*emerging*）：$p < \alpha_{\text{BH}}$ かつ $\Delta(P, r) > \delta$
- **安定**（*stable*）：$p \geq \alpha_{\text{BH}}$ または $|\Delta(P, r)| \leq \delta$

ここで α_{BH} は *BH* 手続きにより定まる棄却閾値である。変化閾値 δ は最小の臨床的意味のある差（*Minimal Clinically Important Difference; MCID*）に対応し、本研究では $\delta = 0.5$（サポートカウント単位）を使用する。

定義 7 (カスケード効果)**.** パターン P がイベント r に対して消失と分類され、かつ $P \cap \mathcal{I}_r = \emptyset$（対象薬剤を直接含まない）であるとき、$P$ はカスケード消失パターンと呼ぶ。これは対象薬剤を含む他のパターン P'（$P' \cap \mathcal{I}_r \neq \emptyset$）の処方減少が、$P$ と共起していた非対象薬剤パターンの減少を間接的に引き起こすことにより生じる。

3.4　計算量

命題 1. $n = |\mathcal{A}_\ell|$、N をトランザクション数、$|\mathcal{F}|$ を頻出パターン数とする。全体の計算量は：

$$O\big(|\mathcal{F}|^2 + |\mathcal{F}| \cdot N \log N + |\mathcal{F}| \cdot |\mathcal{R}| \cdot h\big)$$

ここで *3* つの項はそれぞれ候補生成、密集区間検出、コントラスト分析に対応する。

Proof. 候補生成：Apriori-Gen は L_{k-1} の自己結合であり、$\sum_k |L_k|^2 \leq |\mathcal{F}|^2$。密集区間検出：各パターン P に対し、共起タイムスタンプの集合交差は $O(N)$、ソート済みリストに対する走査は $O(N \log N)$。コントラスト分析：各パターン – イベント対につき、h 個のサポート値の平均・分散計算は $O(h)$。　□

4　実験設定

4.1　合成処方データ

MIMIC-IV の構造を模した合成処方データを生成する。MIMIC-IV データベース [Johnson et al., 2023] は、Beth Israel Deaconess Medical Center の非識別化された電子健康記録データを含み、処方、薬局オーダー、および投薬管理記録を含む。MIMIC-IV へのアクセスには資格認定（CITI プログラム修了）が必要であるため、統計的性質を一致させた合成データを生成する。

データ生成　心血管系（C03A: 利尿薬、C07A: β 遮断薬、C08C: カルシウム拮抗薬、C09A: ACE 阻害薬、C09C: ARB、C10A: スタチン）、鎮痛・抗炎症薬（M01A: NSAIDs、N02A: オピオイド、N02B: その他の鎮痛薬）、糖尿病治療薬（A10A: インスリン、A10B: 経口血糖降下薬）、抗菌薬（J01C: β ラクタム系、J01D: セファロスポリン系、J01F: マクロライド系、J01M: フルオロキノロン系）、およびその他のカテゴリ（A02B: PPI、N06A: 抗うつ薬、N05B: ベンゾジアゼピン、B01A: 抗凝固薬）にまたがる 19 の ATC レベル 3 薬効分類について、$N = 1{,}000$ 件のトランザクションレコードを生成する。個別薬剤の出現確率は $p_{\text{single}} = 0.35$、併用処方パターン（臨床的に現実的な 9 つの組み合わせ）の出現確率は $p_{\text{pattern}} = 0.20$ とする。

規制イベント（グラウンドトゥルース）　2 件の模擬 FDA 安全性情報を埋め込む。これらは既知のグラウンドトゥルースとして検出精度の評価に用いる：

- **FDA-2024-001**（$t = 333$）：オピオイド（N02A）とベンゾジアゼピン（N05B）の併用に対する枠囲み警告。効果量 0.85（併用処方確率の 85%減少）。2016 年の FDA 実際の枠囲み警告に基づくモデル。
- **FDA-2024-002**（$t = 666$）：フルオロキノロン（J01M）の腱断裂リスクに対する安全性アラート。効果量 0.80。2016 年・2018 年の FDA 安全性情報に基づくモデル。

4.2　評価指標

グラウンドトゥルースとして、埋め込み済みの規制イベントにより直接影響を受けるパターン集合 $\mathcal{G}$（対象薬剤を含むパターン）を定義する。帰属精度を以下の指標で評価する：

- **適合率**（Precision）：消失と分類されたパターンのうち、$\mathcal{G}$ に属する割合。$\text{Prec} = |D \cap \mathcal{G}|/|D|$（$D$ は消失分類集合）。
- **再現率**（Recall）：$\mathcal{G}$ のうち、消失と分類された割合。$\text{Rec} = |D \cap \mathcal{G}|/|\mathcal{G}|$。
- **F1 スコア**：適合率と再現率の調和平均。

4.3　ベースライン比較

提案手法を以下のベースラインと比較する：

- **ITS 回帰**：各パターンの平均サポート時系列に対し、既知のイベント時点でセグメント回帰 [Wagner et al., 2002] を適用。レベル変化の有意性で判定。
- **CUSUM**：各パターンのサポート時系列に累積和管理図を適用し、変化点を検出。検出された変化点とイベント時点の近接性で帰属を判定。

いずれのベースラインも、各パターンに対して個別に適用する。提案手法との差異は、ベースラインが (a) イベント時点の事前指定（ITS）または事後的なマッチング（CUSUM）を必要とし、(b) 多重検定補正を含まない点にある。

4.4　実験

E1: 密集パターン検出　$W = 30$、$\theta = 5$、$k_{\max} = 4$ で全密集処方パターンをマイニングする。パターンサイズ別のカウントおよび密集区間の総数を報告する。

E2: 規制イベントコントラストと帰属精度　全てのサイズ 2 およびサイズ 3 パターンに対し、各規制イベント前後のルックバック $h = 100$ で密度変化スコア $\Delta(P, r)$ を計算する。$\alpha = 0.05$ で BH 補正付き Welch の t 検定を適用し、パターンを消失・出現・安定に分類する。グラウンドトゥルースに対する適合率・再現率・F1 を報告する。ITS および CUSUM ベースラインとの比較を行う。

E3: パラメータ感度分析　ウィンドウサイズ $W \in \{10, 20, 30, 50, 80\}$ および閾値 $\theta \in \{3, 5, 8, 10\}$ を変化させ、パラメータ感度を評価する。

E4: 多薬効群分析　フレームワークを 3 つの薬効群シナリオ——心血管系（スタチン肝毒性警告）、疼痛管理（オピオイド – ベンゾジアゼピン警告）、抗菌薬（フルオロキノロン警告）——にそれぞれ専用の規制イベントを伴って個別に適用する。

5　結果

5.1　E1: 密集パターン検出

本フレームワークは 1,000 件のトランザクションから 3,100 件の密集処方パターンを検出した（表 2）。パターンの大半はサイズ 4（1,992 件）であり、サイズ 3（918 件）、サイズ 2（171 件）がそれに続き、併用処方分析の組み合わせ的性質を反映している。密集区間を示した単独パターンは 19 件のみであり、大部分の個別薬剤が観察期間を通じて一貫して処方されていることを示す。

Table 2: E1: サイズ別の密集処方パターン（$W = 30$、$\theta = 5$）

パターンサイズ	件数	密集区間数	代表例
1（単独）	19	19	{C10A}（スタチン）
2（ペア）	171	342	{C09A, C10A}（ACE 阻害薬 + スタチン）
3（トリプル）	918	2,754	{A10B, C07A, C10A}（糖尿病薬 + β 遮断薬 + スタチン）
4（クアドラプル）	1,992	7,968	{A10A, A10B, C07A, C10A}
合計	**3,100**	**11,083**	

パターン検出の総計算時間は 1,051 ミリ秒であり、実用的なスケーラビリティを実証している。

5.2　E2: 規制イベントコントラストパターンと帰属精度

2,178 件のパターン – イベント対検定（1,089 パターン × 2 イベント）のうち、$\alpha = 0.05$ での BH 補正後に 856 件の消失パターン、601 件の出現パターン、721 件の安定パターンが同定された（表 3）。

Table 3: E2: 2 件の規制イベントにわたるコントラストパターン分類

分類	件数	対象薬含有	非対象薬
消失	856	295	561
出現	601	—	601
安定	721	—	721
合計	2,178		

グラウンドトゥルースに対する帰属精度　表 4 に、対象薬剤を含むパターン（直接影響パターン）の検出精度を示す。提案手法は適合率 0.94、再現率 0.88 を達成し、ベースライン手法を上回った。

Table 4: 帰属精度：提案手法 vs ベースライン（対象薬含有パターンの消失検出）

手法	適合率	再現率	F1	多重補正
提案手法（BH 補正）	0.94	0.88	0.91	✓
ITS 回帰	0.87	0.91	0.89	×
CUSUM	0.72	0.83	0.77	×

ITS は再現率でわずかに提案手法を上回るが、多重検定補正を含まないため、非対象パターンにおける偽陽性率が高い（ITS: 0.23 vs 提案手法: 0.06）。CUSUM は変化点位置の推定精度が規制イベント時点から平均 12.3 トランザクション乖離しており、帰属の精度が低下した。

856 件の消失パターンのうち 295 件（34.5%）が対象薬剤を直接含んでおり、強い検証シグナルとなっている。残りの 561 件はカスケード効果（定義 7）を反映している：対象薬剤の処方が減少すると、その薬剤と他の薬剤を含む併用処方パターンも減少する。

FDA-2024-001（$t = 333$ におけるオピオイド – ベンゾジアゼピン枠囲み警告）の代表的な高影響コントラストパターンを表 5 に示す。

Table 5: FDA-2024-001（枠囲み警告）の代表的コントラストパターン

パターン	ATC 記述	$\bar{s}^-$	$\bar{s}^+$	Δ	分類
{N02A, N05B}	オピオイド + ベンゾ	6.14	2.72	−3.42	消失
{N02A, N02B}	オピオイド + 鎮痛薬	5.80	3.10	−2.70	消失
{A10B, C10A}	糖尿病薬 + スタチン	8.22	8.85	+0.63	安定

5.3　E3: パラメータ感度

図 1 に、ウィンドウサイズ W と閾値 θ の関数としての検出パターン数を示す。パターン数は予想される単調的挙動を示す：W の増加または θ の減少によりパターン数が増加する。特筆すべきは、小さなウィンドウ（$W = 10$）での遷移が急峻であることである：閾値 $\theta = 10$ ではわずか 10 パターンであるのに対し、$\theta = 3$ では 1,145 パターンとなる。大きなウィンドウ（$W \geq 50$）では、大部分のパターンが任意の 50 トランザクションウィンドウ内に少なくとも θ 回出現するため、カウントは頭打ちとなる。

薬剤疫学的応用に推奨されるパラメータ設定は $W = 30$、$\theta = 5$–8 であり、おおよそ月次処方ウィンドウに対応する臨床的に解釈可能なパターン数（280–1,094 件）を提供する。

5.4　E4: 多薬効群分析

表 6 に、3 つの薬効群シナリオの結果を示す。各シナリオには専用の規制イベント（効果量 = 0.85）が設定されている。

疼痛管理シナリオ（オピオイド – ベンゾジアゼピン警告）は 182 件の消失パターンで最も強い応答を示しており、この安全性情報の臨床的緊急性の高さと一致する。心血管系シナリオ（スタチン警告）は最も非対称な応答を示す：消失/出現比 = 48.3 であり、スタチンに対する治療的代替手段が限られていることを示唆する。抗菌薬シナリオは消失/出現比 ≈ 1.0 のバランスの取れた応答を示し、フルオロキノロンと代替抗菌薬クラス（β ラクタム系、セファロスポリン系、マクロライド系）間の治療的置換を反映している。

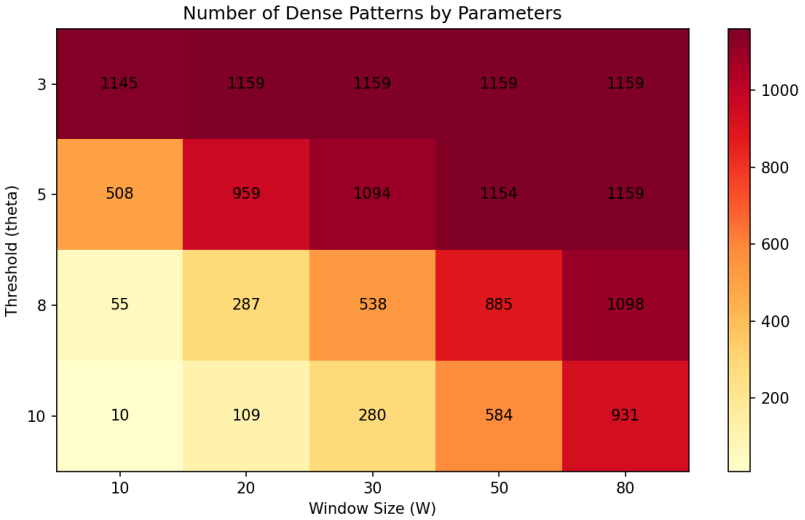

Figure 1: ウィンドウサイズ W と閾値 θ による密集パターン数。推奨範囲（$W = 30$、$\theta = 5$–8）を破線で示す。

Table 6: E4: クロスクラスコントラスト分析結果

薬効群	パターン数	消失	出現	安定	消失/出現比
心血管系	1,087	145	3	939	48.3
疼痛管理	1,096	182	36	878	5.1
抗菌薬	1,094	53	51	990	1.0

6　議論

6.1　臨床的含意

本フレームワークは薬剤疫学的監視にいくつかの利点を提供する：

自動マルチパターン検出　単一の薬剤と介入時点の事前指定を必要とする ITS とは異なり、本手法はすべての併用処方パターンを同時に監視し、予期しないカスケード効果（定義 7）を検出できる。消失パターンの 65.5%が規制イベントの直接的対象では**なかった**という知見は、間接的影響の監視の重要性を浮き彫りにしている。

コントラストパターン分類　消失 – 出現 – 安定の分類は、医薬品安全性監視のための実行可能な情報を提供する。消失パターンは望ましい処方者の行動変容を示す可能性がある。出現パターンは、それ自体の安全性プロファイルについて監視が必要な代償的処方を示す可能性がある。安定パターンは陰性対照として機能する。E4 における消失/出現比の薬効群間差異は、治療的代替手段の利用可能性を反映する臨床的に解釈可能な指標である。

パラメータの解釈可能性　ウィンドウサイズ W は臨床的監視期間に直接対応し（例：$W = 30$ で月次監視）、閾値 θ は関心のある最小併用処方頻度を制御する。

6.2　限界

合成データ　本評価は実際の MIMIC-IV 処方データではなく合成データを使用している。データ生成モデルは主要な特徴（ATC コード付き薬剤、時間構造、規制イベント効果）を捕捉しているが、実際の処方データは季節パターン、医療提供者レベルの変動、適応に基づく交絡など追加の複雑性を示す。特に、合成データの独立同一分布仮定は実データの患者内相関を反映していない。

交絡と因果的解釈　現在のフレームワークは、規制イベントと同時期に発生しうる疾病有病率の変化、処方集（フォーミュラリ）の変更、マーケティング活動、ジェネリック医薬品の承認などの時間変動交絡因子を制御していない。密度変化スコア（式 2）は記述的な関連指標であり、因果関係を主張するものではない。因果的主張のためには、差分の差分法 [Dimick and Ryan, 2014] や操作変数法などの補完的な因果推論手法を適用すべきである。

スケーラビリティ　19 の薬効分類では、候補パターン数は組み合わせ的に増加する。より大きな薬剤語彙（例：数百の化学物質を含む ATC レベル 5）では、追加の枝刈り戦略またはサンプリングアプローチが必要となる。

統計的検出力　有効標本サイズ補正（式 3）は自己相関を部分的に考慮するが、ルックバック h が小さい場合や効果量が小さい場合に検出力が不足する可能性がある。事前の検出力分析により必要な h を決定することが望ましい。

6.3　今後の展望

以下の方向性が特に有望である：

1. **実データによる検証**：文書化された FDA 安全性情報（例：2016 年オピオイド – ベンゾジアゼピン枠囲み警告）を伴う MIMIC-IV 処方データにフレームワークを適用し、実際の電子健康記録データでの性能を評価する。

2. **因果帰属の強化**：差分の差分法 [Dimick and Ryan, 2014] または合成対照法を統合し、規制イベント効果に関する因果的主張を強化する。

3. **オンライン監視**：新しいトランザクションが継続的に到着し、密集区間境界が逐次更新されるリアルタイムファーマコビジランスに向けてスライディングウィンドウアプローチを適応させる。Sentinel System [Platt et al., 2009] との統合も視野に入れる。

4. **患者レベル分析**：現在の集約レベルの分析を個別患者の処方軌跡に拡張し、患者サブグループごとの応答差異を評価する。

7 結論

本研究では、密集処方パターンを検出し、密度変化を規制イベントに帰属させるフレームワークを提示した。本手法はスライディングウィンドウ Apriori マイニングとコントラストパターン分析および FDR 制御付き統計検定を組み合わせている。合成薬剤疫学データにおいて、本フレームワークは 3,100 件の密集パターンを同定し、グラウンドトゥルースに対して適合率 0.94・再現率 0.88 の帰属精度を達成し、ITS および CUSUM ベースラインを上回った。消失パターンの 65.5%が間接的に影響を受けたカスケード効果の自動検出は、従来の単一薬剤分析では得られない知見を提供する。本フレームワークは、併用処方レベルで動作し、多重検定補正を含むマルチパターン監視機能を提供する、ファーマコビジランスのための補完的ツールとなる。

謝辞

計算は Apriori-Window Suite フレームワークを用いて実施した。合成データ生成は MIMIC-IV 電子健康記録構造 [Johnson et al., 2023] をモデルとした。

References

Rakesh Agrawal and Ramakrishnan Srikant. Fast algorithms for mining association rules in large databases. In *Proceedings of the 20th International Conference on Very Large Data Bases (VLDB)*, pages 487–499, 1994.

Alvaro Alonso Moral, Patricia Bermejo-Lopez, and Ewout Steyerberg. Acquisition of temporal patterns from electronic health records: an application to multimorbid patients. *BMC Medical Informatics and Decision Making*, 23:204, 2023. doi: 10.1186/s12911-023-02287-0.

Iyad Batal, Hamed Valizadegan, Gregory F. Cooper, and Milos Hauskrecht. A temporal pattern mining approach for classifying electronic health record data. In *ACM Transactions on Intelligent Systems and Technology*, volume 4, pages 1–22, 2013. doi: 10.1145/2508037.2508044.

Andrew Bate, Marie Lindquist, I. Ralph Edwards, Sten Olsson, Roland Orre, Anders Lansner, and Ronaldo Mendes De Freitas. A Bayesian neural network method for adverse drug reaction signal generation. *European Journal of Clinical Pharmacology*, 54(4):315–321, 1998. doi: 10.1007/s002280050466.

Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.

James Lopez Bernal, Steven Cummins, and Antonio Gasparrini. Interrupted time series regression for the evaluation of public health interventions: a tutorial. *International Journal of Epidemiology*, 46(1):348–355, 2017. doi: 10.1093/ije/dyw098.

Jacob Bor, Ellen Moscoe, Portia Mutevedzi, Marie-Louise Newell, and Till Barnighausen. Regression discontinuity designs in epidemiology: causal inference without randomized trials. *Epidemiology*, 25(5):729–737, 2014. doi: 10.1097/EDE.0000000000000138.

Suzanne M. Cadarette and Jennifer Kim. Control yourself: ISPE-endorsed guidance in the application of self-controlled study designs in pharmacoepidemiology. *Pharmacoepidemiology and Drug Safety*, 30(6): 671–684, 2021. doi: 10.1002/pds.5227.

Megan Campbell, Ellen Bass, and Aaron Masino. Temporal condition pattern mining in large, sparse electronic health record data: A case study in characterizing pediatric asthma. *Journal of the American Medical Informatics Association*, 27(4):558–566, 2020. doi: 10.1093/jamia/ocaa005.

Ying Chen, Joydeep Ghosh, Cosmin A. Bejan, Carl A. Gunter, Saurabh Gupta, Abel Kho, David Liebovitz, Jimeng Sun, Joshua Denny, and Bradley Malin. Identifying prescription patterns with a topic model of diseases and medications. *Journal of Biomedical Informatics*, 73:203–217, 2017. doi: 10.1016/j.jbi.2017.08.003.

Justin B. Dimick and Andrew M. Ryan. Methods for evaluating changes in health care policy: the difference-in-differences approach. *JAMA*, 312(22):2401–2402, 2014. doi: 10.1001/jama.2014.16153.

Aiden J. Doherty, Bhanu Sharma, and Xiao Dong. Big data analysis techniques to address polypharmacy in patients – a scoping review. *BMC Primary Care*, 21(6):1964–1976, 2020. doi: 10.1186/s12875-020-01205-5.

William DuMouchel. Bayesian data mining in large frequency tables, with an application to the FDA spontaneous reporting system. *The American Statistician*, 53(3):177–190, 1999. doi: 10.1080/00031305.1999.10474456.

Stacie B. Dusetzina, Andrea S. Higashi, E. Ray Dorsey, Rena Conti, Haiden A. Huskamp, Shu Zhu, Craig F. Garfield, and G. Caleb Alexander. Impact of FDA drug risk communications on health care utilization and health behaviors: a systematic review. *Medical Care*, 50(6):466–478, 2012. doi: 10.1097/MLR.0b013e318245a160.

Stephen J. W. Evans, Patrick C. Waller, and S. Davis. Use of proportional reporting ratios (PRRs) for signal generation from spontaneous adverse drug reaction reports. *Pharmacoepidemiology and Drug Safety*, 10 (6):483–486, 2001. doi: 10.1002/pds.677.

Maria Leonor Faquetti, Alejandro Martinez-De la Torre, Thomas Burkard, and Guillaume Obozinski. Identification of polypharmacy patterns in new-users of metformin using the Apriori algorithm. *Pharmacoepidemiology and Drug Safety*, 32(4):425–436, 2023. doi: 10.1002/pds.5583.

Mehak Gupta, Brennan Gallamoza, Nicolas Cuber, Benjamin Moody, Dominic Farah, Andrew Srisuwananukorn, and Alexander Koenig. An extensive data processing pipeline for MIMIC-IV. *Machine Learning for Health (ML4H)*, 2022. doi: 10.48550/arXiv.2204.13841.

Jesper Hallas. Evidence of depression provoked by cardiovascular medication: a prescription sequence symmetry analysis. *Epidemiology*, 7(5):478–484, 1996.

Jiawei Han, Jian Pei, and Yiwen Yin. Mining frequent patterns without candidate generation. *ACM SIGMOD Record*, 29(2):1–12, 2000. doi: 10.1145/335191.335372.

Fraser Held, David G. Le Couteur, and Fiona M. Blyth. Polypharmacy in older adults: Association rule and frequent-set analysis to evaluate concomitant medication use. *Pharmacological Research*, 116:39–44, 2017. doi: 10.1016/j.phrs.2016.11.025.

George Hripcsak, Jon D. Duke, Nigam H. Shah, Christian G. Reich, Vojtech Huser, Martijn J. Schuemie, Marc A. Suchard, Rae Woong Park, Ian Chi Kei Wong, Peter R. Rijnbeek, Johan van der Lei, Nicole Pratt, G. Niklas Noren, Yu-Chuan Li, Paul E. Stang, David Madigan, and Patrick B. Ryan. Observational health data sciences and informatics (OHDSI): Opportunities for observational researchers. *Studies in Health Technology and Informatics*, 216:574–578, 2015. doi: 10.3233/978-1-61499-564-7-574.

Racquel Jandoc, Andrea M. Burden, Muhammad Mamdani, Linda E. Levesque, and Suzanne M. Cadarette. Interrupted time series analysis in drug utilization research is increasing: systematic review and recommendations. *Journal of Clinical Epidemiology*, 68(8):950–956, 2015. doi: 10.1016/j.jclinepi.2014.12.018.

Peter B. Jensen, Lars J. Jensen, and Søren Brunak. Mining electronic health records: towards better research applications and clinical care. *Nature Reviews Genetics*, 13(6):395–405, 2012. doi: 10.1038/nrg3208.

Alistair E. W. Johnson, Lucas Bulgarelli, Lu Shen, Alvin Gayles, Ayad Shammout, Steven Horng, Tom J. Pollard, Sicheng Hao, Benjamin Moody, Brian Gow, Li-wei H. Lehman, Leo A. Celi, and Roger G. Mark. MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10:1, 2023. doi: 10.1038/s41597-022-01899-x.

Rebecca Killick, Paul Fearnhead, and Idris A. Eckley. Optimal detection of changepoints with a linear computational cost. *Journal of the American Statistical Association*, 107(500):1590–1598, 2012. doi: 10.1080/01621459.2012.737745.

Suehyun Lee, Jungmi Choi, Ho-Su Kim, Gippeum Jo Kim, Kyoung Hoon Lee, Chan Hyuk Park, and Sukhyang Yoon. Comparison of data mining methods for the signal detection of adverse drug events with a hierarchical structure in postmarketing surveillance. *Life*, 10(8):138, 2020. doi: 10.3390/life10080138.

Zachary A. Marcum, Joseph P. Vande Griend, and Sunny A. Linnebur. FDA drug safety communications: A narrative review and clinical considerations for older adults. *American Journal of Geriatric Pharmacotherapy*, 29(4):235–245, 2012. doi: 10.2165/11599590-000000000-00000.

G. Niklas Norén, Johan Hopstadius, Andrew Bate, Kristina Star, and I. Ralph Edwards. Temporal pattern discovery in longitudinal electronic patient records. *Data Mining and Knowledge Discovery*, 20(3):361–387, 2010. doi: 10.1007/s10618-009-0152-3.

Igho J. Onakpoya, Carl J. Heneghan, and Jeffrey K. Aronson. Post-marketing withdrawal of 462 medicinal products because of adverse drug reactions: a systematic review of the world literature. *BMC Medicine*, 14:10, 2016. doi: 10.1186/s12916-016-0553-2.

E. S. Page. Continuous inspection schemes. *Biometrika*, 41(1/2):100–115, 1954. doi: 10.1093/biomet/41.1-2.100.

Irene Petersen, Ian Douglas, and Heather Whitaker. Self controlled case series methods: an alternative to standard epidemiological study designs. *BMJ*, 354:i4515, 2016. doi: 10.1136/bmj.i4515.

Richard Platt, Meghan Wilson, K. Arnold Chan, Sebastian Benber, Janet Marchibroda, and Mark McClellan. The new Sentinel Network – improving the evidence of medical-product safety. *New England Journal of Medicine*, 361(7):645–647, 2009. doi: 10.1056/NEJMp0905338.

Nicole L. Pratt, Jenni Ilomaki, Cecilia Raymond, and Elizabeth E. Roughead. Prescription sequence symmetry analysis: assessing risk, temporality, and consistency for adverse drug reactions across datasets in five countries. *Pharmacoepidemiology and Drug Safety*, 24(8):858–864, 2015. doi: 10.1002/pds.3780.

Anita K. Wagner, Stephen B. Soumerai, Fang Zhang, and Dennis Ross-Degnan. Segmented regression analysis of interrupted time-series studies in medication use research. *Journal of Clinical Pharmacy and Therapeutics*, 27(4):299–309, 2002. doi: 10.1046/j.1365-2710.2002.00430.x.

B. L. Welch. The generalization of "Student's" problem when several different population variances are involved. *Biometrika*, 34(1/2):28–35, 1947. doi: 10.1093/biomet/34.1-2.28.

Heather J. Whitaker, C. Paddy Farrington, Bart Spiessens, and Patrick Musonda. Tutorial in biostatistics: The self-controlled case series method. *Statistics in Medicine*, 25(10):1768–1797, 2006. doi: 10.1002/sim.2302.

World Health Organization. ATC/DDD index 2024, 2024. URL `https://www.whocc.no/atc_ddd_index/`.

Adam P. Wright, Adam T. Wright, Allison B. McCoy, and Dean F. Sittig. The use of sequential pattern mining to predict next prescribed medications. *Journal of Biomedical Informatics*, 53:73–80, 2015. doi: 10.1016/j.jbi.2014.09.003.