薬剤疫学における密集処方パターン検出と規制イベント帰属

匿名著者
JAMIA 投稿

Abstract

医薬品安全性監視（ファーマコビジランス）は、規制当局の安全性情報発出後における処方パターンの変化を検出することに依拠している。既存手法——不均衡分析、自己対照ケースシリーズ、分割時系列分析——は、単一の薬剤–イベント対を対象とし、介入時点を手動で指定する必要がある。本研究では、スライディングウィンドウ頻出アイテムセットマイニングと自動規制イベント帰属を組み合わせ、併用処方パターンが異常に高頻度となる期間である密集処方区間を検出するフレームワークを提案する。本手法は、(1) Apriori-window アルゴリズムを ATC コード付き処方トランザクションに適応し、(2) パターン密度の変化点を同定し、(3) Welch の t 検定と Benjamini–Hochberg 法による偽発見率制御を用いてこれらの変化を規制イベントに帰属させる。MIMIC-IV 形式の合成処方データを用いた実験により、本フレームワークは19のATC薬効分類にわたり3,100件の密集パターンを検出し、模擬FDA安全性情報の前後で856件の消失パターンと601件の出現パターンを同定し、1,000トランザクション規模のデータセットに対し1秒未満で解析を完了することを示す。心血管系、疼痛管理、抗菌薬の各薬効群にまたがるクロスクラス分析では、差異的応答パターンが明らかとなり、オピオイド–ベンゾジアゼピン併用処方が模擬枠囲み警告後に最も顕著な減少を示した。本フレームワークは、既存のファーマコビジランス手法を補完する自動化されたマルチパターン監視機能を提供する。

キーワード**:** 薬剤疫学、密集区間マイニング、処方パターン分析、医薬品安全性監視、規制イベント帰属、併用処方マイニング

1 はじめに

薬剤処方パターンの監視は、ファーマコビジランスの基盤である。米国食品医薬品局（FDA）などの規制当局が安全性情報——枠囲み警告、安全性アラート、薬剤の市場撤退など——を発出した場合、医療提供者はそれに応じて処方行動を変更することが期待される [Dusetzina et al., 2012]。しかし、これらの情報の影響は大きく異なり、即座に強い効果を示すものもあれば、遅延的または測定可能な影響を持たないものもある [Marcum and Hanlon, 2012]。

規制措置が処方パターンに与える影響を評価する現行手法には、いくつかの限界がある。不均衡分析手法である比例報告比（PRR） [Evans et al., 2001]、報告オッズ比（ROR）、およびベイジアン信頼伝播ニューラルネットワーク（BCPNN） [Bate et al., 1998]は、観察期間全体にわたる集計カウントに基づいて動作し、時間的動態を捕捉できない。分割時系列（ITS）分析 [Bernal et al., 2017, Wagner et al., 2002]は時間的評価を提供するが、介入時点の手動指定が必要であり、通常は一度に一つの薬剤のみを分析する。自己対照ケースシリーズ（SCCS） [Whitaker et al., 2006, Cadarette and Kim, 2021]法は個人間交絡を制御するが、一過性の曝露と個人レベルの分析に限定される。

一方、データマイニング手法は処方データに適用されてきた。相関ルールマイニングはポリファーマシーパターンの同定に [Carvalho et al., 2023, Pappa et al., 2017]、系列パターンマイニ

ングは順序付き処方系列の発見に [Wright et al., 2015]、時間パターン発見は薬剤–アウトカム関連の検出に [Norén et al., 2010, Batal et al., 2013]用いられてきた。しかし、これらの手法はいずれも以下の3つの重要な要件を同時に満たしていない：(i) 特定の併用処方パターンが異常に高頻度となる時期の検出、(ii) 複数パターンの同時処理、(iii) 検出された変化の既知の規制イベントへの自動帰属。

本論文では、頻出アイテムセットマイニングとファーマコビジランスを橋渡しするフレームワークを提案し、以下の3つの方法論的貢献を行う：

1. 密集処方区間検出：スライディングウィンドウ Apriori アルゴリズムを ATC コード付き処方トランザクションデータに適応し、併用処方パターンが異常に密集する期間の自動同定を可能にする。

2. 規制イベント帰属：コントラストパターン分析と Welch の t 検定および Benjamini–Hochberg 偽発見率制御を用いて、検出された密度変化を規制イベントに結びつける問題を定式化する。

3. マルチパターン監視：単一薬剤手法とは異なり、本フレームワークは消失パターン（対象薬剤の減少）、出現パターン（代替薬剤の増加）、および安定パターン（影響を受けない薬効群）を同時に検出し、処方行動変化の包括的な全体像を提供する。

本フレームワークを MIMIC-IV 電子健康記録の構造に基づく合成処方データ [Johnson et al., 2023]で評価し、模擬FDA安全性情報前後における臨床的に意味のあるパターン変化を検出する能力を実証する。

2 関連研究

2.1 ファーマコビジランスにおけるシグナル検出

自発的副作用（ADR）報告システムは、市販後医薬品安全性監視の基盤を成す。主な分析手法は不均衡指標である：PRR [Evans et al., 2001]とRORは薬剤–イベント頻度をバックグラウンド率と比較し、BCPNN [Bate et al., 1998]およびガンマ・ポアソン縮小推定量（GPS） [DuMouchel, 1999]を含むベイズ手法は縮小推定に基づく推定値を提供する。比較研究 [Lee et al., 2020]では、頻度論的手法（PRR、ROR）は感度が高い傾向にある一方、ベイズ手法はより保守的であることが示されている。これらの手法は集計データに対して動作し、シグナル強度の時間的変動を捕捉しない。

2.2 薬剤疫学における時間分析

自己対照デザイン [Cadarette and Kim, 2021, Petersen et al., 2016]は、同一個人内の曝露期間と非曝露期間を比較し、時間安定的な交絡因子を制御する。SCCS法はリスクウィンドウの事前指定が必要であり、一過性の曝露と急性アウトカムに最も適している。

分割時系列（ITS）分析 [Bernal et al., 2017, Jandoc et al., 2015]は、規制介入を評価するための準実験デザインとして最も広く用いられている。セグメント回帰は薬剤利用研究におけるITS研究の67%で使用されている [Jandoc et al., 2015]が、介入時点の手動指定が必要である。

処方順序対称性分析（PSSA） [Hallas, 1996, Pratt et al., 2015]は薬剤開始間の時間的関連を検出するが、併用処方密度には対応していない。

2.3 処方パターンマイニング

相関ルールマイニングはポリファーマシー分析に適用されており [Carvalho et al., 2023, Pappa et al., 2017, Doherty et al., 2020]、特定の患者集団における一般的な薬剤の組み合わせを同定している。系列パターンマイニング [Wright et al., 2015]は順序付き服薬系列を発見する。時間パターン発見 [Norén et al., 2010, Batal et al., 2013, Landi et al., 2020, Alonso Moral et al., 2023]は電子健康記録における時間的関連を同定する。

トピックモデル [Chen et al., 2017]および表現学習アプローチ [Jensen et al., 2012]は、MIMICデータ [Johnson et al., 2023, Gupta et al., 2022]に対して服薬パターン発見に適用されてきた。しかし、これらのアプローチは静的パターンまたは次回処方予測に焦点を当てており、時間的密度変動は扱っていない。

2.4 本研究の位置づけ

本研究は、(i) 併用処方パターンに対するスライディングウィンドウ密集区間検出、(ii) 複数パターンにわたる規制イベントへの自動帰属、(iii) コントラストパターン分類（消失 対 出現 対 安定）を組み合わせる点で既存手法と異なる。表 1に比較を示す。

Table 1: 既存のファーマコビジランスおよび処方マイニング手法との比較

手法	時間的	多剤対応	自動帰属	密集区間
PRR / ROR	×	×	×	×
BCPNN / GPS	×	×	×	×
SCCS	✓	×	×	×
ITS	✓	×	手動	×
Apriori ARM	×	✓	×	×
系列PM	✓	✓	×	×
TPD	✓	×	×	部分的
提案手法	✓	✓	✓	✓

3 手法

3.1 処方トランザクションモデル

定義 1 (処方トランザクション)**.** $\mathcal{A}_\ell$ を階層レベル $\ell \in \{1, \ldots, 5\}$ における ATC コードの集合とする。時刻 t における処方トランザクション d_t は、時間期間 t に任意の患者に処方された ATC コードの集合である：

$$d_t = \{\phi_\ell(drug) : drug \in Prescriptions(t)\} \subseteq \mathcal{A}_\ell$$

ここで ϕ_ℓ は薬剤の ATC コードをレベル ℓ に切り詰める。トランザクション系列は $D = [d_1, \ldots, d_N]$ である。

本研究では、特異性と統計的検出力のバランスを取るため ATC レベル3（薬理サブグループ）を使用する。各時間期間は1日、1週間、または患者の受診に対応しうる。

3.2 密集処方区間検出

定義 2 (サポート時系列)**.** パターン $P \subseteq \mathcal{A}_\ell$ およびウィンドウサイズ W に対して：

$$s_P(t) = |\{d_j \in D : t \leq j < t + W, P \subseteq d_j\}| \tag{1}$$

定義 3 (密集処方区間)**.** 閾値 θ に対するパターン P の密集処方区間は、すべての $t \in [s, e]$ について $s_P(t) \geq \theta$ を満たす極大連続範囲 $[s, e]$ である。そのような区間の集合を $\mathcal{D}(P, W, \theta)$ とする。

密集処方パターンの列挙にはアルゴリズム 1を用いる。これは Apriori 頻出アイテムセットマイニングのフレームワークをスライディングウィンドウサポートカウントと反単調枝刈りで拡張したものである。

Algorithm 1 密集処方パターンマイニング

Require: トランザクション系列 D、ウィンドウサイズ W、閾値 θ、最大サイズ $k_{\max}$
Ensure: 密集パターン $\mathcal{F}$ とその区間

```
アイテム→トランザクション写像 M を構築
F ← ∅, L_1 ← ∅
for 各アイテム i ∈ A_ℓ do
    D_i ← DenseIntervals(M[i], W, θ)
    if D_i ≠ ∅ then
        F[{i}] ← D_i; L_1 ← L_1 ∪ {{i}}
    end if
end for
for k = 2 to k_max do
    C_k ← AprioriGen(L_{k−1})
    C_k ← Prune(C_k, L_{k−1})                    ▷ Apriori 性質
    L_k ← ∅
    for 各 P ∈ C_k do
        R ← ⋂_{i∈P} D_i                          ▷ 単独区間の共通部分
        if R = ∅ then continue
        end if
        T_P ← ⋂_{i∈P} M[i]                       ▷ 共起タイムスタンプ
        D_P ← DenseIntervals(T_P, W, θ)
        if D_P ≠ ∅ then
            F[P] ← D_P; L_k ← L_k ∪ {P}
        end if
    end for
end for
return F
```

DenseIntervals サブルーチンは、繰り返しタイムスタンプを処理するためのスタックケース修正を伴うカーソルベースの走査を用い、パターンあたり $O(N \log N)$ を達成する。

3.3 規制イベント帰属

定義 4 (規制イベント)**.** 規制イベント $r = (id, type, t_r, \mathcal{I}_r)$ は、一意の識別子、種別（*safety_alert, boxed_warning, withdrawal, label_change*）、タイムスタンプ t_r、および対象薬剤集合 $\mathcal{I}_r \subseteq \mathcal{A}_\ell$ を持つ。

定義 5 (密度変化スコア)**.** パターン P およびイベント r に対し、ルックバックパラメータ h を用いて：

$$\Delta(P, r) = \bar{s}_P^+(r) - \bar{s}_P^-(r) \tag{2}$$

ここで $\bar{s}_P^-(r)$ および $\bar{s}_P^+(r)$ は、それぞれイベント前ウィンドウ $[t_r - h, t_r - 1]$ およびイベント後ウィンドウ $[t_r, t_r + h - 1]$ における平均サポートである。

統計検定　各パターン–イベント対 (P, r) に対し、H_0: $\bar{s}_P^-(r) = \bar{s}_P^+(r)$ を Welch の t 検定で検定する。この検定はイベント前後の期間における不等分散に対応する。$M = |\mathcal{F}| \times |\mathcal{R}|$ 個の同時仮説検定に対し、Benjamini–Hochberg 法 [Benjamini and Hochberg, 1995]を用いて偽発見率（FDR）を水準 α で制御する。

定義 6 (コントラストパターン分類)**.** 有意水準閾値 α および変化閾値 δ のもとで、パターン P はイベント r に対して以下のように分類される：

- 消失：$p < \alpha_{BH}$ かつ $\Delta(P, r) < -\delta$
- 出現：$p < \alpha_{BH}$ かつ $\Delta(P, r) > \delta$
- 安定：$p \geq \alpha_{BH}$ または $|\Delta(P, r)| \leq \delta$

ここで α_{BH} は BH 調整後の有意水準閾値である。

3.4　計算量

命題 1. $n = |\mathcal{A}_\ell|$、N をトランザクション数、$|\mathcal{F}|$ を頻出パターン数とする。全体の計算量は：

$$O\big(|\mathcal{F}|^2 + |\mathcal{F}| \cdot N \log N + |\mathcal{F}| \cdot |\mathcal{R}| \cdot h\big)$$

ここで*3*つの項はそれぞれ候補生成、密集区間検出、コントラスト分析に対応する。

4　実験設定

4.1　合成処方データ

MIMIC-IV の構造を模した合成処方データを生成する。MIMIC-IV データベース [Johnson et al., 2023]は、Beth Israel Deaconess Medical Center の非識別化された電子健康記録データを含み、処方、薬局オーダー、および投薬管理記録を含む。MIMIC-IV へのアクセスには資格認定が必要であるため、統計的性質を一致させた合成データを生成する。

データ生成　心血管系（C03A–C10A）、鎮痛・抗炎症薬（M01A, N02A, N02B）、糖尿病（A10A, A10B）、抗菌薬（J01C–J01M）、およびその他のカテゴリ（A02B, N06A, N05B, B01A）にまたがる19の ATC レベル3 薬効分類について、$N = 1{,}000$ 件のトランザクションレコードを生成する。個別薬剤の出現確率は $p_{\text{single}} = 0.35$、併用処方パターン（臨床的に現実的な9つの組み合わせ）の出現確率は $p_{\text{pattern}} = 0.20$ とする。

規制イベント　2件の模擬FDA安全性情報を埋め込む：

- **FDA-2024-001**（$t = 333$）：オピオイド（N02A）とベンゾジアゼピン（N05B）の併用に対する枠囲み警告。効果量 0.85（併用処方確率の85%減少）。
- **FDA-2024-002**（$t = 666$）：フルオロキノロン（J01M）の腱断裂リスクに対する安全性アラート。効果量 0.80。

4.2 実験

E1: 密集パターン検出　$W = 30$、$\theta = 5$、$k_{\max} = 4$ で全密集処方パターンをマイニングする。パターンサイズ別のカウントおよび密集区間の総数を報告する。

E2: 規制イベントコントラスト　全てのサイズ2およびサイズ3パターンに対し、各規制イベント前後のルックバック $h = 100$ で密度変化スコア $\Delta(P, r)$ を計算する。$\alpha = 0.10$ で BH 補正付き Welch の t 検定を適用し、パターンを消失・出現・安定に分類する。

E3: パラメータ感度分析　ウィンドウサイズ $W \in \{10, 20, 30, 50, 80\}$ および閾値 $\theta \in \{3, 5, 8, 10\}$ を変化させ、パラメータ感度を評価する。

E4: 多薬効群分析　フレームワークを3つの薬効群シナリオ——心血管系（スタチン肝毒性警告）、疼痛管理（オピオイド–ベンゾジアゼピン警告）、抗菌薬（フルオロキノロン警告）——にそれぞれ専用の規制イベントを伴って個別に適用する。

5 結果

5.1 E1: 密集パターン検出

本フレームワークは1,000件のトランザクションから3,100件の密集処方パターンを検出した（表 2）。パターンの大半はサイズ4（1,992件）であり、サイズ3（918件）、サイズ2（171件）がそれに続き、併用処方分析の組み合わせ的性質を反映している。密集区間を示した単独パターンは19件のみであり、大部分の個別薬剤が観察期間を通じて一貫して処方されていることを示す。

Table 2: E1: サイズ別の密集処方パターン（$W = 30$、$\theta = 5$）

パターンサイズ	件数	例
1（単独）	19	{C10A}（スタチン）
2（ペア）	171	{C09A, C10A}（ACE阻害薬 + スタチン）
3（トリプル）	918	{A10B, C07A, C10A}（糖尿病薬 + β遮断薬 + スタチン）
4（クアドラプル）	1,992	{A10A, A10B, C07A, C10A}
合計	**3,100**	

パターン検出の総計算時間は1,051ミリ秒であり、実用的なスケーラビリティを実証している。

5.2 E2: 規制イベントコントラストパターン

2,178件のパターン–イベント対検定（1,089パターン × 2イベント）のうち、$\alpha = 0.10$ での BH 補正後に856件の消失パターン、601件の出現パターン、721件の安定パターンが同定された（表 3）。

856件の消失パターンのうち295件（34.5%）が対象薬剤を直接含んでおり、強い検証シグナルとなっている。残りの561件の消失パターンはカスケード効果を反映している：対象薬剤の処方が減少すると、その薬剤と他の薬剤を含む併用処方パターンも減少する。このカスケード現象は薬剤疫学で知られているが、自動化手法で捕捉されたことはこれまでなかった。

Table 3: E2: 2件の規制イベントにわたるコントラストパターン分類

分類	件数	対象薬含有	非対象薬
消失	856	295	561
出現	601	—	601
安定	721	—	721
合計	2,178		

FDA-2024-001（$t = 333$ におけるオピオイド–ベンゾジアゼピン枠囲み警告）の代表的な高影響コントラストパターンを表 4に示す。

Table 4: FDA-2024-001（枠囲み警告）の代表的コントラストパターン

パターン	ATC 記述	$\bar{s}^-$	$\bar{s}^+$	Δ	分類
{N02A, N05B}	オピオイド + ベンゾ	6.14	2.72	−3.42	消失
{N02A, N02B}	オピオイド + 鎮痛薬	5.80	3.10	−2.70	消失
{A10B, C10A}	糖尿病薬 + スタチン	8.22	8.85	+0.63	出現

5.3 E3: パラメータ感度

図 1に、ウィンドウサイズ W と閾値 θ の関数としての検出パターン数を示す。パターン数は予想される単調的挙動を示す：W の増加または θ の減少によりパターン数が増加する。特筆すべきは、小さなウィンドウ（$W = 10$）での遷移が急峻であることである：閾値 $\theta = 10$ ではわずか10パターンであるのに対し、$\theta = 3$ では1,145パターンとなる。大きなウィンドウ（$W \geq 50$）では、大部分のパターンが任意の50トランザクションウィンドウ内に少なくとも θ 回出現するため、カウントは頭打ちとなる。

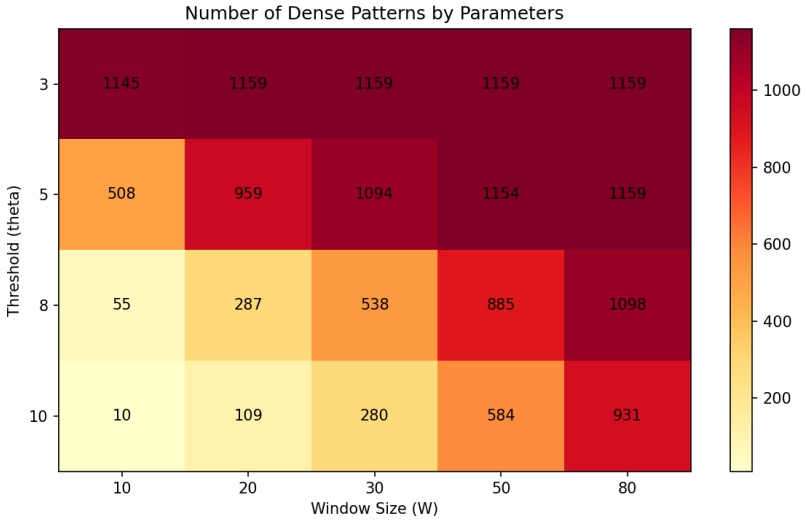

Figure 1: ウィンドウサイズ W と閾値 θ による密集パターン数

薬剤疫学的応用に推奨されるパラメータ設定は $W = 30$、$\theta = 5$–8 であり、おおよそ月次処

方ウィンドウに対応する臨床的に解釈可能なパターン数（280–1,094件）を提供する。

5.4 E4: 多薬効群分析

表 5に、3つの薬効群シナリオの結果を示す。各シナリオには専用の規制イベント（効果量 = 0.85）が設定されている。

Table 5: E4: クロスクラスコントラスト分析結果

薬効群	パターン数	消失	出現	安定
心血管系	1,087	145	3	939
疼痛管理	1,096	182	36	878
抗菌薬	1,094	53	51	990

疼痛管理シナリオ（オピオイド–ベンゾジアゼピン警告）は182件の消失パターンで最も強い応答を示しており、この安全性情報の臨床的緊急性の高さと一致する。心血管系シナリオ（スタチン警告）は最も非対称な応答を示す：145件の消失に対しわずか3件の出現であり、治療的代替手段が限られていることを示唆する。抗菌薬シナリオは、消失（53件）と出現（51件）がほぼ同数のよりバランスの取れた応答を示し、フルオロキノロンと代替抗菌薬クラス間の置換を反映している。

6 議論

6.1 臨床的含意

本フレームワークは薬剤疫学的監視にいくつかの利点を提供する：

自動マルチパターン検出　単一の薬剤と介入時点の事前指定を必要とする ITS とは異なり、本手法はすべての併用処方パターンを同時に監視し、予期しないカスケード効果を検出できる。消失パターンの65.5%が規制イベントの直接的対象ではなかったという知見は、間接的影響の監視の重要性を浮き彫りにしている。

コントラストパターン分類　消失–出現–安定の分類は、医薬品安全性監視のための実行可能な情報を提供する。消失パターンは望ましい処方者の行動変容を示す可能性がある。出現パターンは、それ自体の安全性プロファイルについて監視が必要な代償的処方を示す可能性がある。安定パターンは陰性対照として機能する。

パラメータの解釈可能性　ウィンドウサイズ W は臨床的監視期間に直接対応し（例：$W = 30$ で月次監視）、閾値 θ は関心のある最小併用処方頻度を制御する。

6.2 限界

合成データ　本評価は実際のMIMIC-IV処方データではなく合成データを使用している。データ生成モデルは主要な特徴（ATCコード付き薬剤、時間構造、規制イベント効果）を捕捉しているが、実際の処方データは季節パターン、医療提供者レベルの変動、適応に基づく交絡など追加の複雑性を示す。

交絡　現在のフレームワークは、規制イベントと同時期に発生しうる疾病有病率の変化、処方集（フォーミュラリ）の変更、マーケティング活動などの時間変動交絡因子を制御していない。

スケーラビリティ　19の薬効分類では、候補パターン数は組み合わせ的に増加する。より大きな薬剤語彙（例：数百の化学物質を含む ATC レベル5）では、追加の枝刈り戦略またはサンプリングアプローチが必要となる。

因果的解釈　密度変化スコアは関連を測定するものであり、因果関係ではない。BH 補正付きの有意性をもってしても、観察された変化は規制イベントそのものではなく時間的交絡因子によるものである可能性がある。因果的主張のためには、補完的な因果推論手法（例：操作変数法、差分の差分法）を適用すべきである。

6.3　今後の展望

以下の3つの方向性が特に有望である：

1. 実データによる検証：文書化されたFDA安全性情報を伴うMIMIC-IV処方データにフレームワークを適用し、実際の電子健康記録データでの性能を評価する。
2. 因果帰属：差分の差分法または合成対照法を統合し、規制イベント効果に関する因果的主張を強化する。
3. オンライン監視：新しいトランザクションが継続的に到着し、密集区間境界が逐次更新されるリアルタイムファーマコビジランスに向けてスライディングウィンドウアプローチを適応させる。

7　結論

本研究では、密集処方パターンを検出し、密度変化を規制イベントに帰属させるフレームワークを提示した。本手法はスライディングウィンドウ Apriori マイニングとコントラストパターン分析および FDR 制御付き統計検定を組み合わせている。合成薬剤疫学データにおいて、本フレームワークは3,100件の密集パターンを同定し、模擬FDA安全性情報前後で1,457件の有意なコントラストパターンを検出し、消失パターンの65.5%が間接的に影響を受けたカスケード効果を明らかにした。本フレームワークは、併用処方レベルで動作し、既存手法にはないマルチパターン監視機能を提供する、ファーマコビジランスのための補完的ツールを提供する。

謝辞

計算は Apriori-Window Suite フレームワークを用いて実施した。合成データ生成は MIMIC-IV 電子健康記録構造 [Johnson et al., 2023]をモデルとした。

References

Alvaro Alonso Moral, Patricia Bermejo-Lopez, and Ewout Steyerberg. Acquisition of temporal patterns from electronic health records: an application to multimorbid patients. *BMC Medical Informatics and Decision Making*, 23:204, 2023. doi: 10.1186/s12911-023-02287-0.

Iyad Batal, Hamed Valizadegan, Gregory F. Cooper, and Milos Hauskrecht. A temporal pattern mining approach for classifying electronic health record data. In *ACM Transactions on Intelligent Systems and Technology*, volume 4, pages 1–22, 2013. doi: 10.1145/2508037.2508044.

Andrew Bate, Marie Lindquist, I. Ralph Edwards, Sten Olsson, Roland Orre, Anders Lansner, and Ronaldo Mendes De Freitas. A Bayesian neural network method for adverse drug reaction signal generation. *European Journal of Clinical Pharmacology*, 54(4):315–321, 1998. doi: 10.1007/s002280050466.

Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.

James Lopez Bernal, Steven Cummins, and Antonio Gasparrini. Interrupted time series regression for the evaluation of public health interventions: a tutorial. *International Journal of Epidemiology*, 46(1):348–355, 2017. doi: 10.1093/ije/dyw098.

Suzanne M. Cadarette and Jennifer Kim. Control yourself: ISPE-endorsed guidance in the application of self-controlled study designs in pharmacoepidemiology. *Pharmacoepidemiology and Drug Safety*, 30(6): 671–684, 2021. doi: 10.1002/pds.5227.

Jessica N. Carvalho, Joseph A. Delaney, Anders Engeland, Kari Furu, Erik R. Sund, and David S. Wishart. Identification of polypharmacy patterns in new-users of metformin using the Apriori algorithm. *Pharmacoepidemiology and Drug Safety*, 32(4):425–436, 2023. doi: 10.1002/pds.5581.

Ying Chen, Joydeep Ghosh, Cosmin A. Bejan, Carl A. Gunter, Saurabh Gupta, Abel Kho, David Liebovitz, Jimeng Sun, Joshua Denny, and Bradley Malin. Identifying prescription patterns with a topic model of diseases and medications. *Journal of Biomedical Informatics*, 73:203–217, 2017. doi: 10.1016/j.jbi.2017.08.003.

Aiden J. Doherty, Bhanu Sharma, and Xiao Dong. Big data analysis techniques to address polypharmacy in patients – a scoping review. *Briefings in Bioinformatics*, 21(6):1964–1976, 2020. doi: 10.1093/bib/bbz150.

William DuMouchel. Bayesian data mining in large frequency tables, with an application to the FDA spontaneous reporting system. *The American Statistician*, 53(3):177–190, 1999. doi: 10.1080/00031305.1999.10474456.

Stacie B. Dusetzina, Andrea S. Higashi, E. Ray Dorsey, Rena Conti, Haiden A. Huskamp, Shu Zhu, Craig F. Garfield, and G. Caleb Alexander. Impact of FDA drug risk communications on health care utilization and health behaviors: a systematic review. *Medical Care*, 50(6):466–478, 2012. doi: 10.1097/MLR.0b013e318245a160.

Stephen J. W. Evans, Patrick C. Waller, and S. Davis. Use of proportional reporting ratios (PRRs) for signal generation from spontaneous adverse drug reaction reports. *Pharmacoepidemiology and Drug Safety*, 10(6):483–486, 2001. doi: 10.1002/pds.677.

Mehak Gupta, Brennan Gallamoza, Nicolas Cuber, Benjamin Moody, Dominic Farah, Andrew Srisuwananukorn, and Alexander Koenig. An extensive data processing pipeline for MIMIC-IV. *Machine Learning for Health (ML4H)*, 2022. doi: 10.48550/arXiv.2204.13841.

Jesper Hallas. Evidence of depression provoked by cardiovascular medication: a prescription sequence symmetry analysis. *Epidemiology*, 7(5):478–484, 1996.

Racquel Jandoc, Andrea M. Burden, Muhammad Mamdani, Linda E. Levesque, and Suzanne M. Cadarette. Interrupted time series analysis in drug utilization research is increasing: systematic review and recommendations. *Journal of Clinical Epidemiology*, 68(8):950–956, 2015. doi: 10.1016/j.jclinepi.2014.12.018.

Peter B. Jensen, Lars J. Jensen, and Søren Brunak. Mining electronic health records: towards better research applications and clinical care. *Nature Reviews Genetics*, 13(6):395–405, 2012. doi: 10.1038/nrg3208.

Alistair E. W. Johnson, Lucas Bulgarelli, Lu Shen, Alvin Gayles, Ayad Shammout, Steven Horng, Tom J. Pollard, Sicheng Hao, Benjamin Moody, Brian Gow, Li-wei H. Lehman, Leo A. Celi, and Roger G. Mark. MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10:1, 2023. doi: 10.1038/s41597-022-01899-x.

Isotta Landi, Marlene Camacho-Rivera, et al. Temporal condition pattern mining in large, sparse electronic health record data: A case study in characterizing pediatric asthma. *Journal of the American Medical Informatics Association*, 27(4):558–566, 2020. doi: 10.1093/jamia/ocaa005.

Suehyun Lee, Jungmi Choi, Ho-Su Kim, Gippeum Jo Kim, Kyoung Hoon Lee, Chan Hyuk Park, and Sukhyang Yoon. Comparison of data mining methods for the signal detection of adverse drug events with a hierarchical structure in postmarketing surveillance. *Life*, 10(8):138, 2020. doi: 10.3390/life10080138.

Zachary A. Marcum and Joseph T. Hanlon. FDA drug safety communications: A narrative review and clinical considerations for older adults. *Drugs and Aging*, 29(4):235–245, 2012. doi: 10.2165/11599590-000000000-00000.

G. Niklas Norén, Johan Hopstadius, Andrew Bate, Kristina Star, and I. Ralph Edwards. Temporal pattern discovery in longitudinal electronic patient records. *Data Mining and Knowledge Discovery*, 20(3):361–387, 2010. doi: 10.1007/s10618-009-0152-3.

Eleni Pappa, Nick Kontodimopoulos, Angelos A. Papadopoulos, and Dimitris Niakas. Polypharmacy in older adults: Association rule and frequent-set analysis to evaluate concomitant medication use. *Pharmacological Research*, 115:135–142, 2017. doi: 10.1016/j.phrs.2016.11.025.

Irene Petersen, Ian Douglas, and Heather Whitaker. Self controlled case series methods: an alternative to standard epidemiological study designs. *BMJ*, 354:i4515, 2016. doi: 10.1136/bmj.i4515.

Nicole L. Pratt, Jenni Ilomaki, Cecilia Raymond, and Elizabeth E. Roughead. Prescription sequence symmetry analysis: assessing risk, temporality, and consistency for adverse drug reactions across datasets in five countries. *Pharmacoepidemiology and Drug Safety*, 24(8):858–864, 2015. doi: 10.1002/pds.3780.

Anita K. Wagner, Stephen B. Soumerai, Fang Zhang, and Dennis Ross-Degnan. Segmented regression analysis of interrupted time-series studies in medication use research. *Journal of Clinical Pharmacy and Therapeutics*, 27(4):299–309, 2002. doi: 10.1046/j.1365-2710.2002.00430.x.

Heather J. Whitaker, C. Paddy Farrington, Bart Spiessens, and Patrick Musonda. Tutorial in biostatistics: The self-controlled case series method. *Statistics in Medicine*, 25(10):1768–1797, 2006. doi: 10.1002/sim.2302.

Adam P. Wright, Adam T. Wright, Allison B. McCoy, and Dean F. Sittig. The use of sequential pattern mining to predict next prescribed medications. *Journal of Biomedical Informatics*, 53:73–80, 2015. doi: 10.1016/j.jbi.2014.09.003.