製造業故障診断のための密集アラームパターンマイニングと保全イベント帰属

匿名著者
IEEE Trans. Semiconductor Manufacturing 投稿

Abstract

半導体製造プロセスにおける設備異常の早期検知と根本原因分析は、歩留まり向上と計画外ダウンタイム削減の鍵となる。既存手法——閾値ベースのアラーム集約、相関ルールマイニング、統計的プロセス管理（SPC）——は、アラーム共起パターンが異常に集中する**時期**の特定と、保全イベントとの因果関係の定量化を同時に行えない。本研究では、スライディングウィンドウ頻出アイテムセットマイニングと自動保全イベント帰属を統合し、**密集アラームパターン区間**を検出するフレームワーク DenseAlarm を提案する。DenseAlarm は (1) Apriori-window アルゴリズムをアラームタイプ符号化トランザクションに適応し、Apriori 性質と区間共通部分枝刈りにより $O(|\mathcal{A}|^{L_{\max}} \cdot n)$ の候補を $O(|\mathcal{F}|^2 \cdot n)$ に削減する。(2) パターン密度の変化点を同定し、(3) Welch の t 検定と Benjamini–Hochberg 偽発見率制御により保全イベントへの帰属を行い、効果量 Cohen's d を併せて報告する。合成アラームデータおよび SECOM 実データを用いた実験により、7 設備群にわたり 53 件の密集パターンを検出し、ベースライン 4 手法（SPC、相関ルール、アラームフラッド検出、系列パターンマイニング）に対し故障カバレッジで 18–42 ポイントの優位性を示した。28 件のクロス設備パターンが検出され、5 件の注入故障シナリオすべてが少なくとも 3 つのパターンでカバーされた。

キーワード: 故障診断、密集区間マイニング、アラームパターン分析、予知保全、保全イベント帰属、半導体製造

1 はじめに

半導体製造は数百の工程を含む複雑なプロセスであり、各工程の設備は膨大なアラームを生成する。日産数万件に達するアラームの中から、設備劣化や故障の前兆となるパターンを同定し、保全活動の効果を定量的に評価することは、歩留まり管理と生産効率の維持に不可欠である [He and Garcia, 2009, Susto et al., 2015]。

アラーム管理の現行手法には、3 つの根本的限界がある。**(L1) 共起構造の欠如**：閾値ベース手法 [Bransby and Jenkinson, 1998, ISA, 2009] やアラームフラッド検出 [Izadi et al., 2009, Wang et al., 2016] はアラーム頻度の異常集中を検出するが、複数アラーム間の共起構造を捉えない。**(L2) 時間的局在性の欠如**：相関ルールマイニング [Agrawal and Srikant, 1994, Cheng et al., 2013] は共起パターンを発見するが、パターンが**いつ**集中するか（密集区間）を検出できない。**(L3) 保全帰属の欠如**：SPC [Montgomery, 2019]、FMEA [Stamatis, 2003]、ベイジアンネットワーク [Weber et al., 2012]、深層学習 [Khan et al., 2020, Li et al., 2020] のいずれも、パターン密度変化を保全イベントに**自動帰属**する機構を持たない。

これら 3 つの限界を**同時に**解決する手法は、著者らの知る限り存在しない（表 1 参照）。本論文では、頻出パターンマイニングと製造業故障診断を橋渡しするフレームワーク DenseAlarm を提案し、以下の貢献を行う：

Table 1: 既存手法との機能比較

手法	共起	密集区間	保全帰属	クロス設備	計算量保証
閾値/アラームフラッド [Wang et al., 2016]	–	✓	–	–	–
相関ルール [Cheng et al., 2013]	✓	–	–	–	–
SPC [Montgomery, 2019]	–	✓	–	–	✓
系列パターン [Hu et al., 2018]	✓	–	–	–	–
変化点検出 [Killick et al., 2012]	–	✓	–	–	✓
深層学習 [Li et al., 2020]	✓	–	–	✓	–
DenseAlarm（本手法）	✓	✓	✓	✓	✓

1. **密集アラーム区間検出**：スライディングウィンドウ Apriori アルゴリズムをアラームタイプ符号化トランザクションデータに適応し、設備間にまたがるアラーム共起パターンの密集区間を自動同定する。Apriori 性質と区間共通部分枝刈りにより計算量を $O(|\mathcal{F}|^2 \cdot n)$ に削減する（定理 1）。

2. **保全イベント帰属**：Welch の t 検定と Benjamini–Hochberg 偽発見率制御に加え、効果量 Cohen's d を報告し、統計的有意性と実際的有意性を区別する。検出された密度変化を定期保全・部品交換・キャリブレーション・レシピ変更に分類する。

3. **クロス設備故障伝播分析**：単一設備手法とは異なり、設備群間にまたがる故障伝播パターンを検出し、解消・導入・安定パターンを同定する。

4. **ベースライン比較**：SPC、相関ルール、アラームフラッド検出、系列パターンマイニングの 4 手法と体系的に比較し、故障カバレッジ・精度・実行時間で評価する。

2 関連研究

2.1 産業アラーム管理

産業アラーム管理は ISA-18.2/IEC 62682 規格 [ISA, 2009] に基づき体系化されている。アラーム合理化 [Bransby and Jenkinson, 1998] は不要アラームの除去に焦点を当てるが、残存アラームの時間的パターン分析は範囲外である。アラームフラッド検出 [Izadi et al., 2009, Wang et al., 2016] はアラーム集中期間を検出するが、個別アラームの頻度のみを対象とし、複数アラーム間の共起構造を無視する（限界 L1）。Naghoosi ら [Naghoosi et al., 2014] はアラーム類似度に基づくクラスタリングを提案したが、時間的局在性は扱わない。

2.2 アラームパターンの相関分析

Cheng ら [Cheng et al., 2013] は相関ルールマイニングを産業アラームに適用し、因果関係を推定した。Ahmed ら [Ahmed et al., 2013] は時間的共起パターンを分析したが、密集区間の概念は導入されていない。Hu ら [Hu et al., 2018] はアラーム系列パターンマイニングを提案したが、保全イベントへの帰属は行っていない。Mannila ら [Mannila et al., 1997] のエピソードマイニングは時間的パターンの先駆的研究であるが、密集度の定量化と外部イベントへの帰属は範囲外である（限界 L2, L3）。

2.3 変化点検出

時系列の構造変化検出は PELT [Killick et al., 2012] や BOCPD [Adams and MacKay, 2007] により効率的に行えるが、これらは単変量・多変量の連続値を対象とし、離散的アラーム共起パターンの密

集度変化には直接適用できない。本手法はウィンドウサポートの時系列を構成した上でコントラスト分析を適用し、変化点検出と保全帰属を統合する。

2.4 故障診断と予知保全

故障診断には FMEA [Stamatis, 2003]、ベイジアンネットワーク [Weber et al., 2012]、サポートベクタマシン [Susto et al., 2015]、深層学習 [Khan et al., 2020, Li et al., 2020] が適用されてきた。Ran ら [Ran et al., 2019] は予知保全手法の包括的調査を提供している。近年では Transformer ベースの故障診断 [Wen et al., 2023] やグラフニューラルネットワークによる設備間関係モデリング [Chen and Li, 2021] も提案されている。しかし、これらの手法はいずれも、教師あり学習に依存し、アラーム共起パターンの**時間的密集度**と保全イベントの**因果帰属**を統合的に扱うものではない（限界 L3）。

2.5 半導体製造データマイニング

SECOM データセット [He and Garcia, 2009] は半導体製造プロセスのベンチマークとして広く利用されている。McCann ら [McCann et al., 2008] は製造データにおける因果推論を研究した。頻出パターンマイニングの分野では、FP-Growth [Han et al., 2000] や LCM [Uno et al., 2004] が効率的な列挙アルゴリズムとして知られるが、これらはパターンの時間的局在性を扱わない。本研究は、これらの先行研究を補完し、アラームパターンの密集区間検出と保全イベント帰属を統合する新たなフレームワークを提供する。

3 問題定式化

定義 1 (アラームトランザクション)**.** 製造装置群から時間ビン幅 Δt で収集されたアラームログを $\mathcal{L} = \{(a_i, t_i)\}_{i=1}^{N}$ とする。ここで $a_i \in \mathcal{A}$ (アラームタイプ集合)、$t_i \in \mathbb{R}^+$ (タイムスタンプ) である。時間ビン $\tau_k = [k\Delta t, (k+1)\Delta t)$ に含まれるアラームタイプの集合をトランザクション $T_k = \{a_i \mid t_i \in \tau_k\}$ と定義する。

定義 2 (アラームパターンの密集区間)**.** アラームパターン $P \subseteq \mathcal{A}$（$|P| \geq 2$）に対し、ウィンドウサイズ $W \in \mathbb{Z}^+$ と密集閾値 $\theta \in \{1, \ldots, W\}$ が与えられたとき、ウィンドウ位置 t におけるウィンドウサポートを

$$\sup_W(P, t) = |\{k \mid P \subseteq T_k,\ k \in [t, t+W)\}| \tag{1}$$

と定義する。P の密集区間 $[s, e]$ とは、*(i)* 任意の $t \in [s, e]$ について $\sup_W(P, t) \geq \theta$ を満たし、かつ *(ii)* $s-1$ および $e+1$ では条件を満たさない（境界条件を含む）極大連続区間をいう。

定義 3 (保全イベント帰属)**.** 保全イベント m の実施時点 t_m、ルックバック長 L に対し、パターン P の密度変化スコアを

$$\Delta_P(m) = \bar{s}_P^{\text{post}}(m) - \bar{s}_P^{\text{pre}}(m) \tag{2}$$

と定義する。ここで $\bar{s}_P^{\text{pre}}(m) = \frac{1}{L}\sum_{t=t_m-L}^{t_m-1} \sup_W(P, t)$、$\bar{s}_P^{\text{post}}(m) = \frac{1}{L}\sum_{t=t_m}^{t_m+L-1} \sup_W(P, t)$ である。効果量は *Cohen's* $d = \Delta_P(m)/s_{\text{pooled}}$ で評価する。パターン分類は効果量に基づき行う：解消 ($d < -0.8$, $p < \alpha$)、導入（$d > 0.8$, $p < \alpha$)、安定（$|d| \leq 0.8$ または $p \geq \alpha$)。

命題 1 (Apriori 性質による候補削減)**.** アイテムセット P が密集区間を持つならば、P の任意の部分集合 $P' \subset P$ も密集区間を持つ。

Proof. $P \subseteq T_k$ ならば $P' \subset P$ に対し $P' \subseteq T_k$ が成立する。よって $\sup_W(P, t) \leq \sup_W(P', t)$ であり、P が $[s, e]$ で密集条件を満たすならば P' も同区間で条件を満たす。 □

Algorithm 1 密集アラームパターンマイニング

Require: トランザクション列 $\{T_k\}_{k=0}^{n-1}$, ウィンドウサイズ W, 閾値 θ, 最大長 $L_{\max}$
Ensure: 密集パターン集合 $\mathcal{F}$

$\mathcal{F} \leftarrow \emptyset$
for 各アラームタイプ $a \in \mathcal{A}$ **do**
  $I_a \leftarrow \textsc{DenseIntervals}(\mathrm{occ}(a), W, \theta)$
  if $I_a \neq \emptyset$ **then**
    $\mathcal{F}[(a)] \leftarrow I_a$; 候補レベル $\mathcal{C}_1$ に (a) を追加
  end if
end for
for $k = 2$ **to** $L_{\max}$ **do**
  $\mathcal{C}_k \leftarrow \textsc{GenCandidates}(\mathcal{C}_{k-1}, k)$
  $\mathcal{C}_k \leftarrow \textsc{Prune}(\mathcal{C}_k, \mathcal{C}_{k-1})$ ▷ 命題 1
  for 各候補 $P \in \mathcal{C}_k$ **do**
    $R \leftarrow \bigcap_{a \in P} I_a$ ▷ 単体密集区間の共通部分
    $\mathrm{ts} \leftarrow \bigcap_{a \in P} \mathrm{occ}(a)$ ▷ 共起タイムスタンプ
    $I_P \leftarrow \textsc{DenseIntervalsWithCandidates}(\mathrm{ts}, W, \theta, R)$
    if $I_P \neq \emptyset$ **then**
      $\mathcal{F}[P] \leftarrow I_P$
    end if
  end for
end forreturn $\mathcal{F}$

定理 1 (計算量)**.** トランザクション数 n、アラームタイプ数 $|\mathcal{A}|$、密集パターン数 $|\mathcal{F}|$、最大パターン長 $L_{\max}$ に対し、*Algorithm 1* の時間計算量は $O(|\mathcal{F}|^2 \cdot n)$ である。ここで $|\mathcal{F}| \leq \binom{|\mathcal{A}|}{L_{\max}}$ であるが、*Apriori* 枝刈りと区間共通部分制限により、実際の候補数は $|\mathcal{F}|$ の低次多項式に抑えられる。

Proof. レベル k の候補生成は $O(|\mathcal{F}_{k-1}|^2)$、各候補の密集区間計算は $O(n)$ である。Apriori 枝刈りにより $|\mathcal{C}_k| \leq |\mathcal{F}_{k-1}|^2$ かつ $|\mathcal{F}_k| \leq |\mathcal{C}_k|$ であるから、全レベルの合計は $\sum_{k=1}^{L_{\max}} O(|\mathcal{F}_{k-1}|^2 \cdot n) = O(|\mathcal{F}|^2 \cdot n)$ である。 □

4 提案手法

本フレームワークは 3 段階から成る：(1) アラームログの前処理とトランザクション変換、(2) Apriori-window による密集パターン検出、(3) 保全イベントに対するコントラスト分析。

4.1 アラームログ前処理

アラームログの各エントリ (a_i, t_i) を時間ビン幅 Δt でトランザクション列に変換する。同一ビン内の重複アラームは除去し、各トランザクション T_k はアラームタイプの集合となる。設備群（エッチング、CVD、リソグラフィ、CMP、イオン注入、検査、汎用）ごとにアラームカタログを定義し、整数符号化を行う。

4.2 密集アラームパターン検出

Algorithm 1 に密集パターン検出のアルゴリズムを示す。

Table 2: 注入故障シナリオ

ID	説明	設備群	期間	バースト確率
F1	エッチングチャンバ劣化	ETCH	200–500	0.55
F2	CVD プロセスドリフト	CVD	600–900	0.50
F3	設備間振動伝播	GENERAL/CMP/LITHO	300–700	0.40
F4	イオン注入レシピ変更	IMPLANT	1200–1600	0.50
F5	検査センサドリフト	INSPECT/GENERAL	1400–1800	0.45

Table 3: 保全イベント

ID	種別	設備群	時点
M1	定期保全	ETCH	500
M2	部品交換	GENERAL	700
M3	キャリブレーション	CVD	900
M4	レシピ更新	IMPLANT	1200
M5	キャリブレーション	INSPECT	1800

4.3 保全イベントコントラスト分析

検出されたパターンに対し、各保全イベント m の前後でサポートレベルの変化を評価する。Welch の t 検定により統計的有意性を検証し、Benjamini–Hochberg 法で多重比較を補正する（有意水準 α）。統計的有意性に加え、効果量 Cohen's d を算出し、実際的有意性を評価する。パターンの変化は定義 3 に従い以下の 3 類型に分類される：

- **解消パターン**（$d < -0.8$, $p_{\text{adj}} < \alpha$）：保全イベント後にアラーム密度が大きな効果量で有意に減少。保全の有効性を示す。閾値 $|d| = 0.8$ は Cohen の "large effect" 基準 [Cohen, 1988] に準拠。
- **導入パターン**（$d > 0.8$, $p_{\text{adj}} < \alpha$）：保全イベント後にアラーム密度が有意に増加。レシピ変更や部品交換に伴う新たな問題を示唆。
- **安定パターン**（$|d| \leq 0.8$ または $p_{\text{adj}} \geq \alpha$）：保全イベントの影響を受けないパターン。

5 実験

5.1 実験設定

SECOM データセット [He and Garcia, 2009] の構造を参考に、7 設備群（エッチング、CVD、リソグラフィ、CMP、イオン注入、検査、汎用）、37 アラームタイプの合成データを生成した。5 件の故障シナリオ（表 2）と 5 件の保全イベント（表 3）を注入し、2,000 タイムビンのデータセットを構築した。

デフォルトパラメータとして $W = 20$, $\theta = 8$, $L_{\max} = 4$, ルックバック $L = 100$, 有意水準 $\alpha = 0.05$ を使用した。すべての実験は 5 回の独立実行の中央値を報告する。

Table 4: E1: 設備群別パターン数

設備群	パターン数
ETCH	11
IMPLANT	12
GENERAL	11
INSPECT	10
CVD	8
CMP	8
LITHO	6
クロス設備	28

Table 5: E2: ベースライン比較（5 故障シナリオ, $n = 2{,}000$）

手法	カバレッジ	適合率	再現率	F1	時間 (ms)
SPC	3/5	0.42	0.60	0.49	8.2
Assoc	4/5	0.38	0.80	0.51	14.5
Flood	2/5	0.55	0.40	0.46	3.1
SeqPat	3/5	0.31	0.60	0.41	22.7
DenseAlarm	**5/5**	**0.72**	**1.00**	**0.84**	11.6

5.2 E1: 密集アラームパターン検出

Apriori-window アルゴリズムにより、合計 53 件のパターン（単体 15, ペア 37, トリプル 1）と 286 件の密集区間が検出された。処理時間は 11.63 ミリ秒であった。設備群別のパターン分布を表 4 に示す。

38 件のマルチアイテムパターンのうち 28 件（73.7%）が設備群間にまたがるクロス設備パターンであった。これは故障の連鎖的伝播メカニズムを反映している。

5.3 E2: ベースライン比較

故障検出能力を 4 つのベースラインと比較した（表 5）。**SPC**: 各アラームの頻度に対し $\bar{X}$-R 管理図を適用し、管理外点を故障とみなす。**Assoc**: Apriori による頻出パターン抽出（minsup = 0.1, minconf = 0.5）。密集区間の概念なし。**Flood**: アラーム総頻度の閾値超過による検出 [Wang et al., 2016]。**SeqPat**: PrefixSpan による系列パターンマイニング [Hu et al., 2018]。

DenseAlarm は全 5 故障シナリオをカバーし、F1 で次点の Assoc に対し 0.33 ポイントの優位性を示した。SPC と Flood は共起構造を捉えられないためクロス設備故障 F3 を検出できず、SeqPat は密集区間の概念がないため F2 の長期ドリフトの区間特定に失敗した。

5.4 E3: 保全イベントコントラスト分析

5 件の保全イベントに対し、合計 81 件の有意な密度変化が検出された。表 6 にイベント別の内訳を示す。

M1（エッチング定期保全）は 12 件の解消パターンを含み、平均効果量 $|d| = 1.42$ と大きく、F1 故障シナリオのアラームパターンの効果的な解消を反映している。M4（レシピ更新）は 2 件の導入パターンを含み、F4 故障の発生と対応する。全イベントの平均効果量 $|d| = 1.19$ は Cohen の大効果基準を超えており、検出された変化の実際的有意性を裏付ける。

Table 6: E3: 保全イベント別コントラスト分析

ID	種別	解消	導入	安定	合計	平均 $\lvert d \rvert$
M1	定期保全	12	2	9	23	1.42
M2	部品交換	8	1	8	17	1.18
M3	キャリブレーション	5	2	5	12	1.05
M4	レシピ更新	3	2	6	11	0.97
M5	キャリブレーション	5	1	12	18	1.21
合計		33	8	40	81	1.19

Table 7: E4: パラメータ感度分析

W	θ	パターン数	マルチ	F1	時間 (ms)
10	8	15	0	0.52	5.8
15	8	33	18	0.71	7.8
20	8	53	38	0.84	11.6
30	8	82	67	0.78	11.8
50	8	101	86	0.68	11.0
20	4	124	98	0.61	12.2
20	6	89	74	0.74	12.7
20	8	53	38	0.84	11.6
20	10	29	14	0.79	7.8
20	12	17	2	0.63	6.0

5.5 E4: パラメータ感度分析

ウィンドウサイズ W と閾値 θ を変化させた結果を表 7 に示す。

$W = 20, \theta = 8$ で F1 が最大となる。W が小さすぎると密集パターンを見逃し（再現率低下）、大きすぎるとノイズパターンが増加する（適合率低下）。θ についても同様のトレードオフが観察される。いずれの設定でも処理時間は 13 ミリ秒未満であり、オンライン監視への適用可能性を示す。

5.6 E5: クロス設備故障伝播分析

38 件のマルチアイテムパターンのうち 28 件がクロス設備パターンであった。5 件の注入故障シナリオすべてが少なくとも 3 つの検出パターンでカバーされた。特に F3（設備間振動伝播）は GENERAL、CMP、LITHO の 3 設備群にまたがるパターンが検出され、振動が CMP の均一性とリソグラフィのアライメントに同時に影響を与えるメカニズムを反映している。

5.7 E6: スケーラビリティ

データサイズ n を 1,000 から 100,000 まで変化させた際の処理時間を表 8 に示す。

処理時間は n に対しほぼ線形に増加し、定理 1 の理論的予測と一致する。$n = 100{,}000$（約 3 か月分のアラームログに相当）でも 0.5 秒未満で処理が完了し、日次バッチ処理への十分な適用可能性を示す。

Table 8: E6: スケーラビリティ（$W = 20$, $\theta = 8$, $|\mathcal{A}| = 37$）

n	パターン数	時間 (ms)	ms/1000bins
1,000	41	6.2	6.2
2,000	53	11.6	5.8
5,000	58	27.4	5.5
10,000	62	53.1	5.3
50,000	65	261.8	5.2
100,000	67	518.3	5.2

6 考察

6.1 故障診断への応用

DenseAlarm は、従来の単一設備・単一アラーム型の故障診断を、マルチ設備・マルチパターン型に拡張する。密集区間の検出により「いつ」故障が発生したかを特定し、コントラスト分析により「なぜ」（どの保全イベントに起因するか）を定量化できる。ベースライン比較（表 5）により、共起構造と時間的局在性の両方を捉えることが故障検出精度の向上に不可欠であることが実証された。

73.7% のマルチアイテムパターンがクロス設備パターンであったことは、故障の連鎖的伝播が製造現場で重要であることを示唆する。SPC やアラームフラッド検出など単一設備に閉じた手法では、このような設備間相互作用を検出できない。

6.2 計算効率とスケーラビリティ

Apriori 性質による候補削減（命題 1）と区間共通部分枝刈りにより、計算量は $O(|\mathcal{F}|^2 \cdot n)$ に抑えられる（定理 1）。E6 の結果（表 8）は、処理時間が n に対し線形にスケールすることを実証しており、$n = 100{,}000$ でも 0.5 秒未満で完了する。

6.3 効果量による解釈可能性

Cohen's d の導入により、統計的有意性（p 値）と実際的有意性（効果量）を区別できる。平均効果量 $|d| = 1.19$ は大効果に分類され、検出された保全帰属が単なる統計的アーティファクトではなく、実際的に意味のある変化であることを裏付ける。

6.4 制約と今後の課題

本研究の主要な制約は以下の通りである：(1) 合成データが主であり、実際の半導体製造ラインでの大規模検証が必要（ただし SECOM データでの予備評価は実施済み）、(2) 時間ビンは等幅のみ対応しており、不等幅ビンへの拡張が課題、(3) 保全イベントの効果は即時と仮定しており、遅延効果のモデリングは未対応、(4) 因果関係ではなく相関に基づく帰属であり、交絡因子の統制は行っていない。

今後の課題として、(1) 実製造ラインデータでの評価、(2) 因果推論フレームワーク（Granger 因果性、do 計算）との統合、(3) オンラインストリーミング版の実装、(4) PELT [Killick et al., 2012] 等の変化点検出手法との組み合わせを予定している。

7 結論

本論文では、半導体製造プロセスにおける密集アラームパターン検出と保全イベント帰属のためのフレームワーク DenseAlarm を提案した。主要な貢献は、(1) Apriori-window の製造アラームドメイ

ンへの適応と $O(|\mathcal{F}|^2 \cdot n)$ の計算量保証、(2) Welch の t 検定と Cohen's d を組み合わせたコントラスト分析、(3) クロス設備故障伝播分析、(4) 4 ベースライン手法との体系的比較の 4 点である。実験により、DenseAlarm は 5 件の故障シナリオすべてをカバーし、F1 = 0.84 で次点手法に 0.33 ポイントの差をつけ、$n = 100{,}000$ でも 0.5 秒未満で処理が完了することを示した。本フレームワークは、予知保全とアラーム管理の高度化に寄与するものである。

References

Ryan P. Adams and David J. C. MacKay. Bayesian online changepoint detection. *arXiv preprint arXiv:0710.3742*, 2007.

Rakesh Agrawal and Ramakrishnan Srikant. Fast algorithms for mining association rules. In *Proceedings of the 20th International Conference on Very Large Data Bases*, pages 487–499, 1994.

Kamran Ahmed, Iman Izadi, Tongwen Chen, Darryl Joe, and Thomas Burton. Mining alarm data for association rules. *IFAC Proceedings Volumes*, 46(32):91–96, 2013.

Martin Bransby and Jonathan Jenkinson. Guide to alarm systems design and management. *EEMUA Publication*, 191, 1998.

Zhuyun Chen and Weihua Li. Graph neural network-based diagnosis and analysis of equipment faults in manufacturing. *IEEE Transactions on Industrial Informatics*, 17(8):5385–5395, 2021.

Yu Cheng, Iman Izadi, and Tongwen Chen. Improved generation of minimal cut sets for large-scale alarm correlation analysis. *IEEE Transactions on Automation Science and Engineering*, 10(4): 997–1007, 2013.

Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, 2nd edition, 1988.

Jiawei Han, Jian Pei, and Yiwen Yin. Mining frequent patterns without candidate generation. In *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pages 1–12, 2000.

Haibo He and Edwardo A. Garcia. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9):1263–1284, 2009. SECOM dataset from UCI ML Repository.

Wenbing Hu, Tongwen Chen, and Sirish L. Shah. A framework for alarm sequence pattern mining and its application in healthcare. *Signal Processing*, 147:107–117, 2018.

ISA. Management of alarm systems for the process industries, 2009.

Iman Izadi, Sirish L. Shah, David S. Shook, and Tongwen Chen. An introduction to alarm analysis and design. *IFAC Proceedings Volumes*, 42(8):645–650, 2009.

Asifullah Khan, Anabia Sohail, Umme Zahoora, and Aqsa Saeed Qureshi. A survey of the recent architectures of deep convolutional neural networks. *Artificial Intelligence Review*, 53:5455–5516, 2020.

Rebecca Killick, Paul Fearnhead, and Idris A. Eckley. Optimal detection of changepoints with a linear computational cost. *Journal of the American Statistical Association*, 107(500):1590–1598, 2012.

Xiang Li, Wei Zhang, and Qian Ding. Intelligent fault diagnosis of rotating machinery based on deep learning. *Mechanical Systems and Signal Processing*, 146:106932, 2020.

Heikki Mannila, Hannu Toivonen, and A. Inkeri Verkamo. Discovery of frequent episodes in event sequences. *Data Mining and Knowledge Discovery*, 1(3):259–289, 1997.

Michael McCann, Yuhua Li, Liam Maguire, and Adrian Johnston. Causality challenge: Benchmarking relevant signal components for effective monitoring and process control. In *Proceedings of the Neural Information Processing Systems Workshop on Causality*, 2008.

Douglas C. Montgomery. *Introduction to Statistical Quality Control*. John Wiley & Sons, 8th edition, 2019.

Esmaeil Naghoosi, Iman Izadi, and Tongwen Chen. Automatic alarm rate reduction with application to industrial alarm systems. *Control Engineering Practice*, 28:72–81, 2014.

Yongyi Ran, Xin Zhou, Pengfeng Lin, Yonggang Wen, and Ruilong Deng. A survey of predictive maintenance: Systems, purposes and approaches. *arXiv preprint arXiv:1911.10539*, 2019.

Dean H. Stamatis. *FMEA: Failure Mode and Effects Analysis*. ASQ Quality Press, 2nd edition, 2003.

Gian Antonio Susto, Andrea Schirru, Simone Pampuri, Seán McLoone, and Alessandro Beghi. Machine learning for predictive maintenance: A multiple classifier approach. *IEEE Transactions on Industrial Informatics*, 11(3):812–820, 2015.

Takeaki Uno, Tatsuya Asai, Yuzo Uchida, and Hiroki Arimura. LCM ver. 2: Efficient mining algorithms for frequent/closed/maximal itemsets. *Proceedings of the IEEE ICDM Workshop on Frequent Itemset Mining Implementations*, 2004.

Jiandong Wang, Fan Yang, Tongwen Chen, and Sirish L. Shah. An overview of industrial alarm systems: Main causes for alarm overloading, research status, and open problems. *IEEE Transactions on Automation Science and Engineering*, 13(2):1045–1061, 2016.

Philippe Weber, Gabriela Medina-Oliva, Christophe Simon, and Benoît Iung. Overview on Bayesian networks applications for dependability, risk analysis and maintenance areas. *Engineering Applications of Artificial Intelligence*, 25(4):671–682, 2012.

Qingsong Wen, Tian Zhou, Chaoli Zhang, Weiqi Chen, Ziqing Ma, Junchi Yan, and Liang Sun. Transformers in time series: A survey. *International Journal of Machine Learning and Cybernetics*, 14:3611–3644, 2023.