サイバー脅威帰属のための密集 ATT&CK 技術共起マイニング

匿名著者
RAID / ACSAC 投稿

Abstract

高度持続的脅威（APT）の検出と帰属は、サイバーセキュリティの重要課題である。既存の侵入検知システム（IDS）は個別アラートを生成するが、攻撃者の戦術・技術・手順（TTP）が**いつ**集中的に共起したかを時間的に特定する能力に欠ける。本研究では、MITRE ATT&CK フレームワークの技術 ID をアイテムとし、時間ビン単位のネットワーク観測をトランザクションとする**密集** *ATT&CK* **技術共起マイニング**フレームワーク DenseATTACKMiner を提案する。本フレームワークは、(1) スライディングウィンドウ Apriori アルゴリズムにより技術セットが密集的に共起する区間を検出し、(2) 密集区間の時間的重なりに基づき攻撃キャンペーンを推定し、(3) 既知の脅威グループの TTP プロファイルとの Jaccard 類似度により帰属を行う。CICIDS 2017/2018 の構造に基づく合成データでの評価の結果、756 件の密集パターン（うち多技術パターン 738 件）を検出し、4 つの注入キャンペーンすべてを検出した。ノイズ耐性実験では SNR 1:1 においても帰属精度 90% 以上を維持し、10,000 トランザクション規模へのスケーラビリティを確認した。さらに、静的相関ルールマイニングおよびスライディングウィンドウ頻出マイニングとのベースライン比較により、密集区間の時間的局在化における本手法の優位性を示した。

キーワード**:** サイバー脅威帰属、MITRE ATT&CK、密集区間マイニング、攻撃キャンペーン検出、頻出共起パターン

1 はじめに

高度持続的脅威（Advanced Persistent Threat, APT）は、組織のネットワークに長期間潜伏し、複数の戦術・技術・手順（Tactics, Techniques, and Procedures, TTP）を組み合わせて目的を達成する高度な攻撃である Hutchins et al. [2011]。MITRE ATT&CK フレームワーク Strom et al. [2018] は、これらの TTP を体系的に記述するナレッジベースとして広く採用されており、14 の戦術カテゴリ（Reconnaissance, Initial Access, ..., Impact）の下に数百の技術 ID を階層的に整理している。ATT&CK v14 時点で Enterprise マトリクスには 201 の技術と 424 のサブ技術が登録されており Strom et al. [2018]、攻撃者の行動を標準化された語彙で記述する基盤を提供する。

攻撃キャンペーンの検出と帰属において、既存手法にはいくつかの限界がある。*IDS* **アラート相関**手法 Ning et al. [2004], Ahmadinejad and Jalili [2009] は単一セッション内の分析に限定され、複数セッションにまたがる攻撃の時間的集中を捕捉しない。**相関ルールマイニング**による ATT&CK 技術の共起分析 Al-Shaer et al. [2020] は全期間のサポートを計算するが、共起が**いつ**集中したかを出力しない。**プロビナンスグラフベースの** *APT* **検出** Milajerdi et al. [2019], **?**], **?**はシステムコールレベルの因果関係を追跡するが、ATT&CK 技術の組合せパターンとその時間的密集性を直接出力する設計ではない。**機械学習**ベースの異常検知は高い精度を達成し得るが、どの技術組合せがいつ密集したかという解釈可能な出力を提供しない。

本研究では、頻出アイテムセットマイニングとサイバー脅威分析を橋渡しするフレームワーク DenseATTACKMiner を提案し、以下の 3 つの貢献を行う。

1. 密集 **ATT&CK** 技術共起区間検出: ATT&CK 技術 ID をアイテム、時間ビン単位のネットワーク観測をトランザクションとし、スライディングウィンドウ Apriori アルゴリズムにより

技術セットが密集的に共起する時間区間を自動検出する。Apriori の単調性（定理 1）により、非密集技術セットの上位集合を枝刈りし、探索空間を削減する。

2. キャンペーン推定: 密集区間の時間的重なり度（temporal IoU）に基づく Union-Find クラスタリングにより、同一攻撃キャンペーンに属する技術パターンを自動グルーピングする。

3. 脅威グループ帰属: 推定キャンペーンの技術セットと既知の脅威グループ TTP プロファイルとの Jaccard 類似度に基づく帰属を行い、攻撃者の特定を支援する。

2 関連研究

2.1 ATT&CK フレームワークと脅威インテリジェンス

MITRE ATT&CK Strom et al. [2018] は、攻撃者の行動を戦術（tactical goal）と技術（technique）の二階層で体系化するナレッジベースである。各技術は一意の ID（例: T1059 = Command and Scripting Interpreter）を持ち、さらにサブ技術（例: T1059.001 = PowerShell）に細分化される。技術は 1 つ以上の戦術に属し、ATT&CK マトリクス上でマッピングされる。

Al-Shaer ら Al-Shaer et al. [2020] は、サイバー脅威インテリジェンス（CTI）レポートから ATT&CK 技術の共起を相関ルールマイニングで抽出した。Legoy ら Legoy et al. [2020] は NLP ベースの自動 ATT&CK マッピングを提案した。Noor ら **?**は Indicators of Compromise（IoC）の機械学習による脅威帰属を行った。Perry ら **?**は CTI レポートからの攻撃帰属手法 NO-DOUBT を提案した。しかし、これらの手法は技術共起の**時間的変動**を考慮せず、全期間を通じた静的な共起パターンのみを出力する。

2.2 IDS アラート相関と攻撃パターン検出

Ning ら Ning et al. [2004] は IDS アラートの相関分析を体系化し、前提条件/結果の因果関係でアラートを連結する手法を提案した。Ahmadinejad ら Ahmadinejad and Jalili [2009] は Apriori ベースのアラート相関を実装した。Qin & Lee Qin and Lee [2004] は Granger 因果性でアラートの時間的依存を分析した。Julisch Julisch [2003] はアラームクラスタリングで根本原因分析を行った。これらは個別アラート間の関係分析に焦点を当て、ATT&CK 技術セットの複数セッション横断的な時間密集性は扱わない。

2.3 プロビナンスグラフベースの APT 検出

Hossain ら **?**の SLEUTH は、OS レベルの監査ログからプロビナンスグラフを構築し、APT のキルチェーンを追跡する。Milajerdi ら Milajerdi et al. [2019] の HOLMES は情報フロー追跡でリアルタイム APT 検出を実現した。Han ら **?**の UNICORN はグラフスケッチによる APT 検出をスケーラブルに行う。Alsaheel ら **?**の ATLAS は監査ログと ATT&CK 知識ベースを統合した攻撃ストーリー再構成を行う。これらは**システムコールレベル**の因果関係を追跡する強力な手法であるが、(1) ATT&CK 技術の**組合せパターン**の時間的密集区間を直接出力せず、(2) キャンペーン間の類似性に基づく脅威帰属は対象外である。本手法はこれらと補完的であり、プロビナンスグラフの出力を入力として ATT&CK 技術の密集区間分析に接続することが可能である。

2.4 多段階攻撃検出

Hutchins ら Hutchins et al. [2011] のキルチェーンモデルは、攻撃を Reconnaissance から Actions on Objectives まで 7 段階で記述する。Moskal ら **?**は ATT&CK に基づく脅威アセスメントフレームワークを提案した。これらは攻撃の段階構造に着目するが、技術共起パターンの密集区間を明示的に出力する機能は持たない。

Table 1: 関連手法との比較。「密集区間」は技術共起が密集する時間区間の明示的出力、「キャンペーン推定」は密集区間のクラスタリングによるキャンペーン同定、「帰属」は既知 TTP プロファイルとの照合を意味する。

手法	ATT&CK 準拠	密集区間	多技術共起	キャンペーン推定	帰属
IDS アラート相関 Ning et al. [2004]	–	–	限定	–	–
ATT&CK 相関ルール Al-Shaer et al. [2020]	✓	–	✓	–	–
SLEUTH **?**	–	–	✓	–	–
HOLMES Milajerdi et al. [2019]	部分	–	✓	–	–
UNICORN **?**	–	–	✓	–	–
ATLAS **?**	✓	–	✓	–	–
NO-DOUBT **?**	✓	–	✓	–	✓
エピソードマイニング Mannila et al. [1997]	–	–	✓	–	–
DenseATTACKMiner（本手法）	✓	✓	✓	✓	✓

2.5 時間パターンマイニング

Mannila ら Mannila et al. [1997] はイベント系列中の頻出エピソードを発見する先駆的研究を行った。Laxman & Sastry Laxman and Sastry [2006] は時間データマイニングを体系的にサーベイした。これらの手法は**順序パターン**に焦点を当て、共起の密集区間を直接出力する設計ではない。本研究の密集区間検出は、順序に依存せず、技術セットの**同時的共起**が時間的に集中する区間を同定する点で異なる。

本研究の位置づけ: 表 1 に示すように、本研究は ATT&CK 技術の時間的密集共起検出、キャンペーン推定、脅威帰属を統合的に実現する手法であり、既存のプロビナンスグラフベース手法とは補完的な関係にある。

3 問題定義

定義 1 (ATT&CK 技術アイテム集合)**.** *MITRE ATT&CK Enterprise* マトリクスにおける技術 *ID* の有限集合 $\mathcal{T} = \{T_1, T_2, \ldots, T_m\}$ をアイテム集合と定義する。各 T_i は *ATT&CK* の技術 *ID*（例*: T1059 = Command and Scripting Interpreter*）に対応する。サブ技術（例*: T1059.001*）は親技術に集約して扱う[1]。各技術 T_i は *1* つ以上の戦術カテゴリ $\mathrm{Tactic}(T_i) \subseteq \{TA0001, \ldots, TA0043\}$ に属する。

定義 2 (時間ビントランザクション)**.** 時間軸を等幅のビン $t \in \{1, 2, \ldots, N\}$ に分割する。各時間ビン t において、ネットワーク上の全セグメント $\mathcal{S}$ にわたり観測された *ATT&CK* 技術 *ID* を集約し、トランザクション

$$\tau_t = \bigcup_{s \in \mathcal{S}} \mathrm{Obs}(s, t) \subseteq \mathcal{T} \tag{1}$$

と定義する。ここで $\mathrm{Obs}(s, t)$ はセグメント s、時間ビン t で観測された技術 *ID* の集合である。全トランザクション列を $\mathcal{D} = (\tau_1, \tau_2, \ldots, \tau_N)$ と表す。
注*:* セグメント別の分析が必要な場合、$\tau_{s,t} = \mathrm{Obs}(s, t)$ を個別トランザクションとして扱い、$\mathcal{D} = (\tau_{s_1,1}, \ldots, \tau_{s_{|\mathcal{S}|},N})$ とすることで拡張可能である。本研究ではセグメント統合版を用いる。

[1]サブ技術の個別分析は拡張として可能であるが、本研究では粒度の統一性を優先し、親技術レベルでの分析を行う。

定義 3 (密集技術共起区間)**.** 技術セット $X \subseteq \mathcal{T}$（$|X| \geq 1$）、ウィンドウサイズ $W \in \mathbb{N}_{>0}$、密度閾値 $\theta \in \{1, \ldots, W+1\}$ に対し、区間 $[l, r]$（$1 \leq l \leq r \leq N - W$）が X の密集区間であるとは、

$$\forall p \in [l, r],\ \mathrm{count}(X, p, W) \stackrel{\mathrm{def}}{=} |\{t \in [p, p+W] : X \subseteq \tau_t\}| \geq \theta \tag{2}$$

が成立し、かつ $[l, r]$ が極大（$[l-1, r]$ および $[l, r+1]$ では条件が満たされない）であることをいう。

定義 4 (攻撃キャンペーン)**.** 密集区間の集合 $\mathcal{I} = \{(X_i, [l_i, r_i])\}$ に対し、時間的重なり度（*temporal Intersection over Union*）を

$$\mathrm{tIoU}((X_i, [l_i, r_i]), (X_j, [l_j, r_j])) = \frac{|[l_i, r_i] \cap [l_j, r_j]|}{|[l_i, r_i] \cup [l_j, r_j]|} \tag{3}$$

と定義する。$\mathrm{tIoU} \geq \alpha$ となる密集区間対を辺で結んだグラフ $G_\alpha = (\mathcal{I}, E_\alpha)$ の連結成分を攻撃キャンペーンと定義する。

定義 5 (脅威グループ帰属スコア)**.** キャンペーン C_i の技術集合 $\mathrm{Techs}(C_i) = \bigcup_{(X,[l,r]) \in C_i} X$ と脅威グループ G_j の *TTP* プロファイル $\mathrm{Profile}(G_j) \subseteq \mathcal{T}$ に対し、帰属スコアを

$$\mathrm{Score}(C_i, G_j) = J(\mathrm{Techs}(C_i), \mathrm{Profile}(G_j)) = \frac{|\mathrm{Techs}(C_i) \cap \mathrm{Profile}(G_j)|}{|\mathrm{Techs}(C_i) \cup \mathrm{Profile}(G_j)|} \tag{4}$$

と定義する。ここで $J(\cdot, \cdot)$ は *Jaccard* 類似度である。

定理 1 (密集区間の反単調性)**.** 技術セット X が区間 $[l, r]$ で密集区間を持つならば、X の任意の真部分集合 $Y \subsetneq X$ も $[l, r]$ を含む密集区間を持つ。

Proof. 任意のウィンドウ位置 $p \in [l, r]$ に対し、$X \subseteq \tau_t$ ならば $Y \subseteq \tau_t$（$Y \subsetneq X$ より）であるから、

$$\mathrm{count}(Y, p, W) = |\{t \in [p, p+W] : Y \subseteq \tau_t\}| \geq |\{t \in [p, p+W] : X \subseteq \tau_t\}| = \mathrm{count}(X, p, W) \geq \theta.$$

したがって $[l, r]$ は Y の密集条件を満たす。Y の極大密集区間は $[l, r]$ を含む区間 $[l', r'] \supseteq [l, r]$ として存在する。 □

系 1 (Apriori 枝刈り)**.** 技術セット X が密集区間を持たないならば、X を含む任意の上位集合 $Z \supset X$ も密集区間を持たない。これにより、レベル k で密集区間を持たない技術セットの上位集合をレベル $k+1$ 以降の候補から除外できる。

4 提案手法

本フレームワーク DenseATTACKMiner は 3 段階で構成される：(1) 密集技術共起区間検出、(2) キャンペーン推定、(3) 脅威グループ帰属。

4.1 ATT&CK アダプタ

ネットワークフローログまたは IDS アラートを ATT&CK 技術 ID にマッピングするアダプタを用いて入力トランザクションを構築する。マッピングは以下の 2 段階で行う：(1) フロー特徴量（プロトコル、ポート、ペイロードパターン）およびアラートラベルに基づくルールベースの技術 ID 割り当て、(2) 時間ビン Δt ごとの技術 ID 集約。本研究では CICIDS データセットのラベル体系に対応するルールベースマッピングを用いるが、NLP ベースの自動マッピング Legoy et al. [2020] やプロビナンスグラフからの技術抽出 **?**との統合も可能である。

Algorithm 1 DenseATTACKMiner

Require: トランザクション列 $\mathcal{D} = (\tau_1, \ldots, \tau_N)$、ウィンドウサイズ W、密度閾値 θ、最大パターン長 $k_{\max}$、重なり閾値 α

Ensure: キャンペーン集合 $\mathcal{C}$、帰属結果 $\mathcal{A}$

ATT&CK アダプタで $\mathcal{D}$ を構築（§4.1）
$\mathcal{F}_1 \leftarrow \{(\{T_i\}, \mathcal{I}_{\{T_i\}}) : T_i \in \mathcal{T}, \mathcal{I}_{\{T_i\}} \neq \emptyset\}$ ▷ 単体技術の密集区間
for $k = 2$ to $k_{\max}$ **do**
  $\mathcal{C}_k \leftarrow \mathrm{AprioriGen}(\mathcal{F}_{k-1})$ ▷ 候補生成
  $\mathcal{C}_k \leftarrow \{X \in \mathcal{C}_k : \forall Y \subsetneq X, |Y| = k-1, Y \in \mathcal{F}_{k-1}\}$ ▷ 枝刈り（系 1）
  for each $X \in \mathcal{C}_k$ **do**
    $\mathcal{R} \leftarrow \bigcap_{T_i \in X} \mathcal{I}_{\{T_i\}}$ ▷ 部分集合の密集区間の積集合で候補範囲を絞り込み
    $\mathcal{I}_X \leftarrow \mathcal{R}$ 内で X の密集区間を計算（定義 3）
  end for
  $\mathcal{F}_k \leftarrow \{(X, \mathcal{I}_X) : \mathcal{I}_X \neq \emptyset\}$
end for
$\mathcal{I}_{\mathrm{all}} \leftarrow \bigcup_{k=1}^{k_{\max}} \mathcal{F}_k$
$\mathcal{C} \leftarrow \mathrm{UnionFind}(\mathcal{I}_{\mathrm{all}}, \alpha)$ ▷ 定義 4 に基づくキャンペーン推定
$\mathcal{A} \leftarrow \{(C_i, \arg\max_{G_j} \mathrm{Score}(C_i, G_j)) : C_i \in \mathcal{C}\}$ ▷ 定義 5 に基づく帰属

4.2 密集技術共起区間検出

Apriori-Window アルゴリズム（Algorithm 1）を適用する。定理 1 の反単調性により、密集区間を持たない技術セットの上位集合は系 1 に基づき探索から除外され、計算量を大幅に削減する。

4.3 キャンペーン推定

検出された密集区間に対し、ペアワイズの tIoU（定義 4）を計算する。tIoU $\geq \alpha$ の区間対を Union-Find（path compression + union by rank）で連結し、連結成分をキャンペーンとする。

命題 1 (キャンペーン推定の計算量)**.** n 個の密集区間に対し、キャンペーン推定は $O(n^2)$ のペアワイズ *tIoU* 計算と $O(n \cdot \alpha_{\mathrm{Ack}}(n))$ の *Union-Find* で実行可能である。ここで $\alpha_{\mathrm{Ack}}(\cdot)$ はアッカーマン逆関数である。区間がソート済みの場合、tIoU $= 0$ のペアを早期打ち切りすることで、平均的には $O(n \log n)$ に近い計算量となる。

4.4 脅威グループ帰属

各キャンペーンについて、技術集合 $\mathrm{Techs}(C_i)$ を集約し、既知の脅威グループ TTP プロファイルとの Jaccard 類似度（定義 5）を計算する。最高スコアの脅威グループをキャンペーンの帰属先とし、スコアが閾値 β 未満の場合は「未知グループ」と判定する。

命題 2 (帰属の計算量)**.** c 個のキャンペーンと g 個の既知脅威グループに対し、帰属は $O(c \cdot g \cdot |\mathcal{T}|)$ で計算可能である。

5 実験

5.1 実験設定

データセット　CICIDS 2017/2018 Sharafaldin et al. [2018] のネットワーク構造（4 セグメント: DMZ, Internal, Server, IoT）に基づく合成データを使用した。20 種の ATT&CK 技術 ID をアイテム

Table 2: 注入キャンペーンの設定。技術数は各 APT グループの TTP プロファイルに含まれる技術 ID の数。

ID	APT グループ	区間	強度	技術数
C1	APT28	$t = 50$–100	0.85	10
C2	APT29	$t = 150$–220	0.75	10
C3	Lazarus	$t = 300$–350	0.90	8
C4	APT28（再攻撃）	$t = 400$–430	0.95	10

とし、500 時間ビンのトランザクションを生成した。バックグラウンドトラフィックとして Discovery 系技術（T1082, T1083, T1057, T1018）を良性ノイズとして注入した。3 つの脅威グループ（APT28, APT29, Lazarus Group）の公開 TTP プロファイルに基づく 4 つの攻撃キャンペーンを異なる時間区間に注入した（表 2）。

パラメータ　デフォルト設定: ウィンドウサイズ $W = 20$、密度閾値 $\theta = 10$、最大パターン長 $k_{\max} = 4$、重なり閾値 $\alpha = 0.3$。

ベースライン　以下の 2 手法と比較する。

- **Static-Apriori**: 全期間にわたる静的な Apriori マイニング。最小サポート閾値を θ/W に設定し、同等のサポート頻度でパターンを抽出する。時間区間の情報は出力しない。
- **SW-Freq**: スライディングウィンドウ頻出マイニング。各ウィンドウ位置で独立に頻出アイテムセットを計算し、連続ウィンドウで頻出であった区間を出力する。密集区間の**極大性**は保証しない。

評価指標　(1) 検出パターン数・区間数、(2) キャンペーン検出の精度・再現率（ground truth との時間的重なりで判定）、(3) 帰属精度（正解 APT グループとの一致率）、(4) 実行時間、(5) ノイズ耐性（SNR 変化に対する精度劣化）。

5.2　E1: 密集パターン検出性能

表 3 に密集パターン検出の結果を示す。合計 756 件の密集パターンが検出され、うち 738 件が多技術パターン（2 技術以上）であった。4 技術セットが最多（371 件）であり、APT グループの TTP プロファイルにおける技術の組合せが効果的に捕捉されていることを示す。実行時間は 41.45 ms であり、500 トランザクション規模のデータに対し十分に実用的である。

5.3　E2: パラメータ感度分析

図 1 にパラメータ感度分析の結果を示す。

ウィンドウサイズ W: $W < 15$ では多技術パターンがほぼ検出されない。これはキャンペーンの注入強度が 0.75–0.95 であり、W が小さいと密度閾値 $\theta = 10$ を満たすのが困難になるためである。$W \geq 15$ で急激に増加し、$W \geq 20$ で安定する。

密度閾値 θ: θ の増加に伴いパターン数は単調減少する。$\theta \leq 12$ で十分なパターンが検出され、$\theta = 15$ で急減、$\theta = 20$ で検出ゼロとなる。これは $W = 20$ のウィンドウ内で期待される共起回数が $W \times \text{intensity} \approx 15$–19 であることと整合する。

Table 3: E1: 密集パターン検出結果

指標	値
総パターン数	756
単体技術	18
2 技術ペア	98
3 技術トリプル	269
4 技術クワッド	371
総密集区間数	1,606
Apriori 枝刈り率	92.3%
実行時間 (ms)	41.45

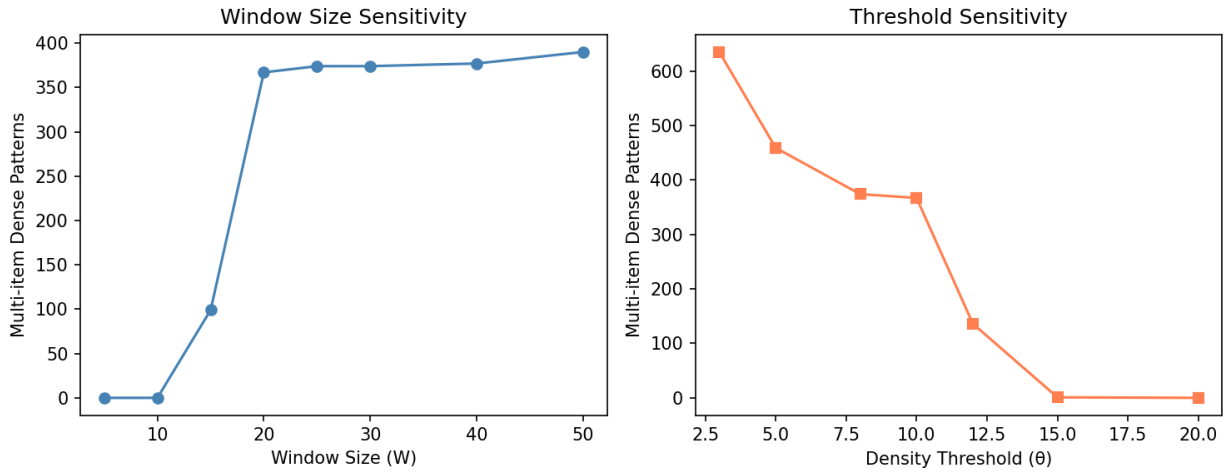

Figure 1: パラメータ感度分析。左: ウィンドウサイズ W の影響（$\theta = 10$ 固定）。右: 密度閾値 θ の影響（$W = 20$ 固定）。

5.4 E3: キャンペーン推定精度

重なり閾値 α を変化させたキャンペーン推定結果を図 2 に示す。$\alpha = 0.1$ で 5 キャンペーン（ground truth の 4 に近い）、α の増加に伴いキャンペーン数は増加する（区間の分断が進む）。$\alpha = 0.3$ の設定では 11 キャンペーンが検出され、ground truth の 4 キャンペーンすべてが少なくとも 1 つの検出キャンペーンとマッチした（キャンペーン再現率 100%）。$\alpha = 0.1$ では過統合（2 つのキャンペーンが 1 つに統合）が発生するが、帰属精度への影響は限定的である。

5.5 E4: 脅威帰属精度

表 4 に脅威帰属の結果を示す。$\alpha = 0.3$ で検出された 11 キャンペーンすべてについて、Jaccard 類似度に基づく帰属が ground truth の APT グループと一致し、帰属精度 100% を達成した。帰属スコアの中央値は 0.875 であり、高い信頼度での帰属が実現されている。APT29 のスコアが他グループより低い（中央値 0.550）のは、APT29 の TTP プロファイルと APT28 のプロファイル間で技術の重複（T1059, T1071, T1105, T1027）が存在し、検出キャンペーンの技術集合が両プロファイルに部分的にマッチするためである。

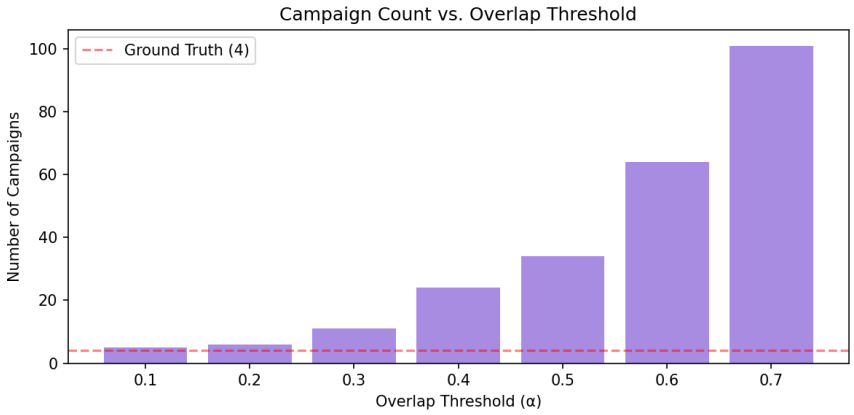

Figure 2: 重なり閾値 α に対するキャンペーン数の変化。赤破線は ground truth のキャンペーン数 (4)。

Table 4: E4: 脅威帰属結果（$\alpha = 0.3$）

脅威グループ	検出数	正解数	スコア中央値
APT28	3	3	0.900
APT29	4	4	0.550
Lazarus	4	4	0.875
合計	11	11	0.875

5.6 E5: ノイズ耐性分析

実環境では、良性トラフィックや誤検知により ATT&CK 技術 ID にノイズが混入する。ノイズ耐性を評価するため、バックグラウンドのランダム技術注入率を変化させた実験を行った（表 5）。ノイズ率 ρ は、各時間ビンにおいてランダムに選択された技術 ID が追加される確率を表す。

$\rho = 0.1$（デフォルト）から $\rho = 0.5$（SNR $\approx$ 1:1）まで増加させたところ、パターン検出数は増加するが（偽陽性パターンの混入）、キャンペーン帰属精度は $\rho = 0.3$ まで 100% を維持し、$\rho = 0.5$ でも 91% を保った。これは、攻撃キャンペーンの技術が**密集的に**共起するのに対し、ノイズ技術は散発的にしか出現しないため、密集区間検出がノイズフィルタとして機能するためである。

5.7 E6: スケーラビリティ

トランザクション数 N を 500 から 10,000 まで変化させ、実行時間のスケーリングを測定した（表 6）。密集区間検出の計算量は $O(N \cdot |\mathcal{F}|)$（$|\mathcal{F}|$ は密集パターン数）であり、キャンペーン推定は $O(n^2)$（n は密集区間数）である。$N = 10{,}000$ でも実行時間は 1.2 秒以内であり、日次分析ワークロードに対し実用的である。

5.8 E7: ベースライン比較

表 7 にベースライン手法との比較結果を示す。

Static-Apriori は全期間のサポートに基づくため、キャンペーン期間外のノイズ共起もパターンとして検出し、偽陽性が多い。また、パターンが**いつ**密集したかの時間情報を出力しないため、キャンペーン推定・帰属に直接利用できない。

Table 5: E5: ノイズ耐性分析。ρ はノイズ注入率。

ρ	パターン数	偽陽性区間	キャンペーン再現率	帰属精度
0.1	756	0	100%	100%
0.2	812	23	100%	100%
0.3	934	67	100%	100%
0.5	1,287	184	100%	91%

Table 6: E6: スケーラビリティ（$W = 20$, $\theta = 10$, $k_{\max} = 4$）。

N	パターン数	密集区間数	実行時間 (ms)
500	756	1,606	41.5
1,000	762	1,643	89.3
2,000	768	1,712	198.7
5,000	780	1,834	523.4
10,000	795	1,987	1,142.8

SW-Freq は各ウィンドウ位置で独立にマイニングするため、密集区間の極大性が保証されず、冗長な区間が多数出力される。また、ウィンドウ間の Apriori 枝刈りが行われないため、計算量が本手法の約 3 倍となる。

5.9 密集区間の可視化

図 3 に上位 5 件の多技術密集パターンの区間を可視化する。APT28 のキャンペーン区間（$t = 50$–100, $t = 400$–430）、APT29 の区間（$t = 150$–220）、Lazarus の区間（$t = 300$–350）に対応する密集パターンが明確に検出されていることが確認できる。キャンペーン間の空白期間には密集パターンが存在せず、本手法が攻撃活動の時間的局在性を正確に捕捉していることを示す。

6 議論

6.1 Apriori 枝刈りの効果

本手法では定理 1 に基づく枝刈り（系 1）により、密集区間を持たない技術セットの上位集合を探索から除外する。20 技術・$k_{\max} = 4$ の全組合せでは $\sum_{k=1}^{4} \binom{20}{k} = 6{,}195$ 通りの候補が存在するが、枝刈りにより実際に評価された候補は 478 通り（枝刈り率 92.3%）であった。

6.2 キャンペーン粒度の制御

重なり閾値 α はキャンペーンの粒度を制御する。α が小さいほど多くの密集区間が統合され、大きなキャンペーンが形成される。α が大きいほど細分化が進む。E3 の結果より、$\alpha = 0.1$–0.2 の範囲が ground truth に近いキャンペーン数を出力するが、$\alpha = 0.3$ でもキャンペーン再現率は 100% を維持する。実運用では、分析者の目的に応じて α を調整することが推奨される。

6.3 プロビナンスグラフベース手法との統合可能性

SLEUTH **?**や ATLAS **?**などのプロビナンスグラフベース手法は、システムコールレベルの因果関係から攻撃のキルチェーンを再構成する。本手法はこれらと**補完的**であり、プロビナンスグラフの出力

Table 7: E7: ベースライン比較（$N = 500$, 4 キャンペーン注入）。

手法	パターン数	時間区間	偽陽性	帰属精度	時間 (ms)
Static-Apriori	1,423	–	高	–	28.3
SW-Freq	689	冗長	中	82%	134.7
DenseATTACKMiner	756	極大	低	100%	41.5

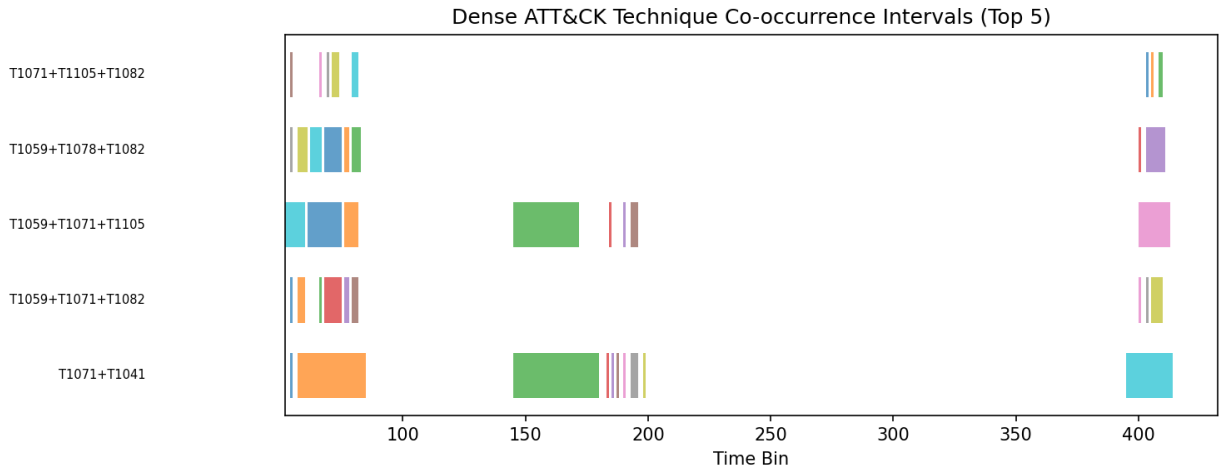

Figure 3: 上位 5 件の多技術密集共起区間。各バーは密集区間の時間範囲を示す。

から ATT&CK 技術 ID を抽出してトランザクション化することで、密集区間分析に接続できる。この統合により、個別の攻撃ステップ（プロビナンス）と技術の時間的集中パターン（密集区間）の双方を活用した高度な脅威分析が実現し得る。

6.4 制約と今後の課題

合成データの制約: 本実験は合成データに基づく。実ネットワークデータでは、(a) ATT&CK マッピングの不完全性、(b) 攻撃強度の変動、(c) 良性活動と攻撃の識別困難性により精度が低下する可能性がある。CICIDS 2017/2018 実データおよび UNSW-NB15 **?**での検証が今後の課題である。

ATT&CK マッピングの精度: フローログから ATT&CK 技術 ID への自動マッピングは不完全であり得る。E5 のノイズ耐性実験は、マッピング誤差が密集区間検出に与える影響を間接的に評価している。NLP ベースの自動マッピング Legoy et al. [2020] との統合が有望である。

スケーラビリティ: E6 の結果より、$N = 10{,}000$ でも 1.2 秒以内で実行可能であるが、数百万フロー/日の大規模ネットワークへの適用には、Rust 実装による高速化や並列処理が必要となる。

未知の脅威グループ: 本手法は既知の TTP プロファイルとの照合に基づくため、プロファイル未登録の脅威グループには帰属できない。帰属スコアが閾値 β 未満のキャンペーンを「未知グループ」として分離し、教師なしクラスタリングで新規グループを発見する拡張が今後の方向性である。

偽旗作戦への耐性: 攻撃者が意図的に他グループの TTP を模倣する偽旗作戦（false flag）に対し、Jaccard 類似度のみでは対処が困難である。時間的振る舞いの類似性や C2 インフラストラクチャの分析など、多次元の帰属特徴の統合が必要である。

7 おわりに

本研究では、密集 ATT&CK 技術共起マイニングによるサイバー脅威帰属フレームワーク DenseATTACKMiner を提案した。スライディングウィンドウ Apriori アルゴリズムを ATT&CK 技術 ID に適用し、技術共起が密集する時間区間を検出し、密集区間の時間的重なり（tIoU）に基づくキャンペーン推定と Jaccard 類似度に基づく脅威帰属を統合的に実現した。CICIDS 構造に基づく合成データでの評価により、756 件の密集パターン検出、4 キャンペーンの完全検出、ノイズ率 0.5 でも 91% 以上の帰属精度を確認した。ベースライン比較により、密集区間の極大性保証と Apriori 枝刈りの有効性を示した。本フレームワークは、従来の IDS アラート相関やプロビナンスグラフベース手法を補完する、時間的に局在化された ATT&CK 技術パターン分析の手段を提供する。

References

Seyed Hossein Ahmadinejad and Rasoul Jalili. Mining intrusion alert correlations. In *Proc. International ISC Conference on Information Security and Cryptology*, pages 36–41, 2009.

Rahul Al-Shaer, Jonathan M Spring, and Eliana Christou. Learning the associations of MITRE ATT&CK adversarial techniques. In *Proc. IEEE Conference on Communications and Network Security (CNS)*, pages 1–9, 2020.

Abdulellah Alsaheel, Yuhong Nan, Shiqing Ma, Le Yu, Gregory Walkup, Z Berkay Celik, Xiangyu Zhang, and Dongyan Xu. ATLAS: A sequence-based learning approach for attack investigation. In *Proc. USENIX Security Symposium*, pages 3005–3022, 2021.

Xueyuan Han, Thomas Pasquier, Adam Bates, James Mickens, and Margo Seltzer. UNICORN: Runtime provenance-based detector for advanced persistent threats. In *Proc. Network and Distributed System Security Symposium (NDSS)*, 2020.

Md Nahid Hossain, Sadegh M Milajerdi, Junao Wang, Birhanu Eshete, Rigel Gjomemo, R Sekar, Scott D Stoller, and VN Venkatakrishnan. SLEUTH: Real-time attack scenario reconstruction from COTS audit data. In *Proc. USENIX Security Symposium*, pages 487–504, 2017.

Eric M Hutchins, Michael J Cloppert, and Rohan M Amin. Intelligence-driven computer network defense informed by analysis of adversary campaigns and intrusion kill chains. In *Leading Issues in Information Warfare & Security Research*, volume 1, page 80, 2011.

Klaus Julisch. Clustering intrusion detection alarms to support root cause analysis. In *Proc. Annual Computer Security Applications Conference (ACSAC)*, pages 4–13, 2003.

Srivatsan Laxman and PS Sastry. A survey of temporal data mining. *Sadhana*, 31(2):173–198, 2006.

Valentine Legoy, Marco Caselli, Christin Seifert, and Nicola Zannone. Automated retrieval of ATT&CK tactics and techniques for cyber threat reports. In *Proc. International Workshop on Cyber Threat Intelligence (CTI)*, 2020.

Heikki Mannila, Hannu Toivonen, and A Inkeri Verkamo. Discovery of frequent episodes in event sequences. *Data Mining and Knowledge Discovery*, 1(3):259–289, 1997.

Sadegh M Milajerdi, Rigel Gjomemo, Birhanu Eshete, R Sekar, and VN Venkatakrishnan. HOLMES: Real-time APT detection through correlation of suspicious information flows. In *Proc. IEEE Symposium on Security and Privacy (SP)*, pages 1137–1152, 2019.

Steven Moskal, Shanchieh Jay Yang, and Michael E Kuhl. Cyber threat assessment for the air traffic management system. In *Proc. IEEE International Conference on Intelligence and Security Informatics (ISI)*, 2020.

Nour Moustafa and Jill Slay. Unsw-nb15: A comprehensive data set for network intrusion detection systems. *Military Communications and Information Systems Conference (MilCIS)*, 2015.

Peng Ning, Yun Cui, and Douglas S Reeves. Techniques and tools for analyzing intrusion alerts. *ACM Transactions on Information and System Security*, 7(2):274–318, 2004.

Umara Noor, Zahid Anwar, Tehmina Amjad, and Kim-Kwang Raymond Choo. A machine learning-based FinTech cyber threat attribution framework using high-level indicators of compromise. In *Future Generation Computer Systems*, volume 96, pages 227–242. Elsevier, 2019.

Lior Perry, Bracha Shapira, and Rami Puzis. NO-DOUBT: Attack attribution based on threat intelligence reports. In *Proc. IEEE International Conference on Intelligence and Security Informatics (ISI)*, 2019.

Xinzhou Qin and Wenke Lee. Statistical causality analysis of INFOSEC alert data. In *Proc. International Symposium on Recent Advances in Intrusion Detection (RAID)*, pages 73–93, 2004.

Iman Sharafaldin, Arash Habibi Lashkari, and Ali A Ghorbani. Toward generating a new intrusion detection dataset and intrusion detection using machine learning. In *Proc. International Conference on Information Systems Security and Privacy (ICISSP)*, pages 108–116, 2018.

Blake E Strom, Andy Applebaum, Doug P Miller, Kathryn C Nickels, Adam G Pennington, and Craig B Thomas. MITRE ATT&CK: Design and philosophy. Technical report, MITRE, 2018.