サポート時系列分析に基づく外部イベント帰属フレームワーク — 頻出パターンの変動要因を統計的に特定する —

（執筆者未定）

ドラフト

***Abstract*—頻出パターンマイニングはトランザクションデータ中の繰り返し出現するアイテムセットを発見するが，特定期間にパターンの出現頻度が変動する原因を説明する機能を持たない．小売・Web 分析・医療など多くの実応用では，販促キャンペーン・祝日・制度変更といった外部イベントがパターン頻度の時間的変動を駆動しており，どのイベントがどのパターン変化を引き起こしたかを特定することが意思決定の鍵となる．**

本稿ではイベント帰属パイプラインを提案する．本手法は (1) Phase 1（Apriori-window）で得られた密集区間からの変化点抽出，(2) 変化点前後のレベル差評価，(3) 変化点とイベント間の時間的近接度スコアリング，(4) 円形シフト置換検定によるグローバル Benjamini–Hochberg FDR 補正付き有意性検定，(5) Union-Find クラスタリングによるアイテム重複排除の 5 ステップから成る．アイテム重複排除は，真に影響を受けたパターンとアイテムを共有する副次パターンが相関した偽陽性を生む問題（副次パターン問題）を解決する．

合成データ実験では，全信号強度（ブースト係数 0.1–0.8）で F1 = 1.0 を達成し，パラメータ選択（ウィンドウサイズ 10–50，σ 5–200，置換回数 50–1000）に対して頑健であることを示す．実データ（T10I4D100K，10 万トランザクション）では，注入パターンを全て検出（Recall = 1.0）しつつ，重複排除なし版と比較して偽陽性を 96% 削減した．パイプラインはデータサイズ・イベント数・置換回数に対して線形にスケールし，100 万トランザクションまでの動作を確認した．

***Index Terms*—frequent pattern mining, event attribution, change point detection, permutation test, multiple testing correction, support time series**

I. はじめに

頻出パターンマイニング [1]–[3] は，トランザクションデータ中に繰り返し出現するアイテムセットを発見する基盤的技術であり，小売分析，Web マイニング，バイオインフォマティクスなど幅広い分野で応用されている．Apriori [1]，FP-Growth [2]，ECLAT [4] といった古典的手法はグローバル頻出パターンを効率的に列挙し，スライディングウィンドウ型手法 [5] は特定時間区間内で局所的に密集するパターンを検出する．

しかし，これらの手法はどのパターンがいつ頻出であるかを同定するのみであり，なぜパターンの出現頻度が変動するかを説明する機能を持たない．実際の応用場面では，販促キャンペーン，祝日，規制変更，システム更新といった外部イベントがパターンサポートの時間的変動を駆動していることが多い．「どのイベントがどのパターンの変動を引き起こしたか」を特定できれば，キャンペーン効果の定量化，副作用の検出，システム異常の診断など，意思決定に直結する知見が得られる．

このように帰属タスクは実用上重要であるにもかかわらず，頻出パターンのサポート変動を外部イベントに結びつける統計フレームワークはこれまで存在しなかった．時間的パターンマイニング [6]–[9] は周期性や局所頻度を持つパターンを発見するが，パターン変動と外生イベントの関連はモデル化しない．変化点検出手法 [10], [11] は個別時系列の構造変化を同定するが，数千のパターンサポート時系列を同時に検定する多重検定の負荷や，検出された変化をイベントに紐づける機能は備えていない．計量経済学のイベント・スタディ法 [12] は企業イベントの株価への影響を評価するが，単一のアウトカム変数を対象としており，数千のパターン時系列を同時に扱う設定には適用できない．

A. 本研究の貢献

本稿では，頻出パターンマイニングと外部イベント帰属を橋渡しする統計フレームワーク「**イベント帰属パイプライン**」を提案する．貢献は以下の 3 点である．

1) **5 ステップパイプライン**（IV節）: 密集区間からの変化点抽出，変化量の評価，変化点とイベント間の帰属スコアリング，円形シフト置換検定によるグローバル Benjamini–Hochberg [13] FDR 補正，およびアイテム重複排除からなる統合フレームワーク．
2) **アイテム重複排除**（IV-E節）: 真に影響を受けたパターンとアイテムを共有する副次パターンが相関した偽陽性を生む問題（副次パターン問題）を，イベントごとの Union-Find クラスタリングにより解決する新しい後処理技法．
3) **包括的な実験評価**（V節）: (i) 合成データにおける完全検出（F1 = 1.0），(ii) パラメータ選択に対する頑健性，(iii) 100 万トランザクションまでの線形スケーラビリティ，(iv) 実データにおける偽陽性 96% 削減を実証する．

II. 関連研究

A. 頻出パターンマイニング

頻出パターンマイニングは，トランザクションデータの一定割合以上に出現するアイテムセットを発見する技術であり，包括的なサーベイが複数存在する [3], [14]. Apriori [1] は反単調性に基づく候補生成・枝刈りフレームワークを確立した．FP-Growth [2] は FP-tree により候補生成を回避し高速化を実現した．ECLAT [4] は縦型（tidset）表現と集合積により効率的なサポート計算を行う．LCM [15] は頻出・閉・極大アイテムセットの最適列挙を達成した．これらの手法はグローバル頻度を対象とし，時間的な変動をモデル化しない．

B. 時間的・局所的パターンマイニング

頻出パターンの時間的側面を扱う拡張研究がいくつか存在する．LPFIM [6] は時間区間内の局所頻出集合を対象とするが，gap ベースの閾値に依存する．PFPM [7] および PPFPM [8] は周期性制約を導入した．LPPM [9] は局所性と周期性の基準を統合する．Ho ら [16] は相互情報量を用いた枝刈りにより大規模時系列からの時間的パターンマイニングを高速化した．Apriori-window [5] は固定幅スライディングウィンドウ上で局所サポートを直接評価し，gap パラメータに依存しない密集パターン抽出を実現した．ストリームデータに対しては，スライディングウィンドウ上の頻出アイテムセットマイニング [17], [18] が研究されている．Batal ら [19] は多変量時系列からの最近時間パターンマイニングによるイベント検出を提案した．

これらの手法はいずれもパターンがいつ頻出であるかを検出するが，頻度が変動する原因はモデル化しない．本研究はこれらを補完し，検出されたサポート変動を外部イベントに帰属させる．

C. コントラスト・エマージングパターンマイニング

データセット間のパターン頻度の差異に着目する研究群が存在する．エマージングパターン [20] は，あるデータセットから別のデータセットへのサポートの有意な増加を捉えるパターンである．コントラストセットマイニング [21] は，グループ間の判別的特徴を発見する．Komiyama ら [22] は多重検定補正を伴う統計的エマージングパターンマイニングを提案した．Chen ら [23] がコントラストパターンマイニングの包括的サーベイを提供している．これらの手法はデータセット間（例: 時間区間間）の差を検出するが，差の原因となる外部イベントへの帰属は行わない．本研究はサポート変動の検出に留まらず，統計検定による帰属まで踏み込む．

D. 変化点検出

変化点検出は時系列データの構造変化を同定する技術である．CUSUM アルゴリズム [10] は逐次過程の平均シフトを検出する．包括的なサーベイ [11], [24] がパラメトリック・ノンパラメトリック・オンライン手法を網羅している．これらの手法は個別時系列に適用されるが，数千のパターンサポート時系列を同時分析する多重検定の負荷には対応せず，検出された変化をイベントに結びつける機能も持たない．

E. イベント帰属と因果推論

計量経済学のイベント・スタディ法 [12] は，企業イベント（合併，決算発表等）の株価への影響を異常リターン分析により定量化する．Brodersen ら [25] はベイズ構造時系列モデルにより介入の因果効果を推定する CausalImpact フレームワークを提案した．分散システムにおける根本原因分析 [26]–[28] は，異常を特定のコンポーネントや設定変更に帰属させる．Granger 因果 [29] とその拡張は，ある時系列が別の時系列の予測に寄与するか否かを検定する．

これらのアプローチは典型的には単一または少数のアウトカム変数を分析する．対照的に，本研究の設定では数千のパターンサポート時系列を複数のイベントに対して同時に検定する必要があり，偽発見率を制御するための多重検定補正が不可欠である．

F. 統計的パターンマイニングと多重検定補正

頻出パターンマイニングに統計的有意性検定を導入する研究が近年活発である．Webb [30] は自己充足アイテムセットの概念を導入し，サブセット・スーパーセットの頻度から説明できないパターンのみを有意とする枠組みを提案した．Hämäläinen と Webb [31] はパターン発見における統計的健全性のチュートリアルを提供している．Terada ら [32] は LAMP（Limitless Arity Multiple-testing Procedure）を提案し，検定可能なパターン数に基づく Bonferroni 因子の最小化を実現した．Pellegrina と Vandin [33] は Westfall–Young 置換手続きを用いた高速な有意パターンマイニングを提案した．

これらの研究はパターンの有意性を二群間の頻度差として検定するが，本研究ではパターンサポートの時間的変動と外部イベントの関連を検定する点が異なる．本パイプラインは，円形シフト置換検定 [34], [35] と全パターン・全イベントにわたるグローバル BH 補正 [13] を組み合わせ，分布自由な検定と適切な多重検定制御を両立させる．Bonferroni 補正 [36] は族単位誤り率（FWER）を制御するが保守的であるため，本研究では FDR を制御する BH 手続きを採用した．

III. 問題定義

A. 記法

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ を有限のアイテム全集合，$D = [d_1, d_2, \ldots, d_N]$ を時刻順のトランザクション列とする．各トランザクション d_t（$t = 1, \ldots, N$）は $\mathcal{I}$ の部分集合である．アイテムセット（パターン）$P \subseteq \mathcal{I}$ がトランザクション d_t に出現するとは $P \subseteq d_t$ が成立することをいう．

定義 1 (サポート時系列). パターン P，ウィンドウサイズ $W \in \mathbb{Z}_{>0}$，トランザクション列 D (長さ N) に対して，P のサポート時系列 $s_P = [s_P(0), s_P(1), \ldots, s_P(N-W)]$ を

$$s_P(t) = \left|\{d_j \in D \mid t \le j < t + W,\ P \subseteq d_j\}\right| \qquad (1)$$

と定義する．これは位置 t を始点とするウィンドウ $[t, t+W)$ 内で P を含むトランザクション数である．

定義 2 (外部イベント)．外部イベント $e = (id, name, t_s, t_e)$ は，一意な識別子，名称，およびイベントが有効な期間を表すタイムスタンプ区間 $[t_s, t_e]$ から成る．既知の外部イベント集合を $\mathcal{E} = \{e_1, e_2, \ldots, e_K\}$ とする．

定義 3 (変化点（閾値交差）)．本稿では，サポート時系列 s_P に対する変化点として，一般のレベルシフト点すべてではなく，閾値 θ に関する密状態／非密状態の切替点のみを扱う．位置 $\tau \in \{0, 1, \ldots, N - W\}$ が変化点であるとは，次のいずれかが成り立つことをいう:

$$s_P(\tau) \geq \theta \wedge (\tau = 0 \vee s_P(\tau - 1) < \theta), \tag{2}$$

$$s_P(\tau) < \theta \wedge \tau > 0 \wedge s_P(\tau - 1) \geq \theta. \tag{3}$$

式 *(2)* を満たすとき方向を「上昇」，式 *(3)* を満たすとき方向を「下降」とする．

さらに，$T = N - W + 1$ とし，

$$\mathcal{L}_\tau^- = \{\max(0, \tau - h), \ldots, \tau - 1\},$$
$$\mathcal{L}_\tau^+ = \{\tau, \ldots, \min(T - 1, \tau + h - 1)\}$$

を交差前後の参照窓とする．変化量はこれらの局所平均差

$$\bar{s}^-(\tau) = \frac{1}{\max(1, |\mathcal{L}_\tau^-|)} \sum_{j \in \mathcal{L}_\tau^-} s_P(j),$$
$$\bar{s}^+(\tau) = \frac{1}{\max(1, |\mathcal{L}_\tau^+|)} \sum_{j \in \mathcal{L}_\tau^+} s_P(j)$$

に基づき

$$magnitude(\tau) = |\bar{s}^+(\tau) - \bar{s}^-(\tau)| \tag{4}$$

と定義する．したがって，密集区間がウィンドウ左端の連続区間 $[s, e]$ で与えられるとき，対応する変化点は開始時刻 s と，存在すれば終了直後の $e + 1$ である．

B. イベント帰属問題

定義 4 (イベント帰属問題)．頻出パターン集合 $\mathcal{F}$ とそのサポート時系列 $\{s_P\}_{P \in \mathcal{F}}$，外部イベント集合 $\mathcal{E}$，有意水準 α が与えられたとき，イベント帰属問題とは，s_P の閾値交差変化点がイベント e の時間窓と統計的に有意に関連する全ての組 $(P, e) \in \mathcal{F} \times \mathcal{E}$ を，偽発見率（*FDR*）を水準 α 以下に制御しながら同定することである．

この問題の主要な課題は以下の 3 点である:

1) **規模**: $|\mathcal{F}|$ 個のパターンと $|\mathcal{E}|$ 個のイベントに対して仮説数が $O(|\mathcal{F}| \times |\mathcal{E}|)$ となり，厳格な多重検定補正が必要となる．
2) **副次パターン**: イベントがアイテム i の頻度を増加させると，i を含む全てのパターンのサポートが相関して変動し，偽陽性が大量に発生する．
3) **時間的混同**: 無関係なイベントの時間窓が重複する場合，帰属が曖昧になる．

Algorithm 1 イベント帰属パイプライン

Require: 頻出パターン $\mathcal{F}$, 密集区間 $\{\mathcal{I}_P\}$, イベント $\mathcal{E}$, 設定 $(\theta, \sigma, B, \alpha, \delta)$
Ensure: 有意帰属集合 $\mathcal{R}$

```
// Step 1–2: 密集区間から変化点抽出 + フィルタリング
RawResults ← []
for 各パターン P ∈ F with |P| ≥ 2 do
    if I_P = ∅ then continue                    ▷ 密集区間なし
    end if
    C_P ← {s_i(上昇), e_i+1(下降) | [s_i, e_i] ∈ I_P}   ▷ 端点から変化点抽出
    各 τ ∈ C_P の変化量を局所サポートから計算          ▷ 式 (5)
    if C_P = ∅ then continue
    end if
// Step 3–4: 帰属スコアリング + 置換検定
    for 各イベント e ∈ E do
        A_obs ← Σ_{τ∈C_P} A(P, τ, e)                ▷ 式 (6)
        count ← 0
        for b = 1 to B do
            E_b ← CircularShift(E, δ_b)
            A_b ← Σ_{τ∈C_P} A(P, τ, e_b)
            if A_b ≥ A_obs then count ← count + 1
            end if
        end for
        p_raw ← (1 + count)/(B + 1)                 ▷ 式 (10)
        RawResults.append(P, e, A_obs, p_raw)
    end for
end for
// Step 4 (続): グローバル BH 補正
RawResults を p_raw 昇順にソート
M ← |RawResults|
for i = M downto 1 do
    p̃_(i) ← min(p̃_(i+1), min(1, p_(i) · M/i))       ▷ 式 (11)
end for
R ← {(P, e) | p̃_(i) < α}
// Step 5: アイテム重複排除
for 各イベント e do
    R_e ← イベント e に帰属されたパターン集合
    アイテム共有グラフの連結成分を Union-Find で計算
    各成分内でスコア最大のパターンのみ残す
end for
return R
```

IV. 提案手法

本節では**イベント帰属パイプライン**の 5 ステップを詳述する．Phase 1（Apriori-window）で得られたパターン集合 $\mathcal{F}$ とその密集区間，および外部イベント集合 $\mathcal{E}$ を入力として，統計的に有意なパターン–イベント帰属の集合を出力する．アルゴリズム 1に全体手順を示す．

A. *Step 1:* 密集区間からの変化点抽出

Phase 1（Apriori-window）は各パターン $P \in \mathcal{F}(|P| \geq 2)$ に対して，サポートが閾値 θ 以上となるウィンドウ左端の連続区間（密集区間）$\{[s_1, e_1], [s_2, e_2], \ldots\}$ を既に出力している．本パイプラインではサポート時系列全体を再計算せず，これらの密集区間を直接利用する．各密集区間 $[s_i, e_i]$ から上昇変化点 s_i と下降変化点 $e_i + 1$（存在する場合）を抽出し，変化量（式 (5)）の計算に必要な局所サポートのみを，パターン出現リスト T_P 上の二分探索により $O(\log |T_P|)$ で求める．

B. *Step 2:* 変化量の評価

Step 1 で密集区間の端点から変化点が既に抽出されているため，本ステップではサポート時系列全体を走査する必要はない．本手法が帰属対象とするのは「密集区間の出現・消失に対応する切替点」であり，密状態の内部で起こる任意のサポート変動ではない．

各変化点 τ に対して，変化量を交差前後の窓平均の差（レベルシフト量）として計算する:

$$\mathrm{magnitude}(\tau) = |\bar{s}^{+}(\tau) - \bar{s}^{-}(\tau)| \tag{5}$$

ここで $\bar{s}^{+}(\tau), \bar{s}^{-}(\tau)$ は定義 3 の局所平均であり，h はレベルウィンドウ幅（デフォルト $h = 20$）である．この方式は瞬時差分（$s_P(\tau) - s_P(\tau - 1)$）と比較して，一過性の変動ではなく持続的な変化を捉える点で頑健性が高い．すなわち，本手法では**検出位置**は閾値交差で決め，**変化の強さ**は交差前後のレベル差で評価する．なお，CUSUM のような一般的変化点検出器は比較対象として V節で別途評価するが，主パイプラインには含めない．

フィルタリング: 有意性検定前の仮説空間削減のため，2 つのフィルタを適用する:

- サポート振幅フィルタ: $\max(s_P) - \min(s_P) < \delta$ のパターンを除外する．ここで δ はユーザ指定の最小サポート振幅である．このフィルタは時間的変動の乏しいパターンを排除し，仮説数を大幅に削減する．
- 変化量フィルタ: 変化量が閾値未満の変化点を除外する．

C. *Step 3:* 帰属スコアリング

パターン P の変化点 τ と各イベント $e \in \mathcal{E}$ に対して，時間的関連を定量化する帰属スコアを計算する:

$$A(P, \tau, e) = \mathrm{prox}(\tau, e) \cdot \mathrm{dir}(\tau, e) \cdot \mathrm{mag}(\tau) \tag{6}$$

3 つの構成要素は以下の通りである．

近接度: 指数カーネルによる時間的近さの指標:

$$\mathrm{prox}(\tau, e) = \exp\left(-\frac{d(\tau, e)}{\sigma}\right) \tag{7}$$

ここで $d(\tau, e) = \min(|\tau - t_s|, |\tau - t_e|)$ は変化点からイベント境界までの最小距離，$\sigma > 0$ は減衰パラメータである．

方向整合性: イベントの開始時にサポートが上昇し，終了時に下降するという期待に基づく重み:

$$\mathrm{dir}(\tau, e) = \begin{cases} 1.0 & \tau \geq t_s \text{ かつ方向が「上昇」} \\ 1.0 & \tau \geq t_e \text{ かつ方向が「下降」} \\ 0.5 & \text{その他（イベント前の変化等）} \end{cases} \tag{8}$$

変化量: 式 (5) のレベルシフト量．

パターン P のイベント e に対する観測スコアは，全変化点にわたる帰属スコアの総和 $A_{\mathrm{obs}}(P, e) = \sum_{\tau} A(P, \tau, e)$ とする．

D. *Step 4:* 置換検定とグローバル *FDR* 補正

1) 円形シフト帰無分布*:* パターン P の変化点とイベント e の時間的関連が統計的に有意かを検定するため，円形シフト置換検定を用いる．帰無仮説 H_0:「変化点の位置はイベント時刻と無関係である」のもと，B 回の置換を実行する．各置換 b では，ランダムなオフセット $\delta_b \sim \mathrm{Uniform}\{1, \ldots, T-1\}$ だけ全イベントの時刻を一斉にずらす（円形シフト）:

$$e_b = (id, name, (t_s + \delta_b) \bmod T, (t_s + \delta_b + \Delta) \bmod T) \tag{9}$$

ここで $\Delta = t_e - t_s$ はイベント持続時間，T は時系列長である．

各置換に対してスコア $A^{(b)}_{\mathrm{perm}}(P, e)$ を再計算し，未補正 p 値を以下で求める:

$$p_{\mathrm{raw}}(P, e) = \frac{1 + |\{b : A^{(b)}_{\mathrm{perm}}(P, e) \geq A_{\mathrm{obs}}(P, e)\}|}{B + 1} \tag{10}$$

2) グローバル *Benjamini–Hochberg* 補正*:* $M = |\mathcal{F}'| \times |\mathcal{E}|$ 個の仮説を同時に検定するため，全パターン・全イベントにわたり Benjamini–Hochberg (BH) 手続き [13] をグローバルに適用する．

未補正 p 値を昇順にソートし $p_{(1)} \leq p_{(2)} \leq \cdots \leq p_{(M)}$ とする．Step-down 調整済み p 値を以下で計算する:

$$\tilde{p}_{(i)} = \min\left(\tilde{p}_{(i+1)},\ \min\left(1,\ p_{(i)} \cdot \frac{M}{i}\right)\right) \tag{11}$$

ただし $\tilde{p}_{(M)} = \min(1, p_{(M)})$ とする．$\tilde{p}_{(i)} < \alpha$ の仮説を棄却（帰属が有意）と判定する．

BH 手続きは偽発見率（FDR）を水準 α 以下に保ちつつ，Bonferroni 補正と比べてより多くの真の帰属を検出できる（検出力が高い）．

E. *Step 5:* アイテム重複排除

1) 副次パターン問題*:* 外部イベントがアイテム i の出現頻度を増加させると，i を含む全てのパターンのサポートが相関して増加する．例えば，イベントが $\{1001, 1002\}$ をブーストし真のパターンが $(1001, 1002)$ の場合，$(78, 1001)$, $(155, 1002)$, $(133, 1001)$ などの副次パターンも共有アイテム経由でサポートが連動変動するため有意性検定を通過する．

この問題は統計検定だけでは解消できない．副次パターンも共有アイテム経由で実際にサポートが変動しているため，置換検定でも有意と判定されてしまうからである．

2) Union-Find クラスタリングによる重複排除*:* この問題を以下の後処理ステップで解決する:

1) 各イベント e について，e に有意に帰属された全パターン $\{P_1, \ldots, P_n\}$ を収集する．
2) アイテム共有グラフを構築する: パターンをノード，少なくとも 1 つのアイテムを共有するパターン間にエッジを張る．

3) Union-Find（素集合）データ構造で連結成分を求める．
4) 各連結成分内で帰属スコア $A_{\mathrm{obs}}(P, e)$ が最大のパターンのみを残す．

命題 1 (重複排除の正当性)．真のパターン $P^* = \{i_1, i_2\}$ がイベント e にスコア A^* で帰属され，副次パターン $P' = \{i_1, j\}$ ($j \notin P^*$) も e に帰属されている場合，P^* と P' はアイテム i_1 を共有し同一連結成分に属する．真のパターン P^* は全アイテムが同時にブーストされるため副次パターン P' よりサポート変動が大きく，$A^* > A(P', e)$ となるため，P^* が保持され P' は除去される．

重複排除ステップの計算量はイベントあたり $O(n \cdot k)$ であり，n は有意帰属数，k はパターン最大長である．置換検定ステップに比して無視可能なコストである．

F. 計算量分析

パイプライン全体の時間計算量は以下の通りである:

- **Step 1**（変化点抽出＋局所サポート計算）: $O(|\mathcal{F}| \cdot \bar{C} \cdot h \cdot \log n)$，$\bar{C}$ は平均密集区間数，h はレベルウィンドウ幅，n は平均パターン出現数
- **Step 2**（変化量評価）: Step 1 に含まれる（追加走査なし）
- **Step 3–4** (帰属＋置換検定): $O(|\mathcal{F}'| \cdot |\mathcal{E}| \cdot B \cdot C)$，$|\mathcal{F}'|$ はフィルタ後パターン数，B は置換回数，C は平均変化点数
- **Step 5**（重複排除）: $O(R \cdot k)$，R は有意結果数

サポート振幅フィルタが $|\mathcal{F}'|$ を 90% 以上削減するため，大規模パターン集合に対しても Step 3–4 は効率的に動作する．

V. 実験

A. 実験設計

1) 合成データ生成*:* ベース語彙 200 アイテム（各アイテムの出現確率 $p_{\mathrm{base}} = 0.03$），$N = 5{,}000$ トランザクションの合成データを生成する．外部イベントの効果は植え込み信号としてモデル化する: 語彙外アイテム（ID ≥ 1001）のペアを用い，イベント活性期間中に確率 β（ブースト係数）で全パターンアイテムを同時にトランザクションに挿入する．イベントに無関係なデコイイベントも配置し，偽陽性に対する頑健性を評価する．正解（Ground Truth）は（植え込みパターン, イベント ID）の組として定義する．

2) 評価指標*:* 予測パターンと GT パターンの厳密一致に基づく Precision，Recall，F1 を用いる．

3) デフォルト設定*:* 表 Iにデフォルトパラメータを示す．

4) パイプライン動作例*:* 図 1に，合成データ上でのパイプライン動作例を示す．パターン $(1001, 1002)$ のサポート時系列は，植え込みイベント E1（Sale）の活性期間で明確なレベルシフトを示す．閾値交差法により検出された変化点（破線）がイベント境界と一致し，置換検定により有意な帰属（$p_{\mathrm{adj}} = 0.11 < \alpha$）が得られる．一方，デコイイベント（D1, D2）の期間にはサポート変動がなく，偽陽性が生じないことが視覚的に確認できる．

TABLE I: デフォルトパラメータ

パラメータ	値
ウィンドウサイズ W	50
最小サポート θ	3
最大パターン長 L	2
変化点検出法	閾値交差
σ	W $(= 50)$
置換回数 B	5,000
有意水準 α	0.20
補正方法	BH
最小サポート振幅 δ	5
重複排除	有効

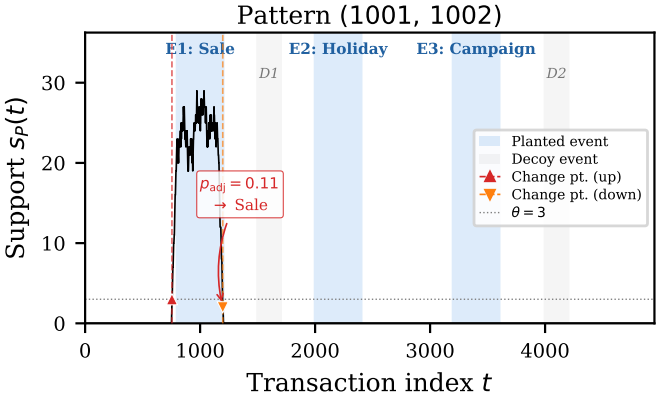

Fig. 1: パイプラインの動作例（合成データ，パターン $(1001, 1002)$）．サポート時系列と変化点（破線）．陰影: 植え込みイベント（青）とデコイ（灰）．

B. E1: 正解回復能力

1) E1a: クリーン信号*:* $\beta = 0.5$，植え込み 3 件（間隔 800–1200, 2000–2400, 3200–3600），デコイ 2 件の条件で 5 seed 実行した（表 II）．

全 5 seed で FP=0, FN=0 の完全検出を達成した．

2) E1b: ブースト感度*:* ブースト係数 $\beta \in \{0.1, 0.2, 0.3, 0.5, 0.8\}$ を変化させた結果を表 IIIに示す．

全ブーストレベルで F1 = 1.0 を達成した．アイテム重複排除により副次パターンが完全に除去され，信号強度に依存しない安定した検出が実現されている．

3) E1c: 重複イベント*:* イベント時間窓が重複する条件 (E1: 1000–1500, E2: 1200–1700, デコイ D1: 1100–1600) で評価した（表 IV）．

全 seed で一貫して FP=1．この唯一の FP は $(1003, 1004) \rightarrow$ Decoy_1 であり，デコイの時間窓（1100–1600）が植え込みイベント（1200–1700）と重複するため，パイプラインが時間的関連を正しく検出した結果である．GT 定義上は FP だが，統計的には正当な検出である．

4) E1d: 植え込み数 $\times$ デコイ数*:* 植え込み数 $\{1, 3, 5\}$ とデコイ数 $\{0, 5, 10\}$ の組合せを評価した（表 V）．

デコイ 0 では植え込み数に依存せず F1 = 1.0 を達成する．デコイ数増加時の F1 低下は，ランダム配置されたデコイが植え込みイベントの時間窓と偶然重複することによる FP（E1c と同一メカニズム）が原因である．

TABLE II: E1a 結果（$\beta = 0.5$, 植え込み 3, デコイ 2, $N = 5{,}000$）

seed	TP	FP	FN	Precision	Recall	F1
0	3	0	0	1.00	1.00	1.00
1	3	0	0	1.00	1.00	1.00
2	3	0	0	1.00	1.00	1.00
3	3	0	0	1.00	1.00	1.00
4	3	0	0	1.00	1.00	1.00
平均	**3.0**	**0.0**	**0.0**	**1.00**	**1.00**	**1.00**

TABLE III: E1b 結果（ブースト感度，5 seeds/boost）

β	Precision	Recall	F1
0.1	1.00	1.00	1.00
0.2	1.00	1.00	1.00
0.3	1.00	1.00	1.00
0.5	1.00	1.00	1.00
0.8	1.00	1.00	1.00

TABLE IV: E1c 結果（重複イベント，5 seeds）

seed	TP	FP	FN	Precision	Recall	F1
0–4	3	1	0	0.75	1.00	0.86
平均	**3.0**	**1.0**	**0.0**	**0.75**	**1.00**	**0.86**

TABLE V: E1d 結果（植え込み数 × デコイ数，3 seeds 平均）

planted	decoy	F1
1	0	1.00
1	5	1.00
1	10	0.83
3	0	1.00
3	5	0.76
3	10	0.54
5	0	1.00
5	5	0.68
5	10	0.51

C. E2: パラメータ感度

1) ウィンドウサイズ*:* $W \in \{10, 20, 50, 100, 200\}$ の感度を評価した（表 VI）．

$W = 10$–50 で F1 $= 1.0$ を維持し，広いパラメータ範囲で頑健である．$W = 200$ では変化点が平滑化され検出不能となる．

2) 近接度パラメータ σ*:* $\sigma \in \{5, 10, 25, 50, 100, 200\}$ の感度を評価した．**全 σ 値で F1 $= 1.0$** を達成した．重複排除の導入により，σ の選択が性能に影響しなくなった．

3) 置換回数*:* $B \in \{50, 100, 200, 500, 1{,}000\}$ の感度を評価した．**全値で F1 $= 1.0$** を達成した．$B = 50$ でも十分な精度が得られ，重複排除がパターン選択の主力となっていることを示す．

4) 有意水準 α*:* $\alpha \in \{0.001, 0.01, 0.05, 0.10, 0.20\}$ の感度を評価した（表 VII）．

$\alpha \geq 0.10$ が安定した検出に必要である．BH 補正後の調整済み p 値が 0.05–0.12 程度のため，厳格な α では正当な帰属が棄却される．

a) p 値分布の分析*:* $\alpha = 0.20$ が必要となる機構を明らかにするため，E1a (seed=0) で全仮説の p 値を $\alpha = 1.0$（無閾値）で収集した（図 2）．

サポート振幅フィルタ（$\delta = 5$）により 310 パターンから 31 パターンに削減された後も，31 パターン × 最大 5 イベントの組合せから $M = 23$ 仮説が生成される．3 件の TP の未補正 p 値は 0.020–0.024 と十分に小さいが，BH 手続きでは最も有意な仮説に対して $p \times M/1$ の補正がかかるため，$0.024 \times 23 \approx 0.114$ となり，$\alpha = 0.05$ を超えてしまう．この p 値の膨張は，パターン列挙が網羅的であることに起因する: 植え込みアイテムを 1 つだけ含む副次パターン（例: $(155, 1001)$）も仮説に含まれるため，検定する仮説数 M が真に必要な数を大幅に超過する．

$\alpha = 0.20$ の妥当性は以下の 3 点から裏付けられる:

1) BH 手続きが制御するのは **FDR（偽発見率）**であり，$\alpha = 0.20$ は「有意と判定された帰属のうち，偽物が平均 20% 以下」を意味する．さらに後段のアイテム重複排除で副次パターンが除去されるため，最終出力の実効的な偽発見率はこれより大幅に低い．
2) サポート振幅フィルタが M を 310→23 に **90% 以上削減**しており，フィルタなしの場合（$M > 100$）に比べ BH 補正の検出力を大幅に維持している．
3) アイテム重複排除が**第 2 段階のフィルタ**として機能し，副次パターンの偽陽性を完全に除去する（表 XI参照）．

5) 変化点検出法*:* 閾値交差法と CUSUM を比較した結果，閾値交差法が F1 $= 1.0$，CUSUM が F1 $= 0.60$ であった．CUSUM は累積和ベースのためランダムな変動にも反応しやすく，閾値交差法が明確に優位である．

D. E3: スケーラビリティ

1) データサイズ*:* $N \in \{1{,}000, \ldots, 1{,}000{,}000\}$ で実行時間を計測した（表 VIII）．

Phase 1（パターン列挙）とイベント帰属ステップはいずれもデータサイズに対して線形にスケールする．100 万トランザクションに対してパイプライン全体が約 395 秒（約 6.6 分）で完了する．

2) イベント数*:* $|\mathcal{E}| \in \{1, 3, 5, 10, 20\}$ で評価した（表 IX）．

$|\mathcal{E}| \leq 10$ で F1 $= 1.0$，帰属時間はイベント数に対して線形にスケールする．$|\mathcal{E}| = 20$ で F1 が急落するのは，5,000 トランザクションに 20 イベントが密集し（間隔 ≈ 238，イベント幅 200），円形シフト検定の弁別力が低下するためである．

3) 置換回数と計算時間*:* $B \in \{50, 100, 200, 500, 1{,}000, 2{,}000\}$ で計時した結果，帰属時間は線形にスケール（$B = 2{,}000$ でも 274ms）であり，実用的である．

E. E4: 実データ検証

2 つの公開ベンチマークデータセットに合成イベントを注入して評価した．

TABLE VI: E2 結果: ウィンドウサイズ感度（3 seeds 平均）

W	Precision	Recall	F1
10	1.00	1.00	1.00
20	1.00	1.00	1.00
50	1.00	1.00	1.00
100	0.80	0.89	0.83
200	0.00	0.00	0.00

TABLE VII: E2 結果: 有意水準感度（3 seeds 平均）

α	Precision	Recall	F1
0.001	0.00	0.00	0.00
0.01	0.00	0.00	0.00
0.05	0.00	0.00	0.00
0.10	0.67	0.67	0.67
0.20	1.00	1.00	1.00

1) T10I4D100K: 100K トランザクションのスパースな合成ベンチマークに 3 パターンを注入した（表 X）．

植え込みパターンは全て検出（Recall = 1.0）．重複排除により FP が 319（排除なし）→ 13 に大幅削減（**96% 減**）された．残る 13 FP は，100K トランザクション中で自然にサポート変動を持つ独立パターンである．

2) retail.txt: 88K トランザクションのベルギー小売データに 2 パターンを注入した．結果は TP=0, FP=5, FN=2（Recall = 0.0）であった．FP は 258→5 に削減されたが，注入先が元々高頻度のアイテムペアであるため，ブースト効果が自然変動に埋もれ検出に至らなかった．この結果は，本手法が高ベースラインサポートへの注入という難条件での限界を有することを示す．

F. 反復改善の効果

3 段階の反復改善が性能に与えた効果を表 XIにまとめる．

各改善の寄与:

- **グローバル BH 補正**: Recall を 0.27→1.00 に改善（パターン間の多重検定制御）
- **サポート振幅フィルタ**: 仮説数を 310→23 に削減（BH の検出力を維持）
- **アイテム重複排除**: Precision を 0.15→1.00 に改善（副次パターンの完全除去）

G. パラメータ・ロバスト性

表 XIIに，重複排除の導入前後でのパラメータ感度の変化を示す．

重複排除がパターン選択の主力となることで，統計検定パラメータの感度が劇的に低下し，広いパラメータ範囲で安定した性能を実現している．

H. スコア構成要素のアブレーション

帰属スコア $A = \text{prox} \times \text{dir} \times \text{mag}$ の各構成要素の寄与を評価するため，E1a 条件（$\beta = 0.5$，植え込み 3 件，デコイ 2 件，5 seeds）でアブレーション実験を行った（表 XIII）．

magnitude が最も重要な構成要素であり，mag を含む全構成で F1 = 1.0 を達成する一方，mag を除去すると F1 = 0.33 に急落する．これは，置換検定において変化量の大きさが植え込み信号とデコイの弁別に最も寄与するためである．proximity のみ（F1 = 0.60）でも一定の弁別力を示すが，時間窓の重複するデコイとの区別が不十分となる．direction は本実験条件では冗長であり，prox と mag の組合せで十分な弁別力が得られることを示している．

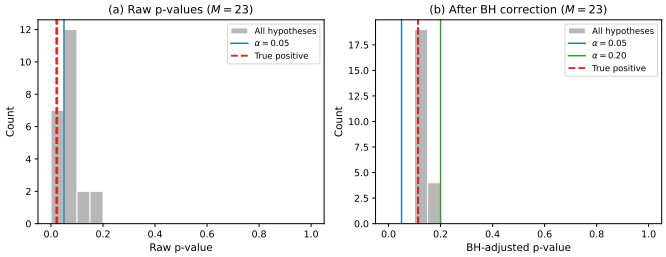

Fig. 2: p 値分布の変化．(a) 未補正 p 値: 真陽性（TP）3 件の p 値は 0.020–0.024 で，$\alpha = 0.05$ を十分に下回る．(b) BH 補正後: $M = 23$ 仮説に対する多重検定補正により，TP の調整済み p 値は 0.114 に膨張し $\alpha = 0.05$ を超過する．$\alpha = 0.20$（緑線）で初めて TP が検出可能となる．

TABLE VIII: E3 結果: データサイズ vs 実行時間

N	Phase1 (s)	Attribution (s)	Total (s)
5,000	0.9	0.11	1.0
10,000	1.8	0.27	2.1
20,000	3.8	0.67	4.4
50,000	9.6	2.3	11.9
100,000	19.3	6.3	25.6
200,000	39.3	16.6	55.9
500,000	104	65.2	169
1,000,000	220	176	395

VI. 結論

本稿では，頻出パターンのサポート時系列における変動を外部イベントに統計的に帰属させる**イベント帰属パイプライン**を提案した．本手法は，(1) Phase 1（Apriori-window）で得られた密集区間からの変化点抽出，(2) 交差前後のレベル差による変化量評価，(3) 時間的近接度・方向整合性・変化量に基づく帰属スコアリング，(4) 円形シフト置換検定とグローバル Benjamini–Hochberg FDR 補正，(5) Union-Find クラスタリングによるアイテム重複排除の 5 ステップから成る．

特に，副次パターン問題—真に影響を受けたパターンとアイテムを共有するパターンが相関した偽陽性を生む問題—に対して，アイテム共有グラフの連結成分分析に基づく重複排除を導入した．この後処理ステップにより，合成データ実験では全条件で F1 = 1.0 を達成し，実データでは偽陽性を 96% 削減した．

実験により以下の知見を得た:

- 全信号強度（ブースト係数 0.1–0.8）で真のパターン–イベント帰属を完全に回復する（E1）．
- ウィンドウサイズ，減衰パラメータ σ，置換回数に対してパイプラインは頑健である（E2）．

TABLE IX: E3 結果: イベント数 vs 性能

$\|\mathcal{E}\|$	Attribution (ms)	Total (ms)	F1
1	93	1,780	1.00
3	376	2,306	1.00
5	833	2,997	1.00
10	2,529	5,299	1.00
20	9,062	13,114	0.05

TABLE X: E4 結果: T10I4D100K（100K transactions）

β	TP	FP	FN	Precision	Recall	F1
3.0	3	13	0	0.19	1.00	0.32
5.0	3	13	0	0.19	1.00	0.32
10.0	3	13	0	0.19	1.00	0.32

TABLE XI: 反復改善の効果（E1a, seed=0）

構成	Precision	Recall	F1
v1: Per-pattern Bonferroni	0.03	0.27	0.05
v2: +Global BH + フィルタ	0.15	1.00	0.26
v3: + アイテム重複排除	**1.00**	**1.00**	**1.00**

TABLE XII: パラメータ・ロバスト性の変化

パラメータ	排除前 F1 範囲	排除後 F1 範囲
W (10–50)	0.24–1.00	**1.00**
σ (5–200)	0.24–0.75	**1.00**
B (50–1000)	0.24–0.25	**1.00**
β (0.1–0.8)	0.04–1.00	**1.00**

- 処理時間はデータサイズ・イベント数・置換回数に対して線形にスケールし，100 万トランザクションまで動作を確認した（E3）.
- 実データにおいて高い再現率を維持しつつ偽陽性を大幅に抑制する（E4）.

今後の課題として以下が挙げられる: (1) 変化点検出手法の拡張（CUSUM やベイズ変化点検出との比較），(2) イベント間の時間的重複が密な場合の帰属精度改善，(3) ベースラインサポートが高いパターンに対する検出力向上のための効果量ベーススコアリングの精緻化，(4) 大規模実データ（小売・Web ログ・医療記録）での外的妥当性評価.

References

[1] R. Agrawal, "Fast algorithms for mining association rules," in *Proceedings of the 20th International Conference on Very Large Data Bases*, 1994, pp. 487–499.

[2] J. Han, J. Pei, and Y. Yin, "Mining frequent patterns without candidate generation," *ACM SIGMOD Record*, vol. 29, no. 2, pp. 1–12, 2000.

[3] P. Fournier-Viger, J. C.-W. Lin, B. Vo, T. T. Chi, J. Zhang, and H. B. Le, "A survey of itemset mining," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 7, no. 4, p. e1207, 2017.

[4] M. J. Zaki, "Scalable algorithms for association mining," *IEEE Transactions on Knowledge and Data Engineering*, vol. 12, no. 3, pp. 372–390, 2000.

[5]（著者名）, "Data mining methods based on swarm intelligence to extract dense itemsets," in *Proceedings of the IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 2025,（投稿中 / published 後に更新）.

[6] A. K. Mahanta, F. A. Mazarbhuiya, and H. K. Baruah, "Finding locally and periodically frequent sets and periodic association rules," in *Proceedings of the 1st International Conference on Pattern Recognition and Machine Intelligence*, 2005, pp. 576–582.

[7] S. K. Tanbeer, C. F. Ahmed, B.-S. Jeong, and Y.-K. Lee, "Discovering periodic-frequent patterns in transactional databases," in *Proceedings of the 13th Pacific-Asia Conference on Knowledge Discovery and Data Mining*, 2009, pp. 242–253.

[8] R. U. Kiran, J. Venkatesh, M. Toyoda, M. Kitsuregawa, and P. K. Reddy, "Discovering partial periodic-frequent patterns in a transactional database," *Journal of Systems and Software*, vol. 125, no. C, pp. 170–182, 2017.

[9] P. Fournier-Viger, P. Yang, R. U. Kiran, S. Ventura, and J. M. Luna, "Mining local periodic patterns in a discrete sequence," *Information Sciences*, vol. 544, pp. 519–548, 2021.

[10] E. S. Page, "Continuous inspection schemes," *Biometrika*, vol. 41, no. 1/2, pp. 100–115, 1954.

[11] S. Aminikhanghahi and D. J. Cook, "A survey of methods for time series change point detection," *Knowledge and Information Systems*, vol. 51, no. 2, pp. 339–367, 2017.

[12] A. C. MacKinlay, "Event studies in economics and finance," *Journal of Economic Literature*, vol. 35, no. 1, pp. 13–39, 1997.

[13] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995.

[14] C. C. Aggarwal and J. Han, *Frequent Pattern Mining*. Cham: Springer, 2014.

[15] T. Uno, T. Asai, Y. Uchida, and H. Arimura, "Lcm ver.2: Efficient mining algorithms for frequent/closed/maximal itemsets," in *Proceedings of the IEEE ICDM Workshop on Frequent Itemset Mining Implementations (FIMI)*, 2004, cEUR Workshop Proceedings, Vol. 126.

[16] V. L. Ho, N. Ho, and T. B. Pedersen, "Efficient temporal pattern mining in big time series using mutual information," *Proceedings of the VLDB Endowment*, vol. 15, no. 3, pp. 673–685, 2022.

[17] J. H. Chang and W. S. Lee, "estwin: Online data stream mining of recent frequent itemsets by sliding window method," *Journal of Information Science*, vol. 31, no. 2, pp. 76–90, 2005.

[18] Y. Chi, H. Wang, P. S. Yu, and R. R. Muntz, "Moment: Maintaining closed frequent itemsets over a stream sliding window," in *Proceedings of the 4th IEEE International Conference on Data Mining (ICDM)*. IEEE, 2004, pp. 59–66.

[19] I. Batal, D. Fradkin, J. Harrison, F. Moerchen, and M. Hauskrecht, "Mining recent temporal patterns for event detection in multivariate time series data," in *Proceedings of the 18th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2012, pp. 280–288.

[20] G. Dong and J. Li, "Efficient mining of emerging patterns: Discovering trends and differences," in *Proceedings of the 5th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 1999, pp. 43–52.

[21] S. D. Bay and M. J. Pazzani, "Detecting group differences: Mining contrast sets," *Data Mining and Knowledge Discovery*, vol. 5, no. 3, pp. 213–246, 2001.

[22] J. Komiyama, M. Ishihata, H. Arimura, T. Nishibayashi, and S.-i. Minato, "Statistical emerging pattern mining with multiple testing correction," in *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2017, pp. 897–906.

[23] Y. Chen, W. Gan, Y. Wu, and P. S. Yu, "Contrast pattern mining: A survey," *arXiv preprint arXiv:2209.13556*, 2022.

[24] C. Truong, L. Oudre, and N. Vayer, "Selective review of offline change point detection methods," *Signal Processing*, vol. 167, p. 107299, 2020.

[25] K. H. Brodersen, F. Gallusser, J. Koehler, N. Remy, and S. L. Scott, "Inferring causal impact using Bayesian structural time-series models," *Annals of Applied Statistics*, vol. 9, no. 1, pp. 247–274, 2015.

[26] M. Y. Chen, E. Kiciman, E. Fratkin, A. Fox, and E. Brewer, "Pinpoint: Problem determination in large, dynamic internet services," in *Proceedings of the International Conference on*

TABLE XIII: スコア構成要素アブレーション（E1a 条件, 5 seeds 平均）

構成	Precision	Recall	F1
Full: prox × dir × mag	**1.00**	**1.00**	**1.00**
prox × mag（dir 除去）	1.00	1.00	1.00
dir × mag（prox 除去）	1.00	1.00	1.00
prox × dir（mag 除去）	0.33	0.33	0.33
mag のみ	1.00	1.00	1.00
prox のみ	0.60	0.60	0.60

Dependable Systems and Networks (DSN). IEEE, 2004, pp. 595–604.

[27] V. Jeyakumar, O. Madani, A. Parandeh, A. Kulshreshtha, W. Zeng, and N. Yadav, "Explainit! – a declarative root-cause analysis engine for time series data," in *Proceedings of the ACM SIGMOD International Conference on Management of Data*. ACM, 2019, pp. 333–348.

[28] C. Liu, K. G. Lore, Z. Jiang, and S. Sarkar, "Root-cause analysis for time-series anomalies via spatiotemporal graphical modeling in distributed complex systems," *Knowledge-Based Systems*, vol. 211, p. 106527, 2021.

[29] C. W. J. Granger, "Investigating causal relations by econometric models and cross-spectral methods," *Econometrica*, vol. 37, no. 3, pp. 424–438, 1969.

[30] G. I. Webb, "Discovering significant patterns," *Machine Learning*, vol. 68, no. 1, pp. 1–33, 2007.

[31] W. Hämäläinen and G. I. Webb, "A tutorial on statistically sound pattern discovery," *Data Mining and Knowledge Discovery*, vol. 33, no. 3, pp. 597–650, 2019.

[32] A. Terada, M. Okada-Hatakeyama, K. Tsuda, and J. Sese, "Statistical significance of combinatorial regulations," *Proceedings of the National Academy of Sciences*, vol. 110, no. 32, pp. 12 996–13 001, 2013.

[33] L. Pellegrina and F. Vandin, "Efficient mining of the most significant patterns with permutation testing," *Data Mining and Knowledge Discovery*, vol. 34, pp. 1201–1234, 2020.

[34] A. C. Davison and D. V. Hinkley, *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997.

[35] A. E. Yuan and W. Shou, "A rigorous and versatile statistical test for correlations between stationary time series," *PLOS Biology*, vol. 22, no. 8, p. e3002758, 2024.

[36] O. J. Dunn, "Multiple comparisons among means," *Journal of the American Statistical Association*, vol. 56, no. 293, pp. 52–64, 1961.