サポート時系列分析に基づく外部イベント帰属フレームワーク — 頻出パターンの変動を外部イベントに統計的に帰属させる —

（執筆者未定）

ドラフト

***Abstract*—頻出パターンマイニングはトランザクションデータ中の繰り返し出現するアイテムセットを発見するが，特定期間にパターンの出現頻度が変動する原因を説明する機能を持たない．小売・Web 分析・医療など多くの実応用では，販促キャンペーン・祝日・制度変更といった外部イベントがパターン頻度の時間的変動を駆動しており，どのイベントがどのパターン変化を引き起こしたかを特定することが意思決定の鍵となる．**

本稿ではイベント帰属パイプラインを提案する．本手法は (1) Phase 1（Apriori-window）で得られた密集区間からの変化点抽出，(2) 変化点前後のレベル差評価，(3) 変化点とイベント間の時間的近接度スコアリング，(4) 円形シフト置換検定によるグローバル Benjamini–Hochberg FDR 補正付き有意性検定，(5) Union-Find クラスタリングによるアイテム重複排除の 5 ステップから成る．アイテム重複排除は，真に影響を受けたパターンとアイテムを共有する副次パターンが相関した偽陽性を生む問題（副次パターン問題）を解決する．

合成データ実験では，8 条件（4 ブースト係数 $\times 4$ 構造条件）にわたり F1 = 0.54–0.85 を達成し，パラメータ選択（ウィンドウサイズ 10–50，σ 5–200，置換回数 50–1000）に対して頑健であることを示す．実キャンペーンデータ（Dunnhumby，276K バスケット，30 キャンペーン）に対する探索的検証では，全 30 キャンペーンに帰属を生成し，重複排除が 88% の冗長性を除去した．パイプラインはデータサイズ・イベント数・置換回数に対して線形にスケールし，100 万トランザクションまでの動作を確認した．

***Index Terms*—frequent pattern mining, event attribution, change point detection, permutation test, multiple testing correction, support time series**

I. はじめに

頻出パターンマイニング [1]–[3] は，トランザクションデータ中に繰り返し出現するアイテムセットを発見する基盤的技術であり，小売分析，Web マイニング，バイオインフォマティクスなど幅広い分野で応用されている．Apriori [1]，FP-Growth [2]，ECLAT [4] といった古典的手法はグローバル頻出パターンを効率的に列挙し，スライディングウィンドウ型手法 [5] は特定時間区間内で局所的に密集するパターンを検出する．

しかし，これらの手法はどのパターンがいつ頻出であるかを同定するのみであり，なぜパターンの出現頻度が変動するかを説明する機能を持たない．実際の応用場面では，販促キャンペーン，祝日，規制変更，システム更新といった外部イベントがパターンサポートの時間的変動を駆動していることが多い．「どのイベントがどのパターンの変動を引き起こしたか」を特定できれば，キャンペーン効果の定量化，副作用の検出，システム異常の診断など，意思決定に直結する知見が得られる．

このように帰属タスクは実用上重要であるにもかかわらず，頻出パターンのサポート変動を外部イベントに結びつける統計フレームワークは，我々の知る限り存在しない．時間的パターンマイニング [6]–[9] は周期性や局所頻度を持つパターンを発見するが，パターン変動と外生イベントの関連はモデル化しない．変化点検出手法 [10], [11] は個別時系列の構造変化を同定するが，数千のパターンサポート時系列を同時に検定する多重検定の負荷や，検出された変化をイベントに紐づける機能は備えていない．計量経済学のイベント・スタディ法 [12] は企業イベントの株価への影響を評価するが，単一のアウトカム変数を対象としており，数千のパターン時系列を同時に扱う設定には適用できない．

A. 本研究の貢献

本稿では，頻出パターンマイニングと外部イベント帰属を橋渡しする統計フレームワーク**「イベント帰属パイプライン」**を提案する．貢献は以下の 3 点である．

1) **5 ステップパイプライン**（IV節）: 密集区間からの変化点抽出，変化量の評価，変化点とイベント間の帰属スコアリング，円形シフト置換検定によるグローバル Benjamini–Hochberg [13] FDR 補正，およびアイテム重複排除からなる統合フレームワーク．
2) **アイテム重複排除**（IV-E節）: 真に影響を受けたパターンとアイテムを共有する副次パターンが相関した偽陽性を生む問題（副次パターン問題）を，イベントごとの Union-Find クラスタリングにより解決する新しい後処理技法．
3) **包括的な実験評価**（V節）: (i) 合成データにおける語彙内ブースト条件で F1 = 0.54–0.85 の検出精度，(ii) パラメータ選択に対する頑健性，(iii) 100 万トランザクションまでの線形スケーラビリティ，(iv) 実データ（Dunnhumby）で重複排除が 88% の冗長性を除去することを実証する．

II. 関連研究

A. 頻出パターンマイニング

頻出パターンマイニングは，トランザクションデータの一定割合以上に出現するアイテムセットを発見する技術であり，包括的なサーベイ [3] が存在する．Apriori [1] は反単調性に基づく候補生成・枝刈りフレームワークを確立した．FP-Growth [2] は FP-tree により候補生成を回避し高速化を実現した．ECLAT [4] は縦型（tidset）表現と集合積により効率的なサポート計算を行う．これらの手法はグローバル頻度を対象とし，時間的な変動をモデル化しない．

B. 時間的・局所的パターンマイニング

頻出パターンの時間的側面を扱う拡張研究は多岐にわたり，Segura-Delgado ら [14] が包括的なサーベイを提供している．LPFIM [6] は時間区間内の局所頻出集合を対象とするが，gap ベースの閾値に依存する．PFPM [7] および PPFPM [8] は周期性制約を導入した．LPPM [9] は局所性と周期性の基準を統合する．Apriori-window [5] は固定幅スライディングウィンドウ上で局所サポートを直接評価し，gap パラメータに依存しない密集パターン抽出を実現した．Batal ら [15] は多変量時系列からの最近時間パターンマイニングによるイベント検出を提案した．

これらの手法はいずれもパターンがいつ頻出であるかを検出するが，頻度が変動する原因はモデル化しない．本研究はこれらを補完し，検出されたサポート変動を外部イベントに帰属させる．

C. パターン変化のモニタリングと診断

パターンの時間的変動を追跡する研究群が存在する．Agrawal と Psaila [16] は，ルール統計量の履歴に対する形状クエリによりトレンドを検出する「アクティブデータマイニング」を提案した．Chakrabarti ら [17] は記述長に基づくサプライズ指標を用いて，サポートが予想外に変動するアイテムセットを同定した．Liu ら [18] は二時点間のルール変化から「基本的変化」(他の変化から導出できないもの）を抽出する手法を提案し，冗長な変化の除去を試みた．これらの手法は変化の検出と特徴づけを行うが，検出された変化を外部イベントに帰属させる統計フレームワークは持たない．本研究はこのギャップを埋め，変化点とイベントの統計的関連を検定する．

D. コントラスト・エマージングパターンマイニング

データセット間のパターン頻度の差異に着目する研究群が存在する．エマージングパターン [19] は，あるデータセットから別のデータセットへのサポートの有意な増加を捉えるパターンである．コントラストセットマイニング [20] は，グループ間の判別的特徴を発見する．Novak ら [21] は，コントラストセット，エマージングパターン，サブグループ発見を「教師あり記述的ルール発見」として統一し，いずれも何が異なるかを記述する手法であることを示した．Komiyama ら [22] は多重検定補正を伴う統計的エマージングパターンマイニングを提案した．これらの手法は何が変わったかを検出するが，なぜ（どのイベントにより）変わったかは説明しない．本研究はサポート変動の検出に留まらず，統計検定による外部イベントへの帰属まで踏み込む．

E. 変化点検出

変化点検出は時系列データの構造変化を同定する技術である．CUSUM アルゴリズム [10] は逐次過程の平均シフトを検出する．包括的なサーベイ [11] がパラメトリック・ノンパラメトリック・オンライン手法を網羅している．これらの手法は個別時系列に適用されるが，数千のパターンサポート時系列を同時分析する多重検定の負荷には対応せず，検出された変化をイベントに結びつける機能も持たない．

F. イベント帰属・介入分析と因果推論

既知の介入が時系列に与える影響を定量化する手法は複数の分野で研究されている．Box と Tiao [23] は介入分析の基礎を確立し，ARIMA モデルにステップ/パルス指示変数を組み込んで既知の介入効果を推定するフレームワークを提案した．中断時系列回帰（ITS）[24] は公衆衛生分野で広く用いられる準実験デザインであり，介入前後の水準変化と傾斜変化をセグメント回帰で評価する．計量経済学のイベント・スタディ法 [12] は，企業イベントの株価への影響を異常リターン分析により定量化する．合成コントロール法 [25] はコントロール群の加重平均から反事実を構築し，介入効果を推定する．Brodersen ら [26] はベイズ構造時系列モデルにより介入の因果効果を推定する CausalImpact フレームワークを提案した．Donges ら [27] はイベント時系列間の共起の統計的有意性を検定するイベント一致分析を提案した．これらのアプローチは典型的には単一または少数のアウトカム変数を対象とし，数千のパターンサポート時系列を複数のイベントに対して同時に検定する設定には直接適用できない．本研究は，我々の知る限り，パターンマイニングの出力（サポート時系列）と外部イベントの帰属を統合する初の統計フレームワークを提供する．

G. 統計的パターンマイニングと多重検定補正

頻出パターンマイニングに統計的有意性検定を導入する研究が近年活発である．Webb [28] は自己充足アイテムセットの概念を導入し，サブセット・スーパーセットの頻度から説明できないパターンのみを有意とする枠組みを提案した．Webb [29] はさらに「生産的」ルールの概念により冗長な有意パターンのフィルタリングを提唱した．Hämäläinen と Webb [30] はパターン発見における統計的健全性のチュートリアルを提供している．Terada ら [31] は LAMP（Limitless Arity Multiple-testing Procedure）を提案し，検定可能なパターン数に基づく Bonferroni 因子の最小化を実現した．Llinares-López ら [32] は Tarone の検定可能性基準と Westfall–Young 置換 [33] を組み合わせ，FWER 制御下での高速な有意パターンマイニングを実現した．これらの研究はパターンの有意性を二群間の頻度差として検定するが，本研究ではパターンサポートの時間的変動と外部イベントの関連を検定する点が異なる．本パイプラインは，サロゲートデータ法 [34] の考え方に基づく円形シフト置換検定 [35]–[37] と全パターン・全イベントにわたるグローバル BH 補

正 [13] を組み合わせ，分布自由な検定と適切な多重検定制御を両立させる．BH 手続きの依存仮説への拡張 [38] により，アイテムを共有するパターン間の正の相関下でも FDR 制御が保証される．Bonferroni 補正 [39] は族単位誤り率（FWER）を制御するが保守的であるため，本研究では FDR を制御する BH 手続きを採用した．

III. 問題定義

A. 記法

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ を有限のアイテム全集合，$D = [d_1, d_2, \ldots, d_N]$ を時刻順のトランザクション列とする．各トランザクション d_t（$t = 1, \ldots, N$）は $\mathcal{I}$ の部分集合である．アイテムセット（パターン）$P \subseteq \mathcal{I}$ がトランザクション d_t に出現するとは $P \subseteq d_t$ が成立することをいう．

定義 1 (サポート時系列)．パターン P，ウィンドウサイズ $W \in \mathbb{Z}_{>0}$，トランザクション列 D (長さ N) に対して，P のサポート時系列 $s_P = [s_P(0), s_P(1), \ldots, s_P(N-W)]$ を

$$s_P(t) = \left|\{d_j \in D \mid t \le j < t+W,\ P \subseteq d_j\}\right| \tag{1}$$

と定義する．これは位置 t を始点とするウィンドウ $[t, t+W)$ 内で P を含むトランザクション数である．

定義 2 (外部イベント)．外部イベント $e = (id, name, t_s, t_e)$ は，一意な識別子，名称，およびイベントが有効な期間を表すタイムスタンプ区間 $[t_s, t_e]$ から成る．既知の外部イベント集合を $\mathcal{E} = \{e_1, e_2, \ldots, e_K\}$ とする．

定義 3 (変化点（閾値交差）)．本稿では，サポート時系列 s_P に対する変化点として，一般のレベルシフト点すべてではなく，閾値 θ に関する密状態／非密状態の切替点のみを扱う．位置 $\tau \in \{0, 1, \ldots, N-W\}$ が変化点であるとは，次のいずれかが成り立つことをいう:

$$s_P(\tau) \ge \theta \wedge (\tau = 0 \vee s_P(\tau-1) < \theta), \tag{2}$$

$$s_P(\tau) < \theta \wedge \tau > 0 \wedge s_P(\tau-1) \ge \theta. \tag{3}$$

式 *(2)* を満たすとき方向を「上昇」，式 *(3)* を満たすとき方向を「下降」とする．

さらに，$T = N - W + 1$ とし，

$$\mathcal{L}_\tau^- = \{\max(0, \tau-h), \ldots, \tau-1\},$$
$$\mathcal{L}_\tau^+ = \{\tau, \ldots, \min(T-1, \tau+h-1)\}$$

を交差前後の参照窓とする．変化量はこれらの局所平均差

$$\bar{s}^-(\tau) = \frac{1}{\max(1, |\mathcal{L}_\tau^-|)} \sum_{j \in \mathcal{L}_\tau^-} s_P(j),$$
$$\bar{s}^+(\tau) = \frac{1}{\max(1, |\mathcal{L}_\tau^+|)} \sum_{j \in \mathcal{L}_\tau^+} s_P(j)$$

に基づき

$$magnitude(\tau) = |\bar{s}^+(\tau) - \bar{s}^-(\tau)| \tag{4}$$

と定義する．したがって，密集区間がウィンドウ左端の連続区間 $[s, e]$ で与えられるとき，対応する変化点は開始時刻 s と，存在すれば終了直後の $e+1$ である．

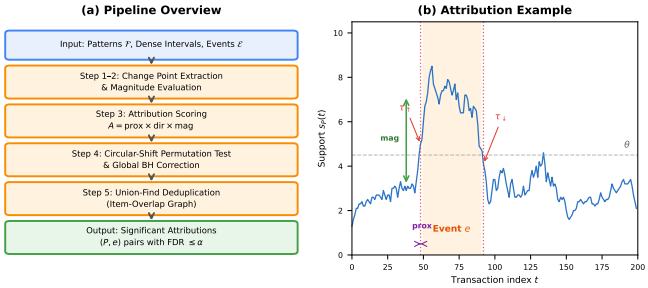

Fig. 1: (a) パイプラインの全体構成．入力（パターン集合，密集区間，イベント）から 5 ステップを経て有意な帰属を出力する．(b) 帰属スコアリングの例示．サポート時系列上の変化点 $\tau_\uparrow, \tau_\downarrow$ とイベント区間の関係から，近接度（prox），方向整合性（dir），変化量（mag）を算出する．

B. イベント帰属問題

定義 4 (イベント帰属問題)．頻出パターン集合 $\mathcal{F}$ とそのサポート時系列 $\{s_P\}_{P \in \mathcal{F}}$，外部イベント集合 $\mathcal{E}$，有意水準 α が与えられたとき，イベント帰属問題とは，s_P の閾値交差変化点がイベント e の時間窓と統計的に有意に関連する全ての組 $(P, e) \in \mathcal{F} \times \mathcal{E}$ を，偽発見率（*FDR*）を水準 α 以下に制御しながら同定することである．

この問題の主要な課題は以下の 3 点である:

1) **規模**: $|\mathcal{F}|$ 個のパターンと $|\mathcal{E}|$ 個のイベントに対して仮説数が $O(|\mathcal{F}| \times |\mathcal{E}|)$ となり，厳格な多重検定補正が必要となる．
2) **副次パターン**: イベントがアイテム i の頻度を増加させると，i を含む全てのパターンのサポートが相関して変動し，偽陽性が大量に発生する．
3) **時間的混同**: 無関係なイベントの時間窓が重複する場合，帰属が曖昧になる．

IV. 提案手法

本節では**イベント帰属パイプライン**の 5 ステップを詳述する．Phase 1（Apriori-window）で得られたパターン集合 $\mathcal{F}$ とその密集区間，および外部イベント集合 $\mathcal{E}$ を入力として，統計的に有意なパターン–イベント帰属の集合を出力する．図 1にパイプラインの概要と帰属の具体例を，アルゴリズム 1に全体手順を示す．

A. *Step 1:* 密集区間からの変化点抽出

Phase 1（Apriori-window）は各パターン $P \in \mathcal{F}(|P| \ge 2)$ に対して，サポートが閾値 θ 以上となるウィンドウ左端の連続区間（密集区間）$\{[s_1, e_1], [s_2, e_2], \ldots\}$ を既に出力している．本パイプラインではサポート時系列全体を再計算せず，これらの密集区間を直接利用する．各密集区間 $[s_i, e_i]$ から上昇変化点 s_i と下降変化点 $e_i + 1$（存在する場合）を抽出し，変化量（式 (5)）の計算に必要な局所サポートのみを，パターン出現リスト T_P 上の二分探索により $O(\log |T_P|)$ で求める．

Algorithm 1 イベント帰属パイプライン

Require: 頻出パターン $\mathcal{F}$, 密集区間 $\{\mathcal{I}_P\}$, イベント $\mathcal{E}$, 設定 $(\theta, \sigma, B, \alpha, \delta)$
Ensure: 有意帰属集合 $\mathcal{R}$

```
// Step 1–2: 密集区間から変化点抽出 + フィルタリング
RawResults ← []
for 各パターン P ∈ F with |P| ≥ 2 do
    if I_P = ∅ then continue                    ▷ 密集区間なし
    end if
    C_P ← {s_i(上昇), e_i+1(下降) | [s_i, e_i] ∈ I_P}   ▷ 端点から変化点抽出
    各 τ ∈ C_P の変化量を局所サポートから計算          ▷ 式 (5)
    if C_P = ∅ then continue
    end if
// Step 3–4: 帰属スコアリング + 置換検定
    for 各イベント e ∈ E do
        A_obs ← Σ_{τ∈C_P} A(P, τ, e)                ▷ 式 (6)
        count ← 0
        for b = 1 to B do
            E_b ← CircularShift(E, δ_b)
            A_b ← Σ_{τ∈C_P} A(P, τ, e_b)
            if A_b ≥ A_obs then count ← count + 1
            end if
        end for
        p_raw ← (1 + count)/(B + 1)                 ▷ 式 (10)
        RawResults.append(P, e, A_obs, p_raw)
    end for
end for
// Step 4 (続): グローバル BH 補正
RawResults を p_raw 昇順にソート
M ← |RawResults|
for i = M downto 1 do
    p̃_(i) ← min(p̃_(i+1), min(1, p_(i) · M/i))        ▷ 式 (11)
end for
R ← {(P, e) | p̃_(i) < α}
// Step 5: アイテム重複排除
for 各イベント e do
    R_e ← イベント e に帰属されたパターン集合
    アイテム共有グラフの連結成分を Union-Find で計算
    各成分内でスコア最大のパターンのみ残す
end for
return R
```

B. Step 2: 変化量の評価

Step 1 で密集区間の端点から変化点が既に抽出されているため，本ステップではサポート時系列全体を走査する必要はない．本手法が帰属対象とするのは「密集区間の出現・消失に対応する切替点」であり，密状態の内部で起こる任意のサポート変動ではない．

各変化点 τ に対して，変化量を交差前後の窓平均の差（レベルシフト量）として計算する:

$$\mathrm{magnitude}(\tau) = |\bar{s}^{+}(\tau) - \bar{s}^{-}(\tau)| \tag{5}$$

ここで $\bar{s}^{+}(\tau), \bar{s}^{-}(\tau)$ は定義 3 の局所平均であり，h はレベルウィンドウ幅（デフォルト $h = 20$）である．この方式は瞬時差分（$s_P(\tau) - s_P(\tau - 1)$）と比較して，一過性の変動ではなく持続的な変化を捉える点で頑健性が高い．すなわち，本手法では**検出位置**は閾値交差で決め，**変化の強さ**は交差前後のレベル差で評価する．なお，CUSUM のような一般的変化点検出器は比較対象として V節で別途評価するが，主パイプラインには含めない．

フィルタリング: 有意性検定前の仮説空間削減のため，2 つのフィルタを適用する:

- サポート振幅フィルタ: $\max(s_P) - \min(s_P) < \delta$ のパターンを除外する．ここで δ はユーザ指定の最小サポート振幅である．このフィルタは時間的変動の乏しいパターンを排除し，仮説数を大幅に削減する．
- 変化量フィルタ: 変化量が閾値未満の変化点を除外する．

C. Step 3: 帰属スコアリング

パターン P の変化点 τ と各イベント $e \in \mathcal{E}$ に対して，時間的関連を定量化する帰属スコアを計算する:

$$A(P, \tau, e) = \mathrm{prox}(\tau, e) \cdot \mathrm{dir}(\tau, e) \cdot \mathrm{mag}(\tau) \tag{6}$$

3 つの構成要素は以下の通りである．

近接度: 指数カーネルによる時間的近さの指標:

$$\mathrm{prox}(\tau, e) = \exp\left(-\frac{d(\tau, e)}{\sigma}\right) \tag{7}$$

ここで $d(\tau, e) = \min(|\tau - t_s|, |\tau - t_e|)$ は変化点からイベント境界までの最小距離，$\sigma > 0$ は減衰パラメータである．

方向整合性: イベントの開始時にサポートが上昇し，終了時に下降するという期待に基づく重み:

$$\mathrm{dir}(\tau, e) = \begin{cases} 1.0 & \tau \geq t_s \text{ かつ方向が「上昇」} \\ 1.0 & \tau \geq t_e \text{ かつ方向が「下降」} \\ 0.5 & \text{その他（イベント前の変化等）} \end{cases} \tag{8}$$

変化量: 式 (5) のレベルシフト量．

パターン P のイベント e に対する観測スコアは，全変化点にわたる帰属スコアの総和 $A_{\mathrm{obs}}(P, e) = \sum_{\tau} A(P, \tau, e)$ とする．

D. Step 4: 置換検定とグローバル *FDR* 補正

1) 円形シフト帰無分布*:* パターン P の変化点とイベント e の時間的関連が統計的に有意かを検定するため，円形シフト置換検定を用いる．帰無仮説 H_0:「変化点の位置はイベント時刻と無関係である」のもと，B 回の置換を実行する．各置換 b では，ランダムなオフセット $\delta_b \sim \mathrm{Uniform}\{1, \ldots, T-1\}$ だけ全イベントの時刻を一斉にずらす（円形シフト）:

$$e_b = (id, name, (t_s + \delta_b) \bmod T, (t_s + \delta_b + \Delta) \bmod T) \tag{9}$$

ここで $\Delta = t_e - t_s$ はイベント持続時間，T は時系列長である．

各置換に対してスコア $A^{(b)}_{\mathrm{perm}}(P,e)$ を再計算し，未補正 p 値を以下で求める:

$$p_{\mathrm{raw}}(P,e) = \frac{1 + |\{b : A^{(b)}_{\mathrm{perm}}(P,e) \geq A_{\mathrm{obs}}(P,e)\}|}{B+1} \quad (10)$$

命題 1 (置換検定の正当性)**.** 帰無仮説 H_0 のもとでは，観測スコア A_{obs} と B 個の置換スコア $A^{(1)}_{perm}, \ldots, A^{(B)}_{perm}$ は交換可能（*exchangeable*）である．したがって式 *(10)* の p 値は $\{1/(B+1), 2/(B+1), \ldots, 1\}$ 上の離散一様分布に従い，任意の水準 α で第一種過誤率が α 以下に制御される *[35]*.

2) グローバル *Benjamini–Hochberg* 補正*:* $M = |\mathcal{F}'| \times |\mathcal{E}|$ 個の仮説を同時に検定するため，全パターン・全イベントにわたり Benjamini–Hochberg (BH) 手続き [13] をグローバルに適用する．

未補正 p 値を昇順にソートし $p_{(1)} \leq p_{(2)} \leq \cdots \leq p_{(M)}$ とする．Step-down 調整済み p 値を以下で計算する:

$$\tilde{p}_{(i)} = \min\left(\tilde{p}_{(i+1)},\ \min\left(1,\ p_{(i)} \cdot \frac{M}{i}\right)\right) \quad (11)$$

ただし $\tilde{p}_{(M)} = \min(1, p_{(M)})$ とする．$\tilde{p}_{(i)} < \alpha$ の仮説を棄却（帰属が有意）と判定する．

BH 手続きは偽発見率（FDR）を水準 α 以下に保ちつつ，Bonferroni 補正と比べてより多くの真の帰属を検出できる（検出力が高い）．

注意 1 (PRDS 条件の充足)**.** *BH* 手続きが独立でない検定統計量に対しても *FDR* を制御するには，p 値が部分集合上の正回帰依存性（*PRDS*）条件を満たす必要がある *[38]*．本設定ではアイテムを共有するパターン対のサポート時系列は正の相関を持つため，対応する p 値間に正の依存性が誘導され，*PRDS* 条件は自然に満たされる．さらに，円形シフトは全イベントを同一オフセットで一斉にずらすため，同一パターンに対する異なるイベントの p 値も同じ置換標本を共有し，正の依存性を持つ．したがってイベント間の依存構造も *PRDS* 条件を満たす．

E. Step 5: アイテム重複排除

1) 副次パターン問題*:* 外部イベントがアイテム i の出現頻度を増加させると，i を含む全てのパターンのサポートが相関して増加する．例えば，イベントが $\{5, 15\}$ をブーストし真のパターンが $(5, 15)$ の場合，$(5, 42)$, $(15, 78)$, $(5, 133)$ などの副次パターンも共有アイテム経由でサポートが連動変動するため有意性検定を通過する．

この問題は統計検定だけでは解消できない．副次パターンも共有アイテム経由で実際にサポートが変動しているため，置換検定でも有意と判定されてしまうからである．

2) Union-Find クラスタリングによる重複排除*:* この問題を以下の後処理ステップで解決する:

1) 各イベント e について，e に有意に帰属された全パターン $\{P_1, \ldots, P_n\}$ を収集する．
2) アイテム共有グラフを構築する: パターンをノード，少なくとも 1 つのアイテムを共有するパターン間にエッジを張る．
3) Union-Find（素集合）データ構造で連結成分を求める．
4) 各連結成分内で帰属スコア $A_{\mathrm{obs}}(P,e)$ が最大のパターンのみを残す．

命題 2 (重複排除の正当性)**.** 真のパターン $P^* = \{i_1, i_2\}$ がイベント e によりブースト確率 β でサポートを増加させられているとする．副次パターン $P' = \{i_1, j\}$ $(j \notin P^*)$ において，j のベースライン出現確率を p_{base} とする．$\beta > p_{base}$ であれば，$mag(\tau, P^*) > mag(\tau, P')$ が成立し，P^* と P' はアイテム i_1 の共有により同一連結成分に属するため，P^* が保持され P' は除去される．

証明の概略. イベント e の影響下では i_1, i_2 の各出現確率が β だけ増加する．P^* のサポート増分は $\Delta s_{P^*} \propto \beta^2$ (両アイテムがブースト）である．一方 P' のサポート増分は $\Delta s_{P'} \propto \beta \cdot p_{\mathrm{base}}$ （i_1 はブーストされるが j は独立にベースライン確率で出現）である．$\beta > p_{\mathrm{base}}$ のとき $\beta^2 > \beta \cdot p_{\mathrm{base}}$ となり $\mathrm{mag}(\tau, P^*) > \mathrm{mag}(\tau, P')$ が成立する．実データにおいてブースト確率 β が個別アイテムのベースライン出現確率 p_{base} を超える条件は，イベントが検出可能な影響を持つ限り広く成立する． □

重複排除ステップの計算量はイベントあたり $O(n \cdot k)$ であり，n は有意帰属数，k はパターン最大長である．置換検定ステップに比して無視可能なコストである．

F. 計算量分析

パイプライン全体の時間計算量は以下の通りである:

- **Step 1**（変化点抽出＋局所サポート計算）: $O(|\mathcal{F}| \cdot \bar{C} \cdot h \cdot \log n)$，$\bar{C}$ は平均密集区間数，h はレベルウィンドウ幅，n は平均パターン出現数
- **Step 2**（変化量評価）: Step 1 に含まれる（追加走査なし）
- **Step 3–4** (帰属＋置換検定) : $O(|\mathcal{F}'| \cdot |\mathcal{E}| \cdot B \cdot C)$, $|\mathcal{F}'|$ はフィルタ後パターン数，B は置換回数，C は平均変化点数
- **Step 5**（重複排除）: $O(R \cdot k)$，R は有意結果数

サポート振幅フィルタが $|\mathcal{F}'|$ を 90% 以上削減するため，大規模パターン集合に対しても Step 3–4 は効率的に動作する．

V. 実験

A. 実験設計

1) 合成データ生成*:* ベース語彙 200 アイテム（各アイテムの出現確率 $p_{\mathrm{base}} = 0.03$），$N = 5{,}000$ トランザクションの合成データを生成する．外部イベントの効果は植え込み信号としてモデル化する．3 種類の信号を 1 つのデータセットに混在させることで，パイプラインの弁別能力を多面的に評価する:

Type A（語彙内ブースト）: ベース語彙内のアイテムペアを使用し，イベント期間外にも p_{base} でベースラインサポートを持たせる．イベント活性期間中に確率 β で全パターンアイテムを同時挿入しサポートを上昇させる．magnitude 単独では不十分な**現実的条件**を構成する．

Type B（イベント非対応密集パターン）: 特定期間にサポートが上昇するが，いずれのイベントとも対応しない

TABLE I: デフォルトパラメータ

パラメータ	値
ウィンドウサイズ W	50
最小サポート θ	3
最大パターン長 L	2
変化点検出法	閾値交差
σ	W (= 50)
置換回数 B	5,000
有意水準 α	0.10
補正方法	BH
最小サポート振幅 δ	5
重複排除	有効

TABLE II: EX1 結果: コア帰属精度（5 seeds 平均）

β	Precision	Recall	F1	FAR
0.1	0.60	1.00	0.74	0.40
0.2	0.64	0.93	0.74	0.30
0.3	0.57	0.87	0.67	0.30
0.5	0.60	0.93	0.73	0.20

パターン．季節性やトレンドを模擬し，パイプラインが**無関係な変動を棄却**できるかを検証する．

Type C（デコイイベント）: パターン変動と無関係なイベント．

2) 評価指標*:*

- **P/R/F1**: 予測と正解の厳密一致に基づく Precision, Recall，F1
- **偽帰属率 (FAR)**: Type B パターンがイベントに誤帰属された割合

3) デフォルト設定*:* 表 Iにデフォルトパラメータを示す．

B. EX1: コア帰属精度

RQ: パイプラインはイベント起因の変動を正しく帰属し，イベント無関係の密集パターンを棄却できるか？

Type A（語彙内ブースト 3 パターン），Type B（イベント非対応 2 パターン），Type C（デコイ 2 件）を混在させ，$\beta \in \{0.1, 0.2, 0.3, 0.5\}$ で 5 seed 実行した（表 II）．

β の変化に対して Recall は 0.87–1.00 と高水準を維持しており，信号強度が低い条件（$\beta = 0.1$）でもパイプラインがイベント起因の変動を安定して検出できることが確認された．一方，FAR は β の増加に伴い 0.40 から 0.20 に低下する．これは信号が強いほど Type A パターンの帰属スコアが高くなり，相対的に Type B の誤帰属が抑制されるためである．

a) 構造条件別の評価*:* デフォルト設定（$\beta = 0.3$）で 4 つの構造条件を評価した結果を表 IIIに示す．

OVERLAP では FAR = 0.00 を達成し，イベント区間が重複する条件でも誤帰属を完全に棄却できている．CONFOUND では Type B パターンがイベント近傍に配置される交絡条件にもかかわらず FAR = 0.10 と低く，置換検定による有意性判定が交絡の影響を適切に排除している．DENSE では高密度なベースライン活性により FAR = 0.55 と最大になるが，Recall = 0.83 は維持されており，検出力は保たれている．SHORT では短期間イベント（持続期間 80）がより鋭いサポート変化を生じるため F1 = 0.85 と最高値を示し，変化点検出に基づくパイプラインの特性と整合する結果となった．

TABLE III: EX1 結果: 構造条件別精度（5 seeds 平均）

条件	Precision	Recall	F1	FAR
OVERLAP	0.55	0.73	0.63	0.00
CONFOUND	0.68	0.80	0.73	0.10
DENSE	0.40	0.83	0.54	0.55
SHORT	0.78	0.93	0.85	0.30

TABLE IV: EX2 結果: シナリオ別アブレーション（5 seeds 平均 F1）

構成	Scenario A	Scenario B	Scenario C
Full: prox × dir × mag	1.00	0.73	1.00
prox × mag（dir 除去）	1.00	0.73	1.00
dir × mag（prox 除去）	1.00	0.73	0.93
prox × dir（mag 除去）	0.60	0.73	0.60
mag のみ	1.00	0.73	0.93
prox のみ	0.80	0.73	0.60

C. EX2: スコア構成要素アブレーション

RQ: prox, dir, mag の各構成要素は現実的条件下でどう寄与するか？

各構成要素の必要性を実証する 3 つのシナリオを設計し，全 6 アブレーションモードを各シナリオに適用する (3 シナリオ × 6 モード × 5 seeds = 90 条件）:

Scenario A (prox 必要): パターン $(5, 15)$ に 2 つの密集区間 — 1 つはイベント近傍（因果的），1 つは遠方（偶発的）．prox なしでは両者に等しいスコアが付与される．

Scenario B (dir 必要): イベント開始付近でパターン $(5, 15)$ のサポートが上昇（整合），別パターン $(25, 35)$ が事前に密集期間を終えてサポート下降（不整合）．dir なしでは下降も帰属される．

Scenario C (mag 必要): パターン $(5, 15)$ が 2 イベントの影響を受けるが，ブースト量が $\beta = 0.5$ と $\beta = 0.1$ で大小異なる．mag なしでは両者が同等に扱われる．

結果を表 IVに示す．

表 IVから，magnitude が支配的な構成要素であることが明らかである．mag 除去時には Scenario A, C の両方で F1 が 1.00→0.60 に低下した．proximity は prox 除去時に F1 が 1.00→0.93 と副次的な効果を示したが，prox 単独では F1 = 0.60–0.80 にとどまり，mag なしでは不十分である．direction は dir 除去と Full 構成の F1 が全シナリオで同一であり，mag の振幅情報と重複しているため独立した効果を示さなかった．本実験の合成データ分布では dir の寄与は冗長であり，スコア関数の簡素化（dir 除去）も選択肢となるが，イベント終了後にサポートが上昇するような逆方向の変動を棄却する概念的安全装置として，異なるデータ分布では有効に機能する可能性があるため現設計では保持している．Scenario B では全モードで F1 = 0.73 と均一であり，置換検定と BH 補正が有意性判定を支配する本パイプラインの設計特性を反映している．

D. EX5: 実データ検証

RQ: 実世界データで意味のある結果を生成できるか？

TABLE V: EX5 結果: Dunnhumby 実キャンペーンデータ

指標	値
トランザクション数	276,484
パターン数（$\lvert P\rvert \geq 2$）	955
キャンペーン数	30
重複排除前の有意帰属数	765
重複排除後の有意帰属数	91
重複排除による削減率	**88%**
帰属のあるキャンペーン数	30/30
キャンペーンあたり平均帰属数	3.0
合計処理時間	593 s

Dunnhumby "The Complete Journey" データセット [40] の 276,484 件の購買バスケットと 30 件の販促キャンペーンを用いた探索的分析．キャンペーンの開始・終了日は既知だが正解帰属は不明のため，**定性的検証**として位置づける．

$W = 300$, $\theta = 5$, $L = 2$, $B = 5{,}000$, $\alpha = 0.10$（BH 補正），$\delta = 3$, 重複排除有効．

重複排除の効果: 765 件の有意帰属が 91 件に削減（88% 減）．

キャンペーンカバレッジ: 全 30 キャンペーンに少なくとも 1 件の有意な帰属が生成された（カバレッジ 100%）．キャンペーンあたりの帰属数は 1–5 件（平均 3.0 件）であり，分析者にとって管理可能な量である．

a) パラメータ感度とスケーラビリティ: W と α の感度分析，および N と $|\mathcal{E}|$ に対するスケーリング特性は付録で報告する．主要な知見として，$W = 10$–50 で安定した検出を維持し，実行時間はデータサイズに対して線形にスケールする．

VI. 結論

本稿では，頻出パターンのサポート時系列における変動を外部イベントに統計的に帰属させる**イベント帰属パイプライン**を提案した．本手法は，(1) Phase 1（Apriori-window）で得られた密集区間からの変化点抽出，(2) 交差前後のレベル差による変化量評価，(3) 時間的近接度・方向整合性・変化量に基づく帰属スコアリング，(4) 円形シフト置換検定とグローバル Benjamini–Hochberg FDR 補正，(5) Union-Find クラスタリングによるアイテム重複排除の 5 ステップから成る．

特に，副次パターン問題—真に影響を受けたパターンとアイテムを共有するパターンが相関した偽陽性を生む問題—に対して，アイテム共有グラフの連結成分分析に基づく重複排除を導入した．

実験により以下の知見を得た:

- 語彙内ブースト条件（ベースラインサポートが存在する現実的設定）において，F1 = 0.54–0.85 の検出精度を達成し，8 条件で多面的に弁別能力を検証した（EX1）．
- スコア構成要素のアブレーションにより，magnitude が支配的な帰属要素であり，proximity が副次的に寄与することを確認した（EX2）．
- 実キャンペーンデータ（Dunnhumby, 276K バスケット, 30 キャンペーン）において，全キャンペーンに対して管理可能な数（平均 3.0 件）の帰属を生成し，重複排除が 88% の冗長性を除去する（EX5）．

A. 制約と限界

本パイプラインにはいくつかの制約がある．第一に，本手法は変化点とイベントの**時間的共起**を検定するものであり，因果効果を立証するものではない．「イベントがなければどうなっていたか」という反事実的問いには答えられず，出力はさらなる調査のためのスクリーニングツールとして解釈すべきである．第二に，複数イベントが時間的に重複する場合，パターンの変化を誤ったイベントに帰属する可能性がある（OVERLAP 条件で F1 = 0.63）．第三に，高密度なベースライン活性下では Type B パターンの誤帰属率が上昇する（DENSE 条件で FAR = 0.55）．第四に，パイプラインは W, θ, σ, δ, α の設定を要するが，パラメータ感度分析では $W = 10$–50 で安定した検出を維持することを確認した（付録）．

今後の課題として以下が挙げられる: (1) 変化点検出手法の拡張（CUSUM やベイズ変化点検出との比較），(2) イベント間の時間的重複が密な場合の帰属精度改善，(3) ベースラインサポートが高いパターンに対する検出力向上のための効果量ベーススコアリングの精緻化，(4) 大規模実データ（小売・Web ログ・医療記録）での外的妥当性評価．

References

[1] R. Agrawal, "Fast algorithms for mining association rules," in *Proceedings of the 20th International Conference on Very Large Data Bases*, 1994, pp. 487–499.

[2] J. Han, J. Pei, and Y. Yin, "Mining frequent patterns without candidate generation," *ACM SIGMOD Record*, vol. 29, no. 2, pp. 1–12, 2000.

[3] P. Fournier-Viger, J. C.-W. Lin, B. Vo, T. T. Chi, J. Zhang, and H. B. Le, "A survey of itemset mining," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 7, no. 4, p. e1207, 2017.

[4] M. J. Zaki, "Scalable algorithms for association mining," *IEEE Transactions on Knowledge and Data Engineering*, vol. 12, no. 3, pp. 372–390, 2000.

[5]（著者名）, "Data mining methods based on swarm intelligence to extract dense itemsets," in *Proceedings of the IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 2025,（投稿中 / published 後に更新）.

[6] A. K. Mahanta, F. A. Mazarbhuiya, and H. K. Baruah, "Finding locally and periodically frequent sets and periodic association rules," in *Proceedings of the 1st International Conference on Pattern Recognition and Machine Intelligence*, 2005, pp. 576–582.

[7] S. K. Tanbeer, C. F. Ahmed, B.-S. Jeong, and Y.-K. Lee, "Discovering periodic-frequent patterns in transactional databases," in *Proceedings of the 13th Pacific-Asia Conference on Knowledge Discovery and Data Mining*, 2009, pp. 242–253.

[8] R. U. Kiran, J. Venkatesh, M. Toyoda, M. Kitsuregawa, and P. K. Reddy, "Discovering partial periodic-frequent patterns in a transactional database," *Journal of Systems and Software*, vol. 125, no. C, pp. 170–182, 2017.

[9] P. Fournier-Viger, P. Yang, R. U. Kiran, S. Ventura, and J. M. Luna, "Mining local periodic patterns in a discrete sequence," *Information Sciences*, vol. 544, pp. 519–548, 2021.

[10] E. S. Page, "Continuous inspection schemes," *Biometrika*, vol. 41, no. 1/2, pp. 100–115, 1954.

[11] S. Aminikhanghahi and D. J. Cook, "A survey of methods for time series change point detection," *Knowledge and Information Systems*, vol. 51, no. 2, pp. 339–367, 2017.

[12] A. C. MacKinlay, "Event studies in economics and finance," *Journal of Economic Literature*, vol. 35, no. 1, pp. 13–39, 1997.

[13] Y. Benjamini and Y. Hochberg, “Controlling the false discovery rate: a practical and powerful approach to multiple testing,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995.
[14] A. Segura-Delgado, C. Romero, S. Ventura *et al.*, “Temporal association rule mining: An overview considering the time variable as an integral or implied component,” *WIREs Data Mining and Knowledge Discovery*, vol. 10, no. 3, p. e1367, 2020.
[15] I. Batal, D. Fradkin, J. Harrison, F. Moerchen, and M. Hauskrecht, “Mining recent temporal patterns for event detection in multivariate time series data,” in *Proceedings of the 18th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2012, pp. 280–288.
[16] R. Agrawal and G. Psaila, “Active data mining,” in *Proceedings of the 1st International Conference on Knowledge Discovery and Data Mining (KDD)*, 1995, pp. 3–8.
[17] S. Chakrabarti, S. Sarawagi, and B. Dom, “Mining surprising patterns using temporal description length,” in *Proceedings of the 24th International Conference on Very Large Data Bases (VLDB)*, 1998, pp. 606–617.
[18] B. Liu, W. Hsu, and Y. Ma, “Discovering the set of fundamental rule changes,” in *Proceedings of the 7th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2001, pp. 335–340.
[19] G. Dong and J. Li, “Efficient mining of emerging patterns: Discovering trends and differences,” in *Proceedings of the 5th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 1999, pp. 43–52.
[20] S. D. Bay and M. J. Pazzani, “Detecting group differences: Mining contrast sets,” *Data Mining and Knowledge Discovery*, vol. 5, no. 3, pp. 213–246, 2001.
[21] P. K. Novak, N. Lavrač, and G. I. Webb, “Supervised descriptive rule discovery: A unifying survey of contrast set, emerging pattern and subgroup mining,” *Journal of Machine Learning Research*, vol. 10, pp. 377–403, 2009.
[22] J. Komiyama, M. Ishihata, H. Arimura, T. Nishibayashi, and S.-i. Minato, “Statistical emerging pattern mining with multiple testing correction,” in *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2017, pp. 897–906.
[23] G. E. P. Box and G. C. Tiao, “Intervention analysis with applications to economic and environmental problems,” *Journal of the American Statistical Association*, vol. 70, no. 349, pp. 70–79, 1975.
[24] J. L. Bernal, S. Cummins, and A. Gasparrini, “Interrupted time series regression for the evaluation of public health interventions: A tutorial,” *International Journal of Epidemiology*, vol. 46, no. 1, pp. 348–355, 2017.
[25] A. Abadie, A. Diamond, and J. Hainmueller, “Synthetic control methods for comparative case studies: Estimating the effect of California’s tobacco control program,” *Journal of the American Statistical Association*, vol. 105, no. 490, pp. 493–505, 2010.
[26] K. H. Brodersen, F. Gallusser, J. Koehler, N. Remy, and S. L. Scott, “Inferring causal impact using Bayesian structural time-series models,” *Annals of Applied Statistics*, vol. 9, no. 1, pp. 247–274, 2015.
[27] J. F. Donges, C.-F. Schleussner, J. F. Siegmund, and R. V. Donner, “Event coincidence analysis for quantifying statistical interrelationships between event time series,” *European Physical Journal Special Topics*, vol. 225, pp. 471–487, 2016.
[28] G. I. Webb, “Discovering significant patterns,” *Machine Learning*, vol. 68, no. 1, pp. 1–33, 2007.
[29] ——, “Filtered-top-k association discovery,” in *WIREs Data Mining and Knowledge Discovery*, vol. 1, no. 3. Wiley, 2011, pp. 183–192.
[30] W. Hämäläinen and G. I. Webb, “A tutorial on statistically sound pattern discovery,” *Data Mining and Knowledge Discovery*, vol. 33, no. 3, pp. 597–650, 2019.
[31] A. Terada, M. Okada-Hatakeyama, K. Tsuda, and J. Sese, “Statistical significance of combinatorial regulations,” *Proceedings of the National Academy of Sciences*, vol. 110, no. 32, pp. 12 996–13 001, 2013.
[32] F. Llinares-López, M. Sugiyama, L. Papaxanthos, and K. Borgwardt, “Fast and memory-efficient significant pattern mining via permutation testing,” in *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2015, pp. 725–734.
[33] P. H. Westfall and S. S. Young, *Resampling-Based Multiple Testing: Examples and Methods for p-Value Adjustment*. New York: Wiley, 1993.
[34] J. Theiler, S. Eubank, A. Longtin, B. Galdrikian, and J. D. Farmer, “Testing for nonlinearity in time series: The method of surrogate data,” *Physica D*, vol. 58, no. 1–4, pp. 77–94, 1992.
[35] A. C. Davison and D. V. Hinkley, *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997.
[36] A. E. Yuan and W. Shou, “A rigorous and versatile statistical test for correlations between stationary time series,” *PLOS Biology*, vol. 22, no. 8, p. e3002758, 2024.
[37] N. Haiminen, H. Mannila, and E. Terzi, “Determining significance of pairwise co-occurrences of events in bursty sequences,” in *BMC Bioinformatics*, vol. 9, 2008, p. 336.
[38] Y. Benjamini and D. Yekutieli, “The control of the false discovery rate in multiple testing under dependency,” *Annals of Statistics*, vol. 29, no. 4, pp. 1165–1188, 2001.
[39] O. J. Dunn, “Multiple comparisons among means,” *Journal of the American Statistical Association*, vol. 56, no. 293, pp. 52–64, 1961.
[40] Dunnhumby, “Dunnhumby – the complete journey,” Kaggle, 2014, https://www.kaggle.com/datasets/frtgnn/dunnhumby-the-complete-journey.

Appendix A
付録

A. *EX3:* パラメータ感度

EX1 の語彙内データ（$\beta = 0.3$ 固定）を用いて，主要パラメータに対する頑健性を評価する（各 3 seeds）．

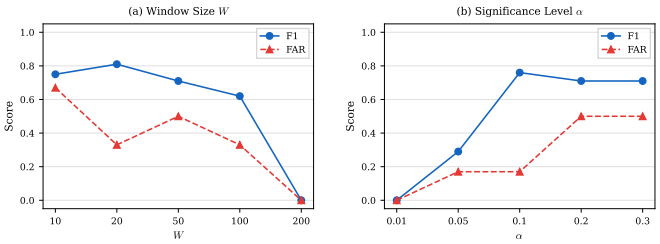

Fig. 2: EX3: パラメータ感度（3 seeds 平均）．(a) ウィンドウサイズ W: $W = 20$ で最高 F1 = 0.81，$W = 200$ では平滑化により検出不能．(b) 有意水準 α: $\alpha = 0.10$ で最良の F1/FAR バランス（F1 = 0.76, FAR = 0.17），$\alpha \leq 0.05$ では BH 補正により真の帰属も棄却され F1 が急落．

TABLE VI: EX3: 置換回数感度（3 seeds 平均）

B	F1	実行時間 (ms)
50	0.71	913
100	0.71	914
500	0.71	941
1,000	0.71	969
5,000	0.71	1,201

1) 置換回数 B*:* 全 B 値で F1 = 0.71 と完全に安定しており，置換回数に対して頑健である．p 値の分解能 $(1/(B+1))$ を確保するため $B = 5{,}000$ をデフォルトとする．

2) 変化点検出法*:* 閾値交差法と CUSUM を比較した結果，語彙内ブースト条件では両手法とも F1 = 0.71 で同等の精度を示した．

B. EX4: スケーラビリティ

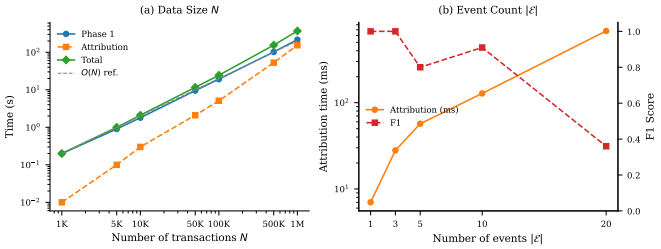

Fig. 3: EX4: スケーラビリティ．(a) データサイズ N: Phase 1 と Attribution の両方が N に対して線形にスケールする．100 万トランザクションで約 6.2 分．(b) イベント数 $|\mathcal{E}|$: 帰属時間は $|\mathcal{E}|$ に対して線形．$|\mathcal{E}| \leq 10$ で F1 ≥ 0.80，$|\mathcal{E}| = 20$ ではイベント密集により弁別力が低下し F1 $= 0.36$．