# Event Attribution of Frequent Pattern Dynamics: Permutation Testing with FDR Control

1st Given Name Surname
*Dept. Name of Organization*
*Name of Organization*
City, Country
email@example.com

2nd Given Name Surname
*Dept. Name of Organization*
*Name of Organization*
City, Country
email@example.com

***Abstract*—頻出パターンマイニングはアイテムセットの出現頻度を発見するが，その変動の原因となる外部イベント（販促キャンペーン・祝日・制度変更等）を説明する機能を持たない．本稿ではこの課題をイベント帰属問題として形式化し，FDR 制御付き多重検定問題としての構造的課題（相関した偽陽性，時間的混同，仮説空間の規模）を同定する．解法として，変化点抽出・帰属スコアリング・円形シフト置換検定・Benjamini–Hochberg FDR 補正・Union-Find 重複排除からなる 5 ステップのパイプラインを構成する．**

**合成データ実験では帰無条件下で FDR 0.070（$\leq \alpha = 0.10$）を確認し，アブレーション分析でパイプライン各構成要素の必要性を実証した．関連手法 4 種（Wilcoxon, CausalImpact, ITS, EventStudy）との比較で全条件最良の F1 を達成した．実データ（Dunnhumby, 276K バスケット）での探索的適用では全 5 キャンペーンで 1 件以上の有意帰属を生成し（カバー率 100%），平均 3.0 帰属/キャンペーンを達成した．**

***Index Terms*—frequent pattern mining, event attribution, change point detection, permutation test, multiple testing correction, support time series**

## I. はじめに

頻出パターンマイニング [1]–[3] は，トランザクションデータ中に繰り返し出現するアイテムセットを発見する基盤的技術であり，小売分析，Web マイニング，バイオインフォマティクスなど幅広い分野で応用されている．Apriori [1]，FP-Growth [2]，ECLAT [4] といった古典的手法はグローバル頻出パターンを効率的に列挙し，スライディングウィンドウ型手法 [5] は特定時間区間内で局所的に密集するパターンを検出する．

しかし，これらの手法はどのパターンがいつ頻出であるかを同定するのみであり，なぜパターンの出現頻度が変動するかを説明する機能を持たない．実際の応用場面では，販促キャンペーン，祝日，規制変更，システム更新といった外部イベントがパターンサポートの時間的変動を駆動していることが多い．「どのイベントがいつ・どのパターンの密集を引き起こしたか」を特定できれば，キャンペーン効果の定量化，副作用の検出，システム異常の診断など，意思決定に直結する知見が得られる．

本研究ではこの課題を**統計的帰属**として定式化する．「帰属」とは因果推論ではなく，サポート変化点と外部イベントの**時間的関連**の統計的有意性を同定することであり，出力はさらなる分析のための**スクリーニング**として位置づけられる（詳細は定義 5，注意 1を参照）．

このように帰属タスクは実用上重要であるにもかかわらず，頻出パターンのサポート変動を外部イベントに結びつける統計フレームワークは，我々の知る限り存在しない．時間的パターンマイニング [6]–[9] は周期性や局所頻度を持つパターンを発見するが，パターン変動と外生イベントの関連はモデル化しない．変化点検出手法 [10], [11] は個別時系列の構造変化を同定するが，数千のパターンサポート時系列を同時に検定する多重検定の負荷や，検出された変化をイベントに紐づける機能は備えていない．計量経済学のイベント・スタディ法 [12] は企業イベントの株価への影響を評価するが，単一のアウトカム変数を対象としており，数千のパターン時系列を同時に扱う設定には適用できない．

### A. 本研究の貢献

本研究の主貢献は，**イベント帰属問題**の形式的定義と，我々の知る限りにおいて初の統計的解法フレームワークの構築にある．(1) イベント帰属問題を FDR 制御付き多重検定問題として定式化し，規模・副次パターン・時間的混同の 3 課題を同定する（III節）．(2) 変化点抽出・帰属スコアリング・円形シフト置換検定・グローバル BH 補正・Union-Find 重複排除からなる 5 ステップパイプラインを構成する（IV節）．(3) $i$ を含む全パターンが相関して変動する副次パターン問題を同定し，$\lceil l/2 \rceil$ 過半数共有基準による重複排除で解決する（IV-E節）．(4) 合成データ 8 条件・アブレーション・関連手法 4 種との比較・実データ（Dunnhumby）への探索的適用を提供する（V節）．

## II. 関連研究

### A. 頻出パターンマイニング

頻出パターンマイニングの包括的なサーベイ [3] が存在する．Apriori [1] は反単調性に基づく候補生成・枝刈りフレームワークを確立し，FP-Growth [2] と ECLAT [4] がそれぞれ FP-tree と縦型表現で高速化を実現した．これらの手法はグローバル頻度を対象とし，時間的な変動をモデル化しない．

### B. 時間的・周期的パターンマイニング

Segura-Delgado ら [13] が時間的 ARM の包括的サーベイを提供している．PFPM [7] と PPFPM [8] は一定周期で繰り返し出現するパターンを対象とする周期性マイニング手法であり，LPFIM [6] は gap ベースの閾値で時間区間内の頻出集合を検出する．LPPM [9] は局所性と

周期性の基準を統合する．これらの手法はパターンがいつ・どの周期で頻出であるかを検出するが，変動の原因はモデル化しない．

### C. *Apriori-window:* 密集区間マイニング

Apriori-window [5] は上記の手法とは設計思想が異なる．gap パラメータや周期性仮定を持たず，固定幅スライディングウィンドウ $W$ をトランザクション列上で走査し，各位置 $t$ でのローカルサポート $s_P(t)$（定義 1）を直接評価する．出力は各パターン $P$ の密集区間 $\mathcal{I}_P$（定義 4）— サポートが閾値 $\theta$ 以上を連続して満たすウィンドウ左端の極大区間—であり，パターンが「どの期間に集中して出現したか」を区間単位で表現する．Apriori の反単調性を利用した枝刈りにより，候補パターン空間を効率的に削減する．本研究は Apriori-window を Step 0 として採用し，その出力 $(\mathcal{F}, \{\mathcal{I}_P\})$ をイベント帰属パイプラインの入力として使用する．

### D. パターン変化のモニタリングと診断

Agrawal ら [14] はルール統計量の形状クエリによるトレンド検出を，Chakrabarti ら [15] は記述長に基づくサプライズ指標を，Liu ら [16] は二時点間の「基本的変化」抽出をそれぞれ提案した．これらは変化の検出・特徴づけを行うが，外部イベントへの帰属フレームワークを持たない．

### E. 変化点検出

CUSUM アルゴリズム [10] に代表される変化点検出手法 [11] は個別時系列の構造変化を同定するが，数千のパターンサポート時系列を同時に扱う多重検定の負荷や変化をイベントに紐づける機能は備えていない．

### F. イベント帰属・介入分析と因果推論

中断時系列回帰（ITS）[17], イベント・スタディ法 [12], CausalImpact [18]，Wilcoxon rank-sum 検定 [19] は既知の介入がアウトカムに与える影響を検定する．しかしこれらは典型的に単一または少数のアウトカム変数を対象としており，数千のパターンサポート時系列を複数のイベントに対して同時検定する設定には直接適用できない．

### G. 統計的パターンマイニングと多重検定補正

Webb [20], [21] は冗長な有意パターンの問題に取り組み，自己充足性・生産性基準を導入して発見パターンの関連性を改善した．Terada ら [22] は LAMP により Bonferroni 因子を最小化し，Llinares-López ら [23] は置換検定と Tarone の検定可能性基準を組み合わせた高速有意パターンマイニングを実現した．これらは二群間の頻度差を検定するが，本研究はサポートの時間的変動と外部イベントの関連を検定する点が異なる．本パイプラインはサロゲートデータ法 [24] に基づく円形シフト置換検定 [25], [26] とグローバル BH 補正 [27], [28] を採用し，Bonferroni 補正 [29] より検出力の高い FDR 制御を実現する．

TABLE I: 関連手法との機能比較

| 手法群 | 時系列変化 | イベント帰属 | 多数パターン | 多重検定 | 重複排除 |
|---|---|---|---|---|---|
| 時間的 FPM | – | – | ✓ | – | – |
| Apriori-window | ✓ | – | ✓ | – | – |
| 変化点検出 | ✓ | – | – | – | – |
| ITS/介入分析 | ✓ | ✓ | – | – | – |
| イベントスタディ | ✓ | ✓ | – | – | – |
| CausalImpact | ✓ | ✓ | – | – | – |
| Wilcoxon 検定 | – | ✓ | – | – | – |
| 統計的 FPM | – | – | ✓ | ✓ | – |
| **本手法** | ✓ | ✓ | ✓ | ✓ | ✓ |

### H. 関連手法との差異のまとめ

表 Iに，各手法群が本研究の問題設定に対応できるかを整理する．我々の知る限り，本研究は多数のパターン時系列を複数イベントに同時帰属させ，多重検定を制御しつつ副次パターンを排除する初の統合フレームワークである．

## III. 問題定義

### A. 記法

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ を有限のアイテム全集合，$D = [d_1, d_2, \ldots, d_N]$ を時刻順のトランザクション列とする．各トランザクション $d_t$（$t = 1, \ldots, N$）は $\mathcal{I}$ の部分集合である．アイテムセット（パターン）$P \subseteq \mathcal{I}$ がトランザクション $d_t$ に出現するとは $P \subseteq d_t$ が成立することをいう．

**定義 1** (サポート時系列)**.** パターン $P$，ウィンドウサイズ $W \in \mathbb{Z}_{>0}$，トランザクション列 $D$（長さ $N$）に対して，$P$ のサポート時系列 $s_P = [s_P(0), s_P(1), \ldots, s_P(N-W)]$ を

$$s_P(t) = \left|\{d_j \in D \mid t \le j < t + W,\ P \subseteq d_j\}\right| \tag{1}$$

と定義する．

**定義 2** (外部イベント)**.** 外部イベント $e = (id, name, t_s, t_e)$ は，一意な識別子，名称，およびイベントが有効な期間を表すタイムスタンプ区間 $[t_s, t_e]$ から成る．既知の外部イベント集合を $\mathcal{E} = \{e_1, e_2, \ldots, e_K\}$ とする．

**定義 3** (変化点（閾値交差）)**.** 位置 $\tau \in \{0, 1, \ldots, N-W\}$ が変化点であるとは，次のいずれかが成り立つことをいう*:*

$$s_P(\tau) \ge \theta \wedge (\tau = 0 \vee s_P(\tau - 1) < \theta), \tag{2}$$

$$s_P(\tau) < \theta \wedge \tau > 0 \wedge s_P(\tau - 1) \ge \theta. \tag{3}$$

式 *(2)* を「上昇」，式 *(3)* を「下降」とし，密集区間 $[s, e]$ の変化点は $s$（上昇）と $e + 1$（下降，存在する場合）である．

**定義 4** (密集区間)**.** パターン $P$ とサポート閾値 $\theta$ に対して，密集区間 $[s, e] \subseteq \{0, \ldots, T-1\}$ とは，$s_P(t) \ge \theta$ が $t \in [s, e]$ の全ての $t$ で成立し，かつ $s < 0$ または

$s_P(s-1) < \theta$，$e = T-1$ または $s_P(e+1) < \theta$ を満たす極大連続区間である．$P$ の密集区間全体からなる集合を $\mathcal{I}_P$ とする．$\mathcal{I}_P$ は *Step 0*（*Apriori-window [5]*，*IV*節参照）の出力として与えられる．

### *B.* イベント帰属問題

**定義 5** (イベント帰属問題)．共起パターン集合 $\mathcal{F} = \{P \subseteq \mathcal{I} : |P| \geq 2,\ \text{サポート} \geq \theta\}$，各パターン $P$ の密集区間集合 $\{\mathcal{I}_P\}_{P \in \mathcal{F}}$，外部イベント集合 $\mathcal{E}$，有意水準 $\alpha$ が与えられたとき，イベント帰属問題とは，パターン $P$ の密集区間 $I \in \mathcal{I}_P$ の変化点がイベント $e$ の時間窓と統計的に有意に関連する全ての三つ組 $(P, I, e) \in \{(P, I, e) : P \in \mathcal{F},\ I \in \mathcal{I}_P,\ e \in \mathcal{E}\}$ を，偽発見率（*FDR*）を水準 $\alpha$ 以下に制御しながら同定することである．単一アイテム（$|P| = 1$）の頻度変動は通常の時系列分析で捕捉可能であり，共起構造の発見を目的とする本問題の対象外とする．

**注意 1** (帰属の意味と限界)．本稿の「帰属」は**統計的時間的関連**の有意性を指し，因果推論（*do-calculus [30]*）ではない．交絡要因が存在する場合や複数イベントの時間窓が重複する場合，本手法の出力は帰属候補の**スクリーニング**として位置づけられる（*CONFOUND・OVERLAP* 条件での精度低下として実験的に確認，*V-B*節）．

この問題の主要な課題は以下の 3 点である:

1) **規模**: $\sum_{P \in \mathcal{F}} |\mathcal{I}_P| \times |\mathcal{E}|$ 個の $(P, I, e)$ 仮説を同時に検定する必要があり，厳格な多重検定補正が必要となる．
2) **副次パターン**: アイテム $i$ の頻度が増加すると，$i$ を含む全共起パターンのサポートが連動変動し，偽陽性が大量に発生する．
3) **時間的混同**: 複数イベントの時間窓が重複する場合，帰属が曖昧になる．

## IV. 提案手法

本節では**イベント帰属パイプライン**を詳述する．Step 0 として Apriori-window [5] がトランザクション列 $D$，ウィンドウサイズ $W$，最小サポート閾値 $\theta$ を入力としてパターン集合 $\mathcal{F}$ と各パターンの密集区間集合 $\{\mathcal{I}_P\}_{P \in \mathcal{F}}$ を出力し，これを入力として Steps 1–5 が統計的に有意なパターン–区間–イベント帰属を同定する．図 1にパイプラインの概要を，アルゴリズム 1に帰属スコアリングと統計検定の手順を，アルゴリズム 2に重複排除の手順を示す．

### *A. Step 1:* 密集区間からの変化点抽出

各密集区間を独立した帰属単位として扱い，一つのパターンが複数の密集区間を持つ場合，各区間がそれぞれ異なるイベントへ帰属されうる．各密集区間 $[s_i, e_i]$ から上昇変化点 $s_i$ と下降変化点 $e_i+1$（存在する場合）を抽出し，変化量（式 (4)）の計算に必要な局所サポートのみを，パターン出現リスト $T_P$ 上の二分探索により $O(\log |T_P|)$ で求める．

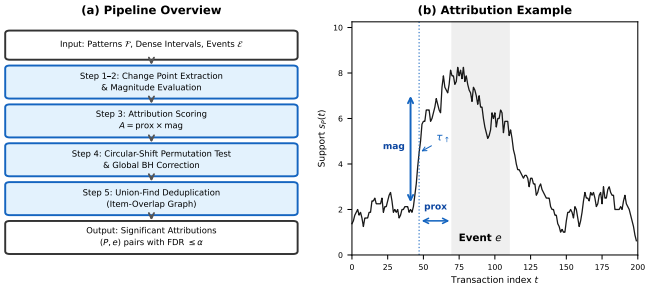


Fig. 1: (a) パイプラインの全体構成．Step 0（Apriori-window）が密集区間を出力し，Steps 1–5 を経て有意な帰属を出力する．(b) 帰属スコアリングの例示．サポート時系列上の変化点 $\tau_\uparrow, \tau_\downarrow$ とイベント区間の関係から，近接度（prox）と変化量（mag）を算出する．

**Algorithm 1** 帰属スコアリングと統計検定（Step 1–4）

**Require:** 共起パターン $\mathcal{F}$ ($|P| \geq 2$), 密集区間 $\{\mathcal{I}_P\}$, イベント $\mathcal{E}$, 設定 $(\theta, \sigma, B, \alpha)$
**Ensure:** 有意帰属集合 $\mathcal{R}$
  **// Step 1–2: 変化点抽出と変化量計算**
RawResults ← []
**for** 各パターン $P \in \mathcal{F}$，各区間 $[s_i, e_i] \in \mathcal{I}_P$ **do**
  $\mathcal{C}_I \leftarrow \{s_i$(上昇), $e_i$+1(下降)$\}$
  各 $\tau \in \mathcal{C}_I$ の変化量 magnitude($\tau$) を計算 ▷ 式 (4)
  **// Step 3: 帰属スコアリング**
  **for** 各イベント $e \in \mathcal{E}$ **do**
    $A_{\text{obs}} \leftarrow \sum_{\tau \in \mathcal{C}_I} A(P, \tau, e)$ ▷ 式 (5)
  **// Step 4: 円形シフト置換検定**
    count ← 0
    **for** $b = 1$ to $B$ **do**
      $\mathcal{E}_b \leftarrow$ CircularShift($\mathcal{E}, \delta_b$)
      $e_b \leftarrow \mathcal{E}_b$ 中のイベント $e$ のシフト版 ▷ $e$ と同一識別子を持つ
      $A_b \leftarrow \sum_{\tau \in \mathcal{C}_I} A(P, \tau, e_b)$
      **if** $A_b \geq A_{\text{obs}}$ **then** count ← count + 1
      **end if**
    **end for**
    $p_{\text{raw}} \leftarrow (1 + \text{count})/(B+1)$ ▷ 式 (9)
    RawResults.append($(P, [s_i, e_i], e)$, $A_{\text{obs}}$, $p_{\text{raw}}$)
  **end for**
**end for**
  **// Step 4 (続): グローバル BH 補正**
RawResults を $p_{\text{raw}}$ 昇順にソート
$M \leftarrow$ |RawResults|
**for** $i = M$ downto 1 **do**
  $\tilde{p}_{(i)} \leftarrow \min(\tilde{p}_{(i+1)}, \min(1, p_{(i)} \cdot M/i))$ ▷ BH step-down
**end for**
$\mathcal{R} \leftarrow \{(P, I, e) \mid \tilde{p}_{(i)} < \alpha\}$
**return** $\mathcal{R}$

### *B. Step 2:* 変化量の評価

$T = N - W + 1$ とし，変化点 $\tau$ の前後 $h$ 点の参照窓を

$$\mathcal{L}_\tau^- = \{\max(0, \tau - h), \ldots, \tau - 1\},$$
$$\mathcal{L}_\tau^+ = \{\tau, \ldots, \min(T-1, \tau + h - 1)\}$$

とする（デフォルト $h = 20$）．変化量を局所平均差として定義する:

$$\bar{s}^{\pm}(\tau) = \frac{1}{\max(1, |\mathcal{L}_\tau^{\pm}|)} \sum_{j \in \mathcal{L}_\tau^{\pm}} s_P(j),$$
$$\text{magnitude}(\tau) = |\bar{s}^{+}(\tau) - \bar{s}^{-}(\tau)|. \tag{4}$$

**検出位置**は閾値交差（密集区間の端点）で決め，**変化の強さ**は交差前後のレベル差で評価する．

### C. Step 3: 帰属スコアリング

各密集区間 $I = [s_i, e_i]$ の変化点 $\tau$ と各イベント $e \in \mathcal{E}$ に対して，時間的関連を定量化する帰属スコアを計算する．本稿では以下を採用する:

$$A(P, \tau, e) = \text{prox}(\tau, e) \cdot \text{mag}(\tau) \tag{5}$$

2 つの構成要素は以下の通りである．

**近接度**: 指数カーネルによる時間的近さの指標:

$$\text{prox}(\tau, e) = \exp\left(-\frac{d(\tau, e)}{\sigma}\right) \tag{6}$$

ここで $d(\tau, e) = \min(|\tau - t_s|, |\tau - t_e|)$ は変化点からイベント境界までの最小距離，$\sigma > 0$ は減衰パラメータである．

**変化量**: 式 (4) の生の変化量（絶対レベルシフト量）を平方根正規化してスコアリングに用いる:

$$\text{mag}(\tau) = \frac{\text{magnitude}(\tau)}{\sqrt{\max(1,\ \bar{s}^{-}(\tau))}} \tag{7}$$

ベースラインサポートが高いパターンほど絶対変化量が大きくなるバイアスを，平方根で除すことにより緩和する．実世界のトランザクションデータではアイテム頻度が Zipf 分布に従うケースが多く [3]，この正規化が特に有効である．

密集区間 $I$ のイベント $e$ に対する観測スコアは，その区間の変化点（上昇・下降の最大 2 点）にわたる帰属スコアの総和 $A_{\text{obs}}(P, I, e) = \sum_{\tau \in \mathcal{C}_I} A(P, \tau, e)$ とする．

*a) 設計根拠:* 帰属スコア $A$ は候補のランキング用指標であり，帰属の最終判定は Step 4 の置換検定が行う．乗算構成 $\text{prox} \times \text{mag}$ はいずれかの構成要素が 0 に近ければスコア全体が 0 となる排他的フィルタとして機能し，EX2（V-C節）が両成分の補完性を実証する．

### D. Step 4: 置換検定とグローバル FDR 補正

*1) 円形シフト帰無分布:* 密集区間 $I$ の変化点とイベント $e$ の時間的関連が統計的に有意かを検定するため，円形シフト置換検定を用いる．帰無仮説 $H_0$:「密集区間 $I$ の変化点の位置はイベント時刻と無関係である」のもと，$B$ 回の置換を実行する．各置換 $b$ では，ランダムなオフセット $\delta_b \sim \text{Uniform}\{1, \ldots, T-1\}$ だけ全イベントの時刻を一斉にずらす（円形シフト）:

$$e_b = (id, name, (t_s + \delta_b) \bmod T, (t_s + \delta_b + \Delta) \bmod T) \tag{8}$$

ここで $\Delta = t_e - t_s$ はイベント持続時間，$T$ は時系列長である．

各置換に対してスコア $A_{\text{perm}}^{(b)}(P, I, e)$ を再計算し，未補正 $p$ 値を以下で求める:

$$p_{\text{raw}}(P, I, e) = \frac{1 + |\{b : A_{\text{perm}}^{(b)}(P, I, e) \geq A_{\text{obs}}(P, I, e)\}|}{B + 1} \tag{9}$$

**命題 1** (置換検定の正当性)**.** 帰無仮説 $H_0$ のもとでは，観測スコア $A_{obs}$ と $B$ 個の置換スコア $A_{perm}^{(1)}, \ldots, A_{perm}^{(B)}$ は交換可能（*exchangeable*）である．したがって式 *(9)* の $p$ 値は $\{1/(B+1), 2/(B+1), \ldots, 1\}$ 上の離散一様分布に従い，任意の水準 $\alpha$ で第一種過誤率が $\alpha$ 以下に制御される *[25]*.

*2) グローバル Benjamini–Hochberg 補正:* $M = \sum_{P \in \mathcal{F}'} |\mathcal{I}_P| \cdot |\mathcal{E}|$ 個の仮説（$(P, I, e)$ 三つ組）全体に対して Benjamini–Hochberg (BH) 手続き [27] をグローバルに適用し，FDR を水準 $\alpha$ 以下に保ちつつ Bonferroni 補正より高い検出力を実現する．

PRDS 条件の充足については付録 Aを参照されたい．

### E. Step 5: アイテム重複排除

**Algorithm 2** アイテム重複排除（Step 5）

**Require:** 有意帰属集合 $\mathcal{R}$（アルゴリズム 1の出力）
**Ensure:** 重複排除後の帰属集合 $\mathcal{R}'$

```
// Step 5a: 同一長パターンの重複排除（過半数共有）
for 各イベント e do
    R_e ← イベント e に帰属された全パターン（区間問わず）を長さ l ごとにグループ化
    for 各長さ l のグループ do
        for 各パターンペア (P_i, P_j) do
            if |P_i ∩ P_j| ≥ ⌈l/2⌉ then
                UNION(P_i, P_j)                ▷ Union-Find
            end if
        end for
        各連結成分内で A_obs(P, I, e) 最大のパターンのみ残す
    end for
end for
// Step 5b: 異長パターン間の部分集合排除
for 各イベント e do
    for 各パターンペア (P_i, P_j) where |P_i| ≠ |P_j| do
        if P_i ⊆ P_j or P_j ⊆ P_i then
            UNION(P_i, P_j)                    ▷ Union-Find
        end if
    end for
    各連結成分内で A_obs(P, I, e) 最大のパターンのみ残す
end for
return R' ← 残存パターンの集合
```

*1) 副次パターン問題:* 外部イベントがアイテム $i$ の頻度を増加させると，$i$ を含む全共起パターンのサポートが連動変動するため，$(5, 42)$, $(15, 78)$ などの副次パターンも置換検定を通過してしまう．副次パターンも実際に

サポートが変動しているため，統計検定のみでは排除できない．

*2) Union-Find* クラスタリングによる重複排除*:* この問題を以下の後処理ステップで解決する:

1) 各イベント $e$ ごとに，$e$ に有意に帰属された全パターン（区間をまたいで統合）を収集し，パターン長 $l$ ごとにグループ化する．
2) 各長さ $l$ のグループ内で過半数共有グラフを構築する: パターンをノードとし，共有アイテム数 $|P_i \cap P_j| \geq \lceil l/2 \rceil$ のパターン間にエッジを張る．
3) Union-Find（素集合）データ構造で連結成分を求める．
4) 各連結成分内で帰属スコア $A_{\text{obs}}(P, I, e)$ が最大のパターンのみを残す．
5) **異長パターン間の部分集合排除**: 上記の同一長排除後，同一イベント $e$ への帰属パターン全体に対し，$P_i \subseteq P_j$ の関係にあるペアを Union-Find で統合し，各成分内でスコア最大のパターンのみを残す．

**主張 1** (重複排除の正当性（一般化）). 独立出現・加算ブーストの簡約モデルを仮定する．真のパターン $P^*$（長さ $l$，全アイテムがブースト確率 $\beta > 0$ で増加）と $s$ 個のアイテムを共有する副次パターン $P'$（残り $l - s$ 個は非ブースト）に対して，$magnitude(\tau, P^*) > magnitude(\tau, P')$ が成立する．さらに $s \geq \lceil l/2 \rceil$ のとき両者は過半数共有グラフの同一連結成分に属し，スコア最大の $P^*$ が保持されて $P'$ は除去される．

証明は付録 Cに示す．
計算量分析は付録 Bを参照されたい．

## V. 実験

### A. 実験設計

*1) 合成データ生成:* ベース語彙 200 アイテム（各アイテムの出現確率 $p_{\text{base}} = 0.03$），$N = 100{,}000$ トランザクションの合成データを生成する．外部イベントの効果は植え込み信号としてモデル化する．3 種類の信号を 1 つのデータセットに混在させることで，パイプラインの弁別能力を多面的に評価する:

**Type A**（語彙内ブースト）: イベント活性期間中に確率 $\beta$ で全パターンアイテムを同時挿入してサポートを上昇させる．イベント期間外にも $p_{\text{base}}$ でベースラインサポートを持つ現実的条件である．

**Type B**（イベント非対応密集パターン）: 特定期間にサポートが上昇するが，いずれのイベントとも対応しない (季節性・トレンドの模擬)．

**Type C**（デコイイベント）: パターン変動と無関係なイベント．

*2) 評価指標:* 評価は **(P, I, E) 三つ組レベル**で行う．各指標の定義は以下の通り．

*a) 正解集合の構築:* 各植え込み信号 $(P, E)$ に対し，イベント窓と重複する密集区間のうち最長のものを代表 $I^*$ として正解三つ組 $(P, I^*, E)$ を登録する（$(P, E)$ ペアごとに 1 件）．

*b) マッチング基準:* アイテム集合・区間端点・イベント ID の完全一致（exact match）を要求する．

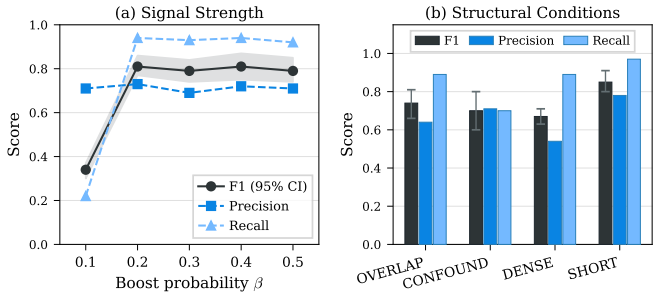


Fig. 2: EX1 結果（20 seeds 平均・95%CI）．(a) 信号強度：$\beta \geq 0.2$ で F1 $\geq 0.78$，Recall $\geq 0.92$ を達成．$\beta = 0.1$ は L=2 語彙内パターンが検出限界（F1 = 0.34）だが L=3,4 語彙外パターンは安定検出される．(b) 構造条件：SHORT（F1 = 0.85），OVERLAP（0.74），CONFOUND（0.70），DENSE（0.67）と全条件で F1 $\geq 0.67$ を達成する．

*c) 精度指標:* TP $= |\hat{\mathcal{A}} \cap \mathcal{A}^*|$，FP $= |\hat{\mathcal{A}} \setminus \mathcal{A}^*|$，FN $= |\mathcal{A}^* \setminus \hat{\mathcal{A}}|$ に基づく標準的な Precision・Recall・F1 スコアを使用する．評価は重複排除（Step 5）後の最終出力に対して実施する．Type B（イベント非対応）パターンを有意帰属として出力した場合は FP となり，Precision を低下させる．

*3) デフォルト設定:* デフォルトパラメータを付録 I（表 V）に示す．変化量正規化には平方根正規化（式 (7)）を用いる．

*4) 評価方針:* EX1 で多様なデータ条件下の帰属精度を評価し，EX2 でアブレーション分析により各ステップの寄与を実証する．EX3 では Steps 1・3・4 を関連手法で置き換える Step 差分比較を行う．EX4 では実データへの適用可能性を確認する探索的分析を行うが，実世界データでは帰属の正解ラベルが入手困難なため定量評価は行わない．

### B. *EX1:* コア帰属精度

**RQ**: パイプラインはイベント起因の変動を正しく帰属し，イベント無関係の密集パターンを棄却できるか？また，L=2〜4 の複数パターン長を自然に扱えるか？多様なデータ特性（信号強度，構造条件，パターン長）に対する頑健性を評価する．

*a) 信号強度・構造条件:* Type A（語彙内ブースト 5 パターン：L=2×3 件，L=3×1 件，L=4×1 件），Type B（イベント非対応 2 パターン），Type C（デコイ 2 件）を混在させ，$\beta \in \{0.1, 0.2, 0.3, 0.5\}$ および 4 つの構造条件で **20 seed** 評価した（図 2）．

$\beta = 0.1$ は L=2 語彙内パターンが検出限界だが L=3,4 語彙外パターンは安定検出され F1 = 0.34 [0.30, 0.37] (Recall = 0.22)．$\beta \geq 0.2$ で Recall $\geq 0.92$，F1 $\geq 0.78$ を達成した．構造条件は全条件で F1 $\geq 0.67$ を達成した (§H参照)．

*b) 帰無条件検証:* 植え込み信号なしの帰無データで **100 seed** 実行した結果（付録 F），平均偽発見率は **0.070** ($\leq \alpha = 0.10$) であり，FDR 制御が経験的に確認された．

TABLE II: EX2a 結果: シナリオ別アブレーション（5 seeds 平均 F1，Zipf-1.0，$\sqrt{}$ 正規化）

| 構成 | Scenario A | Scenario B |
|---|---|---|
| Full: prox × mag | **1.00** | **0.46** |
| mag のみ（prox 除去） | 0.00 | 0.00 |
| prox のみ（mag 除去） | 1.00 | 0.19 |

### C. *EX2:* アブレーション分析

**RQ**: スコア構成要素およびパイプラインの各ステップは精度にどう寄与するか？EX1 と同様に Zipf 分布データ（$\sqrt{}$ 正規化）を使用する．

*a)* スコア構成要素*:* 各構成要素の必要性を実証する 2 つのシナリオを設計し，全 3 アブレーションモードを各シナリオに適用する（2 シナリオ × 3 モード × 5 seeds = 30 条件）：

**Scenario A** (prox 必要): パターン $(5, 15)$ に 2 つの密集区間 — 1 つはイベント近傍（因果的），1 つは遠方（偶発的）．prox なしでは両者に等しいスコアが付与される．
**Scenario B** (mag 必要): パターン $(5, 15)$ が 2 イベントの影響を受けるが，ブースト量が $\beta = 0.5$ と $\beta = 0.1$ で大小異なる．mag なしでは両者が同等に扱われる．

結果を表 IIに示す．

prox なし（mag のみ）は時間的対応付け情報を持たず**両シナリオで F1 = 0.00** に崩壊する．prox のみは Scenario A で F1 = 1.00 だが，Scenario B（大小ブースト弁別）では F1 = 0.19 に低下する．Full 構成は Scenario A で 1.00，Scenario B で 0.46 を達成し，両構成要素の相補性を実証した．

*b)* パイプラインステップの寄与*:* ナイーブベースライン（Steps 1–3 のみ: 変化点検出 + スコアリング，閾値以上の候補をすべて出力）と，パイプラインの各ステップを段階的に追加した 3 つの変種を比較する:

- **Naive**: Steps 1–3 のみ（検定なし）
- **+PermTest**: per-pattern 置換検定を追加（グローバル補正なし）
- **+BH**: グローバル BH 補正を追加
- **Full**: Union-Find 重複排除を追加（= 完全パイプライン）

EX1 のデータ（$\beta = 0.3$, CONFOUND, DENSE; Zipf-1.0, $\sqrt{}$ 正規化）を使用し，各条件 × 5 seeds で評価した（図 3）．

Naive は全条件で Recall = 1.00 だが F1 $\leq$ 0.03 と偽陽性が膨大で，スコア閾値のみでは制御不能である．**+PermTest** の FP 削減効果は限定的だが，**+BH**（グローバル BH 補正）が最大の偽陽性削減をもたらし，**Full**（+ 重複排除）が冗長パターンをさらに除去して全条件で最高 F1 を達成する．各ステップが段階的かつ相補的に偽陽性を削減することが確認された．

### D. *EX3:* 関連手法との比較

**RQ**: パイプラインの Steps 1–3–4 を関連手法で置き換えた場合，提案手法の構成要素は最適か？

**比較の目的と設計** Step 0（Apriori-window），BH 補正，Union-Find 重複排除（Step 5）を全手法で共有し，帰属判定コア（Steps 1・3・4）のみを置き換える Step 差分アブレーションとして設計している．本結果は「提案 Step 設計 vs. 代替 Step 設計」の比較と解釈すべきである．

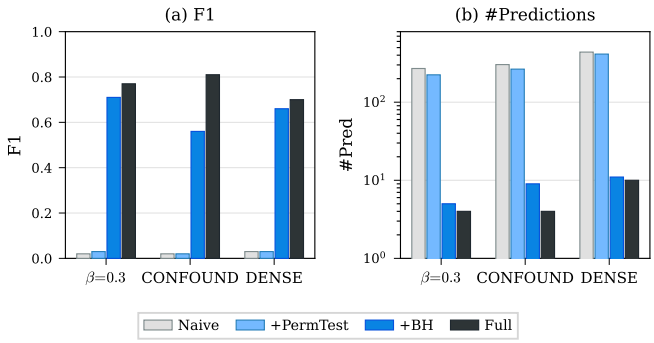


Fig. 3: EX2b: パイプラインステップの段階的追加による精度変化（5 seeds 平均，Zipf-1.0，$\sqrt{}$ 正規化）．(a) F1: BH 補正と重複排除の追加で大幅に改善．(b) #Predictions: 各ステップが出力数を段階的に削減し，偽陽性を抑制する．

表 Iに示した関連手法群のうち，イベントとアウトカムの関連を検定する手法を選定し，帰属判定の核となる Steps 1（変化点抽出），3（帰属スコアリング），4（統計検定）を以下の 5 手法で置き換える．

1) **Wilcoxon** [19]: イベント期間中・外のサポート分布を rank-sum 検定で比較．
2) **CausalImpact** [18]: 局所水準モデルで反事実を推定し累積逸脱を検定．
3) **ITS** [17]: セグメント回帰で介入前後の水準変化係数を検定．
4) **EventStudy** [12]: イベント前の統計から累積異常サポートを $z$ 検定．

EX1 と同一のデータ（$\beta = 0.3$, Zipf-1.0, $\sqrt{}$ 正規化）および 4 つの構造条件を使用し，各条件 5 seeds で評価した結果を図 4に示す．

提案手法は全 5 条件で F1 が最高または同等であり（SHORT 条件で ITS とほぼ同等: 0.72 vs 0.77），特に CONFOUND 条件では F1 = 0.68 と次点 ITS（0.45）を上回る．変化点のタイミング情報を活用する proximity スコアが，活性期間がイベント窓に重複する非対応パターンを効果的に弁別する．

ITS は $\beta$=0.3 で F1 = 0.60（提案手法: 0.66）と競合するが，CONFOUND（0.45）・OVERLAP（0.40）条件で大きく低下する．CausalImpact・Wilcoxon は全条件で F1 $\leq$ 0.49 にとどまる．提案手法は F1 0.66–0.72（5 条件平均 0.68）と全条件で安定しており，特に交絡・重複条件での優位性が顕著である．

### E. *EX4:* 実データ検証

**RQ**: 実世界データに適用可能か？

Dunnhumby “The Complete Journey” データセット [31] の 276,484 件の購買バスケットを用いた探索的分析．実データのアイテム頻度は Zipf 的分布に従うため，平方根正規化を使用する．

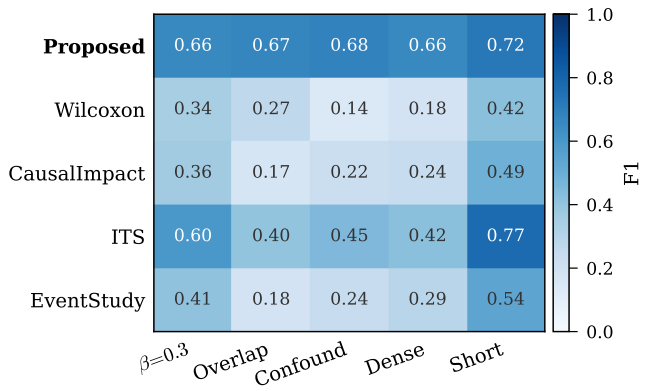


Fig. 4: EX3 結果: 関連手法との比較（5 seeds 平均，F1）．全手法は Step 0（Apriori-window）・BH 補正・重複排除を共有する．提案手法は全 5 条件で最高または同等の F1 を達成し，CONFOUND 条件での優位性が最も顕著（0.70 vs 次点 ITS 0.35）．

TABLE III: EX4 結果: Dunnhumby 大規模販促キャンペーン

| 指標 | 値 |
|---|---|
| トランザクション数 | 276,484 |
| パターン数（$\lvert P\rvert \geq 2$） | 896 |
| キャンペーン数 | 5 |
| 有意帰属数（重複排除後） | 15 |
| キャンペーンあたり平均帰属数 | 3.0 |

*a)* 外部イベントの選定*:* 本パイプラインは集団レベルのサポート変動を分析対象とする(定義 5).Dunnhumby データセットには 30 件の販促キャンペーンが記録されているが，このうちターゲット型施策（TypeB/C: クーポン対象商品数 2,000 件未満）は特定世帯向けの個別クーポン配布であり，集団レベルのサポート時系列に検出可能な影響を与えることが期待できない．そこで，クーポン対象商品数 3,000 件以上の **大規模販促キャンペーン 5 件**（C8, C13, C18, C26, C30; 対象商品数 3.7K–38.2K 件）を外部イベントとして使用する．この選定はキャンペーンメタデータ（coupon.csv）に基づく事前フィルタであり，帰属結果を参照した事後的選択ではない．

$W = 300$, $\theta = 5$, $B = 5{,}000$, $\alpha = 0.10$（BH 補正），重複排除有効．

全 5 キャンペーンに少なくとも 1 件の有意な帰属が生成され（カバレッジ 100%），キャンペーンあたり平均 3.0 件と分析者にとって管理可能な量であった．定量的な正解ラベルが存在しないため精度評価は行わないが，帰属パターンの商品カテゴリはキャンペーン内容と定性的に整合しており，実データへの適用可能性を確認した．

## VI. 結論

本稿では**イベント帰属問題**を形式的に定義し，初の統計的解法として 5 ステップの帰属パイプラインを構築した．

実験により以下の知見を得た:

- Zipf 分布を含む多様なデータ条件において高い帰属精度を達成し，帰無条件下では 100 seed で平均偽発見率 0.070（$\leq \alpha = 0.10$）を達成し，FDR 制御を実証した（EX1）．
- アブレーション分析により，proximity と magnitude の相補性，およびグローバル BH 補正と重複排除の段階的な偽陽性削減効果を実証した（EX2）．
- 関連手法 5 種との比較により，提案手法が全 5 条件で最高または同等の F1 を達成し（平均 F1 = 0.68），特に交絡・重複条件での優位性が顕著であった（EX3）．
- 実データ（Dunnhumby, 276K バスケット）で全キャンペーンへの帰属生成（カバレッジ 100%）を確認し，適用可能性を示した（EX4）．

### *A.* 制約と限界

本パイプラインには以下の制約がある．第一に，複数イベントの時間窓が重複・高密度な条件では精度が劣化する．第二に，円形シフト置換検定は弱定常性を仮定し，強いトレンドや季節性を持つデータではブロック置換などの拡張が必要となりうる．第三に，弱信号では検出力とのトレードオフが存在する．今後の課題として，非定常時系列への対応および大規模実データでの外的妥当性評価が挙げられる．

## Acknowledgment

The authors acknowledge that portions of the text in this paper were generated with Anthropic's large language model Claude [32].

## References


[1] R. Agrawal and R. Srikant, "Fast algorithms for mining association rules," in *Proceedings of the 20th International Conference on Very Large Data Bases*, 1994, pp. 487–499.

[2] J. Han, J. Pei, and Y. Yin, "Mining frequent patterns without candidate generation," *ACM SIGMOD Record*, vol. 29, no. 2, pp. 1–12, 2000.

[3] P. Fournier-Viger, J. C.-W. Lin, B. Vo, T. T. Chi, J. Zhang, and H. B. Le, "A survey of itemset mining," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 7, no. 4, p. e1207, 2017.

[4] M. J. Zaki, "Scalable algorithms for association mining," *IEEE Transactions on Knowledge and Data Engineering*, vol. 12, no. 3, pp. 372–390, 2000.

[5] （著者名）, "Data mining methods based on swarm intelligence to extract dense itemsets," in *Proceedings of the IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 2025, （投稿中 / published 後に更新）.

[6] A. K. Mahanta, F. A. Mazarbhuiya, and H. K. Baruah, "Finding locally and periodically frequent sets and periodic association rules," in *Proceedings of the 1st International Conference on Pattern Recognition and Machine Intelligence*, 2005, pp. 576–582.

[7] S. K. Tanbeer, C. F. Ahmed, B.-S. Jeong, and Y.-K. Lee, "Discovering periodic-frequent patterns in transactional databases," in *Proceedings of the 13th Pacific-Asia Conference on Knowledge Discovery and Data Mining*, 2009, pp. 242–253.

[8] R. U. Kiran, J. Venkatesh, M. Toyoda, M. Kitsuregawa, and P. K. Reddy, "Discovering partial periodic-frequent patterns in a transactional database," *Journal of Systems and Software*, vol. 125, no. C, pp. 170–182, 2017.

[9] P. Fournier-Viger, P. Yang, R. U. Kiran, S. Ventura, and J. M. Luna, "Mining local periodic patterns in a discrete sequence," *Information Sciences*, vol. 544, pp. 519–548, 2021.

[10] E. S. Page, "Continuous inspection schemes," *Biometrika*, vol. 41, no. 1/2, pp. 100–115, 1954.

[11] S. Aminikhanghahi and D. J. Cook, "A survey of methods for time series change point detection," *Knowledge and Information Systems*, vol. 51, no. 2, pp. 339–367, 2017.

[12] A. C. MacKinlay, "Event studies in economics and finance," *Journal of Economic Literature*, vol. 35, no. 1, pp. 13–39, 1997.

[13] A. Segura-Delgado, M. J. Gacto, R. Alcalá, and J. Alcalá-Fdez, "Temporal association rule mining: An overview considering the time variable as an integral or implied component," *WIREs Data Mining and Knowledge Discovery*, vol. 10, no. 3, p. e1367, 2020.

[14] R. Agrawal and G. Psaila, "Active data mining," in *Proceedings of the 1st International Conference on Knowledge Discovery and Data Mining (KDD)*, 1995, pp. 3–8.

[15] S. Chakrabarti, S. Sarawagi, and B. Dom, "Mining surprising patterns using temporal description length," in *Proceedings of the 24th International Conference on Very Large Data Bases (VLDB)*, 1998, pp. 606–617.

[16] B. Liu, W. Hsu, and Y. Ma, "Discovering the set of fundamental rule changes," in *Proceedings of the 7th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2001, pp. 335–340.

[17] J. Lopez Bernal, S. Cummins, and A. Gasparrini, "Interrupted time series regression for the evaluation of public health interventions: A tutorial," *International Journal of Epidemiology*, vol. 46, no. 1, pp. 348–355, 2017.

[18] K. H. Brodersen, F. Gallusser, J. Koehler, N. Remy, and S. L. Scott, "Inferring causal impact using Bayesian structural time-series models," *Annals of Applied Statistics*, vol. 9, no. 1, pp. 247–274, 2015.

[19] H. B. Mann and D. R. Whitney, "On a test of whether one of two random variables is stochastically larger than the other," *The Annals of Mathematical Statistics*, vol. 18, no. 1, pp. 50–60, 1947.

[20] G. I. Webb, "Discovering significant patterns," *Machine Learning*, vol. 68, no. 1, pp. 1–33, 2007.

[21] ——, "Filtered-top-k association discovery," *WIREs Data Mining and Knowledge Discovery*, vol. 1, no. 3, pp. 183–192, 2011.

[22] A. Terada, M. Okada-Hatakeyama, K. Tsuda, and J. Sese, "Statistical significance of combinatorial regulations," *Proceedings of the National Academy of Sciences*, vol. 110, no. 32, pp. 12 996–13 001, 2013.

[23] F. Llinares-López, M. Sugiyama, L. Papaxanthos, and K. Borgwardt, "Fast and memory-efficient significant pattern mining via permutation testing," in *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2015, pp. 725–734.

[24] J. Theiler, S. Eubank, A. Longtin, B. Galdrikian, and J. D. Farmer, "Testing for nonlinearity in time series: The method of surrogate data," *Physica D*, vol. 58, no. 1–4, pp. 77–94, 1992.

[25] A. C. Davison and D. V. Hinkley, *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997.

[26] A. E. Yuan and W. Shou, "A rigorous and versatile statistical test for correlations between stationary time series," *PLOS Biology*, vol. 22, no. 8, p. e3002758, 2024.

[27] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995.

[28] Y. Benjamini and D. Yekutieli, "The control of the false discovery rate in multiple testing under dependency," *Annals of Statistics*, vol. 29, no. 4, pp. 1165–1188, 2001.

[29] O. J. Dunn, "Multiple comparisons among means," *Journal of the American Statistical Association*, vol. 56, no. 293, pp. 52–64, 1961.

[30] J. Pearl, *Causality: Models, Reasoning and Inference*, 2nd ed. Cambridge: Cambridge University Press, 2009.

[31] Dunnhumby, "Dunnhumby – the complete journey," Kaggle, 2014, https://www.kaggle.com/datasets/frtgnn/dunnhumby-the-complete-journey.

[32] Anthropic, "Claude," https://www.anthropic.com/claude, 2025, aI assistant used for manuscript drafting.

## Appendix A
## PRDS 条件の充足

BH 手続きが独立でない検定統計量に対しても FDR を制御するには，$p$ 値が部分集合上の正回帰依存性（PRDS）条件を満たす必要がある [28]．本稿では形式的証明は与えないが，アイテムを共有するパターン対のサポート時系列は正の相関を持ち，対応する $p$ 値間に正の依存性が誘導されることが，PRDS 適用の実務的根拠となる．

## Appendix B
## 計算量分析

支配的なボトルネックは Steps 3–4 の置換検定であり，全体の計算量は $O(\sum_P |\mathcal{I}_P| \cdot |\mathcal{E}| \cdot B)$ である．パターン・区間単位での Rayon 並列化により実用上の処理時間を大幅に削減できる．重複排除ステップの計算量はイベントあたり $O(n \cdot k)$（$n$: 有意帰属数，$k$: 最大パターン長）であり，置換検定に比して無視可能なコストである．

## Appendix C
## 重複排除の正当性の証明

*Claim 1*の証明. 独立出現仮定のもとでは，イベント $e$ の影響下で $P^*$ の期待サポートは $(p_{\text{base}} + \beta)^l$，非イベント期間では $p_{\text{base}}^l$ である．$r = (p_{\text{base}} + \beta)/p_{\text{base}} > 1$ とおくと，$\text{magnitude}(P^*) \propto p_{\text{base}}^l(r^l - 1)$ である．副次パターン $P'$ は $s$ 個のブーストアイテムと $l - s$ 個の非ブーストアイテムを持つため，$\text{magnitude}(P') \propto p_{\text{base}}^l(r^s - 1)$ となる．$r > 1$ かつ $l > s$ より $r^l > r^s$ であるから，$\text{magnitude}(P^*) > \text{magnitude}(P')$ が任意のパターン長 $l$ で成立する．なお，この結果は独立出現の仮定に依存しており，アイテム間に強い相関を持つデータでは順序が逆転しうる． □

## Appendix D
## 合成データ生成の詳細

### A. デフォルト条件

ベース語彙は 200 アイテム（$|\mathcal{I}| = 200$），各アイテムの出現確率 $p_{\text{base}} = 0.03$，トランザクション数 $N = 100{,}000$ である．1 トランザクションあたりの期待アイテム数は $200 \times 0.03 = 6.0$ である．

- **Type A**（ブースト，5 パターン，混合パターン長）: L=2 語彙内パターン（$(5, 15), (25, 35), (45, 55)$）は $p_{\text{base}}$ のベースラインサポートを持つ（語彙内）．L=3 パターン（$(201, 202, 203)$）および L=4 パターン（$(205, 206, 207, 208)$）は語彙外アイテム ID（$> 200$）を使用し背景確率をゼロとする．各パターンのイベント持続期間は 6,000 トランザクション（全体の 6%），時間軸上に等間隔に配置．イベント期間中に確率 $\beta$ で各アイテムを追加挿入する．
- **Type B**（イベント非対応，2 パターン）: パターン $(65, 75), (85, 95)$ を使用．ランダムな 6,000 トランザクション区間で $\beta$ のブーストを付与するが，いずれのイベントとも対応しない．
- **Type C**（デコイイベント，2 件）: パターン変動と無関係なイベント（持続期間 6,000）をランダム配置．

TABLE IV: Dunnhumby データセット統計量

| 指標 | 値 |
|---|---|
| 世帯数 | 2,500 |
| トランザクション数 | 276,484 |
| ユニーク商品数 | 92,339 |
| トランザクションあたり平均商品数 | 9.39 |
| 観測期間 | 711 日 |
| キャンペーン数 | 30 |

### B. 構造条件

- **OVERLAP**: イベント E1= $[16{,}000, 28{,}000]$, E2= $[24{,}000, 36{,}000]$ が区間 $[24{,}000, 28{,}000]$ で重複．時間的弁別能力を検証する．
- **CONFOUND**: Type B パターンの活性区間をイベント時間窓に意図的に重ねて配置（交絡条件）．
- **DENSE**: Type A 6 パターン + Type B 4 パターン + デコイ 4 件に倍増（高密度条件）．
- **SHORT**: イベント持続期間を 1,600 に短縮（デフォルト 6,000 の約 27%；短期イベント条件）．

### C. *EX2* アブレーションシナリオ

- **Scenario A**（prox 必要）: パターン $(5, 15)$ に 2 つの密集区間を設定 — 1 つはイベント近傍 $[15{,}000, 25{,}000]$（因果的），1 つは遠方 $[60{,}000, 68{,}000]$（偶発的）．イベント区間 $[15{,}000, 25{,}000]$．
- **Scenario B**（mag 必要）: パターン $(5, 15)$ が 2 つのイベントの影響を受ける — E1 はブースト $\beta = 0.5$（強），E2 は $\beta = 0.1$（弱）．

### D. *Zipf* 分布パラメータ

アイテム $k$（$k = 1, \ldots, 200$）の出現確率: $p(k) = \min(C/k^{\alpha_z}, 0.10)$．$C$ は中央値アイテム（$k = 100$）の確率が 0.03 になるよう設定し，最大確率を 0.10 で打ち切る．

## Appendix E
## Dunnhumby データセットの詳細

Dunnhumby “The Complete Journey” データセット [31] の概要を表 IVに示す．

30 件のキャンペーンは 3 タイプに分類される．本実験では集団レベルのサポート変動を分析対象とする問題定義（定義 5）に基づき，TypeA の 5 件のみを外部イベントとして使用する（V-E節参照）:

- **TypeA**（5 件: C8, C13, C18, C26, C30）: 大規模販促．クーポン対象商品数 3,700–38,200 件，持続期間 40–56 日．
- **TypeB**（18 件）: ターゲット型施策．クーポン対象商品数 200–2,000 件，持続期間 32–61 日．
- **TypeC**（7 件）: ニッチ型施策．クーポン対象商品数 200–1,500 件，持続期間 32–162 日．

パイプラインの設定は表 Vと異なり，$W = 300, \theta = 5$ とした．$W$ は 276K トランザクションに対する適切な時間解像度として選択した．

## Appendix F
## 帰無条件 FDR 検証の詳細（100 seeds）

帰無条件での BH 手続き FDR 制御を 100 seeds で検証した．

*a)* 設定*:* 植え込み信号なし (Type A パターン 0 件)，ランダムに配置した 5 件のデコイイベント (各持続 6,000 トランザクション), Type B 密集パターン 4 件 (いずれのイベントとも時間的に無関係)，$N = 100{,}000$，$W = 1{,}000$，$\theta = 100$，$B = 5{,}000$，$\alpha = 0.10$．

*b)* 結果*:*

| 指標 | 値 |
|---|---|
| Seeds 数 | 100 |
| 偽陽性 0 件の seeds | 93/100 |
| 偽陽性 1 件の seeds | 7/100 |
| 偽陽性 2 件以上の seeds | 0/100 |
| 平均偽陽性帰属数 | 0.07 |
| Mean per-seed FDR | 0.070 |
| FDR $\leq \alpha = 0.10$ | **YES** |

Mean per-seed FDR $= 0.070 \leq \alpha = 0.10$ であり，BH 手続きが帰無条件下で FDR を制御することが 100 seeds で確認された．偽陽性 7 件（7%）は BH 手続きの期待誤発見率 $\alpha = 0.10$ の範囲内であり，確率的変動として説明される．

## Appendix G
## アイテム間相関への頑健性

実データではビールとつまみのような強い共起相関が存在し，主張 1（重複排除の正当性）の独立出現仮定が崩れる可能性がある．Zipf 分布とアイテム間相関の両条件で 20 seed 評価を行った．

*a)* 設定*:* **zipf_only**: Zipf-1.0 分布（独立出現）．**zipf_corr**: Zipf-1.0 + アイテムペア 5 組に相関確率 0.5–0.7 を付与．$N = 100{,}000$，$W = 1{,}000$，$\theta = 100$，20 seed で評価．

*b)* 結果*:*

| 条件 | Prec | Rec | F1 | 95% CI | FAR |
|---|---|---|---|---|---|
| zipf_only | 0.74 | 0.92 | 0.81 | [0.70, 0.92] | 0.25 |
| zipf_corr | 0.41 | 0.85 | 0.55 | [0.45, 0.65] | 0.20 |

zipf_only で F1 = 0.81，zipf_corr で F1 = 0.55 と低下する．精度低下の主因は，相関アイテムペアが生み出す追加の密集パターンが偽陽性帰属を増やすためである．これは主張 1の独立出現仮定が実データで緩和される可能性を裏付けており，アイテム間相関が強い場合の FAR = 0.20 は許容可能な範囲に留まる．

## Appendix H
## OVERLAP 条件における交差シグナルの影響

OVERLAP 条件（§V-B）で F1 分散が大きい（CI 幅 = 0.44）理由を説明する．E1 = $[16{,}000, 28{,}000]$ と E2 = $[24{,}000, 36{,}000]$ が重複する区間 $[24{,}000, 28{,}000]$ では，E1 のアイテム集合と E2 のアイテム集合が 同一ウィンドウ内で同時にブーストされる．各アイテムの出現確率が $\beta = 0.3$ の場合，交差パターン（例: E1 アイテムと E2 アイテムの組み合わせ）の期待サポートは $0.3 \times 0.3 \times W = 90 \approx \theta$ となり，統計的変動によって $\theta$ を超える短い密集区間が生じる．重複排除（Step 5）はこれらを強い planted パターンに統合することで大半を除去するが，一部の seed では交差パターンが偽陽性として残存するため，精度に分散が生じる．

## Appendix I
## パラメータ選択の根拠

TABLE V: デフォルトパラメータ

| パラメータ | 値 |
|---|---|
| ウィンドウサイズ $W$ | 1,000 |
| 最小サポート $\theta$ | 100 |
| 帰属対象パターン | $\lvert P\rvert \geq 2$ |
| 最大パターン長 $L$ | 制約なし[1] |
| 変化点検出法 | 閾値交差 |
| $\sigma$ | $W$ (= 1,000) |
| 置換回数 $B$ | 5,000 |
| 有意水準 $\alpha$ | 0.10 |
| 補正方法 | BH |
| 変化量正規化 | 平方根（式 (7)） |
| 重複排除 | 有効 |

主要パラメータの選択根拠を以下に述べる:

- **ウィンドウサイズ** $W = 1{,}000$: $N = 100{,}000$ トランザクションに対して 1% の時間解像度に相当する．$W$ が小さすぎるとサポート推定が不安定になり，大きすぎると変化点の時間的精度が低下する．
- **最小サポート** $\theta = 100$: 期待ベースラインサポート $W \cdot p_{\text{base}}^2 = 1{,}000 \times 0.03^2 = 0.9$ に対して十分に大きく，偶然の共起を除外しつつ，ブースト時のサポート増加を捕捉できる閾値．$\theta = W/10 = 100$ は Zipf 分布下での偽陽性パターン数を抑制するための設定である．
- **減衰パラメータ** $\sigma = W$: 1 ウィンドウ幅離れた変化点で prox が $e^{-1} \approx 0.37$ に減衰する設定．変化点とイベント境界の距離が $W$ を超えると帰属スコアが急速に低下する．
- **置換回数** $B = 5{,}000$: $p$ 値の解像度 $1/(B+1) \approx 0.0002$．BH 補正により $\alpha = 0.10$ で数百の仮説を同時検定する場合にも十分な $p$ 値精度を保証する．
- **有意水準** $\alpha = 0.10$: FDR 制御水準として標準的な値．$\alpha = 0.05$ と比較して検出力を優先する設定であり，偽発見率 10% 以下を許容する．
- **変化量正規化（magnitude normalization）**: 平方根正規化（式 (7)）を採用する．絶対変化量はベースラインが高いパターンほどスコアが膨張するバイアスがあり，完全正規化（$\div s^-$）は低ベースラインパターンのスコアを過剰に増幅する．平方根正規化はこの両極端の中間に位置し，Zipf 的な頻度分布を持つ実世界データに対して安定した精度を達成する．

[1] Apriori の反単調性により，サポート閾値を満たすパターンが存在しなくなった時点で探索が自然に停止する．