サポート時系列分析に基づく外部イベント帰属フレームワーク — 頻出パターンの変動を外部イベントに統計的に帰属させる —

（執筆者未定）

ドラフト

***Abstract*—頻出パターンマイニングはトランザクションデータ中の繰り返し出現するアイテムセットを発見するが，特定期間にパターンの出現頻度が変動する原因を説明する機能を持たない．小売・Web 分析・医療など多くの実応用では，販促キャンペーン・祝日・制度変更といった外部イベントがパターン頻度の時間的変動を駆動しており，どのイベントがどのパターン変化を引き起こしたかを特定することが意思決定の鍵となる．**

本稿ではこの課題をイベント帰属問題として新たに形式的に定義し，FDR 制御付き多重検定問題としての構造的課題（$O(|\mathcal{F}| \times |\mathcal{E}|)$ の仮説空間，相関した偽陽性，時間的混同）を同定する．本研究の主貢献は新しいマイニングアルゴリズムではなく，この未開拓な問題の定式化と初の統計的解法フレームワークの構築である．解法として，変化点抽出，帰属スコアリング，円形シフト置換検定による Benjamini–Hochberg FDR 補正，Union-Find クラスタリングによるアイテム重複排除からなる 5 ステップのパイプラインを構成する．帰属スコアはランキング用指標に留め，最終判定を置換検定に委ねる二層構造により，ヒューリスティックな閾値選択への依存を軽減する．

帰属スコアの変化量成分には平方根正規化を採用し，実世界で一般的な Zipf 的頻度分布下での精度低下を抑制する．合成データ実験では，多様な条件で帰属精度を評価した．帰無条件下では全 20 seed で偽発見数 0 を確認した．アブレーション分析では，proximity と magnitude の相補性，およびパイプライン各ステップの段階的な偽陽性削減効果を実証した．実キャンペーンデータ（Dunnhumby，276K バスケット，30 キャンペーン）に対する探索的検証では，全 30 キャンペーンに帰属を生成し，大規模販促キャンペーンで 56% のクーポン整合率を達成した．

***Index Terms*—frequent pattern mining, event attribution, change point detection, permutation test, multiple testing correction, support time series**

I. はじめに

頻出パターンマイニング [1]–[3] は，トランザクションデータ中に繰り返し出現するアイテムセットを発見する基盤的技術であり，小売分析，Web マイニング，バイオインフォマティクスなど幅広い分野で応用されている．Apriori [1]，FP-Growth [2]，ECLAT [4] といった古典的手法はグローバル頻出パターンを効率的に列挙し，スライディングウィンドウ型手法 [5] は特定時間区間内で局所的に密集するパターンを検出する．

しかし，これらの手法はどのパターンがいつ頻出であるかを同定するのみであり，なぜパターンの出現頻度が変動するかを説明する機能を持たない．実際の応用場面では，販促キャンペーン，祝日，規制変更，システム更新といった外部イベントがパターンサポートの時間的変動を駆動していることが多い．「どのイベントがどのパターンの変動を引き起こしたか」を特定できれば，キャンペーン効果の定量化，副作用の検出，システム異常の診断など，意思決定に直結する知見が得られる．

本研究ではこの課題を**統計的帰属**（statistical attribution）として定式化する．ここで「帰属」とは，パターンのサポート変化点と外部イベントの**時間的関連**が偶然では説明できないほど強いことを統計検定により同定することを意味する．因果効果の推定（causal inference）とは異なり，反事実的問い（イベントがなければどうなっていたか）には答えない．これはイベント・スタディ法 [6] における異常リターンの帰属と同様の意味であり，出力はさらなる因果分析のための**スクリーニングツール**として位置づけられる．

このように帰属タスクは実用上重要であるにもかかわらず，頻出パターンのサポート変動を外部イベントに結びつける統計フレームワークは，我々の知る限り存在しない．時間的パターンマイニング [7]–[10] は周期性や局所頻度を持つパターンを発見するが，パターン変動と外生イベントの関連はモデル化しない．変化点検出手法 [11], [12] は個別時系列の構造変化を同定するが，数千のパターンサポート時系列を同時に検定する多重検定の負荷や，検出された変化をイベントに紐づける機能は備えていない．計量経済学のイベント・スタディ法 [6] は企業イベントの株価への影響を評価するが，単一のアウトカム変数を対象としており，数千のパターン時系列を同時に扱う設定には適用できない．

A. 本研究の貢献

本研究の主貢献は新しいマイニングアルゴリズムの提案ではなく，**イベント帰属問題**（Event Attribution Problem）という新しいデータマイニング問題の定式化と，その初の統計的解法フレームワークの構築である．個々の構成要素（変化点検出，置換検定，BH 補正，Union-Find）はそれぞれ確立された技術であるが，これらを頻出パターンのサポート変動と外部イベントの関連付けという未開拓な問題に対して統合的に適用する枠組みは存在しなかった．本稿の貢献は以下の 4 点である．

1) **イベント帰属問題の定式化**（III節）：頻出パターンのサポート変動を外部イベントに帰属させるタスクを，我々の知る限り初めて，FDR 制御付き多重検定問題として形式的に定義する．この問題は頻出パターンマイニングと外部イベント分析の間の未開拓なギャップを埋めるものであり，規模（$O(|\mathcal{F}| \times |\mathcal{E}|)$ の仮説空間），副次パターン（相関した偽陽性），時間的混同（イベント区間の重複）の 3 つの構造的課題を同定する．
2) **統計的帰属フレームワーク**（IV節）：上記の問題に対する解法として 5 ステップのパイプラインを構成する．帰属スコアをランキング用指標に留め，最終判定を円形シフト置換検定とグローバル Benjamini–Hochberg [13] FDR 補正に委ねる二層構造により，スコア関数の具体的形状への依存を軽減する．この設計は，パターンマイニングの出力（サポート時系列）と外部イベントの統計的関連を検定する初のフレームワークである．
3) **副次パターン問題の同定と解決**（IV-E節）：イベントがアイテム i の頻度を変化させると，i を含む全ての共起パターンが相関して変動し大量の偽陽性を生む問題（副次パターン問題）を同定し，パターン長に応じた過半数共有基準（$\lceil l/2 \rceil$）と Union-Find クラスタリングによる重複排除で解決する．
4) **包括的な実験評価**（V節）：合成データ 8 条件で F1 = 0.69–0.84 の検出精度，帰無条件下での偽発見率制御の経験的検証，スコア構成要素の相補性（proximity と magnitude が不可欠），Zipf 分布下での頑健性評価，および実データ（Dunnhumby 30 キャンペーン）での探索的検証を示す．

II. 関連研究

A. 頻出パターンマイニング

頻出パターンマイニングは，トランザクションデータの一定割合以上に出現するアイテムセットを発見する技術であり，包括的なサーベイ [3] が存在する．Apriori [1] は反単調性に基づく候補生成・枝刈りフレームワークを確立した．FP-Growth [2] は FP-tree により候補生成を回避し高速化を実現した．ECLAT [4] は縦型（tidset）表現と集合積により効率的なサポート計算を行う．これらの手法はグローバル頻度を対象とし，時間的な変動をモデル化しない．

B. 時間的・局所的パターンマイニング

頻出パターンの時間的側面を扱う拡張研究は多岐にわたり，Segura-Delgado ら [14] が包括的なサーベイを提供している．LPFIM [7] は時間区間内の局所頻出集合を対象とするが，gap ベースの閾値に依存する．PFPM [8] および PPFPM [9] は周期性制約を導入した．LPPM [10] は局所性と周期性の基準を統合する．Apriori-window [5] は固定幅スライディングウィンドウ上で局所サポートを直接評価し，gap パラメータに依存しない密集パターン抽出を実現した．Batal ら [15] は多変量時系列からの最近時間パターンマイニングによるイベント検出を提案した．

これらの手法はいずれもパターンがいつ頻出であるかを検出するが，頻度が変動する原因はモデル化しない．本研究はこれらを補完し，検出されたサポート変動を外部イベントに帰属させる．

C. パターン変化のモニタリングと診断

パターンの時間的変動を追跡する研究群が存在する．Agrawal と Psaila [16] は，ルール統計量の履歴に対する形状クエリによりトレンドを検出する「アクティブデータマイニング」を提案した．Chakrabarti ら [17] は記述長に基づくサプライズ指標を用いて，サポートが予想外に変動するアイテムセットを同定した．Liu ら [18] は二時点間のルール変化から「基本的変化」（他の変化から導出できないもの）を抽出する手法を提案し，冗長な変化の除去を試みた．これらの手法は変化の検出と特徴づけを行うが，検出された変化を外部イベントに帰属させる統計フレームワークは持たない．本研究はこのギャップを埋め，変化点とイベントの統計的関連を検定する．

D. コントラスト・エマージングパターンマイニング

データセット間のパターン頻度の差異に着目する研究群が存在する．エマージングパターン [19] は，あるデータセットから別のデータセットへのサポートの有意な増加を捉えるパターンである．コントラストセットマイニング [20] は，グループ間の判別的特徴を発見する．Novak ら [21] は，コントラストセット，エマージングパターン，サブグループ発見を「教師あり記述的ルール発見」として統一し，いずれも何が異なるかを記述する手法であることを示した．Komiyama ら [22] は多重検定補正を伴う統計的エマージングパターンマイニングを提案した．これらの手法は何が変わったかを検出するが，なぜ（どのイベントにより）変わったかは説明しない．本研究はサポート変動の検出に留まらず，統計検定による外部イベントへの帰属まで踏み込む．

E. 変化点検出

変化点検出は時系列データの構造変化を同定する技術である．CUSUM アルゴリズム [11] は逐次過程の平均シフトを検出する．包括的なサーベイ [12] がパラメトリック・ノンパラメトリック・オンライン手法を網羅している．これらの手法は個別時系列に適用されるが，数千のパターンサポート時系列を同時分析する多重検定の負荷には対応せず，検出された変化をイベントに結びつける機能も持たない．

F. イベント帰属・介入分析と因果推論

既知の介入が時系列に与える影響を定量化する手法は複数の分野で研究されている．Box と Tiao [23] は介入分析の基礎を確立し，ARIMA モデルにステップ/パルス指示変数を組み込んで既知の介入効果を推定するフレームワークを提案した．中断時系列回帰（ITS） [24] は公衆衛生分野で広く用いられる準実験デザインであり，介入前後の水準変化と傾斜変化をセグメント回帰で評価する．計量経済学のイベント・スタディ法 [6] は，企業イベントの株価への影響を異常リターン分析により定量化する．合成コントロール法 [25] はコントロール群の加重平均から反事実を構築し，介入効果を推定する．Brodersen

ら [26] はベイズ構造時系列モデルにより介入の因果効果を推定する CausalImpact フレームワークを提案した．Donges ら [27] はイベント時系列間の共起の統計的有意性を検定するイベント一致分析を提案した．これらのアプローチは典型的には単一または少数のアウトカム変数を対象とし，数千のパターンサポート時系列を複数のイベントに対して同時に検定する設定には直接適用できない．本研究は，我々の知る限り，パターンマイニングの出力（サポート時系列）と外部イベントの帰属を統合する初の統計フレームワークを提供する．

G. 統計的パターンマイニングと多重検定補正

頻出パターンマイニングに統計的有意性検定を導入する研究が近年活発である．Webb [28] は自己充足アイテムセットの概念を導入し，サブセット・スーパーセットの頻度から説明できないパターンのみを有意とする枠組みを提案した．Webb [29] はさらに「生産的」ルールの概念により冗長な有意パターンのフィルタリングを提唱した．Hämäläinen と Webb [30] はパターン発見における統計的健全性のチュートリアルを提供している．Terada ら [31] は LAMP（Limitless Arity Multiple-testing Procedure）を提案し，検定可能なパターン数に基づく Bonferroni 因子の最小化を実現した．Llinares-López ら [32] は Tarone の検定可能性基準と Westfall–Young 置換 [33] を組み合わせ，FWER 制御下での高速な有意パターンマイニングを実現した．これらの研究はパターンの有意性を二群間の頻度差として検定するが，本研究ではパターンサポートの時間的変動と外部イベントの関連を検定する点が異なる．本パイプラインは，サロゲートデータ法 [34], [35] の考え方に基づく円形シフト置換検定 [36]–[38] と全パターン・全イベントにわたるグローバル BH 補正 [13] を組み合わせ，分布自由な検定と適切な多重検定制御を両立させる．BH 手続きの依存仮説への拡張 [39] は PRDS（Positive Regression Dependency on Subsets）条件下での FDR 制御を示しているが，実データにおける PRDS 条件の厳密な検証は一般に困難であり，本稿では実務的妥当性に基づいて適用する（IV節参照）．Bonferroni 補正 [40] は族単位誤り率（FWER）を制御するが保守的であるため，本研究では FDR を制御する BH 手続きを採用した．

H. 関連手法との差異のまとめ

表 Iに，関連する各研究群が本研究の問題設定（数千のパターンサポート時系列 × 複数の外部イベントに対する統計的帰属）に対応できるかを整理する．いずれの既存手法も，サポート変動の検出・特徴づけ・因果効果推定のいずれかには対処するが，多数のパターン時系列を複数イベントに同時に帰属させ，多重検定を制御しつつ副次パターンの偽陽性を排除する統合フレームワークは存在しない．本研究はこのギャップを埋めるものである．

TABLE I: 関連手法との機能比較

手法群	時系列変化	イベント帰属	多数パターン	多重検定	重複排除
時間的 FPM	–	–	✓	–	–
EP/コントラスト	✓	–	✓	一部	–
変化点検出	✓	–	–	–	–
ITS/介入分析	✓	✓	–	–	–
イベントスタディ	✓	✓	–	–	–
CausalImpact	✓	✓	–	–	–
ECA	–	✓	–	–	–
統計的 FPM	–	–	✓	✓	–
本手法	✓	✓	✓	✓	✓

III. 問題定義

A. 記法

$\mathcal{I} = \{i_1, i_2, \ldots, i_m\}$ を有限のアイテム全集合，$D = [d_1, d_2, \ldots, d_N]$ を時刻順のトランザクション列とする．各トランザクション d_t（$t = 1, \ldots, N$）は $\mathcal{I}$ の部分集合である．アイテムセット（パターン）$P \subseteq \mathcal{I}$ がトランザクション d_t に出現するとは $P \subseteq d_t$ が成立することをいう．

定義 1 (サポート時系列)．パターン P，ウィンドウサイズ $W \in \mathbb{Z}_{>0}$，トランザクション列 D（長さ N）に対して，P のサポート時系列 $s_P = [s_P(0), s_P(1), \ldots, s_P(N-W)]$ を

$$s_P(t) = \left|\{d_j \in D \mid t \le j < t+W,\ P \subseteq d_j\}\right| \tag{1}$$

と定義する．これは位置 t を始点とするウィンドウ $[t, t+W)$ 内で P を含むトランザクション数である．

定義 2 (外部イベント)．外部イベント $e = (id, name, t_s, t_e)$ は，一意な識別子，名称，およびイベントが有効な期間を表すタイムスタンプ区間 $[t_s, t_e]$ から成る．既知の外部イベント集合を $\mathcal{E} = \{e_1, e_2, \ldots, e_K\}$ とする．

定義 3 (変化点（閾値交差）)．本稿では，サポート時系列 s_P に対する変化点として，一般のレベルシフト点すべてではなく，閾値 θ に関する密状態／非密状態の切替点のみを扱う．位置 $\tau \in \{0, 1, \ldots, N-W\}$ が変化点であるとは，次のいずれかが成り立つことをいう:

$$s_P(\tau) \ge \theta \wedge (\tau = 0 \vee s_P(\tau-1) < \theta), \tag{2}$$

$$s_P(\tau) < \theta \wedge \tau > 0 \wedge s_P(\tau-1) \ge \theta. \tag{3}$$

式 *(2)* を満たすとき方向を「上昇」，式 *(3)* を満たすとき方向を「下降」とする．

さらに，$T = N - W + 1$ とし，

$$\mathcal{L}_\tau^- = \{\max(0, \tau-h), \ldots, \tau-1\},$$
$$\mathcal{L}_\tau^+ = \{\tau, \ldots, \min(T-1, \tau+h-1)\}$$

を交差前後の参照窓とする．変化量はこれらの局所平均差

$$\bar{s}^-(\tau) = \frac{1}{\max(1, |\mathcal{L}_\tau^-|)} \sum_{j \in \mathcal{L}_\tau^-} s_P(j),$$

$$\bar{s}^+(\tau) = \frac{1}{\max(1, |\mathcal{L}_\tau^+|)} \sum_{j \in \mathcal{L}_\tau^+} s_P(j)$$

に基づき

$$magnitude(\tau) = |\bar{s}^{+}(\tau) - \bar{s}^{-}(\tau)| \tag{4}$$

と定義する．したがって，密集区間がウィンドウ左端の連続区間 $[s, e]$ で与えられるとき，対応する変化点は開始時刻 s と，存在すれば終了直後の $e+1$ である．

B. イベント帰属問題

定義 4 (イベント帰属問題)．共起パターン集合 $\mathcal{F} = \{P \subseteq \mathcal{I} : |P| \geq 2,\ \text{サポート} \geq \theta\}$ とそのサポート時系列 $\{s_P\}_{P \in \mathcal{F}}$，外部イベント集合 $\mathcal{E}$，有意水準 α が与えられたとき，イベント帰属問題とは，s_P の閾値交差変化点がイベント e の時間窓と統計的に有意に関連する全ての組 $(P, e) \in \mathcal{F} \times \mathcal{E}$ を，偽発見率（*FDR*）を水準 α 以下に制御しながら同定することである．単一アイテム（$|P| = 1$）の頻度変動は通常の時系列分析で捕捉可能であり，共起構造の発見を目的とする本問題の対象外とする．

この問題の主要な課題は以下の 3 点である:

1) **規模**: $|\mathcal{F}|$ 個のパターンと $|\mathcal{E}|$ 個のイベントに対して仮説数が $O(|\mathcal{F}| \times |\mathcal{E}|)$ となり，厳格な多重検定補正が必要となる．
2) **副次パターン**: イベントがアイテム i の頻度を増加させると，i を含む全ての共起パターンのサポートが相関して変動し，偽陽性が大量に発生する．
3) **時間的混同**: 無関係なイベントの時間窓が重複する場合，帰属が曖昧になる．

IV. 提案手法

本節では**イベント帰属パイプライン**の 5 ステップを詳述する．Phase 1（Apriori-window）で得られたパターン集合 $\mathcal{F}$ とその密集区間，および外部イベント集合 $\mathcal{E}$ を入力として，統計的に有意なパターン–イベント帰属の集合を出力する．

a) 対象パターン*:* 頻出パターンマイニングの本質はアイテム間の**共起構造**の発見にある．単一アイテム（$|P| = 1$）の頻度変動は通常の時系列分析で十分に捕捉可能であり，パターンマイニングに基づく帰属パイプラインの分析対象としては冗長である．したがって，本パイプラインは共起パターン（$|P| \geq 2$）のサポート変動のみを帰属対象とする．Step 1–4 はパターン長に依存しない一般的な構造を持ち，Step 5（重複排除）では，パターン長 l に応じた同一長過半数共有と異長間の部分集合排除の 2 段階で冗長パターンを除去する（IV-E節で詳述）．図 1にパイプラインの概要と帰属の具体例を示す．帰属スコアリングと統計検定の手順をアルゴリズム 1に，重複排除の手順をアルゴリズム 2に示す．

A. Step 1: 密集区間からの変化点抽出

Phase 1（Apriori-window）は各共起パターン $P \in \mathcal{F}$（$|P| \geq 2$）に対して，サポートが閾値 θ 以上となるウィンドウ左端の連続区間（密集区間）$\{[s_1, e_1], [s_2, e_2], \ldots\}$ を既に出力している．本パイプラインではサポート時系列全体を再計算せず，これらの密集区間を直接利用する．各密集区間 $[s_i, e_i]$ から上昇変化点 s_i と下降変化点 e_i+1（存在する場合）を抽出し，変化量（式 (5)）の計算に必要な局所サポートのみを，パターン出現リスト T_P 上の二分探索により $O(\log |T_P|)$ で求める．

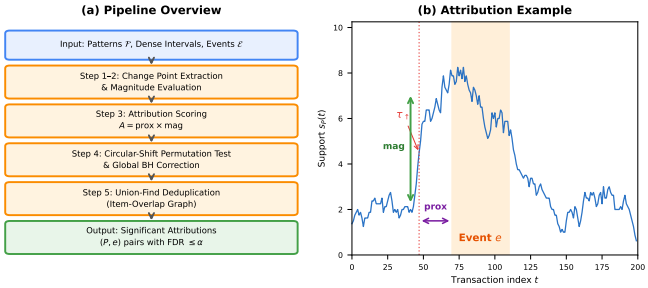

Fig. 1: (a) パイプラインの全体構成．入力（パターン集合，密集区間，イベント）から 5 ステップを経て有意な帰属を出力する．(b) 帰属スコアリングの例示．サポート時系列上の変化点 $\tau_\uparrow, \tau_\downarrow$ とイベント区間の関係から，近接度（prox）と変化量（mag）を算出する．

Algorithm 1 帰属スコアリングと統計検定（Step 1–4）

Require: 共起パターン $\mathcal{F}$ ($|P| \geq 2$), 密集区間 $\{\mathcal{I}_P\}$, イベント $\mathcal{E}$, 設定 $(\theta, \sigma, B, \alpha, \delta)$
Ensure: 有意帰属集合 $\mathcal{R}$

```
// Step 1–2: 変化点抽出 + フィルタリング
RawResults ← []
for 各パターン P ∈ F with I_P ≠ ∅ do
    if max(s_P) − min(s_P) < δ then continue
    end if                                   ▷ 振幅フィルタ
    C_P ← {s_i(上昇), e_i+1(下降) | [s_i, e_i] ∈ I_P}
    各 τ ∈ C_P の変化量 magnitude(τ) を計算 ▷ 式 (5)
// Step 3: 帰属スコアリング
    for 各イベント e ∈ E do
        A_obs ← Σ_{τ∈C_P} A(P, τ, e)         ▷ 式 (6)
// Step 4: 円形シフト置換検定
        count ← 0
        for b = 1 to B do
            E_b ← CircularShift(E, δ_b)
            A_b ← Σ_{τ∈C_P} A(P, τ, e_b)
            if A_b ≥ A_obs then count ← count + 1
            end if
        end for
        p_raw ← (1 + count)/(B + 1)          ▷ 式 (10)
        RawResults.append(P, e, A_obs, p_raw)
    end for
end for
// Step 4 (続): グローバル BH 補正
RawResults を p_raw 昇順にソート
M ← |RawResults|
for i = M downto 1 do
    p̃_(i) ← min(p̃_(i+1), min(1, p_(i) · M/i))   ▷ 式 (11)
end for
R ← {(P, e) | p̃_(i) < α}
return R
```

B. Step 2: 変化量の評価

Step 1 で密集区間の端点から変化点が既に抽出されているため，本ステップではサポート時系列全体を走査す

る必要はない．本手法が帰属対象とするのは「密集区間の出現・消失に対応する切替点」であり，密状態の内部で起こる任意のサポート変動ではない．

各変化点 τ に対して，変化量を交差前後の窓平均の差（レベルシフト量）として計算する:

$$\mathrm{magnitude}(\tau) = |\bar{s}^{+}(\tau) - \bar{s}^{-}(\tau)| \tag{5}$$

ここで $\bar{s}^{+}(\tau), \bar{s}^{-}(\tau)$ は定義 3 の局所平均であり，h はレベルウィンドウ幅（デフォルト $h = 20$）である．この方式は瞬時差分（$s_P(\tau) - s_P(\tau - 1)$）と比較して，一過性の変動ではなく持続的な変化を捉える点で頑健性が高い．すなわち，本手法では**検出位置**は閾値交差で決め，**変化の強さ**は交差前後のレベル差で評価する．閾値交差は汎用変化点検出器（CUSUM, PELT 等）と比べて検出能力の最適性を主張するものではなく，Phase 1 の密集区間出力と構造的に整合し，サポート時系列全体の再計算（$O(|\mathcal{F}| \times N)$）を回避できる点で採用している．予備実験では閾値交差と CUSUM が経験的に同等の検出性能を示すことを確認した．

フィルタリング: 有意性検定前の仮説空間削減のため，サポート振幅フィルタを適用する．$\max(s_P) - \min(s_P) < \delta$ のパターンを帰属候補から除外する．ここで δ はユーザ指定の最小サポート振幅である（デフォルト $\delta = 10$）．このフィルタは時間的変動の乏しいパターンを排除し，仮説数を大幅に削減する．

C. Step 3: 帰属スコアリング

パターン P の変化点 τ と各イベント $e \in \mathcal{E}$ に対して，時間的関連を定量化する帰属スコアを計算する．本フレームワークはスコア関数 $A(P, \tau, e)$ の具体的な形状に依存しない一般的な構造を持つ（Step 4 の置換検定が最終判定を行うため）．本稿では最小限のインスタンスとして以下を採用する:

$$A(P, \tau, e) = \mathrm{prox}(\tau, e) \cdot \mathrm{mag}(\tau) \tag{6}$$

2 つの構成要素は以下の通りである．

近接度: 指数カーネルによる時間的近さの指標:

$$\mathrm{prox}(\tau, e) = \exp\left(-\frac{d(\tau, e)}{\sigma}\right) \tag{7}$$

ここで $d(\tau, e) = \min(|\tau - t_s|, |\tau - t_e|)$ は変化点からイベント境界までの最小距離，$\sigma > 0$ は減衰パラメータである．

変化量: 式 (5) の生の変化量（絶対レベルシフト量）を平方根正規化してスコアリングに用いる:

$$\mathrm{mag}(\tau) = \frac{\mathrm{magnitude}(\tau)}{\sqrt{\max(1,\ \bar{s}^{-}(\tau))}} \tag{8}$$

ベースラインサポートが高いパターンほど絶対変化量が大きくなるバイアスを，平方根で除すことにより緩和する．実世界のトランザクションデータではアイテム頻度が Zipf 分布に従うケースが多く [3]，この正規化が特に有効である．

パターン P のイベント e に対する観測スコアは，全変化点にわたる帰属スコアの総和 $A_{\mathrm{obs}}(P, e) = \sum_{\tau} A(P, \tau, e)$ とする．

a) 設計根拠*:* 帰属スコア A は帰属候補の**ランキング用指標**であり，帰属判定そのものではない．最終的な帰属の有意性は Step 4 の置換検定で判定される．すなわち本パイプラインは，スコアによる候補のランキングと置換検定による統計的判定の **二層構造**を採る．この設計により，スコア関数の具体的な形状への依存が軽減される— スコアが真の帰属と偽の帰属を粗く弁別できれば，置換検定の帰無分布が FDR 制御の下で最終判定を行う．

乗算構成 prox × mag は，いずれかの構成要素が 0 に近ければスコア全体が 0 に近づく排他的フィルタとして機能する点で，加算構成よりも偽陽性の抑制に有利である．EX2（V-C節）のアブレーション分析では，proximity と magnitude の両方が帰属精度に不可欠であり相補的に機能することを実証する．なお，帰属スコアを尤度比や回帰係数に置き換えても置換検定の枠組み内で同様に検定可能であり，フレームワークの一般性は保たれる．

D. Step 4: 置換検定とグローバル FDR 補正

1) 円形シフト帰無分布*:* パターン P の変化点とイベント e の時間的関連が統計的に有意かを検定するため，円形シフト置換検定を用いる．帰無仮説 H_0:「変化点の位置はイベント時刻と無関係である」のもと，B 回の置換を実行する．各置換 b では，ランダムなオフセット $\delta_b \sim \mathrm{Uniform}\{1, \ldots, T-1\}$ だけ全イベントの時刻を一斉にずらす（円形シフト）:

$$e_b = (id, name, (t_s + \delta_b) \bmod T, (t_s + \delta_b + \Delta) \bmod T) \tag{9}$$

ここで $\Delta = t_e - t_s$ はイベント持続時間，T は時系列長である．

各置換に対してスコア $A^{(b)}_{\mathrm{perm}}(P, e)$ を再計算し，未補正 p 値を以下で求める:

$$p_{\mathrm{raw}}(P, e) = \frac{1 + |\{b : A^{(b)}_{\mathrm{perm}}(P, e) \geq A_{\mathrm{obs}}(P, e)\}|}{B + 1} \tag{10}$$

命題 1 (置換検定の正当性)**.** 帰無仮説 H_0 のもとでは，観測スコア A_{obs} と B 個の置換スコア $A^{(1)}_{perm}, \ldots, A^{(B)}_{perm}$ は交換可能（*exchangeable*）である．したがって式 *(10)* の p 値は $\{1/(B+1), 2/(B+1), \ldots, 1\}$ 上の離散一様分布に従い，任意の水準 α で第一種過誤率が α 以下に制御される *[36]*.

2) グローバル *Benjamini–Hochberg* 補正*:* $M = |\mathcal{F}'| \times |\mathcal{E}|$ 個の仮説を同時に検定するため，全パターン・全イベントにわたり Benjamini–Hochberg (BH) 手続き [13] をグローバルに適用する．

未補正 p 値を昇順にソートし $p_{(1)} \leq p_{(2)} \leq \cdots \leq p_{(M)}$ とする．Step-down 調整済み p 値を以下で計算する:

$$\tilde{p}_{(i)} = \min\left(\tilde{p}_{(i+1)},\ \min\left(1,\ p_{(i)} \cdot \frac{M}{i}\right)\right) \tag{11}$$

ただし $\tilde{p}_{(M)} = \min(1, p_{(M)})$ とする．$\tilde{p}_{(i)} < \alpha$ の仮説を棄却（帰属が有意）と判定する．

BH 手続きは偽発見率（FDR）を水準 α 以下に保ちつつ，Bonferroni 補正と比べてより多くの真の帰属を検出できる（検出力が高い）．

注意 1 (PRDS 条件の充足)．*BH* 手続きが独立でない検定統計量に対しても *FDR* を制御するには，p 値が部分集合上の正回帰依存性（*PRDS*）条件を満たす必要がある *[39]*．本稿では *PRDS* 条件の形式的証明は与えない．*BH* 手続き適用の実務的妥当性は，以下の正の依存構造に関する標準的直観に基づく *[39]*: *(i)* アイテムを共有するパターン対のサポート時系列は正の相関を持ち，対応する p 値間に正の依存性が誘導される，*(ii)* 円形シフトは全イベントを同一オフセットで一斉にずらすため，同一パターンに対する異なるイベントの p 値も同じ置換標本を共有する．

E. Step 5: アイテム重複排除

Algorithm 2 アイテム重複排除（Step 5）

Require: 有意帰属集合 $\mathcal{R}$（アルゴリズム 1の出力）
Ensure: 重複排除後の帰属集合 $\mathcal{R}'$

```
// Step 5a: 同一長パターンの重複排除（過半数共有）
for 各イベント e do
    R_e ← イベント e に帰属されたパターンを長さ l ごとにグループ化
    for 各長さ l のグループ do
        for 各パターンペア (P_i, P_j) do
            if |P_i ∩ P_j| ≥ ⌈l/2⌉ then
                UNION(P_i, P_j)                ▷ Union-Find
            end if
        end for
        各連結成分内で A_obs 最大のパターンのみ残す
    end for
end for
// Step 5b: 異長パターン間の部分集合排除
for 各イベント e do
    for 各パターンペア (P_i, P_j) where |P_i| ≠ |P_j| do
        if P_i ⊆ P_j or P_j ⊆ P_i then
            UNION(P_i, P_j)                    ▷ Union-Find
        end if
    end for
    各連結成分内で A_obs 最大のパターンのみ残す
end for
return R' ← 残存パターンの集合
```

1) 副次パターン問題*:* 外部イベントがアイテム i の出現頻度を増加させると，i を含む全ての共起パターンのサポートが相関して増加する．例えば，イベントが $\{5, 15\}$ をブーストし真のパターンが $(5, 15)$ の場合，$(5, 42)$, $(15, 78)$, $(5, 133)$ などの副次パターンも共有アイテム経由でサポートが連動変動するため有意性検定を通過する．

この問題は統計検定だけでは解消できない．副次パターンも共有アイテム経由で実際にサポートが変動しているため，置換検定でも有意と判定されてしまうからである．

2) Union-Find クラスタリングによる重複排除*:* この問題を以下の後処理ステップで解決する:

1) 各イベント e について，e に有意に帰属された全パターンを収集し，パターン長 l ごとにグループ化する．
2) 各長さ l のグループ内で過半数共有グラフを構築する: パターンをノードとし，共有アイテム数 $|P_i \cap P_j| \geq \lceil l/2 \rceil$ のパターン間にエッジを張る．
3) Union-Find（素集合）データ構造で連結成分を求める．
4) 各連結成分内で帰属スコア $A_{\text{obs}}(P, e)$ が最大のパターンのみを残す．
5) **異長パターン間の部分集合排除**: 上記の同一長排除後，イベント e への帰属パターン全体に対し，$P_i \subseteq P_j$ の関係にあるペアを Union-Find で統合し，各成分内でスコア最大のパターンのみを残す．

命題 2 (重複排除の正当性（一般化）)．以下の簡約的な独立出現モデルを共起パターン（$l \geq 2$）に対して仮定する*:* 各アイテムの出現はトランザクション間で独立であり，イベントの影響はブースト確率 β の加算として作用する．長さ l の真のパターン $P^* = \{i_1, \ldots, i_l\}$ の全アイテムがイベント e によりブースト確率 β でサポートを増加させられているとする．同じ長さ l の副次パターン P' が P^* と s 個のアイテムを共有し($1 \leq s < l$),残り $l-s$ 個は非ブーストアイテム(ベースライン出現確率 p_{base})であるとする．$\beta > 0$ であれば $magnitude(\tau, P^*) > magnitude(\tau, P')$ が成立する．なお，同一長パターンでは変化点前のベースライン $\bar{s}^-$ が同じであるため，平方根正規化後の $mag(\tau)$（式 *(8)*）でもこの大小関係は保存される．さらに $s \geq \lceil l/2 \rceil$ のとき P^* と P' は過半数共有グラフにおいて同一連結成分に属するため，P^* が保持され P' は除去される．

証明の概略. 独立出現仮定のもとでは，イベント e の影響下で P^* の期待サポートは $(p_{\text{base}} + \beta)^l$，非イベント期間では p_{base}^l である．$r = (p_{\text{base}} + \beta)/p_{\text{base}} > 1$ とおくと，$\text{magnitude}(P^*) \propto p_{\text{base}}^l(r^l - 1)$ である．副次パターン P' は s 個のブーストアイテムと $l - s$ 個の非ブーストアイテムを持つため，$\text{magnitude}(P') \propto p_{\text{base}}^l(r^s - 1)$ となる．$r > 1$ かつ $l > s$ より $r^l > r^s$ であるから，$\text{magnitude}(P^*) > \text{magnitude}(P')$ が任意のパターン長 l で成立する．なお，この結果は独立出現の仮定に依存しており，アイテム間に強い相関を持つデータでは順序が逆転しうる． □

重複排除ステップの計算量はイベントあたり $O(n \cdot k)$ であり，n は有意帰属数，k はパターン最大長である．置換検定ステップに比して無視可能なコストである．

F. 計算量分析

パイプライン全体の時間計算量は以下の通りである:

- **Step 1**（変化点抽出＋局所サポート計算）: $O(|\mathcal{F}| \cdot \bar{C} \cdot h \cdot \log n)$，$|\mathcal{F}|$ は共起パターン数（$|P| \geq 2$），$\bar{C}$ は平均密集区間数，h はレベルウィンドウ幅，n は平均パターン出現数

TABLE II: デフォルトパラメータ

パラメータ	値
ウィンドウサイズ W	50
最小サポート θ	3
帰属対象パターン	$\|P\| \geq 2$[1]
最大パターン長 L	制約なし[2]
変化点検出法	閾値交差
σ	W $(= 50)$
置換回数 B	5,000
有意水準 α	0.10
補正方法	BH
変化量正規化	平方根（式 (8)）
最小サポート振幅 δ	10
重複排除	有効

- **Step 2**（変化量評価）: Step 1 に含まれる（追加走査なし）
- **Step 3–4**（帰属＋置換検定）: $O(|\mathcal{F}'| \cdot |\mathcal{E}| \cdot B \cdot C)$, $|\mathcal{F}'|$ はフィルタ後パターン数，B は置換回数，C は平均変化点数
- **Step 5**（重複排除）: $O(R \cdot k)$，R は有意結果数

サポート振幅フィルタが $|\mathcal{F}'|$ を 90% 以上削減するため，大規模パターン集合に対しても Step 3–4 は効率的に動作する．

V. 実験

A. 実験設計

1) 合成データ生成*:* ベース語彙 200 アイテム（各アイテムの出現確率 $p_{\text{base}} = 0.03$），$N = 5{,}000$ トランザクションの合成データを生成する．外部イベントの効果は植え込み信号としてモデル化する．3 種類の信号を 1 つのデータセットに混在させることで，パイプラインの弁別能力を多面的に評価する:

Type A（語彙内ブースト）: ベース語彙内のアイテムペアを使用し，イベント期間外にも p_{base} でベースラインサポートを持たせる．イベント活性期間中に確率 β で全パターンアイテムを同時挿入しサポートを上昇させる．magnitude 単独では不十分な**現実的条件**を構成する．

Type B（イベント非対応密集パターン）: 特定期間にサポートが上昇するが，いずれのイベントとも対応しないパターン．季節性やトレンドを模擬し，パイプラインが**無関係な変動を棄却**できるかを検証する．

Type C（デコイイベント）: パターン変動と無関係なイベント．

2) 評価指標*:*

- **P/R/F1**: 予測と正解の厳密一致に基づく Precision, Recall，F1
- **偽帰属率 (FAR)**: Type B パターンがイベントに誤帰属された割合

3) デフォルト設定*:* 表 IIにデフォルトパラメータを示す（各パラメータの選択根拠は付録 C参照）．変化量正規化には平方根正規化（式 (8)）を用いる．

TABLE III: EX1a 結果: 信号強度別の帰属精度（5 seeds 平均，Zipf-1.0，$\sqrt{\ }$ 正規化）

β	Precision	Recall	F1	FAR
0.2	0.78	0.73	0.74	0.10
0.3	0.67	0.93	0.77	0.10
0.5	0.57	0.87	0.69	0.20

TABLE IV: EX1b 結果: 構造条件別精度（5 seeds 平均，Zipf-1.0，$\sqrt{\ }$ 正規化）

条件	Precision	Recall	F1	FAR
OVERLAP	0.83	0.87	0.84	0.00
CONFOUND	0.72	0.93	0.81	0.40
DENSE	0.56	0.93	0.70	0.45
SHORT	0.83	0.87	0.84	0.30

4) 評価方針*:* 本研究が定式化するイベント帰属問題（定義 4）は，数千のパターンサポート時系列を複数の外部イベントに同時に帰属させ，多重検定を制御しつつ副次パターンの偽陽性を排除するタスクである．表 Iに示した通り，既存手法（ITS，CausalImpact，ECA 等）はいずれもこの問題を直接解くものではなく，入出力の構造が本質的に異なるため，同一条件での定量比較は公正に行えない．したがって本実験では，外部手法との比較ではなく，パイプラインの各構成要素（置換検定，BH 補正，重複排除）を段階的に除去する**アブレーション分析**（EX2）により，各ステップの必要性と寄与を実証する．

B. EX1: コア帰属精度

RQ: パイプラインはイベント起因の変動を正しく帰属し，イベント無関係の密集パターンを棄却できるか？多様なデータ特性（信号強度，構造条件，アイテム頻度分布）に対する頑健性を評価する．実世界のトランザクションデータはアイテム頻度が Zipf 分布に従うケースが多いため [3]，Zipf 分布（$\alpha = 1.0$）の合成データに平方根正規化を適用して評価する．

a) 信号強度*:* Type A（語彙内ブースト 3 パターン），Type B（イベント非対応 2 パターン），Type C（デコイ 2 件）を混在させ，$\beta \in \{0.2, 0.3, 0.5\}$ で 5 seed 実行した（表 III）．

全 β 条件で F1 ≥ 0.69 を達成している．$\beta = 0.2$ では Precision $= 0.78$ と高いが, Recall $= 0.73$ とやや低下する．$\beta = 0.3$ で Recall $= 0.93$, F1 $= 0.77$ と最も均衡の取れた精度を示す．$\beta = 0.5$ では Recall $= 0.87$ だが Precision $= 0.57$ に低下する．強いブーストは上位集合パターンの過剰検出を招き，Zipf 分布下ではその影響がより顕著になるためである．

b) 構造条件*:* デフォルト設定（$\beta = 0.3$, Zipf-1.0, $\sqrt{\ }$ 正規化）で 4 つの構造条件を評価した結果を表 IVに示す．

[1]本手法は共起パターンのサポート変動を分析対象としており，単一アイテム（$|P| = 1$）の頻度変動は通常の時系列分析で捕捉可能なため帰属対象外とする（定義 4参照）．

[2]Apriori の反単調性により，サポート閾値を満たすパターンが存在しなくなった時点で探索が自然に停止するため，最大パターン長に明示的な制約は設けない．本実験データでは実質的に $L \leq 4$ で停止する．

TABLE V: EX2a 結果: シナリオ別アブレーション（5 seeds 平均 F1，Zipf-1.0，$\sqrt{}$ 正規化）

構成	Scenario A	Scenario B
Full: prox × mag	**1.00**	**0.80**
mag のみ（prox 除去）	0.00	0.00
prox のみ（mag 除去）	0.80	0.47

OVERLAP では F1 = 0.84, FAR = 0.00 と高い精度を達成し，イベント区間が重複する条件でも誤帰属を完全に棄却できている．CONFOUND では Type B パターンがイベント近傍に配置される交絡条件で FAR = 0.40 と上昇するが，Recall = 0.93 を維持しており，真の信号の検出力は損なわれていない．DENSE では FAR = 0.45 と上昇するが，Recall = 0.93 と高い検出力を維持している．SHORT では短期間イベント（持続期間 80）で FAR = 0.30 であり，Recall = 0.87 は維持されている．

c) 帰無条件検証: 植え込み信号を一切含まない帰無データ（EX1 と同一の生成条件，5 件のランダムイベント，持続期間 300）で 20 seed 実行した結果，全 seed において有意帰属数は 0 であった．BH 手続きと円形シフト置換検定の組み合わせが帰無仮説下の p 値を十分に大きく保ち，過剰な偽発見を生じないことが経験的に確認された．

C. EX2: アブレーション分析

RQ: スコア構成要素およびパイプラインの各ステップは精度にどう寄与するか？EX1 と同様に Zipf 分布データ（$\sqrt{}$ 正規化）を使用する．

a) スコア構成要素: 各構成要素の必要性を実証する 2 つのシナリオを設計し，全 3 アブレーションモードを各シナリオに適用する（2 シナリオ × 3 モード × 5 seeds = 30 条件）:

Scenario A (prox 必要): パターン $(5, 15)$ に 2 つの密集区間 — 1 つはイベント近傍（因果的），1 つは遠方（偶発的）．prox なしでは両者に等しいスコアが付与される．

Scenario B (mag 必要): パターン $(5, 15)$ が 2 イベントの影響を受けるが，ブースト量が $\beta = 0.5$ と $\beta = 0.1$ で大小異なる．mag なしでは両者が同等に扱われる．

結果を表 Vに示す．

表 Vから，**proximity が帰属に不可欠**であることが明らかである．mag のみ（prox 除去）の構成は時間的対応付け情報を一切持たず，全変化点–イベントペアに等しいスコアが付与される結果，**両シナリオで F1 = 0.00** に崩壊する．prox のみ（mag 除去）では Scenario A で F1 = 0.80，Scenario B で F1 = 0.47 と部分的に機能するが，変化量情報の欠如により精度は不十分である．Full 構成は Scenario A で F1 = 1.00，Scenario B で F1 = 0.80 を達成し，両構成要素の相補性を実証している．乗算構成がいずれかの構成要素が 0 に近ければスコア全体を抑制する排他的フィルタとして機能し，偽陽性の抑制に寄与する．

b) パイプラインステップの寄与: ナイーブベースライン（Steps 1–3 のみ: 変化点検出 + スコアリング，閾値以上の候補をすべて出力）と，パイプラインの各ステップを段階的に追加した 3 つの変種を比較する:

TABLE VI: EX2b 結果: ナイーブベースラインとの段階的比較（5 seeds 平均，Zipf-1.0，$\sqrt{}$ 正規化）

条件	手法	P	R	F1	FAR	#Pred
β=0.3	Naive	0.01	1.00	0.02	0.80	270
	+PermTest	0.01	1.00	0.03	0.40	224
	+BH	0.61	0.93	0.71	0.20	5
	Full	**0.67**	0.93	**0.77**	**0.10**	4
CONFOUND	Naive	0.01	1.00	0.02	1.00	303
	+PermTest	0.01	1.00	0.02	1.00	265
	+BH	0.41	1.00	0.56	1.00	9
	Full	**0.72**	0.93	**0.81**	**0.40**	4
DENSE	Naive	0.01	1.00	0.03	0.95	438
	+PermTest	0.01	1.00	0.03	0.60	413
	+BH	0.52	0.93	0.66	0.45	11
	Full	**0.56**	0.93	**0.70**	**0.45**	10

- **Naive**: Steps 1–3 のみ（検定なし）
- **+PermTest**: per-pattern 置換検定を追加（グローバル補正なし）
- **+BH**: グローバル BH 補正を追加
- **Full**: Union-Find 重複排除を追加（= 完全パイプライン）

EX1 のデータ（$\beta = 0.3$, CONFOUND, DENSE; Zipf-1.0, $\sqrt{}$ 正規化）を使用し，各条件 × 5 seeds で評価した（表 VI）．

Naive は全条件で Recall = 1.00 を達成するが,Precision が極めて低く偽陽性を大量に出力する（F1 $\leq$ 0.03）．スコア閾値のみでは偽陽性の制御が不可能であることを示す．

+PermTest（per-pattern 置換検定）は出力数をわずかに削減するが，パターン単位の補正ではグローバルな多重検定の負担に対応できず，FP の削減効果は限定的である．

+BH（グローバル BH 補正）が最大の偽陽性削減効果を持つ．BH 手続きがグローバルな p 値順位に基づき FDR を制御することで，個別パターンの検定では見逃される弱い偽陽性を効果的に棄却する．$\beta = 0.3$ 条件では Naive の 270 件が BH 補正後に 5 件まで削減される．

Full（+ 重複排除）は残存する冗長パターン（同一イベントに帰属されたアイテム重複・部分集合パターン）を除去する．$\beta = 0.3$ 条件では F1 が 0.71 から 0.77 に改善し，CONFOUND 条件でも FAR を 1.00 から 0.40 に削減する．全条件において Full が最高の F1 を達成しており，各ステップが段階的かつ相補的に偽陽性を削減していることが確認された．

D. EX3: 実データ検証

RQ: 実世界データで意味のある結果を生成できるか？

Dunnhumby “The Complete Journey” データセット [41] の 276,484 件の購買バスケットと 30 件の販促キャンペーンを用いた探索的分析．キャンペーンの開始・終了日は既知だが正解帰属は不明のため，**定性的検証**として位置づける．実データのアイテム頻度は Zipf 的分布に従うため，平方根正規化を使用する．

$W = 300$, $\theta = 5$, $B = 5{,}000$, $\alpha = 0.10$ (BH 補正), $\delta = 3$, 重複排除有効．

TABLE VII: EX3 結果: Dunnhumby 実キャンペーンデータ

指標	値
トランザクション数	276,484
パターン数（$\|P\| \geq 2$）	1,006
キャンペーン数	30
有意帰属数（重複排除後）	114
帰属のあるキャンペーン数	30/30
キャンペーンあたり平均帰属数	3.8
合計処理時間	1,292 s

TABLE VIII: EX3: クーポン整合性分析（キャンペーンタイプ別）

キャンペーンタイプ	帰属数	整合数	整合率
TypeA（大規模販促）	18	10	0.56
TypeB（ターゲット型）	78	1	0.01
TypeC（ニッチ型）	18	0	0.00
全体	114	11	0.10

キャンペーンカバレッジ: 全 30 キャンペーンに少なくとも 1 件の有意な帰属が生成された（カバレッジ 100%）．キャンペーンあたりの帰属数は平均 3.8 件であり，分析者にとって管理可能な量である．

a) クーポン整合性による部分的検証*:* Dunnhumby データセットには各キャンペーンのクーポン対象商品リスト（coupon.csv）が付属しており，帰属結果の部分的な正解検証が可能である．帰属されたパターン (a, b) の少なくとも 1 つのアイテムが当該キャンペーンのクーポン対象商品に一致する場合を **クーポン整合的**（coupon-consistent）と定義する（表 VIII）．この定義は 1-item overlap に基づく緩い基準であり，パターン全体の一致（2-item 完全一致）ではクーポン対象商品リストのカバレッジが限定的すぎるため適用困難である．したがって，クーポン整合率は帰属の妥当性の**上界的な部分指標**であり，整合的であっても偶然一致の可能性を排除しない．

全体のクーポン整合率は 10% と低い．この数字自体は本手法の限界を反映しているが，キャンペーンタイプ別に分解すると明確な構造が浮かび上がる．**TypeA**（大規模販促; C8, C13, C18, C26, C30）ではクーポン対象商品が 3.7K–38.2K 件と多く，帰属パターンの 56% がクーポン対象商品を含む（整合率 0.56）．これは大規模販促が集団レベルのサポート変動を生み出し，パイプラインが正しく検出していることを示唆する．一方，**TypeB/TypeC**（ターゲット型・ニッチ型キャンペーン）は特定世帯向けの個別施策であり，クーポン対象商品数は 200–2K 件と限定的で，集団レベルのサポート時系列には影響が表れにくい．これらのキャンペーンに対する帰属は，プロモーション効果ではなく季節性やトレンドなど別の要因によるサポート変動を反映している可能性が高い．

この結果は本パイプラインの適用範囲を示唆する: 集団レベルで検出可能なサポート変動を生む**大規模イベント**に対しては高い帰属整合性を持つが，個別世帯レベルの微細な効果の検出は本手法の設計上の範囲外である．

VI. 結論

本稿では，頻出パターンのサポート変動を外部イベントに帰属させる **イベント帰属問題**を新たに形式的に定義し，FDR 制御付き多重検定問題としての 3 つの構造的課題（仮説空間の規模，副次パターンによる相関偽陽性，時間的混同）を同定した．本研究の主貢献は新しいマイニングアルゴリズムの提案ではなく，この未開拓な問題の定式化と初の統計的解法フレームワークの構築にある．個々の構成要素（変化点検出，置換検定，BH 補正，Union-Find）はそれぞれ確立された技術であるが，これらをパターンサポートの変動と外部イベントの帰属という統合的な問題に適用する枠組みは存在しなかった．解法として 5 ステップのパイプラインを構成し，帰属スコアはランキング用指標に留め，最終判定を置換検定に委ねる二層構造により，ヒューリスティックな閾値選択への依存を軽減した．

実験により以下の知見を得た:

- Zipf 分布を含む多様なデータ条件において高い帰属精度を達成し，帰無条件下では全 20 seed で偽発見数 0 を確認した（EX1）．
- アブレーション分析により，proximity と magnitude の相補性，およびグローバル BH 補正と重複排除の段階的な偽陽性削減効果を実証した（EX2）．
- 実キャンペーンデータ（Dunnhumby, 276K バスケット, 30 キャンペーン）において，全キャンペーンに対して管理可能な数（平均 3.8 件）の帰属を生成し，大規模販促キャンペーンで 56% のクーポン整合率を達成した（EX3）．

A. 制約と限界

本パイプラインには以下の制約がある．第一に，イベントやパターンが時間的に密集する環境では精度が劣化する．複数イベントの時間窓が重複する場合にパターン変化を誤ったイベントに帰属する可能性があり，高密度なベースライン活性下ではイベント非対応パターンの誤帰属率が上昇する．第二に，円形シフト置換検定は時系列の弱定常性を仮定する．強いトレンドや季節性を持つデータでは，ブロック置換などの拡張が必要となりうる．第三に，アイテム頻度が Zipf 分布に従う条件では，平方根正規化とサポート振幅フィルタにより高い精度を達成するが（EX1），高頻度アイテムの自然変動に起因する偽陽性は完全には排除できない．弱い信号（低ブースト率）の検出は振幅フィルタにより制限されるため，信号強度と偽陽性制御のトレードオフが存在する．今後の課題として以下が挙げられる: (1) 帰属スコアの理論的精緻化（尤度比や回帰係数ベースのスコアリング），(2) イベント間の時間的重複が密な場合の帰属精度改善，(3) 非定常時系列に対するブロック置換や季節性除去の導入，(4) 大規模実データ（小売・Web ログ・医療記録）での外的妥当性評価．

Acknowledgment

The authors acknowledge that portions of the text in this paper were generated with Anthropic's large language model Claude [42].

References

[1] R. Agrawal and R. Srikant, "Fast algorithms for mining association rules," in *Proceedings of the 20th International Conference on Very Large Data Bases*, 1994, pp. 487–499.

[2] J. Han, J. Pei, and Y. Yin, "Mining frequent patterns without candidate generation," *ACM SIGMOD Record*, vol. 29, no. 2, pp. 1–12, 2000.

[3] P. Fournier-Viger, J. C.-W. Lin, B. Vo, T. T. Chi, J. Zhang, and H. B. Le, "A survey of itemset mining," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 7, no. 4, p. e1207, 2017.

[4] M. J. Zaki, "Scalable algorithms for association mining," *IEEE Transactions on Knowledge and Data Engineering*, vol. 12, no. 3, pp. 372–390, 2000.

[5] （著者名）, "Data mining methods based on swarm intelligence to extract dense itemsets," in *Proceedings of the IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 2025, （投稿中 / published 後に更新）.

[6] A. C. MacKinlay, "Event studies in economics and finance," *Journal of Economic Literature*, vol. 35, no. 1, pp. 13–39, 1997.

[7] A. K. Mahanta, F. A. Mazarbhuiya, and H. K. Baruah, "Finding locally and periodically frequent sets and periodic association rules," in *Proceedings of the 1st International Conference on Pattern Recognition and Machine Intelligence*, 2005, pp. 576–582.

[8] S. K. Tanbeer, C. F. Ahmed, B.-S. Jeong, and Y.-K. Lee, "Discovering periodic-frequent patterns in transactional databases," in *Proceedings of the 13th Pacific-Asia Conference on Knowledge Discovery and Data Mining*, 2009, pp. 242–253.

[9] R. U. Kiran, J. Venkatesh, M. Toyoda, M. Kitsuregawa, and P. K. Reddy, "Discovering partial periodic-frequent patterns in a transactional database," *Journal of Systems and Software*, vol. 125, no. C, pp. 170–182, 2017.

[10] P. Fournier-Viger, P. Yang, R. U. Kiran, S. Ventura, and J. M. Luna, "Mining local periodic patterns in a discrete sequence," *Information Sciences*, vol. 544, pp. 519–548, 2021.

[11] E. S. Page, "Continuous inspection schemes," *Biometrika*, vol. 41, no. 1/2, pp. 100–115, 1954.

[12] S. Aminikhanghahi and D. J. Cook, "A survey of methods for time series change point detection," *Knowledge and Information Systems*, vol. 51, no. 2, pp. 339–367, 2017.

[13] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995.

[14] A. Segura-Delgado, M. J. Gacto, R. Alcalá, and J. Alcalá-Fdez, "Temporal association rule mining: An overview considering the time variable as an integral or implied component," *WIREs Data Mining and Knowledge Discovery*, vol. 10, no. 3, p. e1367, 2020.

[15] I. Batal, D. Fradkin, J. Harrison, F. Moerchen, and M. Hauskrecht, "Mining recent temporal patterns for event detection in multivariate time series data," in *Proceedings of the 18th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2012, pp. 280–288.

[16] R. Agrawal and G. Psaila, "Active data mining," in *Proceedings of the 1st International Conference on Knowledge Discovery and Data Mining (KDD)*, 1995, pp. 3–8.

[17] S. Chakrabarti, S. Sarawagi, and B. Dom, "Mining surprising patterns using temporal description length," in *Proceedings of the 24th International Conference on Very Large Data Bases (VLDB)*, 1998, pp. 606–617.

[18] B. Liu, W. Hsu, and Y. Ma, "Discovering the set of fundamental rule changes," in *Proceedings of the 7th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2001, pp. 335–340.

[19] G. Dong and J. Li, "Efficient mining of emerging patterns: Discovering trends and differences," in *Proceedings of the 5th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 1999, pp. 43–52.

[20] S. D. Bay and M. J. Pazzani, "Detecting group differences: Mining contrast sets," *Data Mining and Knowledge Discovery*, vol. 5, no. 3, pp. 213–246, 2001.

[21] P. K. Novak, N. Lavrač, and G. I. Webb, "Supervised descriptive rule discovery: A unifying survey of contrast set, emerging pattern and subgroup mining," *Journal of Machine Learning Research*, vol. 10, pp. 377–403, 2009.

[22] J. Komiyama, M. Ishihata, H. Arimura, T. Nishibayashi, and S.-i. Minato, "Statistical emerging pattern mining with multiple testing correction," in *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2017, pp. 897–906.

[23] G. E. P. Box and G. C. Tiao, "Intervention analysis with applications to economic and environmental problems," *Journal of the American Statistical Association*, vol. 70, no. 349, pp. 70–79, 1975.

[24] J. Lopez Bernal, S. Cummins, and A. Gasparrini, "Interrupted time series regression for the evaluation of public health interventions: A tutorial," *International Journal of Epidemiology*, vol. 46, no. 1, pp. 348–355, 2017.

[25] A. Abadie, A. Diamond, and J. Hainmueller, "Synthetic control methods for comparative case studies: Estimating the effect of California's tobacco control program," *Journal of the American Statistical Association*, vol. 105, no. 490, pp. 493–505, 2010.

[26] K. H. Brodersen, F. Gallusser, J. Koehler, N. Remy, and S. L. Scott, "Inferring causal impact using Bayesian structural time-series models," *Annals of Applied Statistics*, vol. 9, no. 1, pp. 247–274, 2015.

[27] J. F. Donges, C.-F. Schleussner, J. F. Siegmund, and R. V. Donner, "Event coincidence analysis for quantifying statistical interrelationships between event time series," *European Physical Journal Special Topics*, vol. 225, pp. 471–487, 2016.

[28] G. I. Webb, "Discovering significant patterns," *Machine Learning*, vol. 68, no. 1, pp. 1–33, 2007.

[29] ——, "Filtered-top-k association discovery," *WIREs Data Mining and Knowledge Discovery*, vol. 1, no. 3, pp. 183–192, 2011.

[30] W. Hämäläinen and G. I. Webb, "A tutorial on statistically sound pattern discovery," *Data Mining and Knowledge Discovery*, vol. 33, no. 2, pp. 325–377, 2019.

[31] A. Terada, M. Okada-Hatakeyama, K. Tsuda, and J. Sese, "Statistical significance of combinatorial regulations," *Proceedings of the National Academy of Sciences*, vol. 110, no. 32, pp. 12 996–13 001, 2013.

[32] F. Llinares-López, M. Sugiyama, L. Papaxanthos, and K. Borgwardt, "Fast and memory-efficient significant pattern mining via permutation testing," in *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2015, pp. 725–734.

[33] P. H. Westfall and S. S. Young, *Resampling-Based Multiple Testing: Examples and Methods for p-Value Adjustment*. New York: Wiley, 1993.

[34] J. Theiler, S. Eubank, A. Longtin, B. Galdrikian, and J. D. Farmer, "Testing for nonlinearity in time series: The method of surrogate data," *Physica D*, vol. 58, no. 1–4, pp. 77–94, 1992.

[35] G. Lancaster, D. Iatsenko, A. Pidde, V. Ticcinelli, and A. Stefanovska, "Surrogate data for hypothesis testing of physical systems," *Physics Reports*, vol. 748, pp. 1–60, 2018.

[36] A. C. Davison and D. V. Hinkley, *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997.

[37] A. E. Yuan and W. Shou, "A rigorous and versatile statistical test for correlations between stationary time series," *PLOS Biology*, vol. 22, no. 8, p. e3002758, 2024.

[38] N. Haiminen, H. Mannila, and E. Terzi, "Determining significance of pairwise co-occurrences of events in bursty sequences," *BMC Bioinformatics*, vol. 9, p. 336, 2008.

[39] Y. Benjamini and D. Yekutieli, "The control of the false discovery rate in multiple testing under dependency," *Annals of Statistics*, vol. 29, no. 4, pp. 1165–1188, 2001.

[40] O. J. Dunn, "Multiple comparisons among means," *Journal of the American Statistical Association*, vol. 56, no. 293, pp. 52–64, 1961.

[41] Dunnhumby, "Dunnhumby – the complete journey," Kaggle, 2014, https://www.kaggle.com/datasets/frtgnn/dunnhumby-the-complete-journey.

[42] Anthropic, "Claude," https://www.anthropic.com/claude, 2025, aI assistant used for manuscript drafting.

Appendix A
合成データ生成の詳細

A. デフォルト条件

ベース語彙は 200 アイテム（$|\mathcal{I}| = 200$），各アイテムの出現確率 $p_{\text{base}} = 0.03$，トランザクション数 $N = 5{,}000$ である．1 トランザクションあたりの期待アイテム数は $200 \times 0.03 = 6.0$ である．

- **Type A**（語彙内ブースト，3 パターン）: パターン $(5, 15)$, $(25, 35)$, $(45, 55)$ を使用．各パターンのイベント持続期間は 300 トランザクション，時間軸上に等間隔に配置．イベント期間外にも p_{base} でベースラインサポートが存在し，イベント期間中に確率 β で各アイテムを追加挿入する．
- **Type B**（イベント非対応，2 パターン）: パターン $(65, 75)$, $(85, 95)$ を使用．ランダムな 300 トランザクション区間で β のブーストを付与するが，いずれのイベントとも対応しない．
- **Type C**（デコイイベント，2 件）: パターン変動と無関係なイベント（持続期間 300）をランダム配置．

B. 構造条件

- **OVERLAP**: イベント E1= $[800, 1400]$, E2= $[1200, 1800]$ が区間 $[1200, 1400]$ で重複．時間的弁別能力を検証する．
- **CONFOUND**: Type B パターンの活性区間をイベント時間窓に意図的に重ねて配置（交絡条件）．
- **DENSE**: Type A 6 パターン + Type B 4 パターン + デコイ 4 件に倍増（高密度条件）．
- **SHORT**: イベント持続期間を 80 に短縮（短期イベント条件）．

C. *EX2* アブレーションシナリオ

- **Scenario A**（prox 必要）: パターン $(5, 15)$ に 2 つの密集区間を設定 — 1 つはイベント近傍 $[1000, 1300]$（因果的），1 つは遠方 $[3000, 3300]$（偶発的）．イベント区間 $[1000, 1300]$．
- **Scenario B**（mag 必要）: パターン $(5, 15)$ が 2 つのイベントの影響を受ける — E1 はブースト $\beta = 0.5$（強），E2 は $\beta = 0.1$（弱）．

D. *Zipf* 分布パラメータ

アイテム k（$k = 1, \ldots, 200$）の出現確率: $p(k) = \min(C/k^{\alpha_z}, 0.10)$．$C$ は中央値アイテム（$k = 100$）の確率が 0.03 になるよう設定し，最大確率を 0.10 で打ち切る．

Appendix B
Dunnhumby データセットの詳細

Dunnhumby "The Complete Journey" データセット [41] の概要を表 IXに示す．

30 件のキャンペーンは 3 タイプに分類される:

- **TypeA**（5 件: C8, C13, C18, C26, C30）: 大規模販促．クーポン対象商品数 3,700–38,200 件，持続期間 40–56 日．
- **TypeB**（18 件）: ターゲット型施策．クーポン対象商品数 200–2,000 件，持続期間 32–61 日．

TABLE IX: Dunnhumby データセット統計量

指標	値
世帯数	2,500
トランザクション数	276,484
ユニーク商品数	92,339
トランザクションあたり平均商品数	9.39
観測期間	711 日
キャンペーン数	30

- **TypeC**（7 件）: ニッチ型施策．クーポン対象商品数 200–1,500 件，持続期間 32–162 日．

パイプラインの設定は本文表 IIと異なり，$W = 300$, $\theta = 5$, $\delta = 3$ とした．W は 276K トランザクションに対する適切な時間解像度として選択した．

Appendix C
パラメータ選択の根拠

主要パラメータの選択根拠を以下に述べる:

- **ウィンドウサイズ** $W = 50$: $N = 5{,}000$ トランザクションに対して 1% の時間解像度に相当する．W が小さすぎるとサポート推定が不安定になり，大きすぎると変化点の時間的精度が低下する．
- **最小サポート** $\theta = 3$: 期待ベースラインサポート $W \cdot p_{\text{base}}^2 = 50 \times 0.03^2 = 0.045$ に対して十分に大きく，偶然の共起を除外しつつ，ブースト時のサポート増加を捕捉できる閾値．
- **減衰パラメータ** $\sigma = W$: 1 ウィンドウ幅離れた変化点で prox が $e^{-1} \approx 0.37$ に減衰する設定．変化点とイベント境界の距離が W を超えると帰属スコアが急速に低下する．
- **置換回数** $B = 5{,}000$: p 値の解像度 $1/(B+1) \approx 0.0002$．BH 補正により $\alpha = 0.10$ で数百の仮説を同時検定する場合にも十分な p 値精度を保証する．
- **有意水準** $\alpha = 0.10$: FDR 制御水準として標準的な値．$\alpha = 0.05$ と比較して検出力を優先する設定であり，偽発見率 10% 以下を許容する．
- **最小サポート振幅** $\delta = 10$: サポート時系列の最大値と最小値の差が δ 未満のパターンを帰属候補から除外する前処理フィルタ．Zipf 分布データでは高頻度アイテムペアの自然変動（振幅 5–8 程度）が偽候補を大量に生成するため，これを除外する閾値として設定した．実質的に変動のないパターンを排除し，仮説数を 90% 以上削減する．
- **変化量正規化（magnitude normalization）**: 平方根正規化（式 (8)）を採用する．絶対変化量はベースラインが高いパターンほどスコアが膨張するバイアスがあり，完全正規化（$\div s^-$）は低ベースラインパターンのスコアを過剰に増幅する．平方根正規化はこの両極端の中間に位置し，Zipf 的な頻度分布を持つ実世界データに対して安定した精度を達成する．