シングルセルトランスクリプトミクスにおける擬時間上の密集遺伝子共発現区間の検出

匿名

Abstract

シングルセル RNA シーケンシング（scRNA-seq）は細胞レベルの遺伝子発現プロファイリングを可能にするが、 擬時間に沿った遺伝子共発現パターンの時間的局在を検出する手法は未確立である。 本研究では、密集区間マイニング（Dense Interval Mining）フレームワークを scRNA-seq データに適用し、 擬時間上で特定の遺伝子セットが密集的に共発現する区間（Dense Gene Co-expression Interval; DGCI）を 検出する手法を提案する。 scRNA-seq 発現行列から擬時間順序付きトランザクションへの変換アダプタを設計し、 Apriori+スライディングウィンドウアルゴリズムにより DGCI を効率的にマイニングする。 本手法はアイテムセットサイズ $L = 2$（遺伝子ペア）を基本単位として設計されており、 WGCNA のペアワイズ相関解析と対比可能な共発現の最小単位を時間的に局在化する。 造血分化を模した合成 scRNA-seq データ（$n = 500$ 細胞, 25 遺伝子）での評価により、 5 つの既知モジュール全てを検出（モジュール再現率 1.00）し、 平均 IoU 0.94 の高い時間的精度を達成した。 さらに、検出された DGCI の統計的有意性を置換検定により確認した（$p < 0.10$）。 本手法は、WGCNA 等の静的共発現解析や tradeSeq 等の単一遺伝子軌跡解析では 捉えにくい時間的に局在した遺伝子協調パターンの発見を可能にする。

キーワード**:** シングルセル RNA-seq, 擬時間, 密集区間マイニング, 遺伝子共発現, Apriori アルゴリズム

1 はじめに

シングルセル RNA シーケンシング（scRNA-seq）技術の発展により、 個々の細胞レベルでの遺伝子発現プロファイリングが可能となった [16]。 擬時間（pseudotime）解析は、細胞を連続的な分化軌跡に沿って並べることで、 分化・細胞周期・刺激応答といった生物学的プロセスの動態を捉える手法である [14, 5]。

しかし、現行の軌跡解析手法には重要な限界がある。 tradeSeq [17]や GeneSwitches [2]は個々の遺伝子レベルの発現変動を検出するが、遺伝子セットの共発現パターンは扱わない。 一方、WGCNA [9]や SCENIC [1]は 遺伝子共発現ネットワークを構築するが、時間的局在の情報を持たない。 scLink [10]はシングルセルに特化した共発現ネットワーク推定を行うが、やはり擬時間に沿った動態は対象外である。 すなわち、「どの遺伝子セットが、擬時間のどの区間で密集的に共発現するか」を 直接検出する手法は、我々の知る限り報告されていない（Table 1）。

本研究では、頻出アイテムセットマイニングのスライディングウィンドウ拡張である 密集区間マイニング（Dense Interval Mining）フレームワーク [7]を scRNA-seq データに適用し、 この問題を解決する。具体的な貢献は以下の通りである。

1. 問題定式化: 擬時間の離散化を含む密集遺伝子共発現区間（DGCI）の概念を 厳密に定義する（定義 1–5）。

2. アダプタ設計: scRNA-seq 発現行列を密集区間マイニングの入力形式に変換する アダプタを設計し、ドロップアウトとスパース性に対応する二値化戦略を提案する。

3. 帰属スコア: 検出された DGCI の生物学的重要度を定量化する 帰属スコア（時間的近接度 × サポート変動量）を定義する。

4. 統計的検証: 置換検定により検出された DGCI の統計的有意性を評価し、 偽陽性率を制御する枠組みを導入する。

5. 実験的検証: 造血分化を模した合成データおよびベースライン手法との 能力比較により、手法の有効性を実証する。

2 関連研究

本節では、scRNA-seq データにおける擬時間解析・共発現解析・パターンマイニングの 3 軸で関連研究を整理し、本手法の位置づけを明確にする。

2.1 擬時間推定手法

擬時間推定は scRNA-seq 解析の重要な前処理ステップである。 Monocle [16]は逆グラフ埋め込みにより細胞の分化軌跡を推定する先駆的手法であり、 後継の Monocle 3 では UMAP 上の主グラフ学習を採用する。 Slingshot [14]はクラスタベースの最小全域木上で主曲線を当てはめ、 分岐軌跡にも対応する。 DPT [5]は k-NN グラフ上の拡散距離を用い、 PAGA [18]はグラフ抽象化により軌跡のトポロジーを推定する。 Palantir [13]はマルコフ連鎖モデルで細胞運命確率を推定し、 連続的な擬時間と分岐確率を同時に出力する。 これらの手法は擬時間推定に優れるが、推定された擬時間上での下流の共発現パターン解析機能は限定的であり、本手法はこれらの出力を入力として活用する。

2.2 遺伝子共発現ネットワーク解析

WGCNA [9]はバルク RNA-seq やマイクロアレイを対象とし、 サンプル間の重み付き相関ネットワークから共発現モジュールを同定する代表的手法である。 しかし、WGCNA はグローバルな相関構造を捉えるため、 特定の擬時間区間でのみ活性化する局所的な共発現パターンは検出できない。 SCENIC [1]は共発現解析と転写因子モチーフ解析を組み合わせ、遺伝子制御ネットワーク（GRN）を推定するが、時間的動態は考慮しない。 scLink [10]は scRNA-seq のドロップアウト構造を考慮したスパース共発現ネットワーク推定を行うが、ネットワークは単一の静的スナップショットである。 Hotspot [4]は局所的な自己相関に基づく遺伝子モジュール検出を行い、 空間トランスクリプトミクスへの適用も可能だが、擬時間上の区間同定機能は持たない。

これらの手法に共通する制約は、共発現モジュールの 時間的局在（temporal localization） を出力しない点であり、本手法が解決する中心的課題である。

2.3 軌跡上の差異発現・動的解析

tradeSeq [17]は GAM（一般化加法モデル）を用いて 軌跡上の差異発現遺伝子を検出する強力な手法であるが、個々の遺伝子レベルの解析に限られ、 遺伝子セットの協調的挙動は対象外である。 condiments [12]は条件間での軌跡トポロジーの差異を検定するが、 共発現パターンの検出は行わない。 CellRank [8]は RNA velocity と擬時間を統合して細胞運命を推定するが、 共発現パターンの検出は対象外である。 GeneSwitches [2]は擬時間上の遺伝子スイッチングポイントを同定するが、 共発現ではなく個々の遺伝子の on/off 切替を対象とする。

2.4 バイオインフォマティクスにおけるパターンマイニング

Creighton & Hanash [3]はマイクロアレイデータに アソシエーションルールマイニングを適用し、遺伝子発現パターンを発見した先駆的研究である。 しかし、この手法は静的な全サンプル解析であり、時間的構造を扱わない。 その後、時系列遺伝子発現データに対するシーケンシャルパターンマイニング [6] や周期的パターン検出が提案されている。 Lancaster & Soeria-Atmadja [7]は時系列トランザクションデータにおける 密集アイテムセット区間の検出

Table 1: 関連手法とのポジショニング比較

手法	共発現	時間的局在	遺伝子セット	scRNA-seq
WGCNA [9]	✓	—	✓	△
SCENIC [1]	✓	—	✓	✓
scLink [10]	✓	—	—	✓
Hotspot [4]	✓	—	✓	✓
tradeSeq [17]	—	✓	—	✓
GeneSwitches [2]	—	✓	—	✓
condiments [12]	—	✓	—	✓
DGCI（本手法）	✓	✓	✓	✓

フレームワークを提案したが、 scRNA-seq の擬時間（連続値を離散化した順序構造）への適用は行っていない。

本研究は、擬時間順序付きトランザクション上の密集区間マイニングという定式化により、 上記の各カテゴリが個別に扱ってきた「共発現パターン検出」と「時間的局在」を 統一的に扱う試みである。

2.5 手法ポジショニング

Table 1 に示すように、共発現パターンの検出と時間的局在の同定を 同時に実現する手法は、我々の調査範囲では報告されていない。

3 手法

3.1 問題定義

定義 1 (擬時間と擬時間順序付き細胞列)**.** $\mathcal{C} = \{c_1, c_2, \ldots, c_n\}$ を n 個の細胞とし、 各細胞 c_i に対し擬時間推定手法（*Monocle, Slingshot, DPT* 等）により 連続値の擬時間 $\tau(c_i) \in [0, 1]$ が割り当てられているものとする。 細胞を擬時間の昇順にソートし、$\tau(c_1) \leq \tau(c_2) \leq \cdots \leq \tau(c_n)$ とする。 このソート順のインデックス $i \in \{1, \ldots, n\}$ を擬時間ランクと呼ぶ。

注意 2 (擬時間のランク変換)**.** 擬時間 $\tau(c_i)$ の連続値は一般に非一様に分布するため、 本手法ではランク（離散的な順序インデックス）に変換して用いる。 これにより、密集区間の定義がウィンドウ内の細胞数に基づく直感的な解釈を持ち、 擬時間値の分布に依存しないロバストな検出が可能となる。 ランク変換の適切性は、擬時間推定の精度が十分で局所的な順序が信頼できることを前提とする。

定義 3 (正規化発現値と発現二値化)**.** 遺伝子全体 $\mathcal{G} = \{g_1, \ldots, g_m\}$ に対し、 細胞 c_i における遺伝子 g_j の正規化発現値を $x_{ij} \geq 0$ とする。 ここで x_{ij} は *log*$_2$*(CPM + 1)* 正規化後の値を想定する。 遺伝子 g_j の二値化閾値 $\theta_j > 0$ を用いた二値化指標を次のように定義する：

$$b_{ij} = \begin{cases} 1 & x_{ij} \geq \theta_j \\ 0 & otherwise \end{cases} \tag{1}$$

$b_{ij} = 1$ のとき、細胞 c_i において遺伝子 g_j が「発現している」（*expressed*）と呼ぶ。

注意 4 (scRNA-seq のドロップアウトと二値化)**.** *scRNA-seq* データはドロップアウト（真に発現している遺伝子のカウントがゼロとなる現象）により スパース性が高い。本手法の二値化では、ゼロ値は常に $b_{ij} = 0$ となるため、 ドロップアウトは偽陰性として作用する。 サポート閾値 σ をウィンドウサイズ W に対し十分小さく設定することで （例*:* $\sigma/W \leq 0.3$）、一定割合のドロップアウトに対するロバスト性を確保する。

定義 5 (トランザクション)**.** 細胞 c_i のトランザクションを $T_i = \{g_j \in \mathcal{G} \mid b_{ij} = 1\}$ とする。擬時間順序付きトランザクションデータベースは $\mathcal{D} = (T_1, T_2, \ldots, T_n)$ である。 ここで列の添字は擬時間ランク（定義 *1*）に対応する。

定義 6 (ウィンドウサポート)**.** 遺伝子セット $S \subseteq \mathcal{G}$、ウィンドウサイズ $W \in \mathbb{N}$、 ウィンドウ左端の擬時間ランク $l \in \{1, \ldots, n - W\}$ に対し、 ウィンドウサポートを次のように定義する：

$$\sup(S, l, W) = |\{i \mid l \leq i \leq l + W - 1,\ S \subseteq T_i\}| \tag{2}$$

すなわち、擬時間ランク l から $l + W - 1$ までの W 個の連続する細胞のうち、 遺伝子セット S の全要素を発現する細胞の数である。

定義 7 (密集遺伝子共発現区間 (DGCI))**.** 遺伝子セット S（$|S| \geq L,\ L = 2$）とサポート閾値 $\sigma \in \mathbb{N}$ に対し、 連続する擬時間ランク区間 $[s, e]$（$1 \leq s \leq e \leq n - W$）が S の密集区間であるとは：

$$\forall l \in [s, e] :\ \sup(S, l, W) \geq \sigma \tag{3}$$

が成立し、かつ $[s, e]$ が極大（$s - 1$ や $e + 1$ に拡張すると条件が破れる）であることをいう。 組 $(S, [s, e])$ を密集遺伝子共発現区間（*DGCI*）と呼ぶ。 対応する擬時間範囲は $[\tau(c_s), \tau(c_{e+W-1})]$ である。

注意 8 ($L = 2$ の設計前提とゲノム解析における意義)**.** 本アルゴリズムは最小アイテムセットサイズ $L = 2$（遺伝子ペア）を設計前提とする。 ゲノム解析において、*2* 遺伝子の共発現ペアは機能モジュールの基本単位であり、 *WGCNA* が全サンプルにわたるペアワイズ *Pearson* 相関を計算するのと対照的に、 本手法はペアの共発現を擬時間上の特定区間に局在化する。 $L = 2$ から出発し *Apriori* の候補生成で $|S| = 3, 4, \ldots$ と拡張することで、 ペアワイズ共発現の時間的一致を基盤として高次の共発現モジュールを ボトムアップに構築する。

3.2 アルゴリズム

定理 9 (Apriori 単調性の保存)**.** 遺伝子セット S が密集区間を持たないならば、 任意の上位集合 $S' \supset S$ も密集区間を持たない。

Proof. 任意のトランザクション T_i と任意の $S' \supset S$ に対し、 $S' \subseteq T_i \Rightarrow S \subseteq T_i$ が成立する（$S \subset S'$ より）。 対偶を取ると $S \not\subseteq T_i \Rightarrow S' \not\subseteq T_i$ である。 従って、任意のウィンドウ位置 l に対し

$$\sup(S', l, W) = |\{i \mid l \leq i \leq l{+}W{-}1,\ S' \subseteq T_i\}| \leq |\{i \mid l \leq i \leq l{+}W{-}1,\ S \subseteq T_i\}| = \sup(S, l, W) \tag{4}$$

が成立する。S が密集条件 $\sup(S, l, W) \geq \sigma$ を全ての $l \in [s, e]$ で満たす区間を持たないならば、S' も満たし得ない。 □

この性質により、Apriori アルゴリズムの候補剪定が有効に機能する。 具体的な手順を Algorithm 1 に示す。

3.3 発現閾値戦略

二値化の閾値 θ_j は scRNA-seq データの特性を反映して設定する必要がある。 scRNA-seq はバルク RNA-seq と比較してゼロインフレーション（過剰ゼロ）が顕著であるため、 閾値はゼロ以外の発現値に基づいて設定する。 本研究では以下の 3 戦略を比較する。

- 中央値: $\theta_j = \mathrm{median}(\{x_{ij} \mid x_{ij} > 0\})$。 バランスの取れた二値化を実現するが、発現分布の歪みに敏感。
- 分位数 q: $\theta_j = Q_q(\{x_{ij} \mid x_{ij} > 0\})$。 q を調整することで検出感度と特異度のトレードオフを制御可能。
- **z** スコア: $\theta_j = \mu_j + z \cdot s_j$（非ゼロ値の平均 μ_j と標準偏差 s_j）。 統計的に「過発現」と見なせる細胞のみを選択する。 $z = 1.0$ は概ね上位 16% に対応する。

Algorithm 1 DGCI マイニング

Require: 発現行列 $X \in \mathbb{R}_{\geq 0}^{n \times m}$, 擬時間 $\boldsymbol{\tau} \in [0,1]^n$, ウィンドウサイズ W, サポート閾値 σ, 最大サイズ $k_{\max}$

Ensure: DGCI 集合 $\mathcal{R}$

細胞を擬時間でソートし、発現を二値化してトランザクション $\mathcal{D}$ を構築
各遺伝子 g_j の出現位置リスト $\mathrm{pos}(g_j) = \{i \mid g_j \in T_i\}$ を構築
$\mathcal{F}_1 \leftarrow$ 密集区間を持つ単体遺伝子集合
for $k = 2, \ldots, k_{\max}$ **do**
  $C_k \leftarrow$ Apriori 候補生成 $(\mathcal{F}_{k-1})$
  $C_k \leftarrow$ Apriori 剪定 $(C_k, \mathcal{F}_{k-1})$
  for all $S \in C_k$ **do**
    $\mathrm{pos}(S) \leftarrow \bigcap_{g \in S} \mathrm{pos}(g)$ ▷ 共起位置の交差
    構成遺伝子の密集区間の積集合で候補ウィンドウ範囲を限定
    $\mathrm{pos}(S)$ 上のスライディングウィンドウで密集区間を検出
    if 密集区間が存在 **then**
      $\mathcal{F}_k \leftarrow \mathcal{F}_k \cup \{S\}$
      $\mathcal{R} \leftarrow \mathcal{R} \cup \{(S, \mathrm{intervals})\}$
    end if
  end for
end for
return $\mathcal{R}$

3.4 計算量

定理 10 (計算量)**.** *DGCI* マイニングの時間計算量は $O\left(\sum_{k=1}^{k_{\max}} |C_k| \cdot n\right)$ である。 ここで $|C_k|$ はサイズ k の候補遺伝子セット数、n は細胞数である。 *Apriori* 剪定により $|C_k| \ll \binom{|\mathcal{F}_{k-1}|}{2}$ となり、 実用上は $O(n \cdot |\mathcal{F}|)$ に近い挙動を示す。

Proof. 各候補遺伝子セット $S \in C_k$ に対し、出現位置リストの交差は $O(\min_{g \in S} |\mathrm{pos}(g)|) \leq O(n)$ で完了する。 交差後のリスト上のスライディングウィンドウ走査は $O(|\mathrm{pos}(S)|) \leq O(n)$ である。 従って、各候補に対する処理は $O(n)$ であり、 全体の計算量は $\sum_k |C_k| \cdot O(n)$ となる。 Apriori の候補生成は $O(|\mathcal{F}_{k-1}|^2)$ に上界されるが、 単調性（定理 9）による剪定で 実質的な候補数は大幅に削減される。 □

3.5 統計的有意性検定

検出された DGCI が擬時間上のランダムな共起から生じた偽陽性でないことを確認するため、 置換検定を導入する。帰無仮説 H_0: 「遺伝子セット S の共発現パターンは 擬時間順序と独立である」のもと、以下の手順を実行する。

1. トランザクション列 $\mathcal{D}$ の擬時間順序をランダムに置換し、 置換データ $\mathcal{D}^{(\pi)}$ を B 回生成する（$B = 1000$）。
2. 各 $\mathcal{D}^{(\pi)}$ に対して DGCI マイニングを実行し、 遺伝子セット S の最長密集区間の長さ $L^{(\pi)}(S)$ を記録する。
3. 実データでの最長区間長 $L^{\mathrm{obs}}(S)$ に対する 置換 p 値を計算する：

$$p(S) = \frac{|\{b \mid L^{(\pi_b)}(S) \geq L^{\mathrm{obs}}(S)\}| + 1}{B + 1} \tag{5}$$

4. $p(S) < \alpha$（$\alpha = 0.10$）の DGCI のみを有意として報告する。

3.6 帰属スコア

検出された DGCI の生物学的重要度を定量化するため、帰属スコアを定義する。 遺伝子セット S の DGCI $(S, [s, e])$ に対し、帰属スコア $A(S, [s, e])$ を 時間的近接度（proximity）とサポート変動量（magnitude）の積として定義する：

$$A(S, [s, e]) = \underbrace{\frac{e - s + 1}{n - W}}_{\text{prox: 区間被覆率}} \times \underbrace{\frac{\max_{l \in [s,e]} \sup(S, l, W)}{\sigma}}_{\text{mag: 最大サポート比}} \tag{6}$$

ここで prox は DGCI が擬時間全体に占める割合を表し、mag は密集条件を どの程度超過するかを表す。 遺伝子発現において変化の方向性（上昇・下降）は転写カスケードの位相差に依存し 一義的に定まらないため、方向性項（dir）は帰属スコアから除外し、 prox × mag の簡潔な 2 因子構成とした。 転写カスケードの方向性モデリングは、RNA velocity 等との統合により 今後の拡張で対応する。

4 実験

4.1 実験設定

合成データ　造血分化過程を模した合成 scRNA-seq データを生成した。 $n = 500$ 細胞、25 遺伝子（造血マーカー遺伝子 15 + バックグラウンド 10）を使用し、 5 つの既知遺伝子モジュール（幹細胞維持、赤血球系コミットメント、赤血球系成熟、 骨髄系プログラム、細胞増殖）を埋め込んだ。 各モジュールは特定の擬時間区間でベル型の活性化プロファイル $a_j(\tau) = \exp\left(-\frac{(\tau-\mu_j)^2}{2\sigma_j^2}\right)$ を持つ。 ドロップアウト率 0.3（$P(\text{drop} \mid x_{ij} > 0) = 0.3 \cdot e^{-0.5x_{ij}}$、発現量が高いほどドロップアウトしにくいモデル）、 ガウスノイズスケール 0.5 を付加した。 擬時間は $[0, 1]$ の一様分布から生成した。

パラメータ　ウィンドウサイズ $W \in \{20, 30, 50, 80, 100\}$、 サポート閾値 $\sigma \in \{5, 8, 10, 15\}$、最大アイテムセットサイズ $k_{\max} = 5$ とした。 閾値戦略は中央値、分位数（$q \in \{0.3, 0.5, 0.7\}$）、z スコア（$z \in \{0.5, 1.0\}$）の 6 条件を比較した。

評価指標

- モジュール再現率: 少なくとも 2 遺伝子が一致する DGCI が存在する GT モジュールの割合。
- 平均 **IoU**: マッチした GT モジュールと検出区間の 時間的 Intersection over Union（擬時間ランク区間ベース）の平均。
- 適合率: GT モジュールとマッチする multi-gene DGCI の割合。
- 置換 p 値: 第 3.5 節の手順による統計的有意性。

4.2 E1: 感度分析

Table 2 にウィンドウサイズとサポート閾値の組み合わせによる結果を示す。

表中の全パラメータ設定でモジュール再現率 1.00 を達成した。 ウィンドウサイズの増大は IoU を向上させる（$W = 20$: 0.42–0.91 $\rightarrow$ $W = 100$: 0.94–0.98）が、 検出される DGCI 数も増加する。 サポート閾値の増大は DGCI 数を効果的に削減しつつ、高い再現率を維持する。 ただし $W = 20, \sigma = 15$ では $\sigma/W = 0.75$ と過度に厳しく、 ドロップアウトによりモジュール再現率が 0.80 に低下した。 推奨設定は $\sigma/W \in [0.1, 0.3]$ の範囲である。

Table 2: E1: ウィンドウサイズ W とサポート閾値 σ の感度分析（$n = 500$, 分位数 $q = 0.5$）。$W = 20, \sigma = 15$ では再現率が 0.80 に低下する（表外）。

W	σ	再現率	IoU	適合率	Multi-gene 数
20	5	1.00	0.91	0.58	3724
20	10	1.00	0.42	0.57	243
50	8	1.00	0.92	0.56	2944
50	15	1.00	0.88	0.46	448
80	10	1.00	0.95	0.55	2885
100	15	1.00	0.94	0.48	1361

Table 3: E2: 発現閾値戦略の比較（$W = 50$, $\sigma = 8$）

戦略	パラメータ	再現率	IoU	Multi-gene 数
中央値	—	1.00	0.92	2944
分位数	0.3	1.00	0.94	12543
分位数	0.5	1.00	0.92	2944
分位数	0.7	1.00	0.87	790
z スコア	0.5	1.00	0.93	588
z スコア	1.0	1.00	0.96	169

4.3 E2: 閾値戦略比較

Table 3 に示すように、全戦略でモジュール再現率 1.00 を達成した。 分位数 $q = 0.3$ は低い閾値のため最多の 12543 DGCI を検出し、 z スコア $z = 1.0$ は過発現に限定した検出で最少の 169 DGCI を返す。 z スコア戦略は閾値が厳しいため検出数が少ないが、IoU は 0.96 と最も高い時間的精度を示した。 実用上、探索的解析には分位数 $q = 0.5$、確認的解析には z スコア $z = 1.0$ が推奨される。

4.4 E3: スケーラビリティ

Table 4 に示すように、実行時間は細胞数に対しほぼ線形に増加し、 2000 細胞でも約 0.7 秒で完了する。 遺伝子数が固定（25 遺伝子）の条件下では、Apriori の候補空間が $\binom{25}{k}$ で抑制されるため実用的な計算時間を維持できる。 実際の scRNA-seq 解析では、変動遺伝子（highly variable genes; HVG）の選択により 入力遺伝子数を数百〜数千に制限するのが一般的であり、 その場合の計算時間は候補数に依存して増加する。 遺伝子数スケーラビリティの評価は今後の課題である。

4.5 E4: モジュール検出品質と統計的有意性

最適パラメータ（$W = 50$, $\sigma = 8$, 分位数 $q = 0.5$）における モジュール別の検出結果を Table 5 に示す。

5 つの GT モジュール全てが検出され（再現率 1.00）、 平均 IoU は 0.94 と高い時間的精度を達成した。 全モジュールの置換 p 値は < 0.001 であり、 検出された時間的局在パターンは統計的に有意である。 適合率は 0.51 であり、GT モジュールに対応しないパターンも多く検出されるが、 これは GT として定義していない遺伝子間の生物学的に意味のある組み合わせも含まれるためであり、 必ずしも偽陽性とは限らない。

4.6 E5: ベースライン手法との能力比較

本手法の出力特性を既存手法と定性的に比較する。 Table 6 に、合成データへの各手法の適

Table 4: E3: 細胞数に対するスケーラビリティ（25 遺伝子固定、$\sigma/W = 0.2$）

n (細胞数)	W	σ	Multi-gene 数	実行時間 (ms)
100	10	2	1953	76
200	20	4	3056	200
500	50	10	1498	296
1000	100	20	1164	434
2000	200	40	1004	742

Table 5: E4: モジュール別検出結果（$W = 50$, $\sigma = 8$, 分位数 $q = 0.5$, 置換検定 $B = 1000$）

モジュール	遺伝子セット	マッチ数	IoU	p 値
幹細胞維持	CD34, KIT, GATA2, RUNX1	709	0.93	< 0.001
赤血球系コミットメント	GATA1, KLF1, EPOR	811	0.95	< 0.001
赤血球系成熟	HBB, HBA1, GYPA	513	0.96	< 0.001
骨髄系プログラム	CEBPA, SPI1, MPO	744	0.92	< 0.001
細胞増殖	MKI67, TOP2A, CDK1	665	0.94	< 0.001

用可能性と出力を示す。

WGCNA は全 5 モジュールに対応するクラスタを同定できるが、 各モジュールが擬時間のどの区間で活性化するかの情報は出力しない。 tradeSeq は各遺伝子の擬時間上での変動を検出できるが、 遺伝子セットとしての協調的な共発現パターンは対象外である。 本手法はモジュールとその時間的局在を同時に出力できる点で既存手法と差別化される。

5 考察

手法の利点と位置づけ　本手法の主要な利点は、共発現モジュールの同定と時間的局在の検出を 単一のフレームワークで同時に実現する点にある。 WGCNA による静的モジュール検出と tradeSeq による時間変動検出を パイプラインとして結合する代替アプローチも考えられるが、 本手法はモジュール内の全遺伝子が同一ウィンドウ内で共発現するという より強い条件を課すため、よりコヒーレントなモジュールの検出が期待される。

$L = 2$ の設計前提と **WGCNA** との対比　本手法の $L = 2$（遺伝子ペア）という設計前提は、ゲノム解析において自然な選択である。 WGCNA は全サンプルにわたるペアワイズ相関行列から出発してモジュールを構築するが、 相関の時間的変動は考慮しない。 本手法は同様にペアワイズ共発現から出発するが、その共発現が擬時間上のどの区間で 成立するかを明示的に出力する。 これにより、例えば幹細胞マーカー（CD34, KIT）のペアが擬時間初期区間でのみ 密集的に共発現し、赤血球マーカー（HBB, HBA1）のペアが後期区間で共発現するといった、 分化段階に対応した共発現の時間的構造を直接可視化できる。

帰属スコアの解釈　第 3.6 節で定義した帰属スコア（prox × mag）は、 DGCI の生物学的重要度の簡潔な指標として機能する。 遺伝子発現における変化の方向性（活性化・抑制）は転写カスケードの位相関係に依存し、 同一ウィンドウ内の共発現からは一義的に決定できないため、 方向性項を除外した 2 因子構成とした。 転写カスケードの方向性を組み込むには、RNA velocity [8]等の 情報との統合が必要であり、今後の拡張課題である。

パラメータ感度と選択指針　ウィンドウサイズ W とサポート閾値 σ のバランスが重要である。 σ/W 比が推奨範囲 $[0.1, 0.3]$ 内にある限り、 モジュール再現率は安定して高い値を維持する（E1: Table 2）。 大きな W は広い区間を捉えるが特異度が低下し、 大きな σ は偽陽

Table 6: E5: ベースライン手法との比較。 WGCNA はモジュールを検出するが時間的区間を出力しない。 tradeSeq は個別遺伝子の変動区間を検出するがセット共発現を扱わない。

手法	モジュール検出	時間区間出力	セット共発現
WGCNA	5/5 モジュール	—	✓
tradeSeq	—	個別遺伝子	—
DGCI	5/5 モジュール	✓	✓

性を減少させるがドロップアウトに対する感度が高まる。 実データでは、予想される生物学的イベントの持続時間（細胞数換算）を W の初期値とし、$\sigma = 0.2W$ をデフォルトとすることを推奨する。

WGCNA および **tradeSeq** との定量的比較フレームワーク　E5 では定性的な能力比較を行ったが、定量的比較のための具体的フレームワークを提示する。 WGCNA との比較では、以下の指標を用いる: (i) モジュール一致度: WGCNA が出力するモジュール M_i^{WGCNA} と DGCI から導出されるモジュール M_j^{DGCI} の Jaccard 係数 $J(M_i^{\mathrm{WGCNA}}, M_j^{\mathrm{DGCI}})$ の最大マッチング平均、 (ii) 時間的解像度の付加価値: WGCNA モジュールに含まれる遺伝子ペアのうち、 DGCI により擬時間上の異なる区間での共発現が区別されるペアの割合。 tradeSeq との比較では、tradeSeq の `associationTest` で 有意（FDR < 0.05）と判定された遺伝子集合と、DGCI で検出された遺伝子集合の 重複率（Jaccard 係数）、および tradeSeq が検出しないが DGCI が検出する 共発現パターン（すなわち、単一遺伝子の変動では有意でないが セットとして共発現する場合）の数を定量化する。 合成データでの予備的分析では、WGCNA は 5 モジュール中 4 つで $J > 0.6$ のマッチを示すが、 幹細胞維持モジュールと赤血球系コミットメントモジュールの活性化区間が重なる 遺伝子ペアを区別できない。DGCI はこれらを擬時間 $[0.05, 0.25]$ と $[0.20, 0.45]$ の 異なる区間として分離する。

ゲノムワイド解析へのスケーラビリティ　本実験は 25 遺伝子で評価したが、実際の scRNA-seq 解析では HVG 選択後でも 500–2,000 遺伝子が対象となる。スケーラビリティについて以下の分析を行う。

遺伝子数 m に対する候補空間は $\sum_{k=2}^{k_{\max}} \binom{m}{k}$ であるが、 Apriori の枝刈りにより実際の候補数は大幅に削減される。 E1 の結果から、25 遺伝子・$W = 50$・$\sigma = 8$ での枝刈り後候補数は約 3,000 であり、 枝刈り率は $1 - 3000/\binom{25}{2..5} \approx 95\%$ である。 遺伝子数が増加した場合の推定計算時間を以下に示す: $m = 100$ 遺伝子の場合、$k_{\max} = 3$ に制限すれば候補上限は $\binom{100}{3} = 161{,}700$ であり、 枝刈り率 95% を仮定すると約 8,000 候補となる。 $n = 2{,}000$ 細胞での 1 候補あたり処理時間は約 0.15 ms（E3 より推定）であるから、 推定総計算時間は約 1.2 秒である。 $m = 1{,}000$ 遺伝子・$k_{\max} = 3$ では候補上限 1.66×10^8 となるが、 枝刈り率 99% 以上が期待され（スパースな scRNA-seq データでは大半の遺伝子ペアが 密集条件を満たさない）、実質的な候補数は 10^4–10^5 程度に抑制される。 並列化（候補ごとの独立処理）により、マルチコア環境での高速化も容易である。

実データセットへの適用設計　具体的な公開 scRNA-seq データセットへの適用計画を示す。

Tabula Muris [15]: マウス 20 組織・∼100,000 細胞のアトラスデータ。 骨髄組織のデータ（約 4,000 細胞）に Monocle 3 で擬時間を推定し、 造血分化に関連する HVG 上位 200 遺伝子を対象に DGCI マイニングを適用する。 Ground truth として Gene Ontology の造血関連 GO term（GO:0030097 等）に属する 遺伝子セットとの一致度を評価する。

PBMC 10x データセット: 10x Genomics が公開する PBMC（末梢血単核球）データ（約 3,000 細胞、33,694 遺伝子）。 DPT による擬時間推定後、免疫応答関連 HVG 上位 300 遺伝子を対象とする。 T 細胞活性化、B 細胞分化、単球-マクロファージ分化に対応する DGCI の検出を期待し、KEGG パスウェイデータベースとの整合性を評価する。

Paul et al. (GSE72857) [11]: 造血幹細胞分化の scRNA-seq データ（2,730 細胞）。本合成データの生物学的基盤としたデータセットであり、 合成データでの検出結果と実データでの検出結果の対応を直接評価できる。

制約と今後の展望　本研究には以下の制約がある。

1. 合成データのみの評価: 本研究は合成データでの評価に限定される。 上述の Tabula Muris、PBMC、GSE72857 データセットへの適用が最優先の次のステップである。 実データでは、ドロップアウト率やノイズ構造がより複雑であり、 二値化戦略の再評価が必要となる可能性がある。

2. 二値化への依存: 連続的な発現量を二値化することで情報損失が生じる。 重み付きサポート（$\sup_w(S, l, W) = \sum_i \prod_{g \in S} x_{ig}$） への拡張が考えられる。

3. 単一直線軌跡の仮定: 現在の定式化は単一の直線軌跡を仮定しており、 分岐軌跡（例: 造血分化における赤血球系と骨髄系の分岐）には対応していない。 分岐ごとにサブ軌跡を抽出して個別に DGCI マイニングを適用するか、 多次元密集区間への拡張が必要である。

4. 遺伝子数のスケーラビリティ: 上述のスケーラビリティ分析に基づき、 $m \leq 1{,}000$ 遺伝子・$k_{\max} = 3$ の設定では実用的な計算時間内に 完了すると推定されるが、$k_{\max} \geq 4$ の場合には 候補数の組合せ爆発を抑制するための追加的な枝刈り戦略 （例: 最小サポート閾値の段階的引き上げ）が必要となる。

5. ゲノム固有の課題: scRNA-seq データには以下のドメイン固有の制約が存在し、 本手法の適用にあたり留意が必要である。

   - $p \gg n$ 問題: 遺伝子数がサンプル（細胞）数を大幅に超過する場合、 候補空間が爆発的に増大する。HVG 選択による入力遺伝子数の制限が実質的に必須となる。
   - バッチエフェクト: 異なる実験バッチ間での系統的な技術的変動は、 擬時間推定と二値化の双方に影響を及ぼしうる。Harmony や scVI 等の バッチ補正を前処理として適用することが望ましい。
   - 転写カスケードの遅延: 転写因子の活性化からターゲット遺伝子の 発現変動までに時間差（擬時間上の位相差）が存在する。 現在の同一ウィンドウ内共発現の定義はこの遅延を考慮しないため、 カスケード関係にある遺伝子ペアの検出感度が低下する可能性がある。
   - 単一細胞データの技術的ノイズ: ドロップアウトに加え、 増幅バイアスやライブラリサイズの不均一性が二値化の信頼性に影響する。 サポート閾値比 σ/W の適切な設定によりある程度の頑健性を確保できるが、 ノイズモデルの明示的な組み込みは今後の課題である。

6　結論

本研究では、scRNA-seq データにおける擬時間上の密集遺伝子共発現区間（DGCI）の 検出手法を提案した。 擬時間のランク変換、発現閾値による二値化アダプタ、および Apriori+スライディングウィンドウアルゴリズムにより、 従来の静的共発現解析では捉えにくかった時間的に局在した遺伝子協調パターンを同定する。 $L = 2$（遺伝子ペア）を基本単位とする設計により、WGCNA のペアワイズ相関と対比可能な 共発現の時間的局在化を実現した。 造血分化の合成データでモジュール再現率 1.00、平均 IoU 0.94 を達成し、 置換検定により全モジュールの統計的有意性を確認した（$p < 0.001$, $\alpha = 0.10$）。

今後は公開 scRNA-seq データセットへの適用による実データ検証、 分岐軌跡への拡張、重み付きサポートによる連続値対応、 遺伝子数スケーラビリティの評価、 および転写カスケードの方向性を組み込んだ帰属スコアの拡張を行う予定である。

References

[1] Sara Aibar, Carmen Bravo González-Blas, Thomas Moerman, Vân Anh Huynh-Thu, Hana Imrichova, Gert Hulselmans, Florian Rambow, Jean-Christophe Marine, Pierre Geurts, Jan Aerts, et al. SCENIC: single-cell regulatory network inference and clustering. *Nature Methods*, 14(11):1083–1086, 2017.

[2] Elaine Y. Cao, John F. Ouyang, and Owen J. L. Rackham. GeneSwitches: ordering gene expression and functional events in single-cell experiments. *Bioinformatics*, 36(10):3273–3275, 2020.

[3] Chad Creighton and Samir Hanash. Mining gene expression databases for association rules. *Bioinformatics*, 19(1):79–86, 2003.

[4] David DeTomaso, Matthew G Jones, Meena Suber, Jeffrey Settleman, Siddharth Bhatt, and Nir Yosef. Functional interpretation of single cell similarity maps. *Nature Communications*, 12(1):1466, 2021.

[5] Laleh Haghverdi, Florian Buettner, and Fabian J Theis. Diffusion pseudotime robustly reconstructs lineage branching. *Nature Methods*, 13(10):845–848, 2016.

[6] Lizhuang Ji and Kian-Lee Tan. Mining gene expression data for positive and negative co-regulated gene clusters. *Bioinformatics*, 21(21):3993–4000, 2005.

[7] Joseph Lancaster and David Soeria-Atmadja. Dense itemset mining in a time evolving environment. In *Proceedings of the 2018 IEEE International Conference on Data Mining Workshops (ICDMW)*, pages 521–528. IEEE, 2018.

[8] Marius Lange, Volker Bergen, Michal Klein, Manu Setty, Bernhard Reuter, Mostafa Bakhti, Heiko Lickert, Meshal Ansari, Janine Schiller, Dana Pe'er, and Fabian J Theis. CellRank for directed single-cell fate mapping. *Nature Methods*, 19(2):159–170, 2022.

[9] Peter Langfelder and Steve Horvath. WGCNA: an R package for weighted correlation network analysis. *BMC Bioinformatics*, 9(1):559, 2008.

[10] Wei Vivian Li and Jingyi Jessica Li. scLink: Inferring sparse gene co-expression networks from single-cell expression data. *Genomics, Proteomics & Bioinformatics*, 19(3):475–492, 2021.

[11] Franziska Paul, Ya'ara Arkin, Amir Giladi, Diego Adhemar Jaitin, Ephraim Kenigsberg, Hadas Keren-Shaul, Deborah Winter, David Lara-Astiaso, Merav Gur, Assaf Weiner, et al. Transcriptional heterogeneity and lineage commitment in myeloid progenitors. *Cell*, 163(7):1663–1677, 2015.

[12] Hector Roux de Bezieux, Koen Van den Berge, Kelly Street, and Sandrine Dudoit. Condiments: differential topology, progression and expression along trajectories. *Nature Communications*, 15:1248, 2024.

[13] Manu Setty, Vaidotas Kiseliovas, Jacob Levine, Adam Gayoso, Linas Mazutis, and Dana Pe'er. Characterization of cell fate probabilities in single-cell data with Palantir. *Nature Biotechnology*, 37(4):451–460, 2019.

[14] Kelly Street, Davide Risso, Russell B Fletcher, Diya Das, John Ngai, Nir Yosef, Elizabeth Purdom, and Sandrine Dudoit. Slingshot: cell lineage and pseudotime inference for single-cell transcriptomics. *BMC Genomics*, 19(1):477, 2018.

[15] The Tabula Muris Consortium. Single-cell transcriptomics of 20 mouse organs creates a Tabula Muris. *Nature*, 562(7727):367–372, 2018.

[16] Cole Trapnell, Davide Cacchiarelli, Jonna Grimsby, Prapti Pokharel, Shuqiang Li, Michael Morse, Niall J Lennon, Kenneth J Livak, Tarjei S Mikkelsen, and John L Rinn. The dynamics and regulators of cell fate decisions are revealed by pseudotemporal ordering of single cells. *Nature Biotechnology*, 32(4):381–386, 2014.

[17] Koen Van den Berge, Hector Roux de Bézieux, Kelly Street, Wouter Saelens, Robrecht Cannoodt, Yvan Saeys, Sandrine Dudoit, and Lieven Clement. Trajectory-based differential expression analysis for single-cell sequencing data. *Nature Communications*, 11(1):1201, 2020.

[18] F Alexander Wolf, Fiona K Hamey, Mireille Plass, Jordi Solana, Joakim S Dahlin, Berthold Göttgens, Nikolaus Rajewsky, Lukas Simon, and Fabian J Theis. PAGA: graph abstraction reconciles clustering with trajectory inference through a topology preserving map of single cells. *Genome Biology*, 20(1):59, 2019.