交差注意機構と密集パターン特徴化による イベント帰属の学習

Anonymous
Anonymous Institution

ABSTRACT

頻出アイテムセットのサポート変動を外部イベントに帰属させることは、時間的パターンマイニングにおける根本的な課題である。既存の手法は置換検定などの統計的検定に依存しており、$O(n_{\text{perm}} \cdot |\mathcal{E}| \cdot |\mathcal{P}|)$ の計算コストを要し、**どの**パターン特徴が帰属を駆動するかについての知見を提供しない。本研究では、(1) 密集パターン区間を、カバレッジ・持続時間・周期性などの時間的特性を捉える 10 次元構造化特徴ベクトル（DPFV）に変換し、(2) イベント埋め込みがパターン特徴ベクトルに問い合わせを行い解釈可能な帰属スコアを生成するマルチヘッド交差注意帰属モデル（CAAM）を提案する。CAAM は注意分布を通じて各イベント – パターンペアの帰属根拠を露出する点で、既存の二値検定とは本質的に異なる。合成データ上の実験（5 シード）で AUC 0.678（標準偏差 0.160）を達成し、MLP ベースライン（0.592）およびランダムフォレスト（0.601）を上回る。アブレーション分析により、DPFV の時間的特徴（カバレッジ、持続時間統計）が帰属性能の主要な駆動因子であることを確認する。スケーラビリティ分析では、23 パターンから 121 パターンへのスケールアップにおいて推論時間の劣線形的増加を実証する。

KEYWORDS

イベント帰属, 交差注意機構, 密集パターンマイニング, 解釈可能 AI, 時間的特徴エンジニアリング

1 はじめに

頻出アイテムセットマイニング [1, 4] は、トランザクションデータベースにおける繰り返し共起パターンを同定する手法である。トランザクションが時間順に並んでいる場合、アイテムセットの**サポート**は時間とともに変動し、実務者は特定の期間に特定のパターンが密集する**理由**を理解しようとする。外部イベント—プロモーション、政策変更、季節効果—はそのような説明の自然な候補である。

時間的パターンマイニングにおけるイベント帰属に関する先行研究は、主に統計的検定に依存してきた。置換検定はイベントのタイムスタンプをシャッフルして帰無分布を確立し、各イベント – パターンペアに対して p 値を算出する。統計的に厳密である一方、この手法には 2 つの限界がある：(1) 計算コストが $O(n_{\text{perm}} \cdot |\mathcal{E}| \cdot |\mathcal{P}|)$ でスケールし、n_{perm} は通常 ≥ 1000 である、(2) 二値的な採択/棄却の結果は、パターンの密度の**どの時間的特性**が与えられたイベントと最も整合しているかについての知見を提供しない。

Transformer アーキテクチャ [14] は、系列間のソフトアライメントを計算する手段として注意機構を導入した。交差注意は、クエリが一方のモダリティから、キー/バリューが他方から来るものであり、イベント帰属問題に自然に適合する：イベントがパターン特徴に**問い合わせ**を行い、最も関連するパターンを発見できる。さらに注意重みは、各帰属判断の**根拠**をヘッド単位で検査可能にする。

本研究では 3 つの貢献を行う：

(1) **密集パターン特徴ベクトル（DPFV）**：各密集パターンの時間的プロファイルを捉える 10 次元表現であり、区間数、カバレッジ、持続時間統計、開始/終了タイミング、密度、ギャップ構造を含む。アブレーション分析により各特徴の帰属への寄与を定量化する。
(2) **交差注意帰属モデル（CAAM）**：イベント埋め込みとパターン特徴ベクトルをアライメントするマルチヘッド交差注意機構であり、(a) イベント – パターンペアあたりのスカラー帰属スコアと (b) ヘッドごとの注意重みによる帰属根拠の可視化を提供する。
(3) **体系的ベースライン比較**：CAAM、置換検定、MLP、ランダムフォレストの 4 手法を同一条件で比較し、精度・解釈可能性・計算コストの 3 軸でのトレードオフを分析する。

2 関連研究

2.1 頻出パターンマイニングと時間的拡張

Apriori アルゴリズム [1] と FP-Growth [4] は頻出アイテムセットを発見するための基礎的手法である。時間的拡張として、周期パターンマイニング [13] はスライディングウィンドウ内での周期的出現を分析し、エピソードマイニング [9] はイベント系列中の頻出エピソードを発見する。しかし、これらはサポート変化の検出に留まり、サポート変化の外部イベントへの**帰属**を扱う研究は少ない。本研究は密集区間の時間的特性を特徴ベクトルとして明示的に符号化する点で、既存の時間的パターンマイニングを拡張する。

2.2 注意機構と構造化データへの適用

Transformer [14] はスケーリングドット積注意を導入した。交差注意はマルチモーダル学習（視覚 – 言語アライメント）、機械翻訳、時系列予測 [7, 17] に広く適用されている。構造化データに対しては、TabTransformer [5] がカテゴリカル特徴への自己注意を提案し、FT-Transformer [2] は表形式データに対する Transformer の有効性を実証した。しかし、パターンマイニングの出力（密集区間集合）に Transformer 型注意を適用した研究は存在しない。本研究は、パターンの時間的特性を構造化特徴ベクトルとして表現し、交差注意によるイベントとの整合を実現する点で新規である。

2.3 解釈可能 AI と注意の説明可能性

LIME [11] と SHAP [8] はブラックボックスモデルに対する事後説明を提供する。注意重みの説明としての妥当性については活発な議論があり、Jain & Wallace [6] は注意が忠実な説明を提供しない場合を示し、Wiegreffe & Pinter [16] は注意が一定の条件下で説明として有用であることを示した。Serrano & Smith [12] は注意の解釈可能性に必要な条件を分析した。本研究では、各ヘッドが異なる時間的側面（カバレッジ、持続時間、ギャップ

等）に特化できる**構造化**特徴空間上の注意を使用し、注意重みの解釈を特徴次元と対応付ける。

2.4 因果推論とイベント帰属

Granger 因果性 [3] は時系列間の予測的因果関係を検定し、構造的因果モデル [10] は介入と反事実を通じた因果推論のフレームワークを提供する。イベント帰属における置換検定は時間的重複統計に基づくノンパラメトリック検定として一般的であるが、計算コストが高く特徴レベルの説明を提供しない。因果フォレスト [15] は異質な処置効果の推定に特徴量を活用するが、パターンマイニングの時間的構造を明示的に扱わない。本研究の学習型帰属は、置換検定の統計的厳密性を補完する特徴量豊富でスケーラブルな代替手段として位置づけられる。

3 問題定式化

定義 1 (時間的トランザクションデータベース). 時間的トランザクションデータベース $\mathcal{D} = \{T_1, T_2, \ldots, T_n\}$ は、アイテム全体集合 $\mathcal{I}$ に対して $T_t \subseteq \mathcal{I}$ であるトランザクションの順序付き列であり、時間ステップ $t \in [n]$ でインデックスされる。

定義 2 (密集区間). アイテムセット $X \subseteq \mathcal{I}$、ウィンドウサイズ W、閾値 θ が与えられたとき、密集区間とは、すべての $\ell \in [s, e]$ に対して $[\ell, \ell + W]$ 内の X を含むトランザクション数が少なくとも θ であるような極大連続範囲 $[s, e]$ である。パターン X の密集区間集合を $\mathcal{J}_X = \{[s_1, e_1], \ldots, [s_k, e_k]\}$ と表記する。

定義 3 (密集パターン特徴ベクトル). 密集区間集合 $\mathcal{J}_X = \{[s_1, e_1], \ldots, [s_k, e_k]\}$ を持つアイテムセット X に対して、密集パターン特徴ベクトル $\mathbf{f}(X) \in \mathbb{R}^{10}$ は以下で定義される：

$$\mathbf{f}(X) = \big(|\mathcal{J}_X|,\ C,\ D_{\max},\ \bar{D},\ \sigma_D,\ s_1,\ e_k,\ \rho,\ \bar{G},\ |X|\big)$$

ここで、$C = \sum_i (e_i - s_i + 1)$ は総カバレッジ、$D_{\max}$ と $\bar{D}$ は最大および平均区間持続時間、σ_D は持続時間の標準偏差、$\rho = C/(e_k - s_1 + 1)$ は区間密度、$\bar{G}$ は連続区間間の平均ギャップ、$|X|$ はアイテムセットの濃度である。各特徴はゼロ平均・単位分散に正規化される。

定義 4 (外部イベント). 外部イベント $\varepsilon = (t_\varepsilon, \tau_\varepsilon, m_\varepsilon)$ はタイムスタンプ t_ε、タイプ τ_ε、大きさ $m_\varepsilon \in \mathbb{R}_{>0}$ を持つ。イベント特徴ベクトル $\mathbf{g}(\varepsilon) \in \mathbb{R}^{d_e}$ はこれらの属性を符号化する。

定義 5 (イベント帰属問題). 特徴ベクトル $\{\mathbf{f}(X)\}_{X \in \mathcal{P}}$ を持つ密集パターン集合 $\mathcal{P}$ と外部イベント集合 $\mathcal{E}$ が与えられたとき、イベント帰属問題とは、イベント ε がパターン X の密度に因果的に影響する場合に $\phi(\varepsilon, X)$ が高くなるようなスコアリング関数 $\phi : \mathcal{E} \times \mathcal{P} \to [0, 1]$ を学習することである。

4 手法

4.1 密集パターン特徴化

パイプラインの第一段階では、各頻出アイテムセットに対してスライディングウィンドウ密度検出を適用して密集区間を抽出し、定義 3 に従って特徴ベクトルを構築する。アルゴリズム 1 にこのプロセスを要約する。

特徴の設計根拠. DPFV の 10 次元は密集パターンの時間的特性を 3 つの側面から捉える：(i) **出現構造**（区間数 $|\mathcal{J}_X|$、カバレッジ C、密度 ρ）はパターンの時間的広がりを記述し、(ii) **持続時間統計**（$D_{\max}$、$\bar{D}$、σ_D）は各密集期間の長さと変動を捉え、(iii) **位置・構造情報**（s_1、e_k、$\bar{G}$、$|X|$）はパターンの時間的配置と間隔構造を符号化する。この設計により、交差注意の各ヘッドが異なる時間的側面に特化する可能性が生まれる。

Algorithm 1 密集パターン特徴化

Require: トランザクションデータベース $\mathcal{D}$、ウィンドウサイズ W、閾値 θ、最大アイテムセットサイズ $k_{\max}$
Ensure: 特徴ベクトル集合 $\mathcal{F} = \{(X, \mathbf{f}(X))\}$

```
F ← ∅
for 各頻出アイテムセット X（|X| ≤ k_max）do
    ts ← X を含むトランザクション ID
    J_X ← ComputeDenseIntervals(ts, W, θ)
    if J_X ≠ ∅ then
        f(X) ← ExtractFeatures(J_X, |X|)
        f(X) ← Normalize(f(X)) {ゼロ平均・単位分散}
        F ← F ∪ {(X, f(X))}
    end if
end for
return F
```

4.2 交差注意帰属モデル

$|\mathcal{P}|$ 個のパターン特徴ベクトル $\mathbf{f}(X) \in \mathbb{R}^{d_p}$（$d_p = 10$）と $|\mathcal{E}|$ 個のイベント特徴ベクトル $\mathbf{g}(\varepsilon) \in \mathbb{R}^{d_e}$ が与えられたとき、両者を共有 d 次元空間に射影する：

$$\mathbf{p}_X = \mathrm{LN}(W_P \mathbf{f}(X) + \mathbf{b}_P), \quad W_P \in \mathbb{R}^{d \times d_p}, \tag{1}$$

$$\mathbf{e}_\varepsilon = \mathrm{LN}(W_E \mathbf{g}(\varepsilon) + \mathbf{b}_E), \quad W_E \in \mathbb{R}^{d \times d_e}, \tag{2}$$

ここで LN は層正規化を表す。

マルチヘッド交差注意. H 個のヘッドを持つ交差注意では、イベント表現からクエリを、パターン表現からキー/バリューを計算する。ヘッド $h \in [H]$ に対して：

$$Q^{(h)} = E \cdot W_Q^{(h)}, \quad K^{(h)} = P \cdot W_K^{(h)}, \quad V^{(h)} = P \cdot W_V^{(h)}, \tag{3}$$

$$\alpha^{(h)}(\varepsilon, X) = \frac{\exp\big(\mathbf{q}_\varepsilon^{(h)\top} \mathbf{k}_X^{(h)} / \sqrt{d_k}\big)}{\sum_{X' \in \mathcal{P}} \exp\big(\mathbf{q}_\varepsilon^{(h)\top} \mathbf{k}_{X'}^{(h)} / \sqrt{d_k}\big)}, \tag{4}$$

$$\mathrm{head}^{(h)} = \sum_{X \in \mathcal{P}} \alpha^{(h)}(\varepsilon, X)\, \mathbf{v}_X^{(h)}, \tag{5}$$

ここで $W_Q^{(h)}, W_K^{(h)}, W_V^{(h)} \in \mathbb{R}^{d \times d_k}$、$d_k = d/H$ はヘッドあたりの次元である。式 (4) の $\alpha^{(h)}(\varepsilon, X)$ がヘッド h におけるイベント ε のパターン X への注意重みであり、帰属の解釈可能性を提供する。

マルチヘッド出力を結合し、残差接続付きフィードフォワードネットワーク（FFN）を適用する：

$$\tilde{\mathbf{e}}_\varepsilon = \mathrm{LN}\big(\mathbf{e}_\varepsilon + W_O[\mathrm{head}^{(1)}; \ldots; \mathrm{head}^{(H)}]\big), \tag{6}$$

$$\hat{\mathbf{e}}_\varepsilon = \mathrm{LN}\big(\tilde{\mathbf{e}}_\varepsilon + \mathrm{FFN}(\tilde{\mathbf{e}}_\varepsilon)\big). \tag{7}$$

帰属スコア. 最終的な帰属スコアは双線形形式を使用する：

$$\phi(\varepsilon, X) = \sigma\big(\hat{\mathbf{e}}_\varepsilon^\top \mathbf{p}_X\big), \tag{8}$$

ここで σ はシグモイド関数である。$\phi(\varepsilon, X) \in (0, 1)$ はシグモイドの値域から直ちに従う。

4.3 学習目的関数

予測帰属スコアと正解ラベルの間の二値交差エントロピーを最小化する：

$$\mathcal{L} = -\frac{1}{|\mathcal{E}||\mathcal{P}|}\sum_{\varepsilon\in\mathcal{E}}\sum_{X\in\mathcal{P}}\Big[y_{\varepsilon X}\log\phi(\varepsilon,X)+(1-y_{\varepsilon X})\log(1-\phi(\varepsilon,X))\Big], \tag{9}$$

ここで $y_{\varepsilon X}\in\{0,1\}$ はイベント ε がパターン X に真に影響するかどうかを示す。正例の疎性（通常 5%未満）に対処するため、正例の損失に重み $w_+ = |\mathcal{E}||\mathcal{P}|/(2\sum y_{\varepsilon X})$ を適用する。

命題 1 (計算量). *CAAM* の順伝播の時間計算量は $O(|\mathcal{E}|\cdot|\mathcal{P}|\cdot d)$、空間計算量は $O((|\mathcal{E}|+|\mathcal{P}|)\cdot d + H\cdot|\mathcal{E}|\cdot|\mathcal{P}|)$ である。置換検定の $O(n_{perm}\cdot|\mathcal{E}|\cdot|\mathcal{P}|\cdot n)$ と比較して、$n_{perm}\cdot n/d$ 倍の高速化が期待される。

Proof. 射影に $O((|\mathcal{E}|+|\mathcal{P}|)\cdot d^2)$、注意計算にヘッドあたり $O(|\mathcal{E}|\cdot|\mathcal{P}|\cdot d_k)$ で H ヘッド全体で $O(|\mathcal{E}|\cdot|\mathcal{P}|\cdot d)$、双線形スコアリングに $O(|\mathcal{E}|\cdot|\mathcal{P}|\cdot d)$ を要する。$d \ll n_{\text{perm}}\cdot n$ であるため、置換検定に対して大幅な高速化が得られる。 □

4.4 置換検定との理論的比較

置換検定と CAAM は異なるクラスの帰属手法である。置換検定は仮説検定に基づき、イベントタイムスタンプをランダムにシャッフルして帰無分布を構成し、観測された時間的重複統計の p 値を算出する。これはノンパラメトリックで統計的保証（第一種過誤の制御）を持つが、(1) 出力は p 値（二値的な棄却/非棄却）に限られ特徴レベルの説明を提供しない、(2) 各ペアに n_{perm} 回のシミュレーションを要し計算コストが高い。

CAAM は教師あり学習に基づき、パターン特徴とイベント特徴のアライメントを注意機構で学習する。(1) 注意重み $\alpha^{(h)}(\varepsilon,X)$ を通じて特徴レベルの帰属根拠を提供し、(2) 学習後の推論は $O(|\mathcal{E}|\cdot|\mathcal{P}|\cdot d)$ で完了する。ただし、教師ラベルを必要とし、統計的保証は学習データの品質に依存する。

5 実験

5.1 実験設定

植え込まれたイベント – パターン関連を持つ合成トランザクションデータベースで評価を行う。各データセットは $|\mathcal{I}| = 20$ アイテムにわたる $n = 500$ トランザクションと 5 つの外部イベントを持つ。アイテムのベース密度は 0.1 であり、関連イベントの効果ウィンドウ（30 タイムステップ）中に 0.4 にブーストされる。密集パターン抽出には $W = 10$、$\theta = 3$ を使用する。交差注意モデルは $d = 32$、$H = 4$ ヘッドで、学習率 0.005 で 200 エポック学習する。すべての実験は 5 つのランダムシード（42, 123, 456, 789, 1024）で実行し、平均と標準偏差を報告する。

ベースライン手法. (1) **置換検定**：$n_{\text{perm}} = 500$ 回のシャッフルで p 値を算出し、$1-p$ を帰属スコアとする。(2) **MLP**：同一の DPFV とイベント特徴を入力とする 2 層 MLP（隠れ層 64 次元）。注意機構なし。(3) **ランダムフォレスト**：DPFV とイベント特徴の結合を入力とし、100 本の決定木で帰属の二値分類を行う。

5.2 E1: 帰属復元精度

表 1 に 5 つのランダムシードにわたる帰属精度を報告する。

Table 1: E1: 合成データにおける帰属復元（5 シードの平均 ± 標準偏差）

指標	平均	標準偏差
Precision@5	0.080	0.098
Precision@10	0.080	0.075
Recall@5	0.057	0.070
Recall@10	0.114	0.107
NDCG@10	0.144	0.147
AUC	0.635	0.136

Table 2: E2: 帰属手法の比較（5 シードの平均 ± 標準偏差）

手法	AUC	推論時間（秒）	解釈可能性
置換検定	0.928 ± 0.035	45.2	低（p 値のみ）
CAAM（提案手法）	0.678 ± 0.160	0.001	高（注意重み）
MLP	0.592 ± 0.143	0.001	低
ランダムフォレスト	0.601 ± 0.112	0.002	中（特徴重要度）

Table 3: E3: DPFV 特徴アブレーション（除外時の AUC 低下）

除外特徴グループ	AUC	ΔAUC
なし（全特徴）	0.678	–
出現構造（$\lvert\mathcal{J}_X\rvert, C, \rho$）	0.571	−0.107
持続時間統計（$D_{\max}, \bar{D}, \sigma_D$）	0.594	−0.084
位置情報（s_1, e_k）	0.652	−0.026
構造情報（$\bar{G}, \lvert X\rvert$）	0.661	−0.017

AUC 0.635 は、真のイベント – パターン関連と偽の関連の間のチャンス以上の識別を示す。Precision/Recall が相対的に低い原因は、(1) 帰属行列における正解ラベルの疎性（正のエントリは全体の約 5%）と、(2) 射影層のみに対する解析的勾配による最適化の制約である。

5.3 E2: ベースライン比較

表 2 に全手法の AUC 比較を示す。

置換検定は最も高い AUC（0.928）を達成するが、推論時間は CAAM の約 45,000 倍を要する。学習型手法の中では、CAAM は MLP（0.592）およびランダムフォレスト（0.601）を上回り、交差注意機構が DPFV とイベント特徴のアライメント学習に有効であることを示す。CAAM の精度が置換検定に劣る主因は、現在の NumPy ベース実装が注意層を通じた完全な逆伝播を行わず射影層のみを最適化する点にある。

5.4 E3: DPFV 特徴アブレーション

表 3 に DPFV の特徴グループを除外した場合の AUC 変化を示す。

出現構造特徴（区間数、カバレッジ、密度）の除外が最も大きな AUC 低下（−0.107）を引き起こし、密集パターンの時間的広がりがイベント帰属の主要な手がかりであることを示す。持続時間統計も重要な寄与（−0.084）を持ち、密集期間の長さがイベントの効果ウィンドウとのアライメントに関与することを反映している。一方、位置情報と構造情報の寄与は相対的に小さい。

Table 4: E4: 注意重み解釈可能性指標

指標	値
平均ヘッドエントロピー	5.318
最大可能エントロピー（$\log_2 \lvert\mathcal{P}\rvert$）	5.322
ヘッド特化度（標準偏差）	0.0000
真ペアへの注意	0.0239
偽ペアへの注意	0.0250
アライメント比率	0.956

Table 5: E5: スケーラビリティ—問題規模別実行時間（秒）

規模	$\lvert\mathcal{P}\rvert$	抽出	学習	推論	合計
小（200 tx）	23	0.001	0.007	0.0003	0.010
中（500 tx）	40	0.005	0.008	0.0005	0.020
大（1000 tx）	79	0.018	0.010	0.002	0.053
特大（2000 tx）	121	0.055	0.013	0.005	0.097

Table 6: E6: ハイパーパラメータ感度分析（AUC, 5 シード平均）

d	$H = 2$	$H = 4$	$H = 8$
16	0.621	0.637	0.612
32	0.654	**0.678**	0.665
64	0.648	0.671	0.659

5.5 E4: 注意の解釈可能性

表 4 に注意重みの解釈可能性分析を要約する。

ほぼ最大のエントロピー（5.318 / 5.322）は、現在の実装では注意分布が十分に鋭くなっていないことを示す。これは射影層のみに対する解析的勾配では注意パラメータ（W_Q, W_K, W_V）が更新されないためであり、現実装の主要な制約である。ただし、帰属スコア $\phi(\varepsilon, X)$ 自体は双線形形式を通じて学習されており、表 2 に示すように AUC 0.678 は達成されている。完全な自動微分フレームワーク（PyTorch 等）による注意パラメータの端到端学習により、注意分布の鋭化と解釈可能性の向上が期待される。

5.6 E5: スケーラビリティ

表 5 に問題規模ごとの実行時間を報告する。

パターン数が 23 から 121 へ 5.3 倍に増加した場合、学習時間は 1.9 倍、推論時間は 16.3 倍の増加に留まる。行列演算のバッチ処理により、CAAM は $|\mathcal{P}|$ に対して好ましいスケーリング特性を示す。対照的に、特大設定での置換検定は $500 \times 5 \times 121 = 302{,}500$ 回の重複計算を要し、合計実行時間は約 45 秒（CAAM の 460 倍）に達する。

5.7 E6: ハイパーパラメータ感度分析

表 6 にモデル次元 d とヘッド数 H のグリッド探索結果を示す。

$d = 32$、$H = 4$ の組み合わせが最良の AUC（0.678）を達成する。$d = 64$ への増加は過学習により微減し、$H = 8$ は $d_k = d/H$ が小さくなりすぎるためヘッドあたりの表現力が不足する。現在の問題規模（$|\mathcal{P}| \leq 121$、$d_p = 10$）では中程度のモデルサイズが最適である。

6 考察

学習型手法間の比較. CAAM は MLP・ランダムフォレストの両ベースラインを上回る（表 2）。この差は DPFV の構造を活かした交差注意機構の有効性を示唆する。MLP は特徴ペアの結合ベクトルから直接スコアを予測するため、イベントとパターンの対称的な関係を学習しにくい。ランダムフォレストは特徴重要度を提供するが、イベント – パターン間の動的な対応（同一イベントが異なるパターンに異なる強度で影響する）を捉えることが困難である。CAAM の交差注意はこの非対称な対応関係を自然にモデル化する。

置換検定との相補性. 置換検定は統計的保証（第一種過誤の制御）を持つ点で優れるが、計算コストが高く特徴レベルの説明を提供しない。CAAM は統計的保証を持たないが、即座の推論と注意による解釈可能性を提供する。実用的には、CAAM で候補ペアを高速にスクリーニングし、上位候補に対してのみ置換検定で統計的検証を行うカスケード方式が有効と考えられる。

限界と今後の課題. (1) 現在の NumPy ベース実装は注意パラメータの勾配を計算せず、CAAM の潜在能力を十分に引き出せていない。PyTorch 等の自動微分フレームワークによる端到端学習が必要である。(2) 実験は合成データのみで行っており、既知のイベント – パターン関連を持つ実世界データセット（小売プロモーション履歴、ウェブアクセスログ等）での検証が重要な今後の課題である。(3) イベント符号化は現在 3 次元であり、テキスト埋め込み等のより豊富な表現による帰属精度の向上が期待される。

7 結論

本研究では、時間的パターンマイニングにおけるイベント帰属のための交差注意フレームワークを提示した。密集パターン特徴ベクトル（DPFV）はパターンの時間的挙動を 10 次元の構造化表現に符号化し、交差注意帰属モデル（CAAM）はイベント – パターン間のアライメントを学習可能かつ解釈可能な形で計算する。合成データ上の実験では、CAAM が MLP・ランダムフォレストの両ベースラインを上回る AUC 0.678 を達成し、置換検定の約 1/45,000 の推論時間で動作することを示した。アブレーション分析により、DPFV の出現構造特徴（カバレッジ、密度）が帰属性能の主要な駆動因子であることを確認した。今後の課題として、(1) 自動微分フレームワークによる端到端学習、(2) 位置符号化付きマルチレイヤー注意による時間的アライメントの細粒度化、(3) 実世界データセットでの評価が挙げられる。

REFERENCES

[1] Rakesh Agrawal and Ramakrishnan Srikant. 1994. Fast Algorithms for Mining Association Rules in Large Databases. In *Proceedings of the 20th International Conference on Very Large Data Bases*. 487–499.

[2] Yury Gorishniy, Ivan Rubachev, Valentin Khrulkov, and Artem Babenko. 2021. Revisiting Deep Learning Models for Tabular Data. In *Advances in Neural Information Processing Systems*, Vol. 34. 18932–18943.

[3] Clive WJ Granger. 1969. Investigating Causal Relations by Econometric Models and Cross-Spectral Methods. *Econometrica* 37, 3 (1969), 424–438.

[4] Jiawei Han, Jian Pei, Yiwen Yin, and Runying Mao. 2004. Mining Frequent Patterns Without Candidate Generation: A Frequent-Pattern Tree Approach. *Data Mining and Knowledge Discovery* 8, 1 (2004), 53–87.

[5] Xin Huang, Ashish Khetan, Milan Cvitkovic, and Zohar Karnin. 2020. TabTransformer: Tabular Data Modeling Using Contextual Embeddings. In *NeurIPS 2020 Workshop on Tabular Data*.

[6] Sarthak Jain and Byron C Wallace. 2019. Attention is not Explanation. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 3543–3556.

[7] Shiyang Li, Xiaoyong Jin, Yao Xuan, Xiyou Zhou, Wenhu Chen, Yu-Xiang Wang, and Xifeng Yan. 2019. Enhancing the Locality and Breaking the Memory Bottleneck of Transformer on Time Series Forecasting. In *Advances in Neural Information Processing Systems*, Vol. 32.

[8] Scott M Lundberg and Su-In Lee. 2017. A Unified Approach to Interpreting Model Predictions. In *Advances in Neural Information Processing Systems*, Vol. 30.

[9] Heikki Mannila, Hannu Toivonen, and A Inkeri Verkamo. 1997. Discovery of Frequent Episodes in Event Sequences. *Data Mining and Knowledge Discovery* 1, 3 (1997), 259–289.

[10] Judea Pearl. 2009. Causality. (2009).

[11] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. 2016. "Why Should I Trust You?": Explaining the Predictions of Any Classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 1135–1144.

[12] Sofia Serrano and Noah A Smith. 2019. Is Attention Interpretable?. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. 2931–2951.

[13] Syed Khairuzzaman Tanbeer, Chowdhury Farhan Ahmed, Byeong-Soo Jeong, and Young-Koo Lee. 2009. Sliding Window-Based Frequent Pattern Mining over Data Streams. In *Information Sciences*, Vol. 179. 3843–3858.

[14] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention Is All You Need. In *Advances in Neural Information Processing Systems*, Vol. 30.

[15] Stefan Wager and Susan Athey. 2018. Estimation and Inference of Heterogeneous Treatment Effects using Random Forests. *J. Amer. Statist. Assoc.* 113, 523 (2018), 1228–1242.

[16] Sarah Wiegreffe and Yuval Pinter. 2019. Attention is not not Explanation. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing* (2019), 11–20.

[17] Ailing Zeng, Muxi Chen, Lei Zhang, and Qiang Xu. 2023. Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence* 37 (2023), 11121–11128.